

TUGAS AKHIR - SS234862

**ANALISIS RISIKO SISTEMIK SAHAM SEKTOR INDUSTRI
MENGUNAKAN *CONDITIONAL VALUE-AT-RISK*
BERBASIS AR-GARCH DAN *QUANTILE REGRESSION*
FOREST DENGAN *STOCHASTIC SEARCH VARIABLE*
*SELECTION***

AYUNDA FATIKHA

NRP 5003221023

Dosen Pembimbing

Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

NIP 19831204 200812 1 002

Program Studi Sarjana Statistika

Departemen Statistika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026



TUGAS AKHIR - SS234862

**ANALISIS RISIKO SISTEMIK SAHAM SEKTOR INDUSTRI
MENGUNAKAN *CONDITIONAL VALUE-AT-RISK*
BERBASIS AR-GARCH DAN *QUANTILE REGRESSION*
FOREST DENGAN *STOCHASTIC SEARCH VARIABLE*
*SELECTION***

AYUNDA FATIKHA

NRP 5003221023

Dosen Pembimbing

Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

NIP 19831204 200812 1 002

Program Studi Sarjana Statistika

Departemen Statistika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026



FINAL PROJECT - SS234862

**SYSTEMIC RISK ANALYSIS OF INDUSTRIALS SECTOR
USING CONDITIONAL VALUE-AT-RISK BASED ON AR-
GARCH AND QUANTILE REGRESSION FOREST WITH
STOCHASTIC SEARCH VARIABLE SELECTION**

AYUNDA FATIKHA

NRP 5003221023

Advisor

Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

NIP 19831204 200812 1 002

Bachelor Program of Statistics

Department of Statistics

Faculty of Science and Data Analytics

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

ANALISIS RISIKO SISTEMIK SAHAM SEKTOR INDUSTRI MENGGUNAKAN *CONDITIONAL VALUE-AT-RISK* BERBASIS AR-GARCH DAN *QUANTILE REGRESSION FOREST* DENGAN *STOCHASTIC SEARCH VARIABLE SELECTION*

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Statistika pada
Program Studi Sarjana Statistika
Departemen Statistika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **AYUNDA FATIKHA**
NRP 5003221023

Tanggal Ujian: 10 Juli 2026
Periode Wisuda: Oktober 2026

Disetujui oleh:
Pembimbing:

1. Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.
NIP 19831204 200812 1 002



Penguji:

2. Neni Alya Firdausanti, S.Si., M.Stat., Ph.D.
NIP 19950701 202012 2 029
3. Dr. Muhammad Sjahid Akbar, S.Si., M.Si.
NIP 19720705 199802 1 001



Kepala Departemen Statistika
Fakultas Sains dan Analitika Data



Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.
NIP 19831204 200812 1 002

(Halaman ini sengaja dikosongkan)

APPROVAL SHEET

SYSTEMIC RISK ANALYSIS OF INDUSTRIALS SECTOR USING CONDITIONAL VALUE-AT-RISK BASED ON AR-GARCH AND QUANTILE REGRESSION FOREST WITH STOCHASTIC SEARCH VARIABLE SELECTION

FINAL PROJECT

Submitted to fulfill one of the requirements
For obtaining a degree Bachelor of Statistics at
Bachelor Program of Statistics
Department of Statistics
Faculty of Science and Data Analytics
Institut Teknologi Sepuluh Nopember

By: **AYUNDA FATIKHA**
NRP 5003221023

Exam Date: 10 July 2026
Graduation Period: October 2026

Approved By:
Advisor:

1. Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.
NIP 19831204 200812 1 002




Examiners:

2. Neni Alya Firdausanti, S.Si., M.Stat., Ph.D.
NIP 19950701 202012 2 029
3. Dr. Muhammad Sjahid Akbar, S.Si., M.Si.
NIP 19720705 199802 1 001



Head of Statistics Department
Faculty of Science and Data Analytics


Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.
NIP 19831204 200812 1 002

(Halaman ini sengaja dikosongkan)

PERNYATAAN ORISINALITAS

Yang bertanda tangan dibawah ini:

Nama Mahasiswa/NRP : Ayunda Fatikha/5003221023
Departemen : Statistika
Dosen Pembimbing/NIP : Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si./
19831204 200812 1 002

Dengan ini menyatakan bahwa Tugas Akhir dengan judul "**ANALISIS RISIKO SISTEMIK SAHAM SEKTOR INDUSTRI MENGGUNAKAN *CONDITIONAL VALUE-AT-RISK* BERBASIS AR-GARCH DAN *QUANTILE REGRESSION FOREST* DENGAN *STOCHASTIC SEARCH VARIABLE SELECTION***" adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, 8 Juni 2026

Mengetahui,
Dosen Pembimbing



(Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.)
NIP 19831204 200812 1 002

Mahasiswa



(Ayunda Fatikha)
NRP 5003221023

(Halaman ini sengaja dikosongkan)

STATEMENT OF ORIGINALITY

The undersigned below:

Student's Name/NRP : Ayunda Fatikha/5003221023
Departement : Statistics
Advisor : Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si./
19831204 200812 1 002

Hereby declare that the Final Project with the title of **"SYSTEMIC RISK ANALYSIS OF INDUSTRIALS SECTOR USING CONDITIONAL VALUE-AT-RISK BASED ON ARCH AND QUANTILE REGRESSION FOREST WITH STOCHASTIC SEARCH VARIABLE SELECTION"** is the result of my own work, is original, and is written by following the rules of scientific writing.

If in the future there is a discrepancy with this statement, then I am willing to accept sanctions in accordance with the provisions that apply at Institut Teknologi Sepuluh Nopember.

Surabaya, 8 June 2026

Acknowledged,
Advisor



(Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.)
NIP 19831204 200812 1 002

Student



(Ayunda Fatikha)
NRP 5003221023

(Halaman ini sengaja dikosongkan)

PERNYATAAN KODE ETIK PENGGUNAAN AI GENERATIF DALAM TUGAS AKHIR

Saya yang bertanda tangan di bawah ini:

Nama mahasiswa (NRP) : Ayunda Fatikha (5003221023)

Program studi : Statistika

Judul tugas akhir : Analisis Risiko Sistemik Saham Sektor Industri Menggunakan *Conditional Value-At-Risk* Berbasis AR-GARCH Dan *Quantile Regression Forest* Dengan *Stochastic Search Variable Selection*

Pembimbing utama : Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

dengan ini menyatakan bahwa pada Tugas Akhir dengan judul di atas sebagai berikut

1. Saya hanya menggunakan AI generatif sebagai alat bantu untuk memperbaiki tata Bahasa penulisan. AI generatif tidak digunakan untuk membuat keseluruhan isi Tugas Akhir.
2. Saya telah memeriksa dan/atau memperbaiki seluruh bagian dari Tugas Akhir saya yang dibantu oleh AI generatif agar sesuai dengan baku mutu penulisan karya ilmiah.
3. Saya tidak menggunakan AI generatif untuk membangkitkan data, membuat grafik dan/atau tabel pada Tugas Akhir saya.
4. Saya memastikan tidak ada plagiarisme, termasuk hal yang berasal dari penggunaan AI generatif.

Jika di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku.

Surabaya, 16 Juli 2026

Mahasiswa pembuat pernyataan



Ayunda Fatikha
NRP 5003221023

(Halaman ini sengaja dikosongkan)

ABSTRAK

ANALISIS RISIKO SISTEMIK SAHAM SEKTOR INDUSTRI MENGGUNAKAN *CONDITIONAL VALUE-AT-RISK* BERBASIS AR-GARCH DAN *QUANTILE REGRESSION FOREST* DENGAN *STOCHASTIC SEARCH VARIABLE SELECTION*

Nama Mahasiswa / NRP : Ayunda Fatikha / 5003221023
Prodi, Departemen : Sarjana Statistika, Departemen Statistika FSAD ITS
Dosen Pembimbing : Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

Abstrak

Sektor industri memiliki kontribusi terbesar terhadap PDB Indonesia dengan nilai 18,98% pada akhir tahun 2024 rentan terhadap risiko sistemik. Volatilitas *return* yang tinggi dan fenomena *clustering volatility* dapat menimbulkan kerugian ekstrem yang tidak hanya berdampak pada perusahaan individual, tetapi juga dapat menyebar ke seluruh sistem keuangan melalui *spillover effect*. Penelitian ini menganalisis risiko sistemik saham sektor industri di BEI menggunakan VaR berbasis AR-GARCH, CoVaR berbasis QRF, Δ CoVaR, dan SSVS pada sepuluh emiten sektor industri dengan kapitalisasi pasar tertinggi (ASII, IMPC, UNTR, SKRN, SINI, SMIL, ARNA, HEXA, TOTO, dan MARK) periode 3 Juli 2023 hingga 31 Desember 2025. Hasil penelitian menunjukkan bahwa seluruh saham memiliki distribusi *return* yang memiliki ekor tebal disertai pola asimetri, sehingga distribusi *standardized skewed Student-t* (sstd) digunakan dalam pemodelan AR-GARCH. Estimasi VaR menghasilkan model yang valid secara statistik pada sebagian besar emiten, kecuali SINI yang menunjukkan *underestimation* risiko pada kuantil 5%. Estimasi CoVaR QRF menunjukkan adanya keterkaitan risiko sistemik yang bervariasi antar emiten dan antar tingkat kuantil, di mana pada kondisi ekstrem batas kerugian kondisional berfluktuasi lebih dalam dibandingkan kondisi lebih moderat. Model CoVaR QRF terbukti valid secara statistik pada hampir seluruh saham, kecuali IMPC pada kuantil 1% akibat karakteristik distribusi *return* yang volatil dan lonjakan ekstrem pada akhir periode pengamatan. Δ CoVaR yang mengidentifikasi potensi kerugian kondisional yang semakin dalam pada kondisi ekstrem di beberapa saham, dengan TOTO mencatat kontribusi risiko sistemik paling terkendali di antara seluruh saham. Penerapan SSVS pada CoVaR menghasilkan model yang lebih *parsimonious*. Perbandingan akurasi ketiga model berdasarkan menunjukkan bahwa CoVaR QRF konvensional secara umum menghasilkan akurasi frekuensi pelanggaran yang lebih baik dibandingkan CoVaR SSVS, mengindikasikan bahwa seleksi variabel melalui SSVS menghasilkan model yang lebih *parsimonious*, namun tidak selalu meningkatkan akurasi frekuensi pelanggaran dibandingkan model yang menggunakan seluruh prediktor dalam mengidentifikasi sumber risiko sistemik sektor industri.

Kata kunci: *AR-GARCH, CoVaR, QRF, SSVS, Sektor Industri.*

(Halaman ini sengaja dikosongkan)

ABSTRACT

SYSTEMIC RISK ANALYSIS OF INDUSTRIALS SECTOR USING CONDITIONAL VALUE-AT-RISK BASED ON AR-GARCH AND QUANTILE REGRESSION FOREST WITH STOCHASTIC SEARCH VARIABLE SELECTION

Student Name / NRP : Ayunda Fatikha / 5003221023
Program, Department : Bachelor Program of Statistics,
Department of Statistics F-Scientics ITS
Advisor : Prof. Dr.rer.pol. Dedy Dwi Prastyo, S.Si., M.Si.

Abstract

The industrial sector contributes the largest share to Indonesia's GDP at 18.98% as of the end of 2024, yet remains vulnerable to systemic risk. High return volatility and volatility clustering phenomena in the industrial sector can generate extreme losses that not only affect individual companies but may also propagate throughout the financial system through spillover effects. This study analyzes the systemic risk of industrial sector stocks listed on the Indonesia Stock Exchange (IDX) using VaR based on AR-GARCH, CoVaR based on QRF, Δ CoVaR, and SSVS on ten industrial sector stocks with the highest market capitalization (ASII, IMPC, UNTR, SKRN, SINI, SMIL, ARNA, HEXA, TOTO, dan MARK) over the period of July 3, 2023 to December 31, 2025. The results indicate that all stocks exhibit leptokurtic return distributions with heavy tails, accompanied by varying degrees of asymmetry across stocks that leading to the adoption of the standardized skewed Student-t (sstd) distribution in AR-GARCH modeling. VaR estimation yields statistically valid models for most stocks, except for SINI which shows risk underestimation at the 5% quantile. QRF-based CoVaR estimation reveals varying systemic risk linkages across stocks and quantile levels, where conditional loss boundaries are deeper under extreme market conditions compared to more moderate conditions. The CoVaR QRF model proves statistically valid for almost all stocks, except for IMPC at the 1% quantile which exhibits a tendency toward risk underestimation due to its highly volatile return distribution and the presence of extreme spikes toward the end of the observation period. Δ CoVaR identifies increasingly deeper conditional loss potential under extreme conditions for several stocks, with TOTO recording the most controlled systemic risk contribution among all stocks. The application of SSVS to CoVaR yields a more parsimonious model. A comparison of the accuracy of the three models indicates that conventional CoVaR QRF generally produces better violation frequency accuracy than CoVaR SSVS, suggesting that variable selection through SSVS produces a more parsimonious model but does not consistently improve violation frequency accuracy compared to models using all predictors in identifying sources of systemic risk in the industrial sector.

Keywords: *AR-GARCH, CoVaR, QRF, SSVS, Industrial Sector*

(Halaman ini sengaja dikosongkan)

KATA PENGANTAR

Alhamdulillah rabbil ‘alamin, puji syukur penulis panjatkan kepada Allah SWT karena berkat rahmat, nikmat, serta karunia-Nya penulis diberikan kemudahan dan kekuatan dalam menyelesaikan Tugas Akhir yang berjudul “Analisis Risiko Sistemik Saham Sektor Industri Menggunakan *Conditional Value-at-Risk* Berbasis AR-GARCH dan *Quantile Regression Forest* dengan *Stochastic Search Variable Selection*” tepat waktu. Penyusunan tugas akhir ini dimaksudkan untuk memenuhi salah satu persyaratan akademik dalam menyelesaikan studi Program Sarjana di Departemen Statistika, Fakultas Sains dan Analitika Data Institut Teknologi Sepuluh Nopember (ITS). Penulis sadar bahwa selesainya tugas akhir ini tidak terlepas dari dukungan, bimbingan, dan motivasi dari berbagai pihak. Oleh karena itu, penulis secara tulus mengucapkan terima kasih kepada:

1. Kedua orang tua tercinta dan adik tersayang yang telah menemani penulis dari awal perkuliahan hingga sampai dititik ini, serta seluruh keluarga yang telah memberikan doa, kasih sayang, nasihat baik, serta dukungan positif tanpa henti untuk penulis. Ibu, Bapak, dan Bibil *thank you for always being there for me through every phase of my life and for being my greatest source of strength, happiness, love, and support.*
2. Bapak Prof. Dr.rer.pol. Dedy Dwi Prasetyo, S.Si., M.Si., selaku Kepala Departemen Statistika ITS, sekaligus dosen pembimbing atas arahan, masukan, serta kesabaran selama proses bimbingan dan pengerjaan tugas akhir, Ibu Dr. Wibawati, S.Si., M.Si., selaku Sekretaris Departemen Statistika ITS dan Ibu Shofi Andari, S.Stat., M.Si., Ph.D., selaku Kepala Program Studi Statistika ITS yang telah memberikan motivasi dan fasilitas yang memadai selama penulis berkuliah di Departemen Statistika.
3. Ibu Neni Alya Firdausanti, S.Si., M.Stat., Ph.D. dan Bapak Dr. Muhammad Sjahid Akbar, S.Si., M.Si., selaku dosen penguji atas saran, masukan, dan koreksi yang membangun demi penyempurnaan tugas akhir penulis.
4. Bapak Dr. Achmad Choiruddin, S.Si, M.Sc. selaku dosen wali penulis yang telah memberikan nasihat, tips dan trik, serta arahan akademik selama penulis menjalani perkuliahan di Departemen Statistika.
5. Bapak Ibu dosen atas ilmu pengetahuan, wawasan, serta pengalaman selama masa perkuliahan, serta staf dan karyawan Departemen Statistika atas bantuan dan pelayanan proses administratif selama proses perkuliahan.
6. Teman seperjuangan Statistika Angkatan 2022 yang telah menjadi keluarga pertama penulis di Surabaya. Terima kasih atas kebersamaan dari awal menjadi mahasiswa baru, proses kaderisasi, hingga sampai di titik ini.
7. Teman terdekat penulis, Marshelia, Haniya, Lintang, Nadel, Nadir, dan Shinta yang telah menjadi teman, penyemangat, serta tempat curahan hati penulis. Terima kasih atas segala cerita, pengalaman, dan bantuan tanpa henti selama hampir 4 tahun penulis di Surabaya.
8. Kampus perjuangan ITS Surabaya yang telah menjadi rumah kedua penulis dalam belajar, bertumbuh, dan berproses. Terima kasih telah membersamai akan segala hal “pertama kali” dalam hidup penulis. Terima kasih atas segala pembelajaran, pengalaman, dan proses pendewasaan selama penulis jauh dari rumah.

9. Ayunda Fatikha, selaku penulis yang telah berjuang dalam menuntut ilmu, pengetahuan, serta pengalaman berharga di bangku perkuliahan ini. Selamat sudah bisa sampai di titik ini dan terima kasih *for never giving up*.

Penulis sadar bahwa Tugas Akhir ini masih memiliki berbagai keterbatasan dan jauh dari kesempurnaan. Oleh karenanya, penulis terbuka terhadap segala saran dan kritik membangun terkait Tugas Akhir ini. Penulis berharap hasil penelitian pada Tugas Akhir ini dapat memberikan manfaat dan berkontribusi positif, baik secara akademis maupun praktis dalam pengembangan kajian risiko sistemik di pasar keuangan Indonesia.

DAFTAR ISI

LEMBAR PENGESAHAN	i
APPROVAL SHEET	iii
PERNYATAAN ORISINALITAS	v
STATEMENT OF ORIGINALITY	vii
PERNYATAAN KODE ETIK PENGGUNAAN AI GENERATIF DALAM TUGAS AKHIR...	ix
ABSTRAK	xi
ABSTRACT	xiii
KATA PENGANTAR	xv
DAFTAR ISI	xvii
DAFTAR GAMBAR	xxi
DAFTAR TABEL	xxiii
DAFTAR LAMPIRAN	1
BAB 1 PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Rumusan Masalah	5
1.3 Tujuan	6
1.4 Manfaat	6
1.5 Batasan Masalah	6
BAB 2 TINJAUAN PUSTAKA	7
2.1 Hasil Penelitian Terdahulu	7
2.2 Statistika Deskriptif	9
2.3 <i>Return</i> Saham	10
2.4 Risiko Sistemik	11
2.5 Analisis Deret Waktu	11
2.5.1 Stasioneritas Data	11
2.6 Model <i>Autoregressive</i> (AR)	12
2.6.1 Identifikasi Model AR	13
2.6.2 Estimasi Parameter AR	13
2.6.3 Uji Signifikansi Parameter AR	16
2.6.4 Uji Ljung-Box	16
2.6.5 Pemilihan Model Terbaik	16
2.7 Model <i>Generalized Autoregressive Conditional Heteroskedasticity</i> (GARCH)..	17
2.7.1 Uji Lagrange Multiplier (LM)	17
2.7.2 Estimasi Parameter Model GARCH	18

2.7.3	Uji Signifikansi Parameter Model GARCH.....	19
2.8	<i>Skewed Student-t Distribution</i>	19
2.8.1	Student-t Distribution.....	20
2.8.2	Skewed Student-t Distribution.....	20
2.8.3	Standardized Skewed Student-t Distribution.....	20
2.9	<i>Value-at-Risk (VaR)</i>	21
2.10	Uji <i>Terasvirta</i>	22
2.11	<i>Quantile Regression Forest (QRF)</i>	23
2.12	<i>Conditional Value-at-Risk (CoVaR)</i>	26
2.13	<i>Backtesting</i>	27
2.13.1	<i>Proportion Shortfall</i>	27
2.13.2	<i>Kupiec Test</i>	28
2.13.3	<i>Pinball Loss</i>	29
2.14	<i>Stochastic Search Variable Selection (SSVS)</i>	30
2.15	Saham Sektor Industri.....	34
BAB 3	METODE PENELITIAN.....	35
3.1	Sumber Data.....	35
3.2	Variabel Penelitian.....	35
3.3	Struktur Data.....	35
3.4	Langkah Analisis.....	37
3.5	Diagram Alir Penelitian.....	40
BAB 4	HASIL DAN PEMBAHASAN.....	43
4.1	Karakteristik Data <i>Return Saham</i>	43
4.2	Estimasi Nilai <i>Value-at-Risk</i> dengan Pendekatan AR-GARCH.....	47
4.2.1	Uji Stasioneritas Data.....	47
4.2.2	Identifikasi Model AR.....	48
4.2.3	Estimasi dan Uji Signifikansi Parameter Model AR.....	50
4.2.4	Lagrange Multiplier Test.....	59
4.2.5	Estimasi dan Uji Signifikansi Model GARCH.....	60
4.2.6	Estimasi Nilai VaR Setiap Saham dengan AR-GARCH.....	68
4.2.7	Backtesting Hasil Estimasi VaR.....	82
4.3	Estimasi Nilai <i>Conditional Value-at-Risk</i> dengan Pendekatan <i>Quantile Regression Forest (QRF)</i> dan Δ CoVaR.....	85
4.3.1	Uji <i>Terasvirta</i>	86
4.3.2	Estimasi Nilai CoVaR Setiap Saham dengan QRF.....	86

4.3.3	Backtesting Hasil Estimasi CoVaR	105
4.3.4	Delta Conditional Value-at-Risk (ΔCoVaR)	108
4.4	Estimasi Nilai CoVaR SSVS	112
4.4.1	<i>Pre-processing</i> Data CoVaR SSVS	113
4.4.2	Estimasi Nilai CoVaR SSVS Setiap Saham	114
4.4.3	<i>Backtesting</i> Hasil Estimasi CoVaR SSVS	143
4.5	Perbandingan Akurasi Model VaR, CoVaR, dan CoVaR SSVS	146
BAB 5	KESIMPULAN	151
5.1	Kesimpulan	151
5.2	Saran	152
	DAFTAR PUSTAKA	155
	LAMPIRAN	163
	BIODATA PENULIS	235

(Halaman ini sengaja dikosongkan)

DAFTAR GAMBAR

Gambar 2.1 Pembentukan Kandidat <i>Block</i>	24
Gambar 2.2 Pembentukan Dataset <i>Bootstrap</i>	25
Gambar 3.1 Diagram Alir Penelitian.....	40
Gambar 4.1 Time Series Plot Data Harga Penutupan Saham	43
Gambar 4.2 Time Series Plot <i>Return</i> Saham.....	44
Gambar 4.3 Boxplot Return Saham Sektor Industri.....	46
Gambar 4.4 Plot ACF dan PACF Saham Sektor Industri	48
Gambar 4.5 Plot VaR ASII Kuantil 1% (Kiri) dan 5% (Kanan).....	69
Gambar 4.6 Plot VaR IMPC Kuantil 1% (Kiri) dan 5% (Kanan).....	70
Gambar 4.7 Plot VaR UNTR Kuantil 1% (Kiri) dan 5% (Kanan).....	72
Gambar 4.8 Plot VaR SKRN Kuantil 1% (Kiri) dan 5% (Kanan).....	73
Gambar 4.9 Plot VaR SINI Kuantil 1% (Kiri) dan 5% (Kanan).....	74
Gambar 4.10 Plot VaR SMIL Kuantil 1% (Kiri) dan 5% (Kanan)	76
Gambar 4.11 Plot VaR ARNA Kuantil 1% (Kiri) dan 5% (Kanan)	77
Gambar 4.12 Plot VaR HEXA Kuantil 1% (Kiri) dan 5% (Kanan).....	78
Gambar 4.13 Plot VaR TOTO Kuantil 1% (Kiri) dan 5% (Kanan).....	80
Gambar 4.14 Plot VaR MARK Kuantil 1% (Kiri) dan 5% (Kanan).....	81
Gambar 4.15 Plot CoVaR ASII Kuantil 1% (Kiri) dan 5% (Kanan)	88
Gambar 4.16 Plot CoVaR IMPC Kuantil 1% (Kiri) dan 5% (Kanan)	90
Gambar 4.17 Plot CoVaR UNTR Kuantil 1% (Kiri) dan 5% (Kanan)	92
Gambar 4.18 Plot CoVaR SKRN Kuantil 1% (Kiri) dan 5% (Kanan)	94
Gambar 4.19 Plot CoVaR SINI Kuantil 1% (Kiri) dan 5% (Kanan)	96
Gambar 4.20 Plot CoVaR SMIL Kuantil 1% (Kiri) dan 5% (Kanan)	98
Gambar 4.21 Plot CoVaR ARNA Kuantil 1% (Kiri) dan 5% (Kanan).....	100
Gambar 4.22 Plot CoVaR TOTO Kuantil 1% (Kiri) dan 5% (Kanan)	102
Gambar 4.23 Plot CoVaR MARK Kuantil 1% (Kiri) dan 5% (Kanan).....	104
Gambar 4.24 Plot Δ CoVaR Saham Sektor Industri	110
Gambar 4.25 <i>Running</i> PIP Saham ASII	116
Gambar 4.26 Plot CoVaR SSVS ASII Kuantil 1% (Kiri) dan 5% (Kanan).....	118
Gambar 4.27 <i>Running</i> PIP Saham IMPC	119
Gambar 4.28 Plot CoVaR SSVS IMPC Kuantil 1% (Kiri) dan 5% (Kanan).....	121
Gambar 4.29 <i>Running</i> PIP Saham UNTR.....	122
Gambar 4.30 Plot CoVaR SSVS UNTR Kuantil 1% (Kiri) dan 5% (Kanan).....	124
Gambar 4.31 <i>Running</i> PIP Saham SKRN	125
Gambar 4.32 Plot CoVaR SSVS SKRN Kuantil 1% (Kiri) dan 5% (Kanan).....	127
Gambar 4.33 <i>Running</i> PIP Saham SINI	128
Gambar 4.34 Plot CoVaR SSVS SINI Kuantil 1% (Kiri) dan 5% (Kanan).....	130
Gambar 4.35 <i>Running</i> PIP Saham SMIL	131
Gambar 4.36 Plot CoVaR SSVS SMIL Kuantil 1% (Kiri) dan 5% (Kanan).....	133
Gambar 4.37 <i>Running</i> PIP Saham ARNA.....	134
Gambar 4.38 Plot CoVaR SSVS ARNA Kuantil 1% (Kiri) dan 5% (Kanan)	136
Gambar 4.39 <i>Running</i> PIP Saham TOTO	137
Gambar 4.40 Plot CoVaR SSVS TOTO Kuantil 1% (Kiri) dan 5% (Kanan).....	139

Gambar 4.41 <i>Running</i> PIP Saham MARK	141
Gambar 4.42 Plot CoVaR SSVS MARK Kuantil 1% (Kiri) dan 5% (Kanan)	142

DAFTAR TABEL

Tabel 2.1 Hasil Penelitian Terdahulu	7
Tabel 3.1 Variabel Penelitian	35
Tabel 3.2 Struktur Data Return Saham	36
Tabel 3.3 Struktur Data Hasil Estimasi VaR.....	36
Tabel 3.4 Struktur Data Hasil Estimasi CoVaR.....	36
Tabel 3.5 Struktur Data Hasil Estimasi Δ CoVaR	37
Tabel 3.6 Struktur Data Hasil Estimasi CoVaR SSVS	37
Tabel 4.1 Statistika Deskriptif Return Saham.....	45
Tabel 4.2 <i>Output</i> Uji Stasioneritas dalam <i>Mean</i>	47
Tabel 4.3 Lag Signifikan Pada Plot ACF dan PACF	49
Tabel 4.4 Hasil Estimasi dan Uji Signifikansi Model AR Saham ASII.....	50
Tabel 4.5 Hasil Reestimasi dan Uji Signifikansi Model AR Saham ASII.....	51
Tabel 4.6 Hasil Uji <i>White Noise</i> Residual Model AR Saham ASII	51
Tabel 4.7 Perbandingan Nilai AIC Model AR Saham ASII	51
Tabel 4.8 Hasil Estimasi dan Uji Signifikansi Model AR Saham IMPC.....	52
Tabel 4.9 Hasil Uji <i>White Noise</i> Residual Model AR Saham IMPC	52
Tabel 4.10 Hasil Estimasi dan Uji Signifikansi Model AR Saham UNTR.....	53
Tabel 4.11 Hasil Uji <i>White Noise</i> Residual Model AR Saham UNTR	53
Tabel 4.12 Hasil Estimasi dan Uji Signifikansi Model AR Saham SKRN.....	54
Tabel 4.13 Hasil Estimasi dan Uji Signifikansi Model AR Saham SINI.....	54
Tabel 4.14 Hasil Reestimasi dan Uji Signifikansi Model AR Saham SINI.....	54
Tabel 4.15 Hasil Uji <i>White Noise</i> Residual Model AR Saham SINI	55
Tabel 4.16 Hasil Estimasi dan Uji Signifikansi Model AR Saham SMIL	55
Tabel 4.17 Hasil Reestimasi dan Uji Signifikansi Model AR Saham SMIL	55
Tabel 4.18 Hasil Uji <i>White Noise</i> Residual Model AR Saham SMIL	56
Tabel 4.19 Hasil Estimasi dan Uji Signifikansi Model AR Saham ARNA	56
Tabel 4.20 Hasil Estimasi dan Uji Signifikansi Model AR Saham HEXA	57
Tabel 4.21 Hasil Estimasi dan Uji Signifikansi Model AR Saham TOTO.....	57
Tabel 4.22 Hasil Reestimasi dan Uji Signifikansi Model AR Saham TOTO	58
Tabel 4.23 Hasil Uji <i>White Noise</i> Residual Model AR Saham TOTO	58
Tabel 4.24 Hasil Estimasi dan Uji Signifikansi Model AR Saham MARK	58
Tabel 4.25 Hasil Reestimasi dan Uji Signifikansi Model AR Saham MARK.....	59
Tabel 4.26 Hasil Uji <i>White Noise</i> Residual Model AR Saham MARK.....	59
Tabel 4.27 Ringkasan Model AR Terpilih	59
Tabel 4.28 Hasil Lagrange Multiplier Test Tiap Saham.....	60
Tabel 4.29 Skenario Perhitungan VaR.....	60
Tabel 4.30 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham IMPC	61
Tabel 4.31 Perbandingan Nilai AIC Model GARCH Saham IMPC.....	61
Tabel 4.32 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SKRN	62
Tabel 4.33 Perbandingan Nilai AIC Model GARCH Saham SKRN.....	63
Tabel 4.34 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SINI	63
Tabel 4.35 Perbandingan Nilai AIC Model GARCH Saham SINI.....	64
Tabel 4.36 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SMIL	64

Tabel 4.37 Perbandingan Nilai AIC Model GARCH Saham SMIL.....	65
Tabel 4.38 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham ARNA	66
Tabel 4.39 Perbandingan Nilai AIC Model GARCH Saham ARNA.....	66
Tabel 4.40 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham MARK	67
Tabel 4.41 Perbandingan Nilai AIC Model GARCH Saham MARK.....	67
Tabel 4.42 Estimasi Nilai VaR Saham ASII	68
Tabel 4.43 Estimasi Nilai VaR Saham IMPC	70
Tabel 4.44 Estimasi Nilai VaR Saham UNTR	71
Tabel 4.45 Estimasi Nilai VaR Saham SKRN.....	72
Tabel 4.46 Estimasi Nilai VaR Saham SINI	74
Tabel 4.47 Estimasi Nilai VaR Saham SMIL.....	75
Tabel 4.48 Estimasi Nilai VaR Saham ARNA.....	76
Tabel 4.49 Estimasi Nilai VaR Saham HEXA	78
Tabel 4.50 Estimasi Nilai VaR Saham TOTO.....	79
Tabel 4.51 Estimasi Nilai VaR Saham MARK	80
Tabel 4.52 Hasil <i>Backtesting</i> Metode <i>Proportion Shortfall</i> pada Estimasi VaR	82
Tabel 4.53 Hasil <i>Backtesting</i> Metode <i>Kupiec Test</i> pada Estimasi VaR.....	84
Tabel 4.54 Hasil <i>Pinball Loss</i> pada Estimasi VaR.....	85
Tabel 4.55 Hyperparameter Estimasi CoVaR dengan QRF	86
Tabel 4.56 Estimasi Nilai CoVaR Saham ASII.....	87
Tabel 4.57 <i>Variable Importance</i> QRF untuk CoVaR Saham ASII	88
Tabel 4.58 Estimasi Nilai CoVaR Saham IMPC.....	89
Tabel 4.59 <i>Variable Importance</i> QRF untuk CoVaR Saham IMPC	91
Tabel 4.60 Estimasi Nilai CoVaR Saham UNTR.....	91
Tabel 4.61 <i>Variable Importance</i> QRF untuk CoVaR Saham UNTR	93
Tabel 4.62 Estimasi Nilai CoVaR Saham SKRN.....	93
Tabel 4.63 <i>Variable Importance</i> QRF untuk CoVaR Saham SKRN	94
Tabel 4.64 Estimasi Nilai CoVaR Saham SINI.....	95
Tabel 4.65 <i>Variable Importance</i> QRF untuk CoVaR Saham SINI	96
Tabel 4.66 Estimasi Nilai CoVaR Saham SMIL	97
Tabel 4.67 <i>Variable Importance</i> QRF untuk CoVaR Saham SMIL	98
Tabel 4.68 Estimasi Nilai CoVaR Saham ARNA	99
Tabel 4.69 <i>Variable Importance</i> QRF untuk CoVaR Saham ARNA.....	100
Tabel 4.70 Estimasi Nilai CoVaR Saham TOTO	101
Tabel 4.71 <i>Variable Importance</i> QRF untuk CoVaR Saham TOTO	102
Tabel 4.72 Estimasi Nilai CoVaR Saham MARK.....	103
Tabel 4.73 <i>Variable Importance</i> QRF untuk CoVaR Saham MARK.....	104
Tabel 4.74 Hasil <i>Backtesting</i> Metode <i>Proportion Shortfall</i> pada Estimasi CoVaR.....	105
Tabel 4.75 Hasil <i>Backtesting</i> Metode <i>Kupiec Test</i> pada Estimasi CoVaR.....	107
Tabel 4.76 Hasil <i>Pinball Loss</i> pada Estimasi CoVaR	108
Tabel 4.77 Estimasi Nilai Risiko Δ CoVaR Saham Sektor Industri.....	109
Tabel 4.78 <i>Hyperparameter</i> Seleksi Variabel pada Estimasi CoVaR SSVS	114
Tabel 4.79 Nilai Prior Saham ASII.....	115
Tabel 4.80 Nilai PIP Prediktor untuk CoVaR SSVS Saham ASII	116
Tabel 4.81 Estimasi Nilai CoVaR SSVS Saham ASII	117
Tabel 4.82 Nilai Prior Saham IMPC.....	118

Tabel 4.83 Nilai PIP Prediktor untuk CoVaR SSVS Saham IMPC.....	119
Tabel 4.84 Estimasi Nilai CoVaR SSVS Saham IMPC.....	120
Tabel 4.85 Nilai Prior Saham UNTR.....	122
Tabel 4.86 Nilai PIP Prediktor untuk CoVaR SSVS Saham UNTR.....	123
Tabel 4.87 Estimasi Nilai CoVaR SSVS Saham UNTR.....	123
Tabel 4.88 Nilai Prior Saham SKRN.....	125
Tabel 4.89 Nilai PIP Prediktor untuk CoVaR SSVS Saham SKRN.....	126
Tabel 4.90 Estimasi Nilai CoVaR SSVS Saham SKRN.....	127
Tabel 4.91 Nilai Prior Saham SINI.....	128
Tabel 4.92 Nilai PIP Prediktor untuk CoVaR SSVS Saham SINI.....	129
Tabel 4.93 Estimasi Nilai CoVaR SSVS Saham SINI.....	130
Tabel 4.94 Nilai Prior Saham SMIL.....	131
Tabel 4.95 Nilai PIP Prediktor untuk CoVaR SSVS Saham SMIL.....	132
Tabel 4.96 Estimasi Nilai CoVaR SSVS Saham SMIL.....	132
Tabel 4.97 Nilai Prior Saham ARNA.....	134
Tabel 4.98 Nilai PIP Prediktor untuk CoVaR SSVS Saham ARNA.....	135
Tabel 4.99 Estimasi Nilai CoVaR SSVS Saham ARNA.....	135
Tabel 4.100 Nilai Prior Saham TOTO.....	137
Tabel 4.101 Nilai PIP Prediktor untuk CoVaR SSVS Saham TOTO.....	138
Tabel 4.102 Estimasi Nilai CoVaR SSVS Saham TOTO.....	139
Tabel 4.103 Nilai Prior Saham MARK.....	140
Tabel 4.104 Nilai PIP Prediktor untuk CoVaR SSVS Saham MARK.....	141
Tabel 4.105 Estimasi Nilai CoVaR SSVS Saham MARK.....	142
Tabel 4.106 Hasil <i>Proportion Shortfall</i> pada Estimasi CoVaR SSVS.....	143
Tabel 4.107 Hasil <i>Kupiec Test</i> pada Estimasi CoVaR SSVS.....	144
Tabel 4.108 Hasil <i>Pinball Loss</i> pada Estimasi CoVaR SSVS.....	146
Tabel 4.109 Perbandingan <i>Proportion Shortfall</i> pada VaR, CoVaR, dan CoVaR SSVS.....	147
Tabel 4.110 Perbandingan <i>Kupiec Test</i> pada VaR, CoVaR, dan CoVaR SSVS.....	148
Tabel 4.111 Perbandingan Nilai <i>Pinball Loss</i> pada VaR, CoVaR, dan CoVaR SSVS ..	149

(Halaman ini sengaja dikosongkan)

DAFTAR LAMPIRAN

Lampiran 1 Data Harga Penutupan 10 Saham Sektor Industri	163
Lampiran 2 Data Return 10 Saham Sektor Industri	164
Lampiran 3 <i>Syntax Download Data</i>	164
Lampiran 4 <i>Syntax Plot Time Series Data Harga Saham</i>	166
Lampiran 5 <i>Syntax Perhitungan Data Return Saham</i>	167
Lampiran 6 <i>Syntax Plot Time Series Data Return Saham</i>	168
Lampiran 7 <i>Syntax Statistika Deskriptif Data Return Saham</i>	170
Lampiran 8 <i>Syntax Boxplot Data Return Saham</i>	170
Lampiran 9 <i>Syntax Uji Stasioneritas dalam Mean</i>	171
Lampiran 10 <i>Syntax Uji Stasioneritas dalam Varians</i>	171
Lampiran 11 Hasil Uji Stasioneritas dalam Varians	173
Lampiran 12 <i>Syntax Plot ACF dan PACF Data Return Saham</i>	173
Lampiran 13 <i>Syntax Pemodelan AR</i>	174
Lampiran 14 <i>Syntax Ringkasan Uji Lagrange Multiplier</i>	180
Lampiran 15 <i>Syntax Pemodelan GARCH</i>	180
Lampiran 16 <i>Syntax Estimasi VaR dengan AR-GARCH</i>	182
Lampiran 17 Hasil Estimasi VaR Kuantil 1%	184
Lampiran 18 Hasil Estimasi VaR Kuantil 5%	185
Lampiran 19 <i>Syntax Statistika Deskriptif VaR Kuantil 1% dan 5%</i>	185
Lampiran 20 <i>Syntax Plot VaR 1% dan 5% vs Actual Return</i>	187
Lampiran 21 <i>Syntax Proportion Shortfall VaR Kuantil 1% dan 5%</i>	189
Lampiran 22 <i>Syntax Kupiec Test VaR Kuantil 1% dan 5%</i>	191
Lampiran 23 <i>Syntax dan Output Uji Terasvirta</i>	193
Lampiran 24 <i>Syntax Estimasi VaR 50%</i>	196
Lampiran 25 <i>Syntax Estimasi CoVaR dengan QRF</i>	196
Lampiran 26 Hasil <i>Variable Importance</i> QRF Kuantil 1% dan 5%	200
Lampiran 27 Hasil Estimasi CoVaR Kuantil 1%.....	202
Lampiran 28 Hasil Estimasi CoVaR Kuantil 5%.....	202
Lampiran 29 <i>Syntax Statistika Deskriptif CoVaR Kuantil 1% dan 5%</i>	203
Lampiran 30 <i>Syntax Plot CoVaR 1% dan 5% vs Actual Return</i>	203
Lampiran 31 <i>Syntax Proportion Shortfall CoVaR Kuantil 1% dan 5%</i>	205
Lampiran 32 <i>Syntax Kupiec Test CoVaR Kuantil 1% dan 5%</i>	206
Lampiran 33 <i>Syntax ΔCoVaR Kuantil 1% dan 5%</i>	207
Lampiran 34 Hasil Δ CoVaR Kuantil 1%.....	209
Lampiran 35 Hasil Δ CoVaR Kuantil 5%.....	210
Lampiran 36 <i>Syntax Statistika Deskriptif ΔCoVaR Kuantil 1% dan 5%</i>	210
Lampiran 37 <i>Syntax Plot ΔCoVaR 1% dan 5% vs Actual Return</i>	210
Lampiran 38 <i>Syntax Estimasi CoVaR SSVS</i>	212
Lampiran 39 <i>Syntax Eksekusi SSVS untuk Masing-Masing Emiten</i>	216
Lampiran 40 Hasil Nilai PIP Kuantil 1% dan 5%.....	224
Lampiran 41 Hasil Estimasi CoVaR SSVS Kuantil 1%	225
Lampiran 42 Hasil Estimasi CoVaR SSVS Kuantil 5%	226
Lampiran 43 <i>Syntax Trace Plot dan Visualisasi Running PIP</i>	226

Lampiran 44 <i>Syntax</i> Statistika Deskriptif CoVaR SSVS Kuantil 1% dan 5%.....	228
Lampiran 45 <i>Syntax</i> Plot CoVaR SSVS 1% dan 5% vs Actual Return	229
Lampiran 46 <i>Syntax Proportion Shortfall</i> CoVaR SSVS Kuantil 1% dan 5%	230
Lampiran 47 <i>Syntax Kupiec Test</i> CoVaR SSVS Kuantil 1% dan 5%	231
Lampiran 48 <i>Syntax Pinball Loss</i> Estimasi VaR, CoVaR, dan CoVaR SSVS	231
Lampiran 49 Surat Pernyataan Data Sekunder	233

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pasar modal memiliki peranan penting dalam mendorong pertumbuhan ekonomi nasional melalui fungsi utamanya sebagai sarana mobilisasi dana untuk kegiatan investasi jangka panjang. Investasi merupakan salah satu alternatif bisnis yang banyak diminati oleh orang banyak. Jenis investasi yang paling populer adalah saham, yaitu tanda penyertaan atau kepemilikan seseorang atau badan dalam suatu perusahaan atau perseroan terbatas (Hamonangan & Wisuda, 2022). Saham memiliki karakteristik harga yang sering mengalami perubahan yang sulit diprediksi sehingga berakibat pada tidak pastinya nilai *return* (Schwert, 1989). *Return* merupakan keuntungan (*capital gain*) atau kerugian (*capital loss*) yang diperoleh perusahaan atau individu dari hasil kebijakan investasi yang dilakukan (Caraka et al., 2015). Pada umumnya data *return* saham memiliki ekor distribusi yang berat (*heavy tail*) yaitu ekor distribusi turun secara lambat bila dibandingkan dengan distribusi normal. Hal ini dapat meningkatkan peluang terjadinya nilai ekstrem dan berdampak pada besarnya risiko keuangan (Cont, 2001).

Di Indonesia, Bursa Efek Indonesia (BEI) yang berperan sebagai pusat aktivitas perdagangan saham terus menunjukkan perkembangan yang positif. Hingga akhir tahun 2024, nilai kapitalisasi pasar BEI tercatat sebesar Rp 12.191 triliun, meningkat sekitar 5,05% dibandingkan tahun sebelumnya (Otoritas Jasa Keuangan, 2024). Adanya kompleksitas dan keterkaitan antar sektor di dalam pasar modal menimbulkan tantangan tersendiri terhadap stabilitas sistem keuangan. Kondisi tersebut dapat memperbesar potensi munculnya risiko sistemik. Risiko sistemik merupakan jenis risiko yang muncul karena adanya keterkaitan dan dependensi antar institusi dalam sistem keuangan (Billio et al., 2012). Berbeda dengan risiko idiosinkratik, risiko sistemik dapat meluas dan memengaruhi stabilitas sistem keuangan secara keseluruhan. Risiko ini menggambarkan potensi terjadinya keruntuhan total pada sistem keuangan yang dapat menimbulkan gangguan besar terhadap kegiatan ekonomi (Acharya et al., 2017). Dalam konteks perekonomian Indonesia, relevansi pengukuran risiko sistemik semakin meningkat seiring dengan dominasi pasar modal oleh beberapa sektor utama yang saling terhubung erat dan memiliki peran besar dalam perekonomian nasional.

Salah satu sektor di BEI yang memiliki kontribusi signifikan dan keterkaitan luas yang membuatnya rentan terhadap risiko sistemik adalah sektor industri. Pada tahun 2024 sektor industri memberikan sumbangan sekitar 18,98% terhadap total Produk Domestik Bruto (PDB) nasional. Dengan tren kenaikan yang konsisten dari tahun sebelumnya menjadikan sektor industri menjadi sektor dengan kontribusi terbesar terhadap PDB nasional (Badan Pusat Statistik, 2024). Kontribusi ini menunjukkan peran penting sektor industri dalam perekonomian nasional serta mencerminkan tingkat risiko yang perlu diperhatikan. Sektor industri memiliki sensitivitas tinggi terhadap fluktuasi ekonomi yang berdampak pada rentannya sektor industri terhadap guncangan eksternal, seperti faktor makroekonomi dan pergerakan harga saham sektor lain (Narayan & Sharma, 2011). Sektor ini juga menunjukkan volatilitas *return* yang relatif tinggi dan kecenderungan terjadinya *clustering volatility*, adanya periode volatilitas meningkat secara terus menerus. Volatilitas yang tinggi dapat menimbulkan risiko kerugian besar bagi investor jika tidak dikelola dengan tepat (Asih et al., 2024; Fadila et al., 2022). Kondisi ini mengindikasikan pentingnya penggunaan pemodelan risiko yang mampu

menangkap dinamika volatilitas secara temporal dan potensi kerugian ekstrem secara akurat, seperti model-model berbasis heteroskedastisitas (Engle, 2001).

Dalam konteks manajemen risiko untuk mengantisipasi volatilitas dan kerugian ekstrem, salah satu pendekatan yang digunakan adalah *Value-at-Risk* (VaR). VaR adalah ukuran risiko yang digunakan dalam manajemen risiko keuangan, dirancang untuk mengestimasi kerugian maksimum yang dapat terjadi pada tingkat kepercayaan tertentu dalam periode waktu tertentu (Jorion, 2007). VaR memberikan ukuran risiko pasar yang bersifat prediktif dimana hasil estimasinya digunakan untuk memberikan peringatan mengenai risiko pasar sebelum kerugian finansial yang sebenarnya terjadi (Holton, 2003).

Meskipun sudah banyak digunakan untuk menilai risiko pasar model VaR memiliki keterbatasan, yaitu hanya bersifat mikropudensial sehingga tidak dapat menangkap risiko sistemik. VaR juga mengabaikan kemungkinan adanya *spillover effect* (efek limpahan) dari tekanan yang dialami oleh suatu perusahaan terhadap perusahaan lainnya. Akibatnya, penggunaannya kurang memadai untuk mengukur risiko pada level sistem keuangan secara menyeluruh karena hanya fokus mengukur secara terpisah risiko tiap sistem keuangan. Untuk mengatasi adanya keterbatasan dari metode VaR, dikembangkan metode *Conditional Value at Risk* (CoVaR). CoVaR mampu memberikan estimasi nilai risiko suatu pasar secara keseluruhan ketika suatu institusi berada dalam keadaan *distress*. Untuk memperoleh pemahaman yang lebih mendalam mengenai perubahan risiko sistemik yang ditimbulkan diperlukan indikator turunannya yaitu ΔCoVaR yang merupakan selisih antara CoVaR sistem ketika institusi berada dalam kondisi *distress* dan ketika institusi berada pada median. ΔCoVaR memberikan ukuran kontribusi marginal suatu institusi terhadap risiko sistemik. Kombinasi ini mampu mendeteksi secara keseluruhan potensi terjadinya *spillover effects* antar pasar keuangan (Adrian & Brunnermeier, 2016; Reboredo & Ugolini, 2015).

Penggunaan metode *Value-at-Risk* (VaR) dan *Conditional Value-at-Risk* (CoVaR) menjadi penting karena keduanya mampu memberikan gambaran kuantitatif mengenai estimasi kerugian maksimum dan potensi risiko sistemik antar pasar. Untuk mengestimasi VaR secara akurat, kunci utamanya adalah pemodelan volatilitas yang dinamis dan responsif terhadap perubahan kondisi pasar. Model *Autoregressive - Generalized Conditional Heteroskedasticity* (AR-GARCH) telah terbukti efektif dalam menangkap volatilitas dan menjadi model dasar yang reliabel untuk mengestimasi volatilitas *return* saham yang ekstrem (Velásquez-Gaviria et al., 2020).

Adapun dalam estimasi CoVaR, regresi kuantil merupakan alat yang efektif untuk mengidentifikasi dan mengukur *spillover risk* antar aset atau perusahaan ketika pasar berada dalam kondisi ekstrem (Keilbar & Wang, 2022). Namun, regresi kuantil memiliki keterbatasan dalam menangkap nonlinieritas dan interaksi kompleks antar variabel yang seringkali ditemukan dalam data keuangan (Adrian & Brunnermeier, 2016). Untuk mengatasi keterbatasan ini, beberapa penelitian terkini mulai mengadopsi pendekatan non-parametrik dan *machine learning*, salah satunya adalah *Quantile Regression Forest* (QRF). *Quantile Regression Forest* (QRF) dikembangkan oleh Meinshausen pada tahun 2006, merupakan pengembangan dari algoritma *Random Forest* untuk estimasi *conditional quantiles*. QRF memiliki beberapa keunggulan dibandingkan dengan *quantile regression linier*, antara lain kemampuan menangkap hubungan non linier antara variabel prediktor dan respons tanpa spesifikasi bentuk fungsional sebelumnya, *robust* terhadap *outliers* dan multikolinieritas, dapat menangani interaksi kompleks antar variabel secara otomatis, serta memberikan estimasi yang

lebih akurat pada *tail distribution*, yang mana sangat relevan digunakan dalam pengukuran risiko ekstrem (Meinshausen, 2006).

Dalam estimasi risiko sistemik, memasukkan seluruh variabel tanpa adanya seleksi variabel dapat menimbulkan masalah *overfitting* dan mengurangi ketepatan model. Oleh karena itu, penelitian ini menerapkan *Stochastic Search Variable Selection* (SSVS), yaitu metode seleksi variabel dalam kerangka Bayesian yang menggunakan *hierarchical mixture prior* pada koefisien regresi, di mana setiap koefisien dikaitkan dengan variabel laten biner yang menentukan apakah variabel tersebut dimasukkan dalam model (George & McCulloch, 1997). SSVS efektif untuk memilih variabel yang paling relevan guna menjaga agar model tidak terlalu kompleks dan meningkatkan kinerja prediksi terutama pada distribusi ekor (Yu et al., 2013).

Penelitian mengenai tingkat risiko antar *return* saham telah beberapa kali dilakukan. Studi oleh Ardhini & Prastyo (2024) menggunakan pendekatan ARMA-GARCH dan *Extreme Value Theory* (EVT) untuk menganalisis risiko saham subsektor perbankan di BEI dan memperoleh estimasi risiko yang cukup baik, tetapi pendekatan ini bergantung pada asumsi distribusi dan kurang fleksibel dalam menangkap hubungan nonlinier serta interaksi kompleks pada kondisi pasar ekstrem. Studi lain yang dilakukan oleh Liu et al. (2022) mengombinasikan model ARMA-GARCH dan regresi kuantil untuk mengukur risiko sistemik. Hasil penelitian menunjukkan regresi kuantil mampu merepresentasikan *spillover* risiko secara lebih realistis dibandingkan model linier. Namun, regresi kuantil parametrik memiliki keterbatasan dalam menangkap pola non-linier dan struktur dependensi yang kompleks pada data. Penelitian oleh Purwanto (2025) mengembangkan regresi kuantil dengan menggunakan pendekatan *Quantile Regression Forest* (QRF) yang menunjukkan hasil bahwa estimasi CoVaR dengan QRF lebih unggul, namun penelitian tersebut masih terbatas pada sektor perbankan dan belum menerapkan seleksi variabel.

Dari latar belakang di atas, penelitian ini berfokus pada pengukuran risiko sistemik pada sektor industri di BEI dengan mengombinasikan model AR-GARCH untuk estimasi VaR dan estimasi CoVaR dengan QRF karena dapat menangkap pola non-linier pada data *return* saham. Penelitian juga mengintegrasikan metode seleksi variabel *Stochastic Search Variable Selection* (SSVS) untuk memilih variabel yang berpengaruh signifikan dalam model. Kombinasi CoVaR berbasis QRF, Δ CoVaR, dan SSVS memungkinkan penelitian ini tidak hanya mengukur risiko sistemik, tetapi juga mengidentifikasi sumber risiko sistemik yang benar-benar relevan dan signifikan. Dengan adanya pemantauan dan pengukuran risiko sistemik yang tepat, potensi kerugian ekstrem dapat dicegah dan stabilitas pasar keuangan dapat terjaga dengan baik (Brownlees & Engle, 2017).

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang di atas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana karakteristik data *return* saham emiten sektor industri di BEI?
2. Bagaimana estimasi risiko pada saham sektor industri secara individu menggunakan metode *Value-at-Risk* (VaR) dengan pendekatan AR-GARCH?
3. Bagaimana *Conditional Value-at-Risk* (CoVaR) berbasis *Quantile Regression Forest* (QRF) dan Δ CoVaR dapat digunakan untuk mengukur risiko sistemik antar saham sektor industri di BEI?
4. Bagaimana penerapan *Stochastic Search Variable Selection* (SSVS) pada model CoVaR berbasis QRF untuk mendapatkan prediktor yang signifikan?

1.3 Tujuan

Berdasarkan rumusan masalah di atas, maka tujuan dari penelitian ini adalah sebagai berikut.

1. Mendeskripsikan karakteristik dari data *return* saham emiten sektor industri di BEI.
2. Mengestimasi risiko individu saham sektor industri menggunakan *Value-at-Risk* (VaR) dengan pendekatan AR-GARCH.
3. Mengukur risiko sistemik antar saham sektor industri menggunakan *Conditional Value-at-Risk* (CoVaR) berbasis QRF dan ΔCoVaR .
4. Menerapkan *Stochastic Search Variable Selection* (SSVS) pada model CoVaR berbasis QRF untuk mendapatkan prediktor yang signifikan.

1.4 Manfaat

Penelitian ini diharapkan memberikan manfaat baik secara teoritis maupun praktis di antaranya sebagai berikut.

1. Memperluas wawasan dan pengetahuan dalam bidang manajemen risiko dan investasi saham, khususnya pada sektor industri.
2. Menyediakan informasi yang relevan bagi investor, manajer investasi, regulator, dan pemangku kepentingan lainnya untuk mendukung pengambilan keputusan investasi yang lebih optimal di pasar modal Indonesia.
3. Menjadi referensi bagi pengembangan penelitian selanjutnya yang ingin melakukan analisis risiko pasar dengan metode statistik yang lebih adaptif dan inovatif terhadap data ekstrem.

1.5 Batasan Masalah

Adapun batasan masalah pada penelitian ini adalah sebagai berikut.

1. Data yang digunakan merupakan data sepuluh emiten sektor industri dengan *market cap* tertinggi per November 2025 yang IPO sebelum 3 Juli 2023.
2. Tidak melibatkan saham yang memiliki volatilitas rendah yang ditandai dengan nilai *return* hampir konstan.
3. Pada estimasi VaR dengan pendekatan AR-GARCH, komponen *mean* model hanya menggunakan model *Autoregressive* (AR) dengan pilihan orde AR(0), AR(1), dan AR(2), sedangkan komponen GARCH dibatasi pada orde GARCH(1,0), GARCH(0,1), dan GARCH(1,1) untuk menjaga kesederhanaan model.
4. *Standardized innovation* pada model GARCH diasumsikan mengikuti distribusi sstd.
5. Uji *Terasvirta* hanya sebagai informasi tambahan yang tidak menjadi syarat dilakukannya QRF.
6. Penelitian tidak membahas faktor eksternal (variabel makroekonomi dan saham sektor lain) di luar pergerakan harga saham yang dapat memengaruhi sektor industri.
7. Ukuran *block* untuk *moving block bootstrap* ditetapkan sebesar 63.

BAB 2 TINJAUAN PUSTAKA

Bab ini berisi mengenai penjelasan metode-metode yang digunakan dalam penelitian ini, meliputi statistika deskriptif, *return* saham, risiko sistemik, model AR-GARCH pada metode *Value-at-Risk*, metode *Conditional Value-at-Risk* dengan pendekatan *Quantile Regression Forest* (QRF), metode seleksi variabel SSVS, serta penelitian terdahulu dengan metode yang serupa.

2.1 Hasil Penelitian Terdahulu

Terdapat beberapa temuan yang berasal dari studi-studi sebelumnya yang menjadi rujukan dalam melaksanakan penelitian ini. Beberapa referensi penelitian ini disajikan pada **Tabel 2.1**.

Tabel 2.1 Hasil Penelitian Terdahulu

Penulis	Judul	Metode	Hasil Penelitian
Purwanto (2025)	Estimasi <i>Conditional Value-at-Risk</i> pada <i>Return</i> Saham Perbankan di Indonesia dengan Pendekatan <i>Peaks Over Threshold</i> dan <i>Quantile Regression Forest</i>	<i>Quantile Regression Forest</i> dan <i>Peaks Over Threshold</i>	Model CoVaR QRF lebih unggul dibandingkan VaR-POT dalam menilai risiko ekstrem di semua tingkatan kuantil. Hasil <i>backtesting</i> QRF juga menghasilkan selisih terkecil antara nilai ES dan kuantil serta memiliki validitas model tertinggi, sehingga CoVaR dengan pendekatan QRF lebih efektif dalam menangkap dependensi antar saham dan mampu menggambarkan risiko pasar lebih realistis dibandingkan VaR-POT.
Ardhini & Prastyo (2024)	Analisis Risiko Saham Subsektor Rumah Makan dan Ritel Pakaian & Tekstil di Bursa Efek Indonesia Menggunakan <i>Conditional Value-at-Risk</i> dengan Pendekatan ARMA-GARCH dan <i>Extreme Value Theory</i>	ARMA-GARCH dan <i>Extreme Value Theory</i>	Metode VaR dengan pendekatan ARMA-GARCH memberikan hasil estimasi risiko dan profit yang lebih akurat dibandingkan pendekatan EVT. Untuk metode CoVaR keakuratan pendekatan ditunjukkan dengan <i>expected shortfall</i> yang lebih mendekati nilai kuantil yang digunakan yaitu 5% dan 1%.

Tabel 2.1 Hasil Penelitian Terdahulu (Lanjutan)

Penulis	Judul	Metode	Hasil Penelitian
Castillo-Mateo et al. (2023)	<i>Bayesian Variable Selection in Generalized Extreme Value Regression: Modeling Annual Maximum Temperature</i>	GEV-SSVS	Hasil penelitian menunjukkan bahwa SSVS dapat secara otomatis mengidentifikasi subset variabel yang berpengaruh tinggi, sehingga membantu dalam pemodelan ekstrem suhu dengan ketidakpastian model yang besar. Terjadi peningkatan dalam kecocokan model dengan metode SSVS dibandingkan dengan metode berbeda yang digunakan pada penelitian sebelumnya.
Liu et al. (2022)	<i>The Impact of Economic Uncertainty Caused by COVID-19 on Renewable Energy Stocks</i>	AR-GARCH dan Regresi Kuantil	Kombinasi AR-GARCH untuk memodelkan volatilitas dan CoVaR regresi kuantil untuk mengukur risiko sistemik memberikan gambaran risiko yang komprehensif. Pendekatan regresi kuantil untuk estimasi CoVaR menggambarkan hubungan antara <i>return</i> pasar energi dan pasar global secara lebih realistis dibandingkan model linier biasa.
(Castoe, 2020)	<i>Predicting Stock Market Price Direction with Uncertainty Using Quantile Regression Forest</i>	<i>Random Forest</i> dan <i>Quantile Regression Forest</i>	Penelitian berfokus pada prediksi arah harga saham AAPL (30, 60, 90 hari ke depan) asil penelitian menunjukkan bahwa <i>Random Forest</i> akurat memprediksi harga saham lebih dari 90% dan <i>Quantile Regression Forest</i> menghasilkan <i>error</i> yang kecil, dengan nilai MAPE 0,03% dan 0,05%.

Penelitian sebelumnya yang mengukur risiko sistemik saham di Indonesia masih memiliki keterbatasan signifikan pada metode dan cakupan sektor. Purwanto (2025) serta Ardhini & Prastyo (2024) menerapkan QRF dan ARMA-GARCH, tetapi tanpa seleksi variabel sistematis dan hanya terbatas pada sektor perbankan serta ritel. Liu et al. (2022) menggunakan regresi kuantil linier yang lemah menangkap nonlinieritas dan interaksi kompleks pada kondisi ekstrem. Castillo-Mateo et al. (2023) menerapkan SSVS di luar konteks keuangan sehingga belum ada adaptasi untuk risiko pasar modal. Serta Castoe (2020) hanya memakai QRF untuk prediksi harga saham, bukan pengukuran kontribusi risiko sistemik.

Terlihat bahwa belum ada penelitian yang secara menyeluruh mengintegrasikan pemodelan volatilitas dinamis, teknik *machine learning* non-parametrik, serta seleksi variabel berbasis Bayesian dalam satu kerangka kerja untuk menganalisis risiko sistemik, khususnya di sektor industri. Oleh karena itu, penelitian ini bertujuan untuk mengatasi keterbatasan metodologis tersebut melalui pendekatan yang menggabungkan model AR-GARCH untuk estimasi *Value-at-Risk* (VaR) pada tingkat individu emiten, *Quantile Regression Forest* untuk estimasi *Conditional Value-at-Risk* (CoVaR) yang lebih baik dalam menangkap ketergantungan ekor dan hubungan nonlinier, serta penerapan *Stochastic Search Variable Selection* (SSVS) untuk memilih variabel prediktor yang benar-benar berpengaruh secara signifikan pada risiko sistemik sektor industri. Kombinasi ini diharapkan tidak hanya meningkatkan ketepatan estimasi risiko sistemik, melainkan juga menghasilkan model yang lebih interpretatif dan *parsimonious*.

2.2 Statistika Deskriptif

Karakteristik suatu data dapat dianalisis dengan menggunakan statistika deskriptif. Statistika deskriptif merupakan metode-metode yang bertujuan untuk merangkum dan menyajikan informasi yang terkandung di dalam data agar lebih mudah dipahami. Adapun statistika deskriptif dibagi menjadi dua, yaitu ukuran pemusatan data dan penyebaran data (Walpole et al., 2012). Salah satu ukuran pemusatan data adalah *mean*. Rata-rata suatu kelompok acak dengan sampel sebanyak n dapat dihitung rata-ratanya menggunakan persamaan (2.1) berikut.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2.1)$$

dengan,

$\bar{x}$ = nilai rata-rata

x_i = nilai sampel ke- i

n = jumlah sampel

Adapun salah satu ukuran penyebaran data adalah varians. Varians merupakan jumlah kuadrat semua deviasi nilai-nilai individu terhadap rata-rata (*mean*) kelompok. Varians merupakan teknik statistik yang digunakan untuk menjelaskan homogenitas kelompok. Nilai varians didapatkan dengan menggunakan persamaan (2.2).

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1} \quad (2.2)$$

dengan s^2 menunjukkan nilai varians. Dari nilai varians ini, dapat digunakan untuk menghitung nilai simpangan baku (standar deviasi) yang merupakan akar kuadrat dari varians. Nilai dari simpangan baku dapat digunakan untuk menghitung ukuran kemiringan (*skewness*). Skewness merupakan ukuran kemiringan atau kecondongan distribusi yang menggambarkan derajat ketidaksimetrisan distribusi data. Nilai *mean*, *modus*, dan median yang tidak seimbang dalam suatu distribusi menyebabkan bentuk kurva tidak simetris (Schmoch, 2020).

Distribusi dikatakan menceng ke kanan apabila kurvanya memiliki ekor yang lebih panjang di bagian kanan. Kondisi ini ditandai dengan nilai rata-rata yang lebih besar dibandingkan modus atau median, sehingga disebut memiliki kemencengan positif. Sebaliknya, apabila kurva

distribusi memiliki ekor yang lebih panjang di sisi kiri, maka distribusi tersebut menceng ke kiri, ditandai dengan rata-rata yang lebih kecil daripada modus atau median, dan disebut memiliki kemencengan negatif (Hippel, 2005). Nilai *skewness* dapat dihitung menggunakan persamaan (2.3)

$$S_k = \frac{\bar{x} - M_0}{s} \text{ atau } S_k = \frac{3(\bar{x} - M_d)}{s} \quad (2.3)$$

dengan,

S_k = nilai *skewness*

s = standar deviasi

M_0 = nilai modus

M_d = nilai median

Pada suatu model, distribusi dapat dilihat juga dari ukuran keruncingannya (kurtosis). Kurtosis merupakan derajat keruncingan atau ketinggian maksimum suatu distribusi dibandingkan dengan distribusi normal. Apabila nilai kurtosis lebih kecil dari 3, distribusi disebut *platykurtic*, yang memiliki puncak lebih datar dengan ekor distribusi yang lebih tipis. Sebaliknya, apabila nilai kurtosis lebih besar dari 3, distribusi disebut *leptokurtic*, yaitu ditandai dengan puncak yang lebih runcing dan ekor distribusi yang lebih tebal (Gujarati & Porter, 2009). Nilai kurtosis dapat dihitung menggunakan persamaan (2.4)

$$\hat{\alpha}^4 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}{s^4} \quad (2.4)$$

2.3 Return Saham

Return merupakan ukuran imbal hasil yang diterima investor selama periode kepemilikan. *Return* saham didefinisikan sebagai peningkatan nilai suatu investasi dalam periode tertentu dibandingkan dengan nilai awal investasi, yang sering disebut *holding period*. Peningkatan nilai atau keuntungan pada *return* saham ini mencakup *capital gain* atau *loss* serta dividen yang diterima (Bodie et al., 2014).

Ukuran *return* yang paling umum adalah *holding period return* (HPR), yaitu perubahan nilai investasi yang mencakup perubahan harga dan pendapatan yang diterima. *Return* ini dihitung sebagai proporsi dari nilai investasi awal, sehingga dapat menunjukkan tingkat keuntungan relatif dari suatu investasi (Biktimirov et al., 2003). Nilai *return* saham dapat dihitung menggunakan *simple return* pada persamaan (2.5).

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} \quad (2.5)$$

dimana,

R_t : *Return* pada waktu t

P_t : Harga penutupan saham pada waktu t

P_{t-1} : Harga penutupan saham pada waktu $t - 1$

2.4 Risiko Sistemik

Risiko sistemik adalah kondisi dimana sistem keuangan berisiko mengalami kegagalan akibat adanya keterkaitan (*interconnected*) antar entitas atau instrumen keuangan. Risiko ini tidak hanya berdampak pada kegagalan satu entitas, tetapi juga dapat menular (*contagion*) ke entitas lain dan memicu dampak berantai terhadap pasar secara keseluruhan (Feinstein et al., 2016).

Secara umum ada tiga faktor utama dalam menganalisis risiko sistemik, yaitu *interconnectedness*, korelasi, dan *contagion*. *Interconnectedness* mengacu pada hubungan sebab-akibat berbagai elemen dalam suatu sistem, korelasi menekankan adanya gerakan bersama (*co-movement*) yang dapat memberikan pengaruh satu sama lain, serta *contagion* yang menekankan gangguan dalam suatu sistem dapat menyebar ke seluruh sistem dengan adanya keterkaitan dan korelasi. Semakin kompleks dan terhubung suatu sistem keuangan dengan sistem keuangan yang lain, maka semakin besar juga kemungkinan terjadinya *domino effect* ketika salah satu komponen mengalami *distress* (Dastkhan, 2024).

Dalam konteks pasar saham, risiko sistemik terjadi saat ada gangguan fluktuasi harga pada saham atau subsektor tertentu menyebar ke saham lain, bahkan hingga ke seluruh pasar. Pengukuran risiko sistemik pada saham memerlukan fokus kepada distribusi kerugian ekstrem (*tail risk*) karena dapat memicu kerugian besar pada portofolio atau indeks pasar (Feinstein et al., 2016).

Salah satu metode yang digunakan untuk menilai risiko sistemik adalah *Conditional Value-at-Risk* (CoVar). Berbeda dengan VaR yang mengevaluasi risiko secara individu, CoVar menilai kerugian prospektif yang ditimbulkan oleh sistem keuangan secara keseluruhan tergantung pada adanya tekanan dalam entitas tertentu. CoVar memiliki kemampuan untuk menggambarkan sejauh mana risiko yang terkait dengan saham atau entitas tertentu berkontribusi pada stabilitas pasar yang lebih luas (Adrian & Brunnermeier, 2016).

2.5 Analisis Deret Waktu

Deret waktu atau *time series* merupakan pengamatan satu atau lebih variabel yang diambil secara berurutan terhadap interval waktu yang tetap. Variabel random pada setiap pengamatannya dinyatakan sebagai y_t yang diperoleh berdasarkan indeks waktu tertentu t_i dengan $i = 1, 2, \dots, n$. Sehingga data *time series* dapat dituliskan sebagai $y_{1,t}, y_{2,t}, \dots, y_{n,t}$ (Wei, 2006).

Pada dasarnya analisis deret waktu digunakan untuk mempertimbangkan pengaruh pengamatan periode sebelumnya dimana data-data yang dikumpulkan menurut urutan waktu (harian, mingguan, bulanan, serta tahunan). Analisis deret waktu secara umum bertujuan untuk mengetahui pola data deret waktu (*time series*) menggunakan data masa lalu guna meramalkan data periode yang akan datang (Cryer & Chan, 2008).

2.5.1 Stasioneritas Data

Data dapat dikatakan stasioner jika tidak terdapat perubahan yang signifikan pada data. Pada data *time series*, stasioneritas dibagi menjadi dua, yaitu stasioner dalam *mean* dan varians. Stasioner dalam *mean* adalah kondisi ketika fluktuasi data berada di sekitar nilai rata-rata tetap, tidak bergantung pada waktu dan variansi dari data. Sedangkan stasioner dalam varians adalah kondisi ketika data mengalami fluktuasi yang tetap dari waktu ke waktu. Uji yang digunakan untuk menguji kestasioneran data dalam *mean* adalah *Augmented Dickey Fuller* (ADF) test (Gujarati & Porter, 2009).

Uji ADF ini mengikuti estimasi regresi yang ditunjukkan pada persamaan (2.6).

$$\Delta y_t = \beta_1 + \beta_2 t + \delta y_{t-1} + \sum_{j=1}^p \alpha_j \Delta y_{t-j} + \varepsilon_t \quad (2.6)$$

Adapun hipotesis yang digunakan untuk uji ADF adalah sebagai berikut.

$H_0 : \delta = 0$ (data tidak stasioner)

$H_1 : \delta < 0$ (data stasioner)

Statistik uji:

$$T = \frac{\hat{\delta}}{SE(\hat{\delta})} \quad (2.7)$$

dengan $\hat{\delta}$ merupakan estimasi *least square* dari δ . Didapatkan keputusan tolak H_0 apabila T lebih besar dari titik kritis T^* pada tabel *Dickey Fuller*, yang artinya data sudah stasioner dalam *mean*. Jika hasil uji ADF menunjukkan bahwa data tidak stasioner dalam *mean* maka dilakukan *differencing* antara data waktu ke- t (y_t) dengan data pengamatan pada waktu sebelumnya (y_{t-1}).

Data dikatakan stasioner dalam varians ketika parameter transformasi *Box-Cox* telah melewati angka satu. Transformasi *Box-Cox* digunakan ketika data *time series* tidak stasioner dalam varians, yaitu dengan cara memodifikasi bentuk distribusi dari data sehingga data menjadi lebih normal dan dapat stasioner dalam varians (Wei, 2006). Persamaan umum transformasi *Box-Cox* ditunjukkan pada persamaan (2.8).

$$T(y_t) = \frac{(y_t^\lambda - 1)}{\lambda} \quad (2.8)$$

dimana λ merupakan parameter transformasi ($\lambda \neq 0$).

Namun, tidak semua kasus ketidakstasioneritasan dalam varians dapat diatasi dengan transformasi *Box-Cox*. Pada penelitian yang dilakukan oleh Nwakuya & Nwabueze (2018) menyatakan bahwa transformasi *Box-Cox* hanya dapat diterapkan pada data bernilai positif, sedangkan data *return* saham cenderung bernilai negatif, positif, hingga nol. *Return* saham juga menunjukkan karakteristik *clustering volatility* dan heteroskedastisitas bersyarat, di mana periode volatilitas tinggi cenderung diikuti oleh volatilitas tinggi dan sebaliknya. Untuk mengatasi hal ini, dapat menggunakan model ARCH/GARCH yang lebih efektif dalam menangkap *clustering volatility* dan heteroskedastisitas yang terdapat pada data *return* saham (Engle, 2001).

2.6 Model Autoregressive (AR)

Pada penelitian ini nilai VaR akan diestimasi menggunakan pendekatan model AR-GARCH. *Autoregressive – Generalized Autoregressive Conditional Heteroscedastisity* (AR-GARCH) merupakan salah satu pendekatan yang banyak digunakan dalam analisis data keuangan untuk menjelaskan karakteristik volatilitas *return* yang berubah-ubah dari waktu ke waktu. Konsep dasarnya berasal dari adanya heteroskedastisitas, yakni kondisi di mana varians *residual* pada suatu periode dipengaruhi oleh varians *residual* pada periode sebelumnya (Bollerslev, 1986).

Model AR-GARCH terdiri atas dua model utama, yaitu *Autoregressive* (AR) yang menjelaskan ketergantungan nilai saat ini terhadap nilai masa lalu pada sisi rata-rata (*mean equation*), dan GARCH yang memodelkan variansi *residual* secara dinamis melalui variansi kondisional. Kombinasi dari keduanya memungkinkan model menangkap fenomena *clustering volatility*, yaitu kecenderungan periode volatilitas tinggi diikuti oleh periode tinggi lainnya seperti yang seringkali ditemui pada data *return* saham sektor keuangan (Tsay, 2010).

Model *Autoregressive* (AR) menggambarkan kondisi y_t yang dipengaruhi oleh kondisi-kondisi sebelumnya ($y_{t-1}, y_{t-2}, \dots, y_{t-p}$) serta diikuti a_t yang sifatnya *White Noise* (Wei, 2006). Persamaan umum dari AR dengan orde p yang dinotasikan dengan AR (p) ditunjukkan pada persamaan (2.9).

$$y_t = \mu + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + a_t \quad (2.9)$$

dimana, μ merupakan rata-rata jangka panjang (*equilibrium mean*) dari proses *autoregressive* yang didapatkan dari $\mu = 1/(1 - \phi_1 - \phi_2 - \dots - \phi_p)$. Adapun ϕ merupakan parameter autoregresif dan a_t merupakan *residual* (*error term*) pada waktu ke- t .

2.6.1 Identifikasi Model AR

Identifikasi model *Autoregressive* (AR) dapat dilakukan melalui pengamatan pola pada plot *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). ACF digunakan untuk mendeteksi korelasi antara y_t dan y_{t-k} , yang dinyatakan sebagai ρ_k , dimana k adalah lag waktu. Rumus ACF diberikan sebagai berikut (2.10).

$$\rho_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (2.10)$$

di mana $\bar{y} = \frac{1}{n} \sum_{t=1}^n y_t$.

Adapun PACF digunakan untuk mengukur korelasi langsung antara y_t dan y_{t-k} , setelah menghilangkan pengaruh variabel *intervening* pada lag ($y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$). Fungsi PACF dinotasikan sebagai ϕ_k dengan rumus yang ditunjukkan pada persamaan (2.11)

$$\phi_k = \frac{\text{Cov}[(y_t - \hat{y}_t), (y_{t-k} - \hat{y}_{t-k})]}{\sqrt{\text{Var}(y_t - \hat{y}_t)} \sqrt{\text{Var}(y_{t-k} - \hat{y}_{t-k})}} \quad (2.11)$$

Identifikasi model AR dilakukan dengan melihat kondisi lag pada plot ACF dan PACF. Untuk model AR (p), ACF menunjukkan pola *dies down* secara bertahap, sedangkan PACF mengalami *cut off* setelah lag ke- p (Wei, 2006).

2.6.2 Estimasi Parameter AR

Setelah identifikasi model AR sementara, tahap selanjutnya adalah estimasi parameter model. Metode yang paling umum digunakan untuk mengestimasi parameter model AR adalah *Maximum Likelihood Estimation* (MLE). Jika terdapat model AR (p) yang disebutkan pada persamaan (2.9) maka fungsi kepadatan peluang gabungan dari $\mathbf{a} = (a_1, a_2, \dots, a_n)^T$ dapat dituliskan seperti pada persamaan (2.12).

$$P(\mathbf{a} | \boldsymbol{\phi}, \mu, \sigma_a^2) = (2\pi\sigma_a^2)^{-\frac{n}{2}} \exp \left[-\frac{1}{2\sigma_a^2} \sum_{t=1}^n a_t^2 \right] \quad (2.12)$$

dimana $a_t = y_t - \mu - \phi_1 y_{t-1} - \phi_2 y_{t-2} - \dots - \phi_p y_{t-p}$.

Diberikan $\mathbf{y} = (y_1, y_2, \dots, y_n)'$ dan vektor $\mathbf{y}_* = (y_{1-p}, y_{2-p}, \dots, y_{-1}, y_0)'$ dan $\mathbf{a}_* = (a_{1-p}, a_{2-p}, \dots, a_{-1}, a_0)'$ sebagai *initial condition*. Sehingga fungsi *conditional ln likelihood* ditunjukkan seperti pada persamaan (2.13).

$$\ln L_*(\boldsymbol{\phi}, \mu, \sigma_a^2) = -\frac{n}{2} \ln(2\pi\sigma_a^2) - \frac{S_*(\boldsymbol{\phi}, \mu)}{2\sigma_a^2} \quad (2.13)$$

Hasil estimasi MLE dengan parameter $\boldsymbol{\phi}$ dan μ dengan $\boldsymbol{\phi} = (\phi_1, \phi_2, \dots, \phi_p)'$ diperoleh dengan cara meminimalkan *residual sum of squares* (S_*). Persamaan *residual sum of square* ditunjukkan pada persamaan (2.14).

$$S_*(\boldsymbol{\phi}, \mu) = \sum_{t=p+1}^n (y_t - \mu - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p})^2 \quad (2.14)$$

Persamaan (2.14) digunakan untuk mencari turunan parsial pertama masing-masing parameter sebagai berikut.

$$\frac{\partial S_*}{\partial \mu} = -2 \sum_{t=p+1}^n (y_t - \mu - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p}) = 0 \quad (2.15)$$

kemudian dari persamaan (2.15) akan diperoleh estimator rata-ratanya sebagai berikut.

$$\hat{\mu} = \frac{1}{n-p} \sum_{t=p+1}^n (y_t - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p}) \quad (2.16)$$

Selanjutnya turunan parsial terhadap $\boldsymbol{\phi}$:

$$\frac{\partial S_*}{\partial \phi_i} = -2 \sum_{t=p+1}^n (y_t - \mu - \phi_1 y_{t-1} - \dots - \phi_p y_{t-p}) y_{t-p} = 0 \quad (2.17)$$

dari persamaan (2.17) diperoleh persamaan untuk setiap lag i :

untuk $i = 1$:

$$\sum_{t=p+1}^n y_{t-1} (y_t - \hat{\mu}) = \phi_1 \sum_{t=p+1}^n y_{t-1}^2 + \phi_2 \sum_{t=p+1}^n y_{t-1} y_{t-2} + \dots + \phi_p \sum_{t=p+1}^n y_{t-1} y_{t-p} \quad (2.18a)$$

untuk $i = 2$:

$$\sum_{t=p+1}^n y_{t-2} (y_t - \hat{\mu}) = \phi_1 \sum_{t=p+1}^n y_{t-2} y_{t-1} + \phi_2 \sum_{t=p+1}^n y_{t-2}^2 + \dots + \phi_p \sum_{t=p+1}^n y_{t-2} y_{t-p} \quad (2.18b)$$

untuk $i = p$:

$$\sum_{t=p+1}^n y_{t-p} (y_t - \hat{\mu}) = \phi_1 \sum_{t=p+1}^n y_{t-p} y_{t-1} + \phi_2 \sum_{t=p+1}^n y_{t-p} y_{t-2} + \dots + \phi_p \sum_{t=p+1}^n y_{t-p}^2 \quad (2.18c)$$

Persamaan tiap lag dapat dibentuk menjadi matriks $\mathbf{y}$ dan $\mathbf{Y}$ untuk estimasi parameter *autoregressive* berikut.

$$\mathbf{y} = \begin{bmatrix} y_{p+1} - \hat{\mu} \\ y_{p+2} - \hat{\mu} \\ \vdots \\ y_n - \hat{\mu} \end{bmatrix}, \mathbf{Y} = \begin{bmatrix} y_p & y_{p-1} & \cdots & y_1 \\ y_{p+1} & y_p & \cdots & y_2 \\ \vdots & \vdots & \ddots & \vdots \\ y_{n-1} & y_{n-2} & \cdots & y_{n-p} \end{bmatrix} \quad (2.19)$$

di mana $p + 1 = t$, diperoleh bentuk matriks $\mathbf{Y}'\mathbf{Y}$:

$$\mathbf{Y}'\mathbf{Y} = \begin{bmatrix} \sum_{t=p+1}^n y_{t-1}^2 & \sum_{t=p+1}^n y_{t-1} y_{t-2} & \cdots & \sum_{t=p+1}^n y_{t-1} y_{t-p} \\ \sum_{t=p+1}^n y_{t-2} y_{t-1} & \sum_{t=p+1}^n y_{t-2}^2 & \cdots & \sum_{t=p+1}^n y_{t-2} y_{t-p} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{t=p+1}^n y_{t-p} y_{t-1} & \sum_{t=p+1}^n y_{t-p} y_{t-2} & \cdots & \sum_{t=p+1}^n y_{t-p}^2 \end{bmatrix} \quad (2.20)$$

dan matriks $\mathbf{Y}'\mathbf{y}$:

$$\mathbf{Y}'\mathbf{y} = \begin{bmatrix} \sum_{t=p+1}^n y_{t-1} (y_t - \hat{\mu}) \\ \sum_{t=p+1}^n y_{t-2} (y_t - \hat{\mu}) \\ \vdots \\ \sum_{t=p+1}^n y_{t-p} (y_t - \hat{\mu}) \end{bmatrix} \quad (2.21)$$

Sehingga estimator untuk $\boldsymbol{\phi}$ dapat diperoleh dengan persamaan (2.22)

$$\hat{\boldsymbol{\phi}} = \begin{bmatrix} \hat{\phi}_1 \\ \hat{\phi}_2 \\ \vdots \\ \hat{\phi}_p \end{bmatrix} = (\mathbf{Y}'\mathbf{Y})^{-1} \mathbf{Y}'\mathbf{y} \quad (2.22)$$

Adapun untuk estimasi varians *error* $\hat{\sigma}_a^2$ dapat dihitung dengan menurunkan fungsi *conditional ln likelihood* terhadap σ_a^2 berikut.

$$\frac{\partial \ln L_*}{\partial \sigma_a^2} = -\frac{n}{2\sigma_a^2} + \frac{S_*(\hat{\boldsymbol{\phi}}, \hat{\mu})}{2\sigma_a^4} = 0 \quad (2.23)$$

Sehingga *unbiased* estimator untuk varians *error* $\hat{\sigma}_a^2$ dapat dihitung menggunakan persamaan (2.24).

$$\hat{\sigma}_a^2 = \frac{S_*(\hat{\boldsymbol{\phi}}, \hat{\mu})}{df} \quad (2.24)$$

dengan $df = n - p$ merupakan derajat bebas (*degree of freedom*). Setelah mendapatkan nilai estimasi parameter dari persamaan model AR (p), dilanjutkan dengan menguji signifikansi parameter.

2.6.3 Uji Signifikansi Parameter AR

Pengujian signifikansi parameter dilakukan untuk menentukan apakah parameter model sudah sesuai dan layak untuk masuk ke dalam model atau sebaliknya. Hipotesis yang digunakan dalam pengujian signifikansi pada model AR (p) adalah sebagai berikut.

$H_0 : \phi_i = 0$ (parameter AR tidak signifikan), $i = 1, 2, \dots, p$

$H_1 : \phi_i \neq 0$ (parameter AR signifikan)

dengan statistik uji:

$$t_{hitung} = \frac{\hat{\phi}_i}{SE(\hat{\phi}_i)} \quad (2.25)$$

Keputusan tolak H_0 jika $|t_{hitung}| > t_{\frac{\alpha}{2}, n-p-1}$ atau $p - value < \alpha$, yang artinya parameter model AR (p) telah signifikan (Montgomery et al., 2012).

2.6.4 Uji Ljung-Box

Dalam memilih model AR terbaik perlu dilakukan pengecekan guna mengetahui apakah model tersebut telah memenuhi asumsi untuk *residual*nya. Pada penelitian ini model AR harus memenuhi asumsi *White Noise*. Pengujian asumsi *White Noise* dilakukan dengan menggunakan uji *Ljung-Box* dengan hipotesis berikut (Wei, 2006).

$H_0 : \rho_1 = \rho_2 = \dots = \rho_k = 0$ (*residual* memenuhi asumsi *White Noise*)

$H_1 : \text{minimal ada satu } \rho_k \neq 0$ (*residual* tidak memenuhi asumsi *White Noise*), $k = 1, 2, \dots, K$

dengan statistik uji:

$$LB = n(n+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2}{n-k} \quad (2.26)$$

dimana $\hat{\rho}_k^2$ merupakan nilai taksiran autokorelasi *residual* lag ke- k . Keputusan akan tolak H_0 jika $LB > \chi_{\alpha, K-p}^2$ atau $p - value < \alpha$, yang artinya *residual* tidak bersifat *White Noise*.

2.6.5 Pemilihan Model Terbaik

Dalam pemilihan model AR terbaik terdapat beberapa kriteria yang dapat digunakan, salah satunya adalah AIC (*Akaike's Information Criterion*). AIC merupakan kriteria pemilihan model terbaik yang mempertimbangkan banyaknya parameter dalam model. Semakin kecil nilai AIC yang dihasilkan, maka kemungkinan suatu model untuk dipilih semakin besar (Wei, 2006). Nilai AIC dapat dihitung menggunakan persamaan (2.27).

$$AIC(\psi) = n \ln \hat{\sigma}_a^2 + 2\psi \quad (2.27)$$

dengan ψ menunjukkan banyaknya parameter dalam model AR. $\hat{\sigma}_a^2$ merupakan nilai estimasi maksimum *likelihood* dari varians *residual* dan n menunjukkan banyaknya observasi.

2.7 Model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH)

Model GARCH merupakan hasil pengembangan dari model *Autoregressive Conditional Heteroscedasticity* (ARCH) yang diperkenalkan pertama kali oleh Engle pada tahun 1982 dan disempurnakan oleh Bollerslev pada tahun 1986. Model ARCH digunakan untuk mengatasi kasus heteroskedastisitas pada *residual* karena terjadi volatilitas yang tinggi (Engle, 2001). Pada kasus heteroskedastisitas, model regresi ditunjukkan pada persamaan (2.28).

$$y_t = \mu_t + a_t \quad (2.28)$$

dengan μ_t merupakan *conditional mean* dan a_t merupakan *residual* yang variansinya tidak tetap. Sehingga a_t dapat dimodelkan dengan model ARCH untuk menangkap heteroskedastisitas pada *residual* seperti pada persamaan (2.29).

$$a_t = \sigma_t z_t, \quad z_t \sim sstd(0, 1, \xi, v) \quad (2.29)$$

Dimana σ_t merupakan varians kondisional pada waktu t dan z_t merupakan inovasi yang sifatnya *independent* dan *identically distributed* (i.i.d.) dengan *mean* nol dan varians satu. Pada penelitian ini, z_t diasumsikan mengikuti distribusi *Skewed Student-t* (sstd) yang memiliki rata-rata nol dan varians satu, dengan ξ merupakan parameter *skewness* dan v adalah parameter *degree of freedom*. Penggunaan distribusi sstd ini memungkinkan model menangkap karakteristik data yang sering muncul pada data empiris, khususnya pada bentuk asimetri distribusi dan *heavy tails*, sehingga dapat memberikan representasi yang lebih sesuai dibandingkan asumsi normal standar. Adapun persamaan umum model ARCH (m) dituliskan pada persamaan (2.30)

$$\sigma_t^2 = \omega + \sum_{i=1}^m \alpha_i a_{t-i}^2 \quad (2.30)$$

dengan $\omega > 0, \alpha_i \geq 0$ dan $i = 1, 2, \dots, m$.

Untuk menghindari orde besar pada model ARCH, digunakan model generalisasinya, yaitu model GARCH (Bollerslev, 1986). Bentuk umum dari model GARCH (m, s) ditunjukkan pada persamaan (2.31).

$$\sigma_t^2 = \omega + \sum_{i=1}^m \alpha_i a_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2 \quad (2.31)$$

dengan $\omega > 0, \alpha_i \geq 0, \beta_j \geq 0$ dan $i = 1, 2, \dots, m; j = 1, 2, \dots, s$.

2.7.1 Uji *Lagrange Multiplier* (LM)

Sebelum mengestimasi model GARCH untuk menangkap volatilitas pada data *return*, dilakukan pengujian untuk mendeteksi adanya heteroskedastisitas kondisional atau efek ARCH/GARCH pada *residual* (a_t) dari model *mean*. Metode yang digunakan untuk mendeteksi efek ARCH/GARCH ini adalah *Lagrange Multiplier* (LM). Pengujian dengan *Lagrange Multiplier* (LM) bertujuan untuk menentukan apakah terdapat autokorelasi pada kuadrat *residual* a_t^2 dan menguji apakah varians *residual* bersifat konstan atau dinamis (Engle, 1982).

Hipotesis yang digunakan dalam pengujian ini adalah sebagai berikut.

$H_0 : \alpha_1 = \alpha_2 = \dots = \alpha_r = 0$ (tidak terdapat efek ARCH-GARCH)

$H_1 : \text{minimal ada satu } \alpha_i \neq 0, i = 1, 2, \dots, r$ (terdapat efek ARCH-GARCH)

dengan statistik uji:

$$LM = (n - r)R^2 \quad (2.32)$$

di mana R^2 merupakan koefisien determinasi dari regresi kuadrat *residual*. Keputusan tolak H_0 jika nilai $LM > \chi^2_{\alpha, r}$ yang artinya terdapat efek ARCH-GARCH pada model atau bersifat heteroskedastisitas, sehingga perlu dilanjutkan pemodelan dengan model GARCH dalam memodelkan heteroskedastisitas akibat volatilitas pada data.

2.7.2 Estimasi Parameter Model GARCH

Setelah model GARCH (m, s) telah teridentifikasi dan didapatkan beberapa kemungkinan orde model, tahap selanjutnya adalah estimasi parameter untuk model GARCH. Estimasi parameter ini dilakukan menggunakan metode *Maximum Likelihood Estimation* (MLE) dengan memaksimumkan *conditional likelihood*, yaitu fungsi yang mengukur seberapa besar kemungkinan parameter θ menghasilkan data yang diamati, di mana pada penelitian ini diasumsikan mengikuti distribusi *standardized skewed Student-t* (ssstd). Asumsi distribusi ssstd digunakan dengan tujuan untuk mengakomodasi karakteristik data *return* keuangan yang umumnya bersifat *fat tails* dan memiliki distribusi yang tidak simetris (*skewed*). Fungsi *log conditional likelihood* untuk model GARCH dapat dinyatakan sebagai berikut (Lambert & Laurent, 2001).

$$\begin{aligned} \ln L(\theta | \mathbf{Z}) = & n \ln \left[\Gamma \left(\frac{v+1}{2} \right) \right] - n \ln \left[\Gamma \left(\frac{v}{2} \right) \right] - \frac{n}{2} \ln [\pi(v-2)] + n \ln \left[\frac{2}{\xi + \xi^{-1}} \right] + n \ln(s) \\ & - \frac{1}{2} \sum_{t=1}^n \left[\ln \sigma_t^2 + (1+v) \ln \left(1 + \frac{(sz_t + m)^2}{v-2} \xi^{-2I_t} \right) \right] \end{aligned} \quad (2.33)$$

dengan

$$I_t = \begin{cases} -1, & \text{jika } z_t < -\frac{m}{s} \\ 1, & \text{jika } z_t \geq -\frac{m}{s} \end{cases} \quad (2.34)$$

di mana $\mathbf{Z} = (z_1, z_2, \dots, z_n)$, z_t merupakan residual terstandarisasi periode ke- t , σ_t^2 varians bersyarat periode ke- t , ξ parameter *skewness*, v parameter derajat bebas, serta m dan s menyatakan nilai *mean* dan standar deviasi. Dengan pendekatan ini, parameter model GARCH diperoleh dengan cara memaksimumkan fungsi *standardized skewed Student-t* (ssstd) berdasarkan nilai residual. Karena fungsi *log-likelihood* distribusi ssstd tidak memiliki solusi analitik (*closed-form*), estimasi parameter ini kemudian dilakukan dengan prosedur optimasi numerik secara iteratif. Sebagai contoh, jika vektor parameter model GARCH(1,1) didefinisikan pada persamaan (2.35).

$$\theta = \begin{bmatrix} \omega \\ \alpha \\ \beta \\ \xi \\ v \end{bmatrix} \quad (2.35)$$

Estimator MLE dari parameter-parameter tersebut bersifat asimtotik normal, yang berarti bahwa ketika jumlah pengamatan cukup besar, hasil estimasi parameter akan mendekati nilai parameter sebenarnya dan mengikuti distribusi normal. Varians dan kovarians dari estimator parameter dapat dihimpun ke dalam sebuah matriks kovarians yang dinotasikan dengan Λ . Diagonal matriks Λ menunjukkan varians dari masing-masing estimator parameter, sedangkan elemen di luar diagonal menunjukkan kovarians antar estimator parameter. Matriks kovarians tersebut dapat didekati menggunakan *invers* matriks Hessian yang diperoleh dari turunan kedua fungsi *log-likelihood* terhadap parameter model. Namun, karena bentuk fungsi *log-likelihood* distribusi *standardized skewed Student-t* cukup kompleks, proses estimasi parameter dilakukan secara numerik hingga diperoleh nilai parameter yang memaksimumkan fungsi *log-likelihood*. Sehingga diperoleh estimator parameter model GARCH yang paling sesuai dalam merepresentasikan volatilitas data.

2.7.3 Uji Signifikansi Parameter Model GARCH

Selanjutnya dilanjutkan dengan uji signifikansi parameter GARCH (m,s) secara parsial. Berikut merupakan hipotesis yang digunakan untuk menguji signifikansi parameter α pada model ARCH (m) bagian dari GARCH.

$H_0 : \alpha_i = 0$ (parameter ARCH tidak signifikan), $i = 1, 2, \dots, m$

$H_1 : \alpha_i \neq 0$ (parameter ARCH signifikan)

Statistik uji:

$$t_{hitung} = \frac{\hat{\alpha}_i}{SE(\hat{\alpha}_i)} \quad (2.36)$$

diperoleh keputusan Tolak H_0 jika $|t_{hitung}| > t_{(\alpha/2, n_m)}$, di mana n_m merupakan banyak parameter model ARCH yang ditaksir.

Kemudian untuk menguji signifikansi parameter β pada model, hipotesis yang digunakan adalah sebagai berikut.

$H_0 : \beta_j = 0$ (parameter GARCH tidak signifikan), $j = 1, 2, \dots, s$

$H_1 : \beta_j \neq 0$ (parameter GARCH signifikan)

Statistik uji:

$$t_{hitung} = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \quad (2.37)$$

diperoleh keputusan Tolak H_0 jika $|t_{hitung}| > t_{(\alpha/2, n_s)}$, di mana n_s merupakan banyak parameter model GARCH yang ditaksir.

2.8 Skewed Student-t Distribution

Dalam analisis deret waktu, terutama pada model yang erat kaitannya dengan volatilitas seperti model GARCH, asumsi distribusi untuk residual yang terstandarisasi menjadi hal krusial. Hal ini disebabkan karena pada umumnya, data empiris sering memperlihatkan pola ekor tebal (*fat tails*) dan distribusi yang tidak simetris (*skewness*). Distribusi normal standar dinilai kurang mampu menangkap karakteristik tersebut. Oleh karena itu, digunakan distribusi *Skewed*

Student-t yang merupakan perluasan dari distribusi *Student-t* dengan kemampuannya yang dapat menangkap fenomena ekor tebal dan *skewness* distribusi (Lambert & Laurent, 2002).

2.8.1 *Student-t Distribution*

Student-t Distribution merupakan perluasan dari distribusi normal yang dirancang secara khusus untuk menangkap fenomena ekor tebal distribusi yang sering ditemukan pada data finansial. Distribusi *student-t* memiliki parameter derajat kebebasan v yang memiliki fungsi sebagai pengontrol ketebalan ekor distribusi. Semakin kecil nilai v , maka semakin tebal juga ekor distribusinya. Penerapan *Student-t distribution* pada model GARCH diperkenalkan pertama kali oleh Bollerslev (1986) untuk mengatasi keterbatasan asumsi normalitas.

Jika diberikan variabel random Y berdistribusi *Student-t* (μ, σ^2, v), maka fungsi kepadatan probabilitas (*probability density function*) dapat dituliskan sebagai berikut.

$$g_v(y|\mu, \sigma^2) = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{\pi(v-2)}\Gamma\left(\frac{v}{2}\right)\sigma} \left[1 + \frac{1}{v-2}\left(\frac{y-\mu}{\sigma}\right)^2\right]^{-\frac{v+1}{2}} \quad (2.38)$$

distribusi ini bersifat simetris, dengan μ dan σ^2 didefinisikan untuk $v > 2$. Ketika $v \rightarrow \infty$, *student-t distribution* akan konvergen menuju distribusi normal standar (Lambert & Laurent, 2002).

2.8.2 *Skewed Student-t Distribution*

Data *return* keuangan biasanya menunjukkan karakteristik asimetris (*skewness*) pada distribusinya, sedangkan distribusi *Student-t* bersifat simetris. Untuk menangkap karakteristik tersebut, diperkenalkan pendekatan untuk membentuk distribusi *skewed* dari distribusi simetris melalui *inverse scale transformation* di sisi kiri dan kanan modus distribusi (Fernandez & Steel, 1996). Jika diberikan $g(y)$ yang merupakan pdf distribusi simetris yang unimodal terhadap titik γ (modus), maka pdf dari distribusi *skewed* didefinisikan pada persamaan (2.39).

$$f(y|\gamma, \xi) = \frac{2}{\xi + \xi^{-1}} \begin{cases} g(\xi(y - \gamma)), & \text{jika } y < \gamma \\ g\left(\frac{y - \gamma}{\xi}\right), & \text{jika } y \geq \gamma \end{cases} \quad (2.39)$$

dengan $\xi > 0$ merupakan parameter *skewness*.

Jika $\xi > 1$, maka peluang *skewness* akan condong ke sisi kanan, sedangkan jika $\xi < 1$ maka *skewness* akan condong ke kiri, serta apabila $\xi = 1$ maka distribusi akan kembali menjadi *Student-t distribution* yang simetris (Lambert & Laurent, 2002)

2.8.3 *Standardized Skewed Student-t Distribution*

Konstruksi Fernandez & Steel (1996) memiliki kelemahan pada parameterisasi awal yang dinyatakan terhadap model dan dispersi, bukan langsung terhadap *mean* dan *varians*. Lambert & Laurent (2001) kemudian memodelkan kembali distribusi *skewed Student-t* sehingga proses inovasi z_t memiliki rata-rata nol dan *varians* satu.

Proses inovasi z_t mengikuti distribusi *skewed Student-t* apabila memenuhi syarat berikut.

$$f(z_t|\xi, v) = \begin{cases} \frac{2}{\xi + \xi^{-1}} g[\xi(sz_t + m)|v], & \text{jika } z_t < -\frac{m}{s} \\ \frac{2}{\xi + \xi^{-1}} g\left[\frac{(sz_t + m)}{\xi}|v\right], & \text{jika } z_t \geq -\frac{m}{s} \end{cases} \quad (2.40)$$

dengan $g(\cdot | v)$ merupakan *density Student-t* simetris dan ξ adalah parameter asimetri. Parameter m dan s^2 masing-masing merepresentasikan *mean* dan *varians* dari distribusi *skewed Student-t* yang belum terstandarisasi (Lambert & Laurent, 2001; Mokni et al., 2009).

$$m = m(\xi, v) = \frac{\Gamma\left(\frac{v-1}{2}\right)\sqrt{v-2}}{\sqrt{\pi} \Gamma\left(\frac{v}{2}\right)}\left(\xi - \frac{1}{\xi}\right) \quad (2.41)$$

dan

$$s^2 = s^2(\xi, v) = \left(\xi^2 + \frac{1}{\xi^2} - 1\right) - m^2 \quad (2.42)$$

Fungsi *log-likelihood* dari distribusi *skewed Student-t* terstandarisasi dinyatakan dengan:

$$\begin{aligned} L_{ssda} = n \ln \left[\Gamma\left(\frac{v+1}{2}\right) \right] - n \ln \left[\Gamma\left(\frac{v}{2}\right) \right] - \frac{n}{2} \ln[\pi(v-2)] + n \ln \left[\frac{2}{\xi + \xi^{-1}} \right] + n \ln(s) \\ - \frac{1}{2} \sum_{t=1}^n \left[\ln(\sigma_t^2) + (1+v) \ln \left(1 + \frac{(sz_t + m)^2}{v-2} \xi^{-2I_t} \right) \right] \end{aligned} \quad (2.43)$$

dimana

$$I_t = \begin{cases} -1, & \text{jika } z_t < -\frac{m}{s} \\ 1, & \text{jika } z_t \geq -\frac{m}{s} \end{cases} \quad (2.44)$$

dengan ξ merupakan parameter *skewness* dan v merupakan derajat kebebasan.

2.9 Value-at-Risk (VaR)

Value-at-Risk (VaR) adalah ukuran risiko yang telah lama digunakan dalam manajemen risiko keuangan yang pertama kali diperkenalkan oleh J. P. Morgan pada tahun 1994. VaR merupakan metode pengukuran risiko secara statistik untuk memperkirakan kerugian maksimum (*maximum expected loss*) yang mungkin terjadi atas suatu portofolio pada tingkat kepercayaan (*level of confidence*) tertentu (Trimono et al., 2017). VaR menggabungkan kemampuan prediksi (*exposure limits*) dan pencegahan (*stop-loss limits*) untuk memberikan peringatan mengenai kemungkinan risiko pasar sebelum kerugian finansial yang sebenarnya terjadi (Holton, 2003).

VaR dengan tingkat kepercayaan $(1 - \tau)$ didefinisikan sebagai kuantil ke- τ dari distribusi *return* dengan persamaan untuk nilai VaR didefinisikan pada persamaan (2.45).

$$P(R_t < VaR_t) = (1 - CI)\% = \tau \quad (2.45)$$

dimana R_t merupakan nilai *return* saham pada periode ke- t , τ merupakan tingkat signifikansi untuk VaR (Chan & Wong, 2015). Persamaan (2.44) berarti dengan probabilitas sebesar τ , *return* saham akan berada di bawah VaR_t , yang mana merepresentasikan batas kerugian maksimum yang mungkin terjadi pada tingkat kepercayaan $1 - \tau$.

Nilai VaR dapat dihitung menggunakan persamaan (2.46).

$$VaR_t(\tau) = F^{-1}(\tau) \quad (2.46)$$

dengan F^{-1} merujuk pada *invers* dari fungsi distribusi kumulatif (CDF) untuk distribusi normal standar (0,1).

Menggunakan pendekatan AR-GARCH, perhitungan nilai VaR dengan pada kuantil τ dan periode ke- t ditunjukkan pada persamaan (2.47).

$$\widehat{VaR}_t(\tau) = \hat{\mu}_t + \hat{\sigma}_t F^{-1}(\tau) \quad (2.47)$$

dengan,

$\hat{\mu}_t = \text{mean}$ kondisional dari model AR,

$\hat{\sigma}_t = \text{standar deviasi kondisional dari model GARCH.}$

Pendekatan AR-GARCH ini menghasilkan VaR dinamis yang responsif terhadap fluktuasi volatilitas pasar saham, sehingga tepat digunakan dalam mengukur risiko individu perusahaan (Chan & Wong, 2015). Jika tidak ada efek GARCH pada persamaan (2.46) maka $\hat{\sigma}_t = \hat{\sigma}$ yang menandakan varians pada model konstan.

Apabila distribusi normal tidak sesuai untuk menggambarkan karakteristik data, maka $F^{-1}(\tau)$ disesuaikan dengan *invers* distribusi yang relevan. Pada model AR-GARCH, asumsi distribusi umumnya diterapkan pada inovasi terstandarisasi z_t , sehingga kuantil yang digunakan dalam perhitungan VaR berasal dari distribusi z_t , bukan dari distribusi *return* secara langsung. Oleh karena itu, ketika inovasi z_t diasumsikan mengikuti distribusi *standardized skewed Student-t* (sstd), model VaR dapat ditulis seperti pada persamaan (2.48).

$$\widehat{VaR}_t(\tau) = \hat{\mu}_t + \hat{\sigma}_t q_{\xi,v}^{sstd}(\tau) \quad (2.48)$$

dengan,

$\hat{\mu}_t = \text{mean}$ kondisional dari model AR,

$\hat{\sigma}_t = \text{standar deviasi kondisional dari model GARCH,}$

$q_{\xi,v}^{sstd}(\tau) = \text{kuantil ke-}\tau \text{ dari distribusi sstd.}$

2.10 Uji Terasvirta

Pada penelitian ini, Uji *Terasvirta* digunakan untuk mendapatkan tambahan informasi mengenai pola data yang digunakan. Pemilihan Uji *Terasvirta* didasarkan pada penelitian yang dilakukan oleh (Prabowo et al., 2020) mengenai perbandingan beberapa jenis uji untuk mengidentifikasi nonlinieritas pada data. Hasil penelitian menunjukkan bahwa Uji *Terasvirta* memberikan deteksi lebih baik dalam mengidentifikasi nonlinieritas data.

Berikut merupakan hipotesis yang digunakan dalam Uji *Terasvirta*.

H_0 : Data mengikuti pola linier

H_1 : Data tidak mengikuti pola linier

Menggunakan statistik uji *Chi-square*, langkah pengujian *Terasvirta* untuk deteksi linieritas data adalah sebagai berikut (Prabowo et al., 2020).

1. Regresikan Y_t terhadap prediktor awal dengan intersep 1, $\widehat{VaR}_{i,t}, X_{1,t}, \dots, X_{p,t}$ lalu hitung *residualnya* dengan persamaan (2.49).

$$\hat{u}_t = Y_t - \hat{Y}_t \quad (2.49)$$

2. Regresikan kembali $\hat{u}_t$ dengan intersep $1, \widehat{Var}_{i,t}, X_{1,t}, \dots, X_{p,t}$ dan m prediktor tambahan yang merupakan komponen kuadrat dan kubik *Taylor Expansion* (komponen nonlinier).
3. Hitung nilai $X^2_{(hitung)}$ menggunakan persamaan (2.50).

$$\chi^2_{(hitung)} = nR^2 \quad (2.50)$$

dimana akan diperoleh keputusan Tolak H_0 jika $nR^2 > \chi^2_{(m)}$ atau $p - value < \alpha$.

2.11 Quantile Regression Forest (QRF)

Quantile Regression Forest (QRF) menggabungkan algoritma *Random Forest* dan regresi kuantil dalam penerapannya. *Random Forest* merupakan salah satu algoritma *machine learning* berbasis *ensemble* yang terdiri dari sekumpulan pohon keputusan (*decision trees*) dimana setiap pohon bergantung pada nilai vektor random yang disampel dengan independen dan dengan distribusi yang sama untuk semua pohon di hutan untuk membuat prediksi yang lebih akurat (Breiman, 2001).

Setiap pohon dalam model dilatih menggunakan subset data pelatihan yang diambil secara acak dengan pengembalian dari dataset asli melalui metode *bagging* (Andreani & Petrella, 2020). Teori *random* tidak hanya mengacu pada proses pengambilan sampel acak untuk data *training*, tetapi juga pada pemilihan acak variabel yang digunakan dalam membentuk pemisahan di setiap pohon keputusan. Jumlah variabel acak inilah disebut *mtry*, yaitu parameter *tuning* tunggal dalam algoritma. Hasil model umumnya sudah mendekati optimal dalam rentang nilai parameter tersebut, di mana nilai *mtry* dapat disesuaikan menggunakan sampel *out-of-bag* (Meinshausen, 2006).

Jika θ merupakan vektor parameter acak yang menentukan titik pemisah di setiap *node leaf*, pohon akan dinotasikan dengan $T(\theta)$. Kemudian Ω merupakan kejadian dimana x dapat didefinisikan sepanjang pohon keputusan. Jika hanya ada satu *node leaf* yang memenuhi kondisi $x \in \Omega$ maka *node leaf* dilambangkan dengan $\ell(x, \theta)$ untuk pohon keputusan $T(\theta)$. Adapun vektor bobot dari semua pengamatan dalam $\ell(x, \theta)$ dilambangkan dengan $w_t(x, \theta)$. Dengan memberikan vektor bobot $w_t(x, \theta)$ dari sebuah konstanta positif jika observasi X_t bagian dari daun $\ell(x, \theta)$ dan 0 jika bukan bagian dari daun $\ell(x, \theta)$. Bobot ini kemudian dijumlahkan menjadi satu yang ditunjukkan pada persamaan (2.51).

$$w_t(x, \theta) = \frac{1_{\{X_t \in R_{\ell(x, \theta)}\}}}{\#\{j: X_j \in R_{\ell(x, \theta)}\}} \quad (2.51)$$

Prediksi dari suatu pohon keputusan diberikan kovariat $X = x$, yang merupakan rata-rata vektor bobot dari observasi asli Y_t , dimana $t = 1, 2, \dots, T$ seperti yang ditunjukkan pada persamaan (2.52).

$$\text{single tree: } \hat{\mu}(x) = \sum_{t=1}^T w_t(x, \theta) Y_t \quad (2.52)$$

Menggunakan *Random Forest*, rata-rata kondisional $E(Y|X = x)$ didekati dengan nilai rata-rata prediksi dari k pohon tunggal yang masing-masing dibangun dengan vektor i.i.d $\theta_k, k = 1, 2, \dots, K$. Sehingga rata-rata dari $w_t(\theta)$ yang dilambangkan dengan $w_t(x)$ dapat dihitung menggunakan persamaan (2.53).

$$w_t(x) = \frac{1}{K} \sum_{k=1}^K w_t(x, \theta_k) \quad (2.53)$$

Prediksi akhir algoritma *Random Forest* dihitung dari agregasi hasil prediksi di setiap pohon dengan menggunakan persamaan pada (2.54).

$$RF: \hat{\mu}(x) = \sum_{t=1}^T w_t(x) Y_t \quad (2.54)$$

Pendekatan untuk nilai rata-rata bersyarat Y dengan syarat $X = x$ dilakukan dengan jumlah berbobot (*weighted sum*) dari semua observasi. Bobot ini bervariasi sesuai dengan kovariat $X = x$ dan nilainya cenderung lebih besar untuk $t \in \{1, 2, \dots, T\}$ dimana distribusi bersyarat Y dengan $X = X_t$, serupa dengan distribusi bersyarat Y dengan syarat $X = x$ (Lin & Jeon, 2006).


Berbeda dengan algoritma *Random Forest* yang jika mendekati rata-rata bersyarat $E(Y|X = x)$ menggunakan rata-rata berbobot atas pengamatan dari variabel respon, metode *Quantile Regression Forest* (QRF) merupakan generalisasi dari *Random Forest*. Output dari prediktor menggunakan QRF tidak hanya berupa rata-rata (*mean*) tetapi juga kuantil τ (Castoe, 2020). Artinya informasi yang dihasilkan dari prediksi berupa distribusi bersyarat penuh di beberapa kondisi kuantil yang diinginkan. Fungsi distribusi bersyarat dari Y dengan syarat $X = x$ ditunjukkan pada persamaan (2.55).

$$F(y|X = x) = P(Y \leq y|X = x) = E(1_{\{Y \leq y\}}|X = x) \quad (2.55)$$

Kemudian dibuat analogi dengan *Random Forest* terhadap rata-rata bersyarat $E(Y|X = x)$, dimana $E(1_{\{Y \leq y\}}|X = x)$ diperoleh dari rata-rata berbobot atas observasi $1_{\{Y \leq y\}}$ yang ditunjukkan persamaan (2.56).

$$\hat{F}(y|X = x) = \sum_{t=1}^T w_t(x) 1_{\{Y_t \leq y\}} \quad (2.56)$$

$w_t(x)$ merupakan bobot yang identik dengan *Random Forest* seperti pada persamaan (2.53). Penerapan QRF pada data *time series* memiliki perbedaan dengan data *cross section* atau data yang memiliki sifat i.i.d., sehingga diperlukan pembentukan algoritma baru dengan menerapkan *moving block bootstrap* yang mampu mempertahankan ketergantungan temporal dalam data (Künsch, 1989). Secara konseptual, *moving block bootstrap* bekerja dalam dua tahap utama yang dapat dipahami melalui ilustrasi pada Gambar 2.1 dan Gambar 2.2 (Wicklin, 2021).




Gambar 2.1 Pembentukan Kandidat Block

Sumber: (Wicklin, 2021)

Tahap pertama adalah pembentukan kumpulan kandidat blok dengan algoritma *moving window* seperti yang diilustrasikan pada **Gambar 2.1**. Seluruh data deret waktu dengan panjang

n dibagi menjadi blok-blok berukuran L , di mana blok ke- i didefinisikan sebagai $B_i = (X_i, X_{i+1}, \dots, X_{i+L-1})$ untuk $i = 1, 2, \dots, n - L + 1$. Dengan demikian, blok pertama mencakup observasi ke-1 hingga L , blok kedua mencakup observasi ke-2 hingga $L + 1$, dan seterusnya hingga blok terakhir. Total kandidat blok yang terbentuk adalah sebanyak $n - L + 1$ blok di mana semuanya memiliki panjang yang sama.

Tahap kedua adalah pembentukan dataset *bootstrap* baru yang diilustrasikan pada Gambar 2.2.



Gambar 2.2 Pembentukan Dataset Bootstrap
Sumber: (Wicklin, 2021)

Dari kumpulan kandidat blok yang telah terbentuk, sebanyak $\lceil n/L \rceil$ blok dipilih secara acak dengan pengembalian (*random sampling with replacement*) dari $n - L + 1$ kandidat blok yang tersedia, kemudian disusun secara berurutan membentuk dataset. Dataset *bootstrap* yang terbentuk selanjutnya digunakan sebagai *input* dalam pemodelan QRF dengan K pohon. Pada Poin utama dari *moving block bootstrap* adalah meskipun blok dipilih secara acak, urutan observasi di dalam setiap blok selalu dipertahankan, sehingga struktur dependensi temporal yang ada dalam data deret waktu tidak rusak (Wicklin, 2021).

Pada penelitian ini, ukuran blok ditetapkan sebesar $L = 63$ yang merepresentasikan periode satu kuartal atau tiga bulan hari perdagangan bursa. Penetapan ini didasarkan pada prinsip *trade-off* antara bias dan varians sebagaimana dikemukakan oleh (Künsch, 1989), di mana blok harus cukup panjang untuk mempertahankan struktur dependensi temporal pada data deret waktu. Pertimbangan lainnya adalah pola volatilitas dan *clustering volatility* pada *return* saham umumnya berlangsung dalam rentang waktu tersebut, sehingga dependensi temporal antar observasi dapat dipertahankan dengan baik dan diharapkan menghasilkan estimasi risiko yang lebih stabil dan realistis.

Berikut algoritma untuk melakukan estimasi $\hat{F}(y|X = x)$ menggunakan metode *Quantile Regression Forest* (Purwanto, 2025).

1. Menentukan ukuran *block* yang akan digunakan.
2. Lakukan pengambilan *block* secara acak dengan *replacement*, lalu susun sesuai urutan yang diambil.
3. Bangun k pohon $T(\theta_k)$, dengan $k = 1, 2, \dots, K$, seperti pada algoritma *Random Forest* menggunakan dataset *moving block bootstrap*. Namun, dalam algoritma QRF tidak hanya mencatat *mean* dari setiap pohon, tetapi juga mencatat semua observasi Y yang berada di setiap *leaf*.
4. Untuk setiap nilai $X = x$ yang diberikan, turunkan x melalui semua pohon. Hitung bobot $w_t(x, \theta_k)$ untuk setiap observasi $t \in \{1, 2, \dots, T\}$ pada setiap pohon sesuai dengan persamaan (2.51). Selanjutnya, hitung bobot keseluruhan $w_t(x)$ untuk setiap observasi t sebagai rata-rata dari bobot-bobot $w_t(x, \theta_k)$ untuk semua $k = 1, 2, \dots, K$, seperti pada persamaan (2.53).
5. Menghitung estimasi fungsi distribusi.

Untuk menghasilkan estimasi QRF yang memiliki nilai koefisien berbeda sesuai dengan nilai kuantilnya, fungsi distribusi bersyarat setiap kuantil τ dari variabel Y dengan syarat $X = x$ ditunjukkan pada persamaan (2.57).

$$\hat{F}_\tau(y|X = x) = \sum_{t=1}^T w_{\tau,t}(x) 1_{\{Y_t \leq y\}} \quad (2.57)$$

Kemudian dilanjutkan dengan mencari nilai $\hat{Q}_\tau(x)$ yang merupakan estimasi kuantil bersyarat dimana $\tau = (0 < \tau < 1)$ dapat dihitung dengan memasukkan $\hat{F}_\tau(y|X = x)$ sebagai pengganti $F(y|X = x)$ ke dalam persamaan (2.58).

$$\hat{Q}_\tau(x) = \inf\{y: F(y|X = x) \geq \tau\} \quad (2.58)$$

Adapun perbedaan utama antara QRF dan *Random Forest* adalah pada cara menyimpan informasi di setiap *node* pohon. *Random Forest* hanya menyimpan rata-rata dari observasi yang masuk ke dalam *node* dan mengabaikan informasi lainnya, sedangkan QRF menyimpan seluruh nilai observasi sehingga dapat mengestimasi distribusi bersyarat lebih akurat berdasarkan seluruh informasi yang disimpan (Meinshausen, 2006).

2.12 Conditional Value-at-Risk (CoVaR)

Conditional Value-at-Risk (CoVaR) dikembangkan untuk menghitung risiko sistemik yang mengestimasi kerugian maksimum yang dialami suatu perusahaan atau sistem secara keseluruhan (S) ketika perusahaan lain (i) berada dalam keadaan *distress*, sehingga dapat digunakan untuk mendeteksi potensi terjadinya risiko *spillover* pada suatu sistem keuangan (Adrian & Brunnermeier, 2016).

CoVaR memberikan pemahaman yang lebih menyeluruh mengenai risiko ekor (*tail risk*) dari distribusi kerugian, karena mencakup potensi kerugian yang terjadi pada bagian ekor distribusi (Rockafellar & Royset, 2015). CoVaR didefinisikan sebagai kuantil τ dari distribusi kerugian pasar atau sistem (S) bersyarat pada kerugian suatu perusahaan individu lain (i) yang berada pada nilai VaRnya sendiri. Sehingga, peluang distribusi bersyarat pada kuantil τ ditunjukkan pada persamaan (2.59).

$$P(R_t^S \leq CoVaR_{t,\tau}^{S|i} \mid R_t^i = VaR_{t,\tau}^i) = \tau \quad (2.59)$$

Persamaan (2.68) merupakan model awal CoVaR dengan regresi kuantil linier yang mengasumikan risiko antar perusahaan dan sistem linier. Model estimasi CoVaR dengan pendekatan QRF untuk menangkap hubungan risiko individu dan risiko sistemik dinyatakan sebagai fungsi non linier pada persamaan (2.60).

$$\widehat{CoVaR}_{t,\tau}^{S|i} = \hat{R}_{t,\tau}^S = f_{QRF}(VaR_i^{AR-GARCH}) \quad (2.60)$$

di mana,

$\hat{R}_{t,\tau}^S$ = estimasi CoVaR sektor industri pada waktu ke- t dan kuantil τ .

f_{QRF} = fungsi non-linier hasil estimasi QRF.

$(VaR_i^{AR-GARCH})$ = vektor prediktor VaR emiten-emiten individu yang diestimasi menggunakan AR-GARCH.

Estimasi parameter yang dihasilkan QRF tidak menghasilkan parameter regresi yang eksplisit dikarenakan sebagai metode *machine learning*, QRF mengestimasi fungsi $f(\cdot)$ secara non parametrik. Berbeda dengan estimasi CoVaR yang langsung diperoleh sebagai kuantil bersyarat dari distribusi prediktif yang dibangun dari bobot observasi historis. Proses ini memberikan estimasi risiko yang lebih fleksibel dan akurat di ekor distribusi.

Untuk mengetahui ukuran perubahan nilai CoVaR ketika kondisi acuan berubah dari kondisi normal dengan pengembalian media suatu institusi ke kondisi kerugian ekstrem yang didefinisikan oleh VaR dapat diukur menggunakan $\Delta CoVaR$. $\Delta CoVaR$ digunakan untuk menggambarkan ketergantungan ekor (*tail dependency*) antara risiko suatu institusi dan risiko sistem secara keseluruhan (Adrian & Brunnermeier, 2016).

Model $\Delta CoVaR$ membandingkan nilai CoVaR saat perusahaan dalam kondisi risiko ekstrem (*distress*), dengan nilai CoVaR saat berada dalam kondisi median risiko yang secara sistematis ditunjukkan pada persamaan (2.61).

$$\Delta CoVaR_{\tau}^{S|i} = CoVaR_{\tau}^{S|i=VaR_{\tau}^i} - CoVaR_{\tau}^{S|i=VaR_{0,5}^i} \quad (2.61)$$

di mana $\Delta CoVaR_{\tau}^{S|i}$ merupakan nilai estimasi QRF yang menunjukkan seberapa besar *spillover effect* dari setiap perusahaan terhadap keseluruhan sistem.

2.13 Backtesting

Backtesting merupakan metode yang digunakan untuk menilai kinerja suatu model atau strategi investasi dengan menggunakan data historis. Dalam analisis risiko, tujuan utama *backtesting* adalah mengukur sejauh mana model seperti *Value-at-Risk* (VaR) dan *Conditional Value-at-Risk* (CoVaR) mampu memprediksi potensi kerugian yang mungkin terjadi. *Backtesting* memiliki peranan penting dalam manajemen risiko karena memberikan bukti empiris mengenai tingkat akurasi model dalam memperkirakan risiko di masa depan (Girardi & Tolga, 2013; Jorion, 2007).

2.13.1 Proportion Shortfall

Model VaR dan CoVaR dianggap kurang akurat apabila nilai estimasinya terlalu tinggi (*overfitting*) atau terlalu rendah (*underfitting*) dibandingkan dengan *return* aktual pada periode berikutnya ($t + 1$). Penentuan nilai VaR dan CoVaR dengan pendekatan *Proportion Shortfall* dilakukan melalui pengkodean indikator pelanggaran (*violation indicator*) seperti pada persamaan (2.62) dan persamaan (2.63).

$$I_t^{VaR} = \begin{cases} 1, & \text{Jika } R_t < VaR_{\tau,t} \\ 0, & \text{Jika } R_t \geq VaR_{\tau,t} \end{cases} \quad (2.62)$$

$$I_t^{CoVaR} = \begin{cases} 1, & \text{Jika } R_t < CoVaR_{\tau,t} \\ 0, & \text{Jika } R_t \geq CoVaR_{\tau,t} \end{cases} \quad (2.63)$$

Dari pengkodean akan diperoleh persamaan untuk memperoleh nilai *Proportion Shortfall* dalam konteks *backtesting* berupa proporsi rata-rata pelanggaran selama periode pengamatan T yang ditunjukkan pada persamaan (2.64) dan (2.65)

$$PS_{VaR} = \frac{1}{T} \sum_{t=1}^T I_{\tau,t}^{VaR} \quad (2.64)$$

$$PS_{CoVaR} = \frac{1}{T} \sum_{t=1}^T I_{\tau,t}^{CoVaR} \quad (2.65)$$

2.13.2 Kupiec Test

Kupiec test merupakan metode statistik yang digunakan untuk menguji validitas model *Value-at-Risk* (VaR) dan *Conditional Value-at-Risk* (CoVaR). Tujuan utama dari pengujian ini adalah untuk menentukan apakah *violations* atau frekuensi pelanggaran yang terjadi sesuai dengan tingkat kepercayaan yang telah ditetapkan. Pelanggaran terjadi ketika nilai kerugian sebenarnya melebihi nilai VaR atau CoVaR yang dihasilkan oleh model.

Kupiec test sering diterapkan untuk mengevaluasi sejauh mana model VaR atau CoVaR mampu berfungsi secara akurat. Uji ini bertujuan untuk mengetahui apakah terdapat perbedaan yang signifikan antara jumlah kegagalan yang teramati ($\hat{s}$) dengan jumlah kegagalan yang diharapkan secara teoritis (s). Hipotesis dalam *Kupiec test* adalah sebagai berikut.

$H_0: s = \hat{s} = \frac{n_{loss}}{N}$ (Model perhitungan VaR atau CoVaR valid)

$H_1: s \neq \hat{s}$ (Model perhitungan VaR atau CoVaR tidak valid)

Kupiec (1995) memperkenalkan variasi uji binomial yang dikenal dengan *Proportion of Failures* (POF) test, yang menggunakan distribusi binomial untuk menilai keakuratan model *Value-at-Risk* (VaR) serta *Conditional Value-at-Risk* (CoVaR). Dalam pengujian Kupiec, terdapat dua jenis statistik uji yang memiliki pendekatan berbeda, salah satunya adalah *Proportion of Failures* (POF). POF ini menggunakan distribusi binomial untuk menghitung rasio kemungkinan (*likelihood ratio*) apakah proporsi kegagalan yang diharapkan s sesuai dengan frekuensi proporsi aktual $\hat{s}$ (Kupiec, 1995). Jika hasilnya menunjukkan bahwa proporsi kegagalan berbeda dari $\hat{s}$, maka model VaR atau CoVaR dianggap tidak valid. Adapun statistik uji POF ditunjukkan pada persamaan (2.66).

$$LR_{POF} = -2 \log \left(\frac{(1-s)^{N-n_{loss}} s^{n_{loss}}}{(1-\hat{s})^{N-n_{loss}} \hat{s}^{n_{loss}}} \right) \quad (2.66)$$

di mana,

$\hat{s} = \frac{n_{loss}}{N}$: estimasi proporsi kejadian aktual,

s : proporsi kejadian pelanggaran VaR atau CoVaR yang diharapkan berdasarkan tingkat kepercayaan,

N : jumlah observasi VaR atau CoVaR,

n_{loss} : jumlah observasi yang melebihi VaR atau CoVaR.

Statistik ini mengikuti distribusi *Chi-square* dengan 1 derajat kebebasan dalam bentuk asimtotiknya. Model dianggap tidak valid jika rasio kemungkinan lebih besar dari nilai kritis, atau akan tolak H_0 jika nilai $LR_{POF} > \chi^2_{(\alpha)}$.

Pada penelitian ini, *Kupiec test* diterapkan pada hasil estimasi CoVaR berperan sebagai proksi untuk menilai konsistensi hasil estimasi CoVaR. Dengan kata lain *Kupiec test* digunakan untuk memverifikasi apakah frekuensi pelanggaran (*violation frequency*) yang teramati konsisten dengan tingkat kepercayaan yang ditetapkan. Kupiec test pada CoVaR memiliki keterbatasan mendasar dibandingkan penerapannya pada VaR. Pada VaR, pelanggaran dapat langsung diverifikasi dari data observasi. Sedangkan pada CoVaR, kecukupan prediksi pelanggaran tidak dapat diverifikasi secara langsung karena CoVaR mengukur risiko sistem di mana tidak bersifat *identifiable* dan *elicitable* secara mandiri karena bergantung pada kondisi emiten lain (Fissler & Hoga, 2022).

2.13.3 Pinball Loss

Fungsi *pinball loss* pertama kali diperkenalkan oleh Koenker & Bassett sebagai fungsi kerugian yang menjadi dasar estimasi regresi kuantil. Berbeda dengan fungsi kerugian simetris seperti *Mean Squared Error* (MSE) yang memberikan bobot penalti sama terhadap kesalahan prediksi di atas maupun di bawah nilai aktual, *pinball loss* bersifat asimetris karena besaran penalti terhadap kesalahan prediksi bergantung pada tingkat kuantil τ . Sifat asimetris ini yang menjadikan *pinball loss* sesuai dalam mengevaluasi ketepatan prediksi kuantil ekstrem seperti pada VaR dan CoVaR, karena estimasi kuantil yang baik akan memberikan penalti lebih besar terhadap pelanggaran (*violation*) pada arah kuantil yang dievaluasi (Koenker & Bassett, 1978).

Secara umum, nilai *pinball loss* untuk kuantil τ dirumuskan pada persamaan (2.67).

$$PL_{\tau} = \frac{1}{T} \sum_{t=1}^T \rho_{\tau}(y_t - \hat{y}_t) \quad (2.67)$$

di mana,

T : Jumlah periode pengamatan VaR atau CoVaR yang dievaluasi

y_t : Nilai return aktual pada waktu ke- t

$\hat{y}_t$: Nilai estimasi kuantil (VaR atau CoVaR) pada waktu ke- t

ρ_{τ} : *Check function* pada kuantil τ

dan *check function* yang ditunjukkan pada persamaan (2.68).

$$\rho_{\tau}(u) = u \cdot (\tau - \mathbb{I}(u < 0)) \quad (2.68)$$

Check function ini bertujuan memberikan bobot yang sesuai, di mana ketika nilai $u < 0$, yaitu terjadi pelanggaran/*violation*, selisih tersebut diberi bobot sebesar $(\tau - 1)$, sedangkan ketika nilai $u \geq 0$, selisih tersebut diberi bobot sebesar τ . Semakin kecil nilai *pinball loss* yang dihasilkan suatu model, semakin akurat model tersebut dalam mengestimasi kuantil yang dievaluasi. Pada penelitian ini, *pinball loss* digunakan untuk membandingkan akurasi estimasi kuantil antar model estimasi.

2.14 Stochastic Search Variable Selection (SSVS)

Kompleksitas estimasi parameter meningkat secara signifikan ketika pemodelan risiko sistemik melibatkan banyak kovariat atau variabel prediktor. Dalam konteks estimasi CoVaR variabel yang tidak relevan dapat menurunkan ketepatan prediksi dan meningkatkan kompleksitas model (Adrian & Brunnermeier, 2016). Diperlukan metode seleksi variabel untuk mengetahui relevansi variabel prediktor yang digunakan dalam penelitian, salah satu metodenya adalah *Stochastic Search Variable Selection* (SSVS).

SSVS diperkenalkan pertama kali oleh George dan McCulloch pada tahun 1993 sebagai salah satu metode seleksi variabel Bayesian *stochastic* yang efisien dalam mengidentifikasi kovariat paling relevan di antara sejumlah kandidat variabel. Berbeda dengan metode klasik seperti *stepwise* yang bersifat deterministik, SSVS bekerja dalam kerangka Bayesian yang memungkinkan mengukur ketidakpastian terhadap inklusi variabel (George & McCulloch, 1993; Perrakis & Ntzoufras, 2015). Pendekatan ini menggunakan parameter model sebagai variabel acak dan menggabungkan kemungkinan informasi data (*likelihood*) dengan informasi sebelumnya (*prior information*) untuk memperoleh distribusi posterior parameter.

Distribusi posterior dalam kerangka Bayesian mencerminkan informasi yang diperbarui mengenai parameter setelah dilakukannya pengamatan terhadap data. Dengan memperlakukan parameter sebagai variabel acak, memungkinkan melakukan pengukuran ketidakpastian terhadap setiap koefisien dan probabilitas inklusi variabel (*posterior inclusion probability*), yaitu peluang suatu variabel secara signifikan berkontribusi dalam model yang dievaluasi menggunakan *pinball loss function* (Koenker & Bassett, 1978). Penggunaan SSVS efektif pada model dengan banyak prediktor potensial yang saling berkorelasi serta rentan terhadap *overfitting* (Rockova & McAlinn, 2020).

Penelitian ini menerapkan SSVS untuk *Quantile Regression Forest* (QRF) sebagai teknik *feature selection*. Pendekatan ini mengintegrasikan metode SSVS klasik dengan karakteristik unik dari *ensemble tree-based methods*. Integrasi SSVS dengan QRF sangat relevan untuk analisis risiko sistemik karena menghasilkan seleksi variabel yang robust pada berbagai tingkat kuantil, khususnya pada distribusi ekor (*tail risks*) yang menjadi fokus dalam pengukuran risiko ekstrem (Meinshausen, 2006; Scornet, 2016). Penerapan seleksi variabel Bayesian dalam QRF mampu menangani model dengan banyaknya variabel prediktor potensial tanpa menghilangkan informasi struktural penting pada kuantil ekstrem (O'Hara & Sillanpää, 2009).

Dikarenakan QRF tidak memiliki parameter koefisien eksplisit, prediksi kuantil dibangun berdasarkan bobot observasi di *leaf nodes* dari *Random Forest*. Sehingga integrasi SSVS dilakukan pada *Variable Importance level* dan probabilitas pemilihan fitur bukan pada koefisien regresi tetapi pada proses pemisahan pohon (*splitting tree*) (Gregorutti et al., 2017; Meinshausen, 2006).

Implementasi SSVS pada QRF dilakukan dengan algoritma *Markov Chain Monte Carlo* (MCMC) yang mengambil sampel dari distribusi posterior probabilitas inklusi variabel. Algoritma ini mengidentifikasi subset kovariat yang memiliki probabilitas lebih tinggi berdasarkan frekuensi munculnya dalam iterasi MCMC (Chipman et al., 2010). Dengan algoritma MCMC, SSVS membantu menyederhanakan model dengan memilih fitur-fitur yang relevan dan memberikan karakteristik kemungkinan nilai parameter yang menunjukkan prediktor mana yang harus dipertahankan dalam model (Bainter et al., 2020; Castillo-Mateo et al., 2023).

Inti dari implementasi QRF-SSVS adalah penggunaan variabel laten biner untuk merepresentasikan status inklusi setiap prediktor. Seluruh pengaturan regresi tersimpan (*embed*) di dalam model *hierarchical* Bayesian dengan cara mengidentifikasi subset variabel berdasarkan variabel laten biner (George & McCulloch, 1993; Ishwaran & Rao, 2005). Variabel laten $\gamma = (\gamma_1, \dots, \gamma_p)^T$ ini menentukan apakah suatu prediktor dimasukkan atau dikeluarkan dari model.

$$\gamma_i = \begin{cases} 1, & \text{variabel masuk model} \\ 0, & \text{variabel keluar model} \end{cases} \quad (2.69)$$

Jika diberikan X_i yang merupakan *return* emiten ke- i , probabilitas pemilihan fitur dalam QRF dimodelkan sebagai *mixture* (Mitchell & Beauchamp, 1988). Probabilitas pemilihan fitur ditunjukkan pada persamaan (2.70).

$$P(X_i | \gamma_i) = (1 - \gamma_i) \epsilon + \gamma_i \pi_i \quad (2.70)$$

Dengan ϵ merupakan *baseline probability* (*spike*) yang nilainya sangat kecil, mengindikasikan X_i hampir tidak terpilih ketika $\gamma_i = 0$. Lalu π_i (*slab*) merupakan probabilitas inklusi yang relevan dengan model ketika $\gamma_i = 1$. Dan γ_i merupakan variabel biner 0 atau 1 dengan $P(\gamma_i = 1) = p_i$ merupakan *prior probability* variabel ke- i harus dimasukkan ke dalam model (Ročková & George, 2018). Variabel X_i dianggap *noise* saat $\gamma_i = 0$ dan tidak dimasukkan ke dalam model karena kemampuannya dalam penurunan *impurity* sangat kecil (Breiman, 2001). Sedangkan X_i akan dimasukkan ke dalam proses pembangunan *forest* jika $\gamma_i = 1$, yang menandakan variabel memberikan informasi penting pada prediksi kuantil (Strobl et al., 2007).

Pengaturan nilai p_i dalam penelitian ini dilakukan menggunakan pendekatan *empirical* Bayes dengan memanfaatkan informasi dari *Variable Importance* (VI) yang diperoleh dari model QRF awal. Dikarenakan nilai VI antar emiten memiliki skala yang berbeda, diperlukan proses normalisasi agar nilai VI yang nanti digunakan sebagai *prior inclusion probability* valid dalam rentang probabilitas. Normalisasi dilakukan menggunakan *min-max scaling* yang memetakan VI ke dalam rentang yang ditentukan tanpa mengubah hubungan relatif antar nilai aslinya (Han et al., 2012). Sehingga nilai p_i akan diperoleh menggunakan persamaan berikut.

$$p_i = \frac{VI_i - \min(VI)}{\max(VI) - \min(VI)}, \quad \text{dengan } VI_i > 0 \quad (2.71)$$

Pendekatan dengan normalisasi ini dapat mempertahankan hubungan relatif antar nilai VI aslinya, sehingga emiten dengan kontribusi yang lebih tinggi terhadap risiko sistemik tetap akan memperoleh nilai p_i yang lebih besar. Pendekatan ini lebih efisien dalam proses komputasi dengan mempercepat konvergensi MCMC (Scott & Berger, 2010). *Prior probability* yang diinformasikan berbasis VI memungkinkan algoritma MCMC mencapai stasioneritas dengan iterasi yang lebih sedikit dibandingkan dengan *non-informative uniform prior* (Gelman et al., 2013; Gelman & Rubin, 1992).

Dalam menentukan kombinasi variabel yang optimal, SSVS menggunakan distribusi posterior $[\gamma | \mathcal{D}, \tau]$ yang memberikan probabilitas lebih tinggi pada kombinasi kovariat yang menghasilkan prediksi kuantil yang lebih akurat. Perhitungan distribusi posteriornya dihitung menggunakan teorema Bayes yang ditunjukkan pada persamaan (2.72).

$$P(\gamma | \mathcal{D}, \tau) \propto P(\mathcal{D} | \gamma, \tau) P(\gamma) \quad (2.72)$$

dengan $P(\gamma)$ merupakan *prior distribution* yang menggambarkan keyakinan awal terhadap suatu vektor inklusi γ dengan asumsi independensi antar variabel inklusi γ_i yang didefinisikan pada persamaan (2.73).

$$P(\gamma) = \prod_{i=1}^p p_i^{\gamma_i} (1 - p_i)^{1-\gamma_i} \quad (2.73)$$

$P(\mathcal{D} | \gamma, \tau)$ merupakan ukuran kesesuaian model terhadap data ($\mathcal{D}$) pada kuantil τ . Untuk suatu vektor inklusi γ tertentu, *likelihood function* didefinisikan pada persamaan (2.74).

$$P(\mathcal{D} | \gamma, \tau) \propto \exp(-\lambda \cdot \mathcal{L}_\tau(y, \hat{Q}_\tau(y | X, \gamma))) \quad (2.74)$$

di mana λ merupakan parameter *precision* untuk mengontrol sensitivitas *likelihood* terhadap perbedaan *loss*.

dengan *pinball loss function* yang ditunjukkan pada persamaan (2.75).

$$\mathcal{L}_\tau(y, \hat{Q}_\tau(y | X, \gamma)) = \frac{1}{T} \sum_{t=1}^T \rho_\tau(y_t - \hat{Q}_\tau(y_t | X_t, \gamma)) \quad (2.75)$$

dan *check function* yang ditunjukkan pada persamaan (2.76).

$$\rho_\tau(u) = u \cdot (\tau - \mathbb{I}(u < 0)) \quad (2.76)$$

Penggunaan *pinball loss function* adalah untuk memastikan seleksi variabel tetap konsisten dalam meminimalkan *asymetric loss* pada kuantil tertentu. Sehingga penerapan SSVS pada QRF dapat mengatasi ketidakpastian model *prior distribution* berupa vektor parameter biner untuk indikasi inklusi atau eksklusi variabel dari model, dengan tetap mempertahankan fleksibilitas non parametrik QRF dalam estimasi kuantil kondisional (Hastie et al., 2009).

Implementasi QRF-SSVS memerlukan penentuan beberapa *hyperparameter* yang berbeda dari SSVS klasik dikarenakan tidak terdapat parameter c_i dan τ_i eksplisit seperti pada regresi linier. Sehingga parameternya dapat didefinisikan sebagai berikut (Genuer et al., 2010).

1. δ_{VI} : Nilai ambang batas (*threshold*) *Variable Importance* berdasarkan distribusi empiris dari *Variable Importance* pada QRF awal. Variabel cenderung memiliki *prior* = 0 jika nilai $VI_i < \delta_{VI}$.
2. p_i : *Prior inclusion probability* yang diinformasikan dari nilai VI .
3. MCMC parameter *tuning* : Jumlah iterasi dan *burn-in period*.

Burn-in period (M_{burn}) merupakan jumlah iterasi awal MCMC yang dibuang karena belum merepresentasikan distribusi posterior yang sebenarnya. Panjang *burn-in* dapat ditentukan melalui diagnostik konvergensi seperti *Gelman-Rubin statistic* ($\hat{R}$) atau dengan melihat *trace plot* parameter γ_i guna memastikan bahwa rantai sudah mencapai stasioneritas (Gelman & Rubin, 1992).

Setelah menentukan *hyperparameter*, pengambilan sampel dapat dijalankan menggunakan algoritma MCMC dengan *Adaptive Metropolis-within-Gibbs* yang akan mengambil sampel dari

distribusi posterior gabungan $[\gamma, \theta | \mathcal{D}, \tau]$, di mana θ mencakup parameter QRF lainnya, seperti jumlah pohon dan kedalaman maksimum (Robert & Casella, 2004). Langkah-langkah algoritma dirancang untuk memperbarui status inklusi variabel secara iteratif berdasarkan *likelihood* dan *prior*, sehingga menghasilkan distribusi posterior yang akurat.

1. Mendapatkan skor atau nilai VI dari *input* awal hasil estimasi CoVaR berbasis QRF.
2. Hasil VI_i dimasukkan ke persamaan (2.69) untuk mendapatkan nilai p_i .
3. Menentukan nilai awal $\gamma^{(0)} = \gamma_1^{(0)}, \dots, \gamma_p^{(0)}$ dengan asumsi semua variabel diinklusi ($\gamma^{(0)} = 1$)
4. Untuk setiap variabel $i = 1, \dots, p$:
 - a. Menyusun *data frame* yang memuat nilai *return* dan nilai estimasi CoVaR dengan QRF, kemudian evaluasi perbedaan kinerja prediksi kuantil antara model dengan dan tanpa variabel X_i sebagai dasar perbandingan inklusi dan eksklusi variabel yang disajikan dalam bentuk rasio evaluasi berikut (Green, 1995).

$$LR_i = \frac{P(\mathcal{D} | \gamma_i = 1, \gamma_{-i}^{(m-1)}, \tau)}{P(\mathcal{D} | \gamma_i = 0, \gamma_{-i}^{(m-1)}, \tau)} \quad (2.77)$$

- b. Update nilai γ_i dari distribusi kondisional penuh menggunakan persamaan (2.78).

$$[\gamma_i | \cdot] \sim \text{Ber} \left(\frac{p_i LR_i}{p_i LR_i + (1 - p_i)} \right) \quad (2.78)$$

- c. Latih ulang QRF dengan subset variabel yang sesuai dengan γ_i baru dan evaluasi *pinball loss function* untuk iterasi berikutnya.
5. Menghitung nilai PIP setiap variabel setelah *burn-in period* dengan persamaan (2.79) (Barbieri & Berger, 2004).

$$PIP_i = P(\gamma_i = 1 | \mathcal{D}, \tau) \approx \frac{1}{M - M_{burn}} \sum_{m=M_{burn}+1}^M \gamma_i^{(m)} \quad (2.79)$$

di mana M_{burn} merupakan jumlah iterasi *burn-in*. Sampel yang digunakan untuk perhitungan PIP pada persamaan (2.77) hanya menggunakan sampel setelah *burn-in period* untuk memastikan konvergensi probabilitas posterior yang diestimasi dan tidak lagi terpengaruh nilai inisialisasi $\gamma^{(0)}$. Nilai PIP yang tinggi menunjukkan kontribusi signifikan terhadap risiko sistemik pada kuantil target (Kass & Raftery, 1995).

Adapun kriteria seleksi variabel berdasarkan nilai PIP masing-masing emiten pada penelitian ini menggunakan *threshold* moderat. *Threshold* moderat adalah kategori emiten dengan nilai $PIP_i \geq 0,5$ yang artinya variabel cukup penting untuk dimasukkan ke dalam model (Barbieri & Berger, 2004). Sehingga emiten dengan nilai $PIP_i < 0,5$ dianggap tidak memiliki kontribusi signifikan terhadap risiko kondisional saham target dan tidak dimasukkan ke dalam model CoVaR SSVS final.

Dengan mengintegrasikan SSVS dengan hasil estimasi CoVaR berbasis QRF, akan diperoleh validasi prediktor yang relevan serta menghasilkan model yang lebih *parsimonious* dan interpretatif karena hanya memasukkan variabel prediktor yang memiliki kontribusi signifikan terhadap model (Tibshiranit, 1996).

2.15 Saham Sektor Industri

Sektor industri (*industrials sector*) di Bursa Efek Indonesia (BEI) mencakup berbagai perusahaan yang bergerak di bidang manufaktur, konstruksi, logistik, permesinan, alat berat, serta layanan pendukung kegiatan industri lainnya. Sektor ini dikenal sebagai sektor yang padat modal (*capital-intensive*) dan sangat bergantung pada efisiensi rantai pasok serta tingkat permintaan dari pasar domestik maupun global. Oleh karena itu, kinerja saham pada sektor industri sangat sensitif terhadap perubahan kondisi makroekonomi, seperti tingkat suku bunga, inflasi, nilai tukar, serta fluktuasi biaya input seperti energi dan bahan baku (Hidayatullah et al., 2022; Nainggolan et al., 2023).

Karakteristik saham sektor industri juga menunjukkan bahwa faktor fundamental internal seperti profitabilitas, likuiditas, struktur modal dan ukuran perusahaan memiliki kaitan erat dengan *return* dan harga saham (Pribadi & Nursiam, 2024). Selain faktor internal, kondisi eksternal seperti dinamika siklus ekonomi, volatilitas global, serta keterkaitan antarperusahaan dalam rantai pasok turut memengaruhi pergerakan saham sektor industri. Mengingat saham sektor industri memiliki sifat *cyclical*, penurunan aktivitas ekonomi atau kenaikan tajam biaya produksi dapat menekan kinerja perusahaan dan berimplikasi langsung terhadap harga saham (Sitorus et al., 2023). Oleh karena itu, sektor industri menjadi objek yang relevan dalam kajian risiko sistemik, karena guncangan pada satu perusahaan atau subsektor berpotensi menimbulkan efek ekstrem terhadap perusahaan lain dalam ekosistem industri yang saling terhubung.

BAB 3

METODE PENELITIAN

Bagian ini menjelaskan mengenai metodologi penelitian yang terdiri dari sumber data, variabel penelitian, struktur data, langkah analisis, diagram alir penelitian, serta rencana jadwal penelitian.

3.1 Sumber Data

Data yang digunakan merupakan data sekunder yang diambil dari *website Yahoo Finance* (finance.yahoo.com) berupa harga penutupan saham (*close price*) 10 emiten saham yang masuk ke dalam sektor industri yang terdaftar di Bursa Efek Indonesia (BEI). Sepuluh emiten saham ini dipilih berdasarkan nilai kapitalisasi pasar tertinggi per November 2025 yang mewakili 92,6% *market share* pada sektor industri. Periode data penelitian dimulai dari 3 Juli 2023 hingga 31 Desember 2025 berdasarkan pertimbangan bahwa periode tersebut merupakan periode pasca pandemi COVID-19 setelah pemerintah resmi mencabut status pandemi melalui Keputusan Presiden Nomor 17 Tahun 2023. Periode ini mencerminkan kondisi pasar yang relatif lebih stabil dibandingkan masa krisis pandemi, namun tetap mengandung dinamika volatilitas serta kejadian ekstrem yang relevan untuk analisis risiko. Harga penutupan saham dipilih dalam menggambarkan pergerakan naik turunnya suatu saham karena bersifat final dan tidak berubah setiap hari kerja bursa selesai. Sehingga *close price* saham baik dalam merepresentasikan seluruh informasi yang dapat memengaruhi pasar.

3.2 Variabel Penelitian

Variabel yang digunakan pada penelitian ini adalah nilai *return* dari 10 emiten saham sektor industri berdasarkan nilai kapitalisasi pasar tertinggi per November 2025 yang ditunjukkan pada Tabel 3.1.

Tabel 3.1 Variabel Penelitian

No.	Kode	Nama Perusahaan	Variabel
1	ASII	Astra Internasional Tbk.	$R_{1,t}$
2	IMPC	Impack Pratama Industri Tbk.	$R_{2,t}$
3	UNTR	United Tractors Tbk.	$R_{3,t}$
4	SKRN	Superkrane Mitra Utama Tbk.	$R_{4,t}$
5	SINI	Singaraja Putra Tbk.	$R_{5,t}$
6	SMIL	Sarana Mitra Luas Tbk.	$R_{6,t}$
7	ARNA	Arwana Citramulia Tbk.	$R_{7,t}$
8	HEXA	Hexindo Adiperkasa Tbk.	$R_{8,t}$
9	TOTO	Surya Toto Indonesia Tbk.	$R_{9,t}$
10	MARK	Mark Dynamics Indonesia Tbk.	$R_{10,t}$

3.3 Struktur Data

Struktur data yang digunakan pada penelitian ini berupa nilai *return* saham tiap emiten pada sektor industri, struktur hasil estimasi model dan pengukuran risiko individu maupun sistemik. Data yang digunakan berupa deret waktu (*time series*), sehingga setiap observasi disusun berdasarkan urutan tanggal perdagangan untuk merekam pergerakan *return* secara kronologis. Adapun struktur data *return* saham pada waktu ke- t dengan skala pengukuran rasio sebagai tahapan awal analisis risiko pada penelitian ini disajikan dalam Tabel 3.2.

Tabel 3.2 Struktur Data Return Saham

Waktu (t)	$R_{1,t}$	$R_{2,t}$	...	$R_{10,t}$
1	$R_{1,1}$	$R_{2,1}$	...	$R_{10,1}$
2	$R_{1,2}$	$R_{2,2}$	...	$R_{10,2}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$
t	$R_{1,t}$	$R_{2,t}$	...	$R_{10,t}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
T	$R_{1,T}$	$R_{2,T}$	...	$R_{10,T}$

Setelah diperoleh nilai *return*, dilakukan estimasi nilai *Value-at-Risk* (VaR) menggunakan pendekatan AR-GARCH untuk menangkap dinamika volatilitas yang mengalami heteroskedastisitas. Model AR-GARCH menghasilkan dua *output* utama, yaitu *conditional mean* ($\mu_{i,t}$) yang menggambarkan nilai ekspektasi *return* dan *conditonal variance* ($\sigma_{i,t}^2$) yang menggambarkan volatilitas dari masing-masing saham. Struktur data estimasi VaR disajikan dalam deret waktu, di mana baris menunjukkan periode pengamatan, sedangkan kolom menunjukkan nilai VaR untuk masing-masing saham sektor industri yang digunakan. Struktur data hasil perhitungan VaR disajikan pada Tabel 3.3.

Tabel 3.3 Struktur Data Hasil Estimasi VaR

Waktu (t)	$VaR_{1,t}$	$VaR_{2,t}$	...	$VaR_{10,t}$
1	$VaR_{1,1}$	$VaR_{2,1}$	...	$VaR_{10,1}$
2	$VaR_{1,2}$	$VaR_{2,2}$	...	$VaR_{10,2}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$
t	$VaR_{1,t}$	$VaR_{2,t}$	...	$VaR_{10,t}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
T	$VaR_{1,T}$	$VaR_{2,T}$	...	$VaR_{10,T}$

Data hasil perhitungan VaR pada Tabel 3.3 akan digunakan sebagai tahap awal untuk menurunkan *Conditional Value-at-Risk* (CoVaR), yang akan mengukur tingkat risiko sistemik suatu sistem, yaitu pada saat saham lain berada pada kondisi ekstrem yang ditentukan oleh nilai VaR-nya. Dengan demikian, CoVaR mencerminkan besarnya potensi risiko sistemik yang dapat ditransmisikan oleh satu saham terhadap saham lainnya. Baris pada struktur data CoVaR merepresentasikan periode pengamatan, sedangkan kolom menunjukkan nilai CoVaR antar pasangan saham. Struktur data CoVaR disajikan pada Tabel 3.4.

Tabel 3.4 Struktur Data Hasil Estimasi CoVaR

Waktu (t)	$CoVaR_{t,\tau}^{x_1 x-1}$	$CoVaR_{t,\tau}^{x_2 x-2}$	...	$CoVaR_{t,\tau}^{x_i x-i}$	...	$CoVaR_{t,\tau}^{x_{10} x-10}$
1	$CoVaR_{1,\tau}^{x_1 x-1}$	$CoVaR_{1,\tau}^{x_2 x-2}$	...	$CoVaR_{1,\tau}^{x_i x-i}$	...	$CoVaR_{1,\tau}^{x_{10} x-10}$
2	$CoVaR_{2,\tau}^{x_1 x-1}$	$CoVaR_{2,\tau}^{x_2 x-2}$	...	$CoVaR_{2,\tau}^{x_i x-i}$	...	$CoVaR_{2,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
t	$CoVaR_{t,\tau}^{x_1 x-1}$	$CoVaR_{t,\tau}^{x_2 x-2}$	...	$CoVaR_{t,\tau}^{x_i x-i}$	...	$CoVaR_{t,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
T	$CoVaR_{T,\tau}^{x_1 x-1}$	$CoVaR_{T,\tau}^{x_2 x-2}$	...	$CoVaR_{T,\tau}^{x_i x-i}$	...	$CoVaR_{T,\tau}^{x_{10} x-10}$

Hasil perhitungan CoVaR digunakan sebagai dasar dalam menghitung $\Delta CoVaR$, yang merupakan selisih antara nilai CoVaR saat berada di kondisi ekstrem (*distress*) dengan nilai CoVaR pada kondisi median risiko. Ukuran ini memberikan gambaran lebih jelas mengenai

kontribusi tambahan suatu saham terhadap peningkatan risiko sistemik. Struktur data ΔCoVaR ditunjukkan pada Tabel 3.5.

Tabel 3.5 Struktur Data Hasil Estimasi ΔCoVaR

Waktu (t)	$\Delta\text{CoVaR}_{t,\tau}^{x_1 x-1}$	$\Delta\text{CoVaR}_{t,\tau}^{x_2 x-2}$	...	$\Delta\text{CoVaR}_{t,\tau}^{x_i x-i}$	...	$\Delta\text{CoVaR}_{t,\tau}^{x_{10} x-10}$
1	$\Delta\text{CoVaR}_{1,\tau}^{x_1 x-1}$	$\Delta\text{CoVaR}_{1,\tau}^{x_2 x-2}$	...	$\Delta\text{CoVaR}_{1,\tau}^{x_i x-i}$	...	$\Delta\text{CoVaR}_{1,\tau}^{x_{10} x-10}$
2	$\Delta\text{CoVaR}_{2,\tau}^{x_1 x-1}$	$\Delta\text{CoVaR}_{2,\tau}^{x_2 x-2}$	...	$\Delta\text{CoVaR}_{2,\tau}^{x_i x-i}$	...	$\Delta\text{CoVaR}_{2,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
t	$\Delta\text{CoVaR}_{t,\tau}^{x_1 x-1}$	$\Delta\text{CoVaR}_{t,\tau}^{x_2 x-2}$	...	$\Delta\text{CoVaR}_{t,\tau}^{x_i x-i}$	...	$\Delta\text{CoVaR}_{t,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
T	$\Delta\text{CoVaR}_{T,\tau}^{x_1 x-1}$	$\Delta\text{CoVaR}_{T,\tau}^{x_2 x-2}$	...	$\Delta\text{CoVaR}_{T,\tau}^{x_i x-i}$	...	$\Delta\text{CoVaR}_{T,\tau}^{x_{10} x-10}$

Setelah diperoleh hasil estimasi CoVaR, akan dilanjutkan dengan seleksi variabel menggunakan *Stochastic Search variable Selection* (SSVS) untuk mengidentifikasi emiten yang berpengaruh signifikan terhadap risiko sistemik pada sektor industri. Struktur data hasil estimasi CoVaR SSVS ditunjukkan pada Tabel 3.6.

Tabel 3.6 Struktur Data Hasil Estimasi CoVaR SSVS

Waktu (t)	$\text{CoVaR}_{t,\tau}^{x_1 x-1} - \text{SSVS}_{t,\tau}^{x_1 x-1}$	$\text{CoVaR}_{t,\tau}^{x_2 x-2} - \text{SSVS}_{t,\tau}^{x_2 x-2}$	...	$\text{CoVaR}_{t,\tau}^{x_i x-i} - \text{SSVS}_{t,\tau}^{x_i x-i}$	...	$\text{CoVaR}_{t,\tau}^{x_{10} x-10} - \text{SSVS}_{t,\tau}^{x_{10} x-10}$
1	$\text{CoVaR}_{1,\tau}^{x_1 x-1} - \text{SSVS}_{1,\tau}^{x_1 x-1}$	$\text{CoVaR}_{1,\tau}^{x_2 x-2} - \text{SSVS}_{1,\tau}^{x_2 x-2}$	...	$\text{CoVaR}_{1,\tau}^{x_i x-i} - \text{SSVS}_{1,\tau}^{x_i x-i}$	...	$\text{CoVaR}_{1,\tau}^{x_{10} x-10} - \text{SSVS}_{1,\tau}^{x_{10} x-10}$
2	$\text{CoVaR}_{2,\tau}^{x_1 x-1} - \text{SSVS}_{2,\tau}^{x_1 x-1}$	$\text{CoVaR}_{2,\tau}^{x_2 x-2} - \text{SSVS}_{2,\tau}^{x_2 x-2}$	...	$\text{CoVaR}_{2,\tau}^{x_i x-i} - \text{SSVS}_{2,\tau}^{x_i x-i}$	...	$\text{CoVaR}_{2,\tau}^{x_{10} x-10} - \text{SSVS}_{2,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
t	$\text{CoVaR}_{t,\tau}^{x_1 x-1} - \text{SSVS}_{t,\tau}^{x_1 x-1}$	$\text{CoVaR}_{t,\tau}^{x_2 x-2} - \text{SSVS}_{t,\tau}^{x_2 x-2}$	...	$\text{CoVaR}_{t,\tau}^{x_i x-i} - \text{SSVS}_{t,\tau}^{x_i x-i}$	...	$\text{CoVaR}_{t,\tau}^{x_{10} x-10} - \text{SSVS}_{t,\tau}^{x_{10} x-10}$
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
T	$\text{CoVaR}_{T,\tau}^{x_1 x-1} - \text{SSVS}_{T,\tau}^{x_1 x-1}$	$\text{CoVaR}_{T,\tau}^{x_2 x-2} - \text{SSVS}_{T,\tau}^{x_2 x-2}$	...	$\text{CoVaR}_{T,\tau}^{x_i x-i} - \text{SSVS}_{T,\tau}^{x_i x-i}$	...	$\text{CoVaR}_{T,\tau}^{x_{10} x-10} - \text{SSVS}_{T,\tau}^{x_{10} x-10}$

3.4 Langkah Analisis

Langkah-langkah penelitian yang dilakukan dalam analisis risiko sistemik saham sektor industri di BEI adalah sebagai berikut.


1. Langkah yang dilakukan untuk menjawab tujuan penelitian pertama pada subbab 1.3:
 - a. Mengumpulkan data harga penutupan (*close price*) saham harian setiap perusahaan dari situs *Yahoo Finance*.
 - b. Menghitung nilai *return* saham masing-masing perusahaan menggunakan persamaan (2.5).
 - c. Melakukan analisis deskriptif terhadap nilai *return* saham berdasarkan harga penutupan setiap perusahaan untuk mengetahui karakteristik data *return* saham perusahaan sektor industri.
2. Langkah yang dilakukan untuk menjawab tujuan penelitian kedua pada subbab 1.3:
 - a. Menguji stasioneritas terhadap *mean* pada data *return* menggunakan uji ADF dan melakukan *differencing* jika tidak memenuhi stasioner dalam *mean*.

- b. Mengidentifikasi model AR (p) berdasarkan plot ACF dan PACF.
 - c. Melakukan estimasi parameter dugaan model AR (p) dengan metode MLE dan menguji signifikansi parameternya.
 - d. Melakukan *diagnostic checking* pada *residual* model.
 - e. Memilih model AR (p) terbaik berdasarkan kriteria nilai AIC terkecil.
 - f. Melakukan deteksi heteroskedastisitas pada *residual* model menggunakan uji *Lagrange Multiplier* (LM).
 - g. Menentukan model GARCH (m,s), mengestimasi parameter dengan mempertimbangkan beberapa asumsi distribusi *residual* serta menguji signifikansi parameter.
 - h. Memilih model GARCH (m,s) terbaik berdasarkan kriteria nilai AIC terkecil.
 - i. Menghitung nilai VaR untuk setiap emiten dengan kombinasi model AR-GARCH terbaik menggunakan persamaan (2.48).
 - j. Melakukan evaluasi validitas hasil estimasi VaR dengan menggunakan *Proportion of Shortfall* (PS) dan *Kupiec test*.
3. Langkah yang dilakukan untuk menjawab tujuan penelitian ketiga pada subbab 1.3:
 - a. Membentuk data *frame* untuk seluruh nilai VaR yang dihasilkan dari model AR-GARCH.
 - b. Melakukan Uji *Terasvirta* untuk mendapatkan informasi tambahan mengenai pola pada data hasil estimasi VaR. Hasil pengujian ini bukan sebagai syarat penentuan metode yang digunakan tetapi sebagai pelengkap dalam memahami pola data yang digunakan. Sehingga pemodelan selanjutnya akan tetap dilanjutkan menggunakan *Quantile Regression Forest* (QRF).
 - c. Menerapkan algoritma QRF dengan jumlah pohon sebesar 1.000, ukuran *block* dalam *moving block bootstrap* sebesar 63, level kuantil (τ) 1% dan 5%, serta taraf signifikansi (α) sebesar 5%.
 - d. Estimasi CoVaR pada setiap kuantil menggunakan QRF, dengan nilai *return* sebagai variabel respon dan nilai VaR individu tiap perusahaan yang sudah dimodelkan dengan AR-GARCH ($VaR_i^{AR-GARCH}$) sebagai variabel prediktor menggunakan persamaan (2.60).
 - e. Menghitung nilai *Variable Importance* (VI) dari model QRF untuk mengukur kontribusi masing-masing emiten prediktor terhadap pembentukan risiko sistemik saham lain, yang selanjutnya akan digunakan sebagai dasar penetapan *prior probabilities* pada tahap estimasi CoVaR SSVS.
 - f. Estimasi nilai Δ CoVaR untuk melihat perubahan nilai CoVaR saat perusahaan berada pada kondisi normal dan saat *distress* menggunakan persamaan (2.61).
 - g. Melakukan evaluasi validitas hasil estimasi CoVaR dengan menggunakan *Proportion of Shortfall* (PS) dan *Kupiec test*.
 4. Langkah yang dilakukan untuk menjawab tujuan penelitian keempat pada subbab 1.3:
 - a. *Preprocessing* dengan melakukan transformasi skala data untuk menghindari masalah numerik dalam proses MCMC.
 - b. Menghitung *prior probabilities* (p_i) berdasarkan informasi nilai VI dengan menggunakan persamaan (2.71).
 - c. Menetapkan variabel laten biner $\gamma = (\gamma_1, \dots, \gamma_p)^T$ dengan *prior distribution* $\gamma_i \sim \text{Bernoulli}(p_i)$ dan inisialisasi awal $\gamma^{(0)}$.

- d. Menetapkan *hyperparameter* berupa M_{burn} dan jumlah iterasi MCMC (M).
 - e. Melakukan estimasi posterior dengan *Markov Chain Monte Carlo* (MCMC) menggunakan *Adaptive Metropolis-within-Gibbs*:
 - Mengevaluasi kinerja prediksi kuantil dengan *pinball loss function* seperti pada persamaan (2.75).
 - Membandingkan kinerja model saat kondisi dengan dan tanpa variabel untuk setiap variabel X_i untuk menilai kontribusi masing-masing prediktor dengan menggunakan persamaan (2.77).
 - *Update* status inklusi variabel γ_i menggunakan persamaan (2.78).
 - Ulangi *train* QRF dengan subset variabel sesuai nilai γ_i baru dan evaluasi menggunakan *pinball loss function* untuk iterasi berikutnya.
 - f. Menghitung nilai *Posterior Inclusion Probability* (PIP) menggunakan persamaan (2.79) untuk mengidentifikasi variabel yang signifikan sesuai dengan *threshold* PIP.
 - g. Melakukan evaluasi validitas hasil estimasi CoVaR QRF dengan SSVS menggunakan *Proportion of Shortfall* (PS) dan *Kupiec test*.
5. Menganalisis dan membandingkan tingkat keakuratan model dari hasil *backtesting* dan *pinball loss* yang didapatkan.
 6. Menyusun kesimpulan dan saran penelitian berdasarkan hasil analisis.

3.5 Diagram Alir Penelitian

Berikut merupakan langkah analisis pada penelitian yang digambarkan pada diagram alir pada Gambar 3.1.



Gambar 3.1 Diagram Alir Penelitian

(Halaman ini sengaja dikosongkan)


BAB 4

HASIL DAN PEMBAHASAN

4.1 Karakteristik Data *Return* Saham

Penelitian ini menggunakan data *return* saham yang dihitung berdasarkan *closing price* harian masing-masing emiten. Harga penutupan saham dipilih karena dinilai paling merepresentasikan kondisi akhir aktivitas perdagangan pada hari kerja bursa. Analisis difokuskan pada nilai *return*, bukan pada tingkat harga saham dikarenakan *return* menunjukkan perubahan nilai investasi yang secara langsung berkaitan dengan keuntungan (*gain*) maupun kerugian (*loss*) yang dialami investor. Selain itu, penggunaan *return* memungkinkan perbandingan risiko dan kinerja antar saham meskipun memiliki tingkat harga yang berbeda.

Data *closing price* harian saham terlebih dahulu divisualisasikan untuk memberikan gambaran awal mengenai pola pergerakan, kecenderungan tren, serta indikasi volatilitas masing-masing saham selama periode pengamatan sebelum digunakan untuk menghitung nilai *return* saham. Gambar 4.1 menunjukkan visualisasi *time series* harga penutupan sepuluh saham sektor industri yang terdaftar di BEI pada periode 3 Juli 2023 hingga 31 Desember 2025.




Gambar 4.1 *Time Series Plot* Data Harga Penutupan Saham


Pergerakan harga sepuluh emiten sektor industri pada Gambar 4.1 menunjukkan karakteristik yang heterogen baik dari rentang harga maupun dinamika volatilitasnya dari waktu ke waktu. UNTR tampak mendominasi dengan level harga yang relatif tinggi menunjukkan pola fluktuasi yang relatif stabil. Pola serupa juga terjadi pada saham ASII dan HEXA, di mana pola pergerakan harganya relatif stabil dan tidak menunjukkan lonjakan ekstrem. Saham yang menunjukkan dinamika paling ekstrem adalah SINI dengan peningkatan yang tajam dalam waktu relatif singkat. Pola tersebut mengindikasikan tingkat volatilitas yang jauh lebih tinggi dibandingkan saham lainnya. Saham IMPC, TOTO, dan MARK menunjukkan pola pergerakan yang lebih fluktuatif dibandingkan UNTR, ASII, dan HEXA meskipun tidak seekstrem SINI. Sementara itu, saham ARNA, SMIL, dan SKRN berada pada kisaran harga yang lebih rendah dan relatif lebih mendatar (*sideways*) sepanjang periode pengamatan. Perbedaan pola tersebut menunjukkan bahwa masing-masing saham memiliki tingkat risiko dan potensi keuntungan yang berbeda. Saham dengan pergerakan yang agresif berpotensi memberikan keuntungan lebih tinggi, namun disertai dengan tingkat risiko yang lebih besar. Sebaliknya, saham yang

memperlihatkan pergerakan yang lebih stabil cenderung memiliki tingkat risiko yang relatif lebih terkendali.

Karena pengukuran risiko dalam penelitian ini didasarkan pada data *return* saham, harga penutupan harian saham kemudian ditransformasikan ke dalam bentuk *return* harian dan divisualisasikan melalui *time series plot* pada Gambar 4.2 untuk mengamati besarnya perubahan serta frekuensi fluktuasi yang terjadi pada masing-masing emiten.



Gambar 4.2 *Time Series Plot Return Saham*



Gambar 4.2 Time Series Plot Return Saham (Lanjutan)

Time series plot menunjukkan bahwa nilai *return* sepuluh emiten berfluktuasi di sekitar rata-rata nol (garis putus-putus merah) dengan pola volatilitas yang dinamis. SINI, SMIL, dan SKRN memiliki tingkat risiko paling tinggi karena sering mengalami lonjakan drastis (*spike*) hingga lebih dari 20% dengan beberapa periode penurunan tajam. Kondisi ini mencerminkan potensi kerugian signifikan bagi investor serta mengindikasikan adanya *return* ekstrem yang tidak sejalan dengan asumsi distribusi normal. Sementara itu, IMPC dan MARK menunjukkan pola volatilitas menengah di mana pergerakan *return* hariannya relatif stabil, meskipun pada beberapa periode muncul lonjakan harga (baik naik maupun turun) yang cukup besar. Sementara itu, ASII, UNTR, ARNA, HEXA, dan TOTO memiliki pola yang lebih stabil karena sebagian besar *return* memiliki fluktuasi yang tidak terlalu ekstrem. Selanjutnya, dilakukan analisis deskriptif terhadap *return* saham untuk memperkuat hasil analisis terhadap karakteristik *return* saham yang disajikan pada Tabel 4.1.

Tabel 4.1 Statistika Deskriptif Return Saham


Variabel	Mean	StDev	Variance	Min	Max	Range	Skewness	Kurtosis
ASII	0,0001	0,0173	0,0003	-0,0975	0,0995	0,1970	0,1770	7,5929
IMPC	0,0044	0,0330	0,0011	-0,1500	0,2500	0,4000	2,2707	14,7791
UNTR	0,0006	0,0188	0,0004	-0,1465	0,0688	0,2153	-0,6821	10,1599
SKRN	0,0009	0,0444	0,0020	-0,1694	0,2500	0,4194	1,8613	14,0944
SINI	0,0054	0,0547	0,0030	-0,2500	0,2500	0,5000	0,3223	5,7560
SMIL	0,0028	0,0548	0,0030	-0,2981	0,3456	0,6437	0,1558	12,7084
ARNA	-0,0008	0,0150	0,0002	-0,0821	0,0619	0,1440	-0,2423	9,4462
HEXA	-0,0004	0,0148	0,0002	-0,1472	0,0608	0,2080	-2,4350	26,5207
TOTO	0,0003	0,0109	0,0001	-0,0508	0,0611	0,1119	0,1765	8,0435
MARK	0,0008	0,0258	0,0007	-0,0914	0,1139	0,2053	0,0732	4,8198

Tabel 4.1 menunjukkan bahwa secara umum data *return* sepuluh emiten sektor industri bersifat fluktuatif dengan rata-rata *return* harian yang kecil dan mendekati nol. Hal ini mencerminkan bahwa tidak terdapat kecenderungan tren *return* yang kuat, sehingga pergerakan harga didominasi oleh fluktuasi jangka pendek. SINI memiliki rata-rata *return* tertinggi sebesar 0,54% yang disertai volatilitas yang tinggi, terlihat dari standar deviasi dan varians yang relatif besar, sehingga memiliki tingkat risiko yang lebih besar. Sebaliknya, ARNA dan HEXA memiliki rata-rata *return* negatif masing-masing sebesar -0,08% dan -0,04%, menandakan bahwa secara rata-rata kedua saham tersebut mengalami penurunan harga selama periode pengamatan. Sementara itu, ASII, UNTR, TOTO, dan MARK memiliki rata-rata *return* positif dalam skala relatif kecil, yang mencerminkan pertumbuhan harga yang relatif moderat.

Dari sisi volatilitas, SMIL dan SINI menunjukkan fluktuasi paling tinggi dengan standar deviasi masing-masing sebesar 0,0548 dan 0,0547, serta *range* terbesar yang mencapai 0,6437 dan 0,5000. SKRN juga menunjukkan volatilitas yang cukup tinggi dengan standar deviasi sebesar 0,0444. IMPC, ASII, UNTR, dan MARK berada pada tingkat volatilitas menengah

dengan standar deviasi yang relatif lebih rendah. Sementara itu, TOTO, ARNA, dan HEXA memiliki volatilitas relatif rendah, di mana TOTO menunjukkan stabilitas tertinggi dengan standar deviasi paling rendah sebesar 0,0109 dan *range* terkecil sebesar 0,1119. Selain volatilitas, bentuk distribusi *return* juga memberikan informasi penting mengenai kecenderungan arah dan intensitas pergerakan harga ekstrem yang mungkin terjadi. Saham IMPC dan SKRN memiliki *skewness* positif yang cukup tinggi menandakan *return* cenderung memiliki peluang lebih besar untuk menghasilkan keuntungan ekstrem daripada kerugian ekstrem. Sebaliknya, HEXA memiliki *skewness* negatif paling ekstrem sebesar $-2,4350$, menandakan bahwa *return* cenderung menghasilkan kerugian ekstrem daripada keuntungan besar, diikuti oleh UNTR dan ARNA yang juga memiliki *skewness* negatif. Sementara ASII, SINI, SMIL, TOTO, dan MARK memiliki *skewness* mendekati nol, mengindikasikan distribusi *return* yang relatif simetris. Sementara itu, dilihat dari nilai kurtosis, HEXA memiliki kurtosis paling tinggi, diikuti IMPC, SKRN, dan SMIL yang mengindikasikan distribusi *return* yang *heavy-tailed* dan jauh dari asumsi distribusi normal.

Hasil analisis statistika deskriptif memperlihatkan bahwa pemahaman terhadap analisis risiko tidak cukup hanya pada nilai rata-rata dan ukuran dispersi. Pola penyebaran *return* serta nilai-nilai ekstrem juga menjadi aspek penting yang perlu diperhatikan. Untuk menggambarkan gambaran persebaran *return* secara lebih komprehensif sekaligus mendeteksi keberadaan pencilan (*outlier*), analisis dilengkapi dengan *boxplot* yang disajikan pada Gambar 4.3.



Gambar 4.3 *Boxplot Return Saham Sektor Industri*

Boxplot return menunjukkan bahwa median *return* harian kesepuluh emiten berada dekat dengan garis nol, sehingga pergeseran rata-rata *return* tidak terlalu besar. Namun, penyebaran dan banyaknya *outlier* untuk setiap emiten menunjukkan karakteristik yang bervariasi. SINI, SMIL, MARK, dan SKRN memiliki rentang interkuartil (*interquartile range/IQR*) yang relatif paling lebar sehingga mencerminkan volatilitas *return* yang tinggi dibandingkan saham lainnya. Dilihat dari persebaran *outlier*, SKRN menunjukkan persebaran *outlier* paling padat dan

tersebar merata ke arah negatif maupun positif, yang mengindikasikan bahwa kejadian return ekstrem terjadi cukup sering pada saham tersebut, diikuti oleh IMPC, HEXA, dan ASII yang juga menunjukkan jumlah *outlier* yang cukup banyak namun dengan IQR yang lebih sempit. Sedangkan emiten lain, seperti TOTO, ARNA, dan UNTR memiliki *outlier* yang lebih sedikit dengan IQR yang lebih sempit. Hal ini menunjukkan bahwa mayoritas *return* hariannya cenderung berada di sekitar nol, meskipun pada waktu tertentu mengalami lonjakan yang cukup ekstrem.

4.2 Estimasi Nilai *Value-at-Risk* dengan Pendekatan AR-GARCH

Dalam penelitian ini, estimasi nilai VaR pada masing-masing emiten dilakukan dengan pendekatan AR-GARCH. Pendekatan AR-GARCH digunakan karena data *return* saham menunjukkan volatilitas yang berubah-ubah dari waktu ke waktu serta adanya nilai ekstrem, sehingga asumsi varians konstan pada model linier biasa menjadi kurang memadai. Kombinasi model AR dan GARCH dinilai tepat untuk memodelkan risiko pada data dengan karakteristik tersebut, karena AR mampu menangkap ketergantungan *return* terhadap nilai masa lalu, sedangkan GARCH menggambarkan dinamika volatilitas bersyarat yang menjadi dasar perhitungan VaR.

Estimasi diawali dengan uji stasioneritas data, dilanjutkan dengan identifikasi orde model AR, estimasi dan uji signifikansi parameter model AR, serta pemilihan model terbaik menggunakan kriteria AIC. Setelah itu, dilakukan pengujian efek ARCH/GARCH melalui *Lagrange Multiplier test*, kemudian diikuti dengan estimasi dan uji signifikansi parameter model GARCH serta pemilihan model GARCH terbaik berdasarkan nilai AIC. Setelah model AR-GARCH tervalidasi, nilai VaR harian untuk masing-masing saham dihitung dan selanjutnya akurasi dievaluasi melalui *backtesting* menggunakan *Proportion Shortfall* dan *Kupiec Test*.

4.2.1 Uji Stasioneritas Data

Model deret waktu seperti AR dan GARCH pada dasarnya dibangun di atas asumsi bahwa data bersifat stasioner dalam mean agar parameter yang diestimasi stabil dan interpretasi hasil model menjadi valid. Dalam penelitian ini, pengujian stasioneritas dilakukan menggunakan *Augmented Dickey Fuller (ADF) test* dengan hipotesis sebagai berikut.

$H_0 : \delta = 0$ (data tidak stasioner dalam *mean*)

$H_1 : \delta < 0$ (data stasioner dalam *mean*)

Hasil uji ADF untuk seluruh *return* saham sektor industri disajikan pada Tabel 4.2.


Tabel 4.2 Output Uji Stasioneritas dalam *Mean*

Saham	Statistik	<i>P-value</i>	Keputusan	Kesimpulan
ASII	-10,4667	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
IMPC	-7,2993	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
UNTR	-8,8127	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
SKRN	-9,2321	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
SINI	-7,4110	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
SMIL	-7,3401	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
ARNA	-7,5728	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
HEXA	-7,1308	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
TOTO	-8,2875	0,01	Tolak H_0	Stasioner dalam <i>mean</i>
MARK	-8,5637	0,01	Tolak H_0	Stasioner dalam <i>mean</i>


Hasil uji stasioneritas dalam *mean* pada Tabel 4.2 menunjukkan bahwa seluruh emiten dalam penelitian ini memiliki nilai *p-value* < 0,05 sehingga pada tingkat signifikansi 5% diperoleh keputusan tolak H_0 yang artinya data *return* saham stasioner dalam *mean*. Pengecekan juga dilakukan terkait stasioneritas dalam varians, namun hasil pada Lampiran 11 menunjukkan bahwa *return* tidak stasioner dalam varians. Hal ini mengindikasikan bahwa varians *residual* pada suatu periode dipengaruhi oleh varians *residual* pada periode sebelumnya, sehingga asumsi varians konstan pada model linier biasa tidak terpenuhi. Oleh karena itu, pemodelan dilakukan dengan menambahkan model yang mampu mengakomodasi kondisi varians ini, yaitu model GARCH yang secara eksplisit memodelkan dinamika varians bersyarat dari waktu ke waktu. Sehingga dari hasil uji stasioneritas yang telah dilakukan, data *return* dapat digunakan dalam pemodelan AR-GARCH tanpa memerlukan transformasi tambahan.

4.2.2 Identifikasi Model AR

Setelah dipastikan data *return* telah stasioner, langkah selanjutnya adalah melakukan identifikasi orde model *autoregressive* (AR) yang akan digunakan untuk memodelkan dinamika *mean return* pada masing-masing emiten. Identifikasi model dilakukan dengan menganalisis pola pada plot *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF) dari data *return* harian. Pola *dies down* secara bertahap pada ACF dan *cut-off* pada PACF memberikan indikasi mengenai banyaknya *lag* yang relevan untuk dimasukkan ke dalam model AR. Adapun Plot ACF dan PACF tiap emiten ditunjukkan pada Gambar 4.4.



Gambar 4.4 Plot ACF dan PACF Saham Sektor Industri



Gambar 4.4 Plot ACF dan PACF Saham Sektor Industri (Lanjutan)

Pola yang terbentuk dari plot ACF dan PACF pada Gambar 4.4 mengindikasikan bahwa dugaan orde model AR untuk masing-masing saham cukup bervariasi. Selanjutnya, *lag-lag* yang signifikan pada tiap emiten selanjutnya dirangkum dan disajikan pada Tabel 4.3.

Tabel 4.3 Lag Signifikan Pada Plot ACF dan PACF

Saham	Lag Signifikan ACF	Lag Signifikan PACF
ASII	1, 2, 10, 12	1, 2, 6, 8, 10, 27
IMPC	2, 4, 9, 10, 12, 13, 14, 15, 17, 19, 24, 26, 29	2, 3, 6, 9, 10, 13, 14, 15, 25, 28
UNTR	2, 8, 17, 20	2, 17, 20
SKRN	4, 8	8
SINI	1, 12	1, 3, 5, 11
SMIL	1, 20	1, 20
ARNA	7, 26	7, 26
HEXA	12, 17	12
TOTO	1	1
MARK	1, 15	1, 12, 15

Hasil *lag* signifikan pada tiap emiten sektor industri yang disajikan pada Tabel 4.3 menunjukkan bahwa sebagian besar memiliki lebih dari satu *lag* signifikan, bahkan pada beberapa saham seperti ASII, IMPC, dan ARNA *lag* signifikan muncul hingga *lag* yang relatif panjang. Apabila semua *lag* yang signifikan dimasukkan ke dalam persamaan *mean*, model AR yang terbentuk akan memiliki orde tinggi dan terlalu kompleks. Untuk menjaga kesederhanaan model (*parsimony*), menghindari overparameterisasi, serta mempertahankan konsistensi struktur persamaan *mean* pada saat pemodelan GARCH, penelitian ini membatasi kandidat model AR hanya pada orde 0, 1, dan 2 dengan tetap mempertimbangkan pola pada plot ACF dan PACF. Orde AR yang dipilih akan ditentukan melalui estimasi dan pengujian signifikansi parameter, uji residual, serta perbandingan nilai AIC.

4.2.3 Estimasi dan Uji Signifikansi Parameter Model AR

Subbab ini memuat hasil estimasi dan pemilihan model AR yang paling sesuai untuk tiap emiten berdasarkan beberapa kandidat orde yang telah ditetapkan sebelumnya. Untuk masing-masing emiten akan diestimasi menggunakan beberapa spesifikasi model AR (misalnya AR(0), AR(1), AR(2)), dilanjutkan dengan uji signifikansi parameter untuk memastikan bahwa koefisien yang diperoleh memberikan kontribusi yang signifikan secara statistik terhadap pergerakan *mean return*. Selanjutnya, model-model yang lolos uji signifikansi parameter dianalisis lebih lanjut melalui uji diagnostik residual untuk melihat apakah masih terdapat autokorelasi yang tersisa sehingga residual dapat memenuhi asumsi *White Noise*. Hanya model yang memenuhi kedua kriteria tersebut yang kemudian dibandingkan menggunakan kriteria *Akaike's Information Criterion* (AIC) untuk menentukan model AR terbaik yang bersifat *parsimonious* untuk setiap saham. Hasil estimasi, pengujian parameter, serta uji diagnostik residual untuk masing-masing saham pada sektor industri disajikan pada subbagian a) hingga j).

a) ASII

Pola autokorelasi saham ASII yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* ke-1 dan ke-2 merupakan *lag* yang signifikan. Berdasarkan pertimbangan ini, pemodelan *mean return* emiten ASII dilakukan dengan menggunakan dua kandidat model, yaitu AR(1) dan AR(2). Dengan tingkat signifikansi 5%, parameter dengan *p-value* di bawah 0,05 menunjukkan pengaruh signifikan terhadap *mean return* ASII. Hasil estimasi dan uji signifikansi parameter untuk kedua model disajikan pada Tabel 4.4.

Tabel 4.4 Hasil Estimasi dan Uji Signifikansi Model AR Saham ASII

Model	Parameter	Estimasi	z_{hitung}	$P\text{-value}$	Kesimpulan
AR(1)	μ	0,0001	0,1947	0,8456	Parameter tidak signifikan
	ϕ_1	-0,1171	-2,8822	0,0039	Parameter signifikan
AR(2)	μ	0,0001	0,2132	0,8311	Parameter tidak signifikan
	ϕ_1	-0,1306	-3,2134	0,0013	Parameter signifikan
	ϕ_2	-0,1147	-2,8248	0,0047	Parameter signifikan

Berdasarkan Tabel 4.4, koefisien di kedua model terbukti signifikan pada taraf signifikansi 5% sedangkan *intercept*-nya memiliki *p-value* lebih besar dari 0,05. Hal ini menunjukkan bahwa komponen *mean* deterministik tidak berperan penting dalam menjelaskan pergerakan *return* harian ASII dan rata-rata *return* saham tersebut secara praktis dapat dianggap mendekati nol. Oleh karena itu, model kemudian diestimasi kembali dengan menspesifikasikan proses AR(1) dan AR(2) tanpa *mean*, yaitu asumsi bahwa nilai harapan *return* ASII sama dengan nol. Hasil reestimasi saham ASII disajikan pada Tabel 4.5.

Tabel 4.5 Hasil Reestimasi dan Uji Signifikansi Model AR Saham ASII

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(1) tanpa konstanta	ϕ_1	-0,1170	-2,8809	0,0406	Parameter signifikan
AR(2) tanpa konstanta	ϕ_1	-0,1305	-3,2115	0,0013	Parameter signifikan
	ϕ_2	-0,1147	-2,8253	0,0047	Parameter signifikan

Hasil reestimasi menunjukkan bahwa koefisien model AR(1) tanpa *mean* dan AR(2) tanpa *mean* tetap signifikan pada taraf 5%, sehingga dinilai cukup untuk merepresentasikan ketergantungan *return* ASII terhadap nilai masa lalunya tanpa perlu menambahkan komponen *intercept* yang tidak signifikan. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model ASII disajikan pada Tabel 4.6.

Tabel 4.6 Hasil Uji *White Noise* Residual Model AR Saham ASII

Model	χ^2_{hitung}	P -value	Keputusan	Kesimpulan
AR(1)	0,1115	0,7384	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(2)	0,0052	0,9423	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(1) tanpa konstanta	0,1123	0,7375	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(2) tanpa konstanta	0,0049	0,9438	Gagal Tolak H_0	Residual <i>White Noise</i>

Karena baik model AR(1) tanpa *mean* dan AR(2) tanpa *mean* untuk saham ASII telah memenuhi kriteria signifikansi parameter dan menghasilkan residual yang memenuhi asumsi *White Noise*, pemilihan *mean* model yang digunakan pada tahap analisis selanjutnya dilakukan berdasarkan kriteria nilai AIC. Model dengan nilai AIC yang lebih kecil dianggap memberikan keseimbangan yang lebih baik antara tingkat kecocokan dan kesederhanaan model. Perbandingan nilai AIC untuk kedua model AR saham ASII ditunjukkan pada Tabel 4.7.

Tabel 4.7 Perbandingan Nilai AIC Model AR Saham ASII

Model	χ^2_{hitung}
AR(1) tanpa konstanta	-3156,142
AR(2) tanpa konstanta	-3162,073

Berdasarkan **Tabel 4.7**, nilai AIC untuk model AR(2) tanpa *mean* tercatat lebih kecil dibandingkan dengan model AR(1) tanpa *mean*, sehingga secara kriteria informasi model AR(2) tanpa *mean* dipilih sebagai spesifikasi terbaik untuk *mean return* saham ASII. Dengan demikian, persamaan *mean* yang digunakan untuk saham ASII pada tahap pemodelan GARCH dan perhitungan VaR selanjutnya adalah model AR(2) tanpa *mean*.

b) IMPC

Pola autokorelasi saham IMPC yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* ke-2 merupakan *lag* yang paling dominan, dengan koefisien autokorelasi yang signifikan pada plot ACF maupun PACF. Oleh karenanya, pemodelan *mean return* IMPC diawali dengan spesifikasi model AR(2). Hasil estimasi awal menunjukkan bahwa koefisien AR(2) dan *intercept* signifikan pada taraf 5%, sedangkan koefisien AR(1) memiliki p -value sekitar 0,55 sehingga koefisien AR(1) tidak memenuhi kriteria signifikansi parameter pada taraf 5%.

Untuk mengatasi kondisi tersebut, dilakukan serangkaian spesifikasi lanjutan untuk memperoleh struktur *mean* yang lebih *parsimonious* namun tetap memadai. Pertama, model AR(2) diestimasi kembali tanpa *intercept* untuk melihat apakah penghapusan *intercept* dapat meningkatkan signifikansi koefisien, namun hasilnya menunjukkan bahwa koefisien AR(2) tetap signifikan sementara AR(1) masih belum signifikan. Selanjutnya, diterapkan pendekatan subset AR(2) dengan hanya mempertahankan *lag* ke-2 dan mengasumsikan koefisien *lag* ke-1 bernilai nol. Spesifikasi subset ini terlebih dahulu diestimasi dengan *intercept* dan diperoleh

hasil baik *intercept* dan koefisien sudah terbukti signifikan pada taraf 5%. Ringkasan hasil estimasi dan uji signifikansi parameter untuk ketiga spesifikasi model tersebut disajikan pada Tabel 4.8.

Tabel 4.8 Hasil Estimasi dan Uji Signifikansi Model AR Saham IMPC

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(2)	μ	0,0044	2,6272	0,0086	Parameter signifikan
	ϕ_1	-0,0236	-0,5945	0,5522	Parameter tidak signifikan
	ϕ_2	0,2478	6,2461	0,0000	Parameter signifikan
AR(2) tanpa konstanta	ϕ_1	-0,0094	-0,2392	0,811	Parameter tidak signifikan
	ϕ_2	0,2618	6,6250	0,0000	Parameter signifikan
AR([2])	μ	0,0044	2,5432	0,011	Parameter signifikan
	ϕ_2	0,2485	6,2628	0,0000	Parameter signifikan

Berdasarkan Tabel 4.8, dapat dilihat bahwa koefisien AR(2) dan *intercept* konsisten signifikan pada taraf 5% di seluruh spesifikasi model, sedangkan koefisien AR(1) tidak signifikan pada semua model. Pola ini menunjukkan bahwa pergerakan *return* IMPC ditentukan oleh *lag* ke-2 dan *intercept*, sementara kontribusi *lag* ke-1 tidak cukup kuat secara statistik untuk dipertahankan dalam model. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model AR saham IMPC disajikan pada Tabel 4.9.

Tabel 4.9 Hasil Uji *White Noise* Residual Model AR Saham IMPC

Model	χ^2_{hitung}	P -value	Keputusan	Kesimpulan
AR(2)	0,2896	0,5905	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(2) tanpa konstanta	0,8296	0,3624	Gagal Tolak H_0	Residual <i>White Noise</i>
AR([2])	1,2465	0,2642	Gagal Tolak H_0	Residual <i>White Noise</i>

Hasil pada Tabel 4.9 menunjukkan bahwa p -value uji *Ljung-Box* untuk seluruh spesifikasi model berada di atas 0,05. Dengan kata lain, residual dari ketiga model dapat dianggap telah memenuhi asumsi *White Noise* dan tidak lagi mengandung autokorelasi yang berarti. Namun, jika dikombinasikan dengan hasil uji signifikansi parameter pada Tabel 4.8, hanya model AR([2]) yang memenuhi kedua kriteria kelayakan, yaitu seluruh parameter yang dipertahankan signifikan secara statistik dan residual memenuhi asumsi *White Noise*. Oleh karena itu, model subset AR([2]) dipilih sebagai *mean* model yang digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham IMPC, tanpa diperlukan perbandingan tambahan menggunakan kriteria AIC karena spesifikasi lainnya gugur pada tahap uji signifikansi parameter.

c) UNTR

Hasil identifikasi emiten UNTR yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* ke-2 merupakan *lag* yang paling dominan, dengan koefisien autokorelasi yang signifikan pada plot ACF maupun PACF. Oleh karena itu, pemodelan *return* UNTR diawali dengan spesifikasi model AR(2). Estimasi awal menunjukkan bahwa koefisien AR(2) signifikan pada taraf 5%, sedangkan koefisien AR(1) dan *intercept* tidak signifikan. Untuk memperoleh struktur *mean* yang lebih sederhana dan hanya mempertahankan komponen yang berkontribusi secara statistik, model kemudian diestimasi ulang dengan model AR(2) tanpa *mean*. Pada spesifikasi ini koefisien AR(2) tetap signifikan, sementara AR(1) masih tidak signifikan. Selanjutnya, dilakukan pemangkasan lebih lanjut dengan menggunakan subset AR([2]) yang hanya mempertahankan *lag* ke-2, namun hasil estimasi menunjukkan bahwa *intercept* tetap tidak

signifikan. Tahap terakhir adalah mengestimasi model subset AR([2]) tanpa *mean* sehingga hanya koefisien AR(2) yang dipertahankan, dan pada spesifikasi ini parameter tersebut terbukti signifikan. Hasil estimasi dan uji signifikansi parameter untuk keempat spesifikasi model AR saham UNTR disajikan pada Tabel 4.10.

Tabel 4.10 Hasil Estimasi dan Uji Signifikansi Model AR Saham UNTR

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(2)	μ	0,0006	0,9269	0,3540	Parameter tidak signifikan
	ϕ_1	-0,0604	-1,4903	0,1361	Parameter tidak signifikan
	ϕ_2	-0,1409	-3,4775	0,0005	Parameter signifikan
AR(2) tanpa konstanta	ϕ_1	-0,0590	-1,4568	0,1452	Parameter tidak signifikan
	ϕ_2	-0,1397	-3,4477	0,0006	Parameter signifikan
AR([2])	μ	0,0006	0,8760	0,3810	Parameter tidak signifikan
	ϕ_2	-0,1377	-3,3972	0,0007	Parameter signifikan
AR([2]) tanpa konstanta	ϕ_2	-0,1366	-3,3706	0,0000	Parameter signifikan

Berdasarkan Tabel 4.10, terlihat bahwa koefisien AR(2) konsisten signifikan pada taraf 5% di seluruh spesifikasi model, sedangkan *intercept* dan koefisien AR(1) tidak signifikan pada semua model. Pola ini menunjukkan bahwa dinamika *return* UNTR ditentukan oleh lag ke-2, sementara kontribusi *intercept* dan lag ke-1 tidak cukup kuat secara statistik untuk dipertahankan dalam model. Untuk memastikan kelayakan model dari sisi diagnostik, selanjutnya dilakukan uji residual menggunakan uji *Ljung-Box* pada taraf signifikansi 5%. Hasil uji *White Noise* residual untuk model AR saham UNTR disajikan pada Tabel 4.11.

Tabel 4.11 Hasil Uji *White Noise* Residual Model AR Saham UNTR

Model	χ^2_{hitung}	P -value	Keputusan	Kesimpulan
AR(2)	0,0001	0,9917	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(2) tanpa konstanta	0,0005	0,9815	Gagal Tolak H_0	Residual <i>White Noise</i>
AR([2])	2,1413	0,1434	Gagal Tolak H_0	Residual <i>White Noise</i>
AR([2]) tanpa konstanta	2,1388	0,1436	Gagal Tolak H_0	Residual <i>White Noise</i>

Hasil pada Tabel 4.11 menunjukkan bahwa p -value uji *Ljung-Box* untuk seluruh spesifikasi model berada di atas 0,05. Dengan kata lain, residual dari keempat model dapat dianggap telah memenuhi asumsi *White Noise* dan tidak lagi mengandung autokorelasi yang berarti. Namun, jika dikombinasikan dengan hasil uji signifikansi parameter pada Tabel 4.10, hanya model AR([2]) tanpa *mean* yang memenuhi kedua kriteria kelayakan, yaitu seluruh parameter yang dipertahankan signifikan secara statistik dan residual memenuhi asumsi *White Noise*. Oleh karena itu, model subset AR([2]) tanpa *mean* dipilih sebagai *mean* model yang digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham UNTR, tanpa diperlukan perbandingan tambahan menggunakan kriteria AIC karena spesifikasi model lainnya gugur pada tahap uji signifikansi parameter.

d) SKRN

Hasil identifikasi saham SKRN yang disajikan pada Gambar 4.4 menunjukkan bahwa lag signifikan pada plot ACF dan PACF muncul pada lag ke-4 dan 8, yang merupakan lag dengan orde cukup tinggi. Untuk menjaga kesederhanaan model serta konsistensi spesifikasi *mean* antar emiten, penelitian ini membatasi pemodelan hanya pada orde AR rendah. Oleh karena itu, pemodelan *return* SKRN diawali dengan beberapa spesifikasi AR orde rendah, yaitu AR(1)

dan AR(2), masing-masing dengan dan tanpa *intercept*. Hasil estimasi dan uji signifikansi parameter untuk seluruh spesifikasi model AR saham SKRN disajikan pada Tabel 4.12.

Tabel 4.12 Hasil Estimasi dan Uji Signifikansi Model AR Saham SKRN

Model	Parameter	Estimasi	z_{hitung}	$P-value$	Kesimpulan
AR(1)	μ	0,0008	0,4721	0,6369	Parameter tidak signifikan
	ϕ_1	-0,0108	-0,2613	0,7939	Parameter tidak signifikan
AR(1) tanpa konstanta	ϕ_1	-0,0106	-0,2547	0,799	Parameter tidak signifikan
AR(2)	μ	0,0008	0,4879	0,6256	Parameter tidak signifikan
	ϕ_1	-0,0119	-0,2862	0,7747	Parameter tidak signifikan
	ϕ_2	-0,0526	-1,2679	0,2048	Parameter tidak signifikan
AR(2) tanpa konstanta	ϕ_1	-0,0116	-0,2789	0,7803	Parameter tidak signifikan
	ϕ_2	-0,0523	-1,2623	0,2068	Parameter tidak signifikan

Berdasarkan Tabel 4.12, diperoleh seluruh parameter pada keempat spesifikasi model, baik *intercept* maupun koefisien AR(1) dan AR(2) memiliki $p-value$ yang lebih besar dari 0,05 sehingga tidak signifikan pada taraf signifikansi 5%. Hal ini menunjukkan bahwa, meskipun terdapat *lag* signifikan pada orde yang lebih tinggi pada plot ACF dan PACF, ketergantungan linier *return* SKRN terhadap *lag* rendah tidak cukup kuat secara statistik, dan komponen *mean* deterministik maupun *autoregressive* orde rendah tidak memberikan kontribusi yang berarti terhadap pergerakan *return* harian. Selanjutnya *return* SKRN dimodelkan sebagai proses AR(0), yaitu model tanpa komponen AR dan *intercept*, di mana *return* harian dianggap sepenuhnya direpresentasikan oleh komponen *error*. Sedangkan dinamika ketergantungan waktu akan dimodelkan melalui komponen volatilitas bersyarat pada model GARCH dalam perhitungan VaR jika SKRN memiliki efek ARCH.

e) SINI

Hasil identifikasi saham SINI yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* ke-1 merupakan *lag* yang signifikan. Berdasarkan pertimbangan tersebut, pemodelan mean return untuk SINI dilakukan dengan menggunakan AR(1). Uji signifikansi parameter dilakukan pada tingkat signifikansi 5%, sehingga parameter dengan $p-value$ di bawah 0,05 dianggap berpengaruh signifikan terhadap *mean* return SINI. Hasil estimasi dan uji signifikansi parameter untuk model AR(1) tersebut disajikan pada Tabel 4.13.

Tabel 4.13 Hasil Estimasi dan Uji Signifikansi Model AR Saham SINI

Model	Parameter	Estimasi	z_{hitung}	$P-value$	Kesimpulan
AR(1)	μ	0,0053	1,7445	0,0811	Parameter tidak signifikan
	ϕ_1	0,3063	7,8712	0,0000	Parameter signifikan

Berdasarkan Tabel 4.13, koefisien AR(1) terbukti signifikan pada taraf signifikansi 5%, sedangkan *intercept* memiliki $p-value$ yang lebih besar dari 0,05 sehingga tidak signifikan secara statistik. Kondisi ini mengindikasikan bahwa komponen *mean* deterministik tidak berperan penting dalam menjelaskan pergerakan *return* harian SINI dan rata-rata *return* saham tersebut secara praktis dapat dianggap mendekati nol. Oleh karena itu, model direestimasi dengan menspesifikasikan proses AR(1) tanpa *mean*, yaitu dengan mengasumsikan bahwa nilai harapan *return* harian SINI sama dengan nol. Hasil estimasi model AR(1) tanpa *mean* disajikan pada Tabel 4.14.

Tabel 4.14 Hasil Reestimasi dan Uji Signifikansi Model AR Saham SINI

Model	Parameter	Estimasi	z_{hitung}	$P-value$	Kesimpulan
AR(1) tanpa konstanta	ϕ_1	0,3129	8,0607	0,0000	Parameter signifikan

Hasil reestimasi menunjukkan bahwa koefisien AR(1) tetap signifikan pada taraf 5%, sehingga proses AR(1) tanpa *mean* dinilai cukup untuk merepresentasikan ketergantungan *return* SINI terhadap nilai masa lalunya tanpa perlu menambahkan komponen *intercept* yang tidak signifikan. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model SINI disajikan pada Tabel 4.15.

Tabel 4.15 Hasil Uji *White Noise* Residual Model AR Saham SINI

Model	χ^2_{hitung}	<i>P-value</i>	Keputusan	Kesimpulan
AR(1)	0,0259	0,8721	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(1) tanpa konstanta	0,0000	0,997	Gagal Tolak H_0	Residual <i>White Noise</i>

Tabel 4.15 menunjukkan bahwa *p-value* lebih besar dari 0,05, sehingga pada taraf signifikansi 5% tidak terdapat cukup bukti untuk menolak H_0 . Dengan demikian, residual model AR(1) dan AR(1) tanpa *mean* dapat dianggap telah memenuhi asumsi *White Noise*. Berdasarkan hasil tersebut, model AR(1) tanpa *mean* untuk saham SINI memenuhi dua kriteria, yaitu parameter yang signifikan secara statistik dan residual yang telah memenuhi asumsi *White Noise* sedangkan AR(1) hanya memenuhi salah satu kriteria. Karena dalam kasus ini hanya ditemukan satu spesifikasi model yang layak, maka tidak perlu dilakukan perbandingan kriteria menggunakan nilai AIC. Oleh karena itu, model AR(1) tanpa *mean* ditetapkan sebagai persamaan *mean* yang akan digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham SINI.

f) SMIL

Hasil identifikasi saham SMIL yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* ke-1 merupakan *lag* yang signifikan. Berdasarkan pertimbangan tersebut, pemodelan mean *return* untuk SMIL dilakukan dengan menggunakan AR(1). Uji signifikansi parameter dilakukan pada tingkat signifikansi 5%, sehingga parameter dengan *p-value* di bawah 0,05 dianggap berpengaruh signifikan terhadap mean *return* SMIL. Hasil estimasi dan uji signifikansi parameter untuk model AR(1) tersebut disajikan pada Tabel 4.16.

Tabel 4.16 Hasil Estimasi dan Uji Signifikansi Model AR Saham SMIL

Model	Parameter	Estimasi	z_{hitung}	<i>P-value</i>	Kesimpulan
AR(1)	μ	0,0028	1,0995	0,2716	Parameter tidak signifikan
	ϕ_1	0,1165	2,8685	0,0041	Parameter signifikan

Berdasarkan Tabel 4.16, koefisien AR(1) terbukti signifikan pada taraf signifikansi 5%, sedangkan *intercept* memiliki *p-value* yang lebih besar dari 0,05 sehingga tidak signifikan secara statistik. Kondisi ini mengindikasikan bahwa komponen *mean* deterministik tidak berperan penting dalam menjelaskan pergerakan *return* harian SMIL dan rata-rata *return* saham tersebut secara praktis dapat dianggap mendekati nol. Oleh karena itu, model direestimasi dengan menspesifikasikan proses AR(1) tanpa *mean*, yaitu dengan mengasumsikan bahwa nilai harapan *return* harian SMIL sama dengan nol. Hasil estimasi model AR(1) tanpa *mean* disajikan pada Tabel 4.17.

Tabel 4.17 Hasil Reestimasi dan Uji Signifikansi Model AR Saham SMIL

Model	Parameter	Estimasi	z_{hitung}	<i>P-value</i>	Kesimpulan
AR(1) tanpa konstanta	ϕ_1	0,1188	2,9249	0,0034	Parameter signifikan

Hasil reestimasi menunjukkan bahwa koefisien AR(1) tetap signifikan pada taraf 5%, sehingga proses AR(1) tanpa *mean* dinilai cukup untuk merepresentasikan ketergantungan

return SMIL terhadap nilai masa lalunya tanpa perlu menambahkan komponen *intercept* yang tidak signifikan. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model SMIL disajikan pada Tabel 4.18.

Tabel 4.18 Hasil Uji *White Noise* Residual Model AR Saham SMIL

Model	χ^2_{hitung}	<i>P-value</i>	Keputusan	Kesimpulan
AR(1)	0,0265	0,8708	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(1) tanpa konstanta	0,0490	0,8248	Gagal Tolak H_0	Residual <i>White Noise</i>

Tabel 4.18 menunjukkan bahwa *p-value* lebih besar dari 0,05. Dengan demikian, residual model AR(1) dan AR(1) tanpa *mean* telah memenuhi asumsi *White Noise*. Berdasarkan hasil tersebut, model AR(1) tanpa *mean* untuk saham SMIL memenuhi dua kriteria, yaitu parameter yang signifikan secara statistik dan residual yang telah memenuhi asumsi *White Noise* sedangkan AR(1) hanya memenuhi salah satu kriteria. Karena dalam kasus ini hanya ditemukan satu spesifikasi model yang layak, maka tidak perlu dilakukan perbandingan kriteria menggunakan nilai AIC. Oleh karena itu, model AR(1) tanpa *mean* ditetapkan sebagai persamaan *mean* yang akan digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham SMIL.

g) ARNA

Hasil identifikasi saham ARNA yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* signifikan pada plot ACF dan PACF muncul pada *lag* ke-7 dan 26, yang merupakan *lag* dengan orde cukup tinggi. Untuk menjaga kesederhanaan model serta konsistensi spesifikasi *mean* antar emiten, penelitian ini membatasi pemodelan hanya pada orde AR rendah. Oleh karena itu, pemodelan *return* ARNA diawali dengan beberapa spesifikasi AR orde rendah, yaitu AR(1) dan AR(2), masing-masing dengan dan tanpa *intercept*. Hasil estimasi dan uji signifikansi parameter untuk seluruh spesifikasi model AR saham ARNA disajikan pada Tabel 4.19.

Tabel 4.19 Hasil Estimasi dan Uji Signifikansi Model AR Saham ARNA

Model	Parameter	Estimasi	z_{hitung}	<i>P-value</i>	Kesimpulan
AR(1)	μ	-0,0008	-1,1868	0,2353	Parameter tidak signifikan
	ϕ_1	0,0389	0,9515	0,3413	Parameter tidak signifikan
AR(1) tanpa konstanta	ϕ_1	0,0414	1,0132	0,311	Parameter tidak signifikan
AR(2)	μ	-0,0008	-1,1462	0,2517	Parameter tidak signifikan
	ϕ_1	0,0379	0,9269	0,3540	Parameter tidak signifikan
	ϕ_2	0,0262	0,6416	0,5211	Parameter tidak signifikan
AR(2) tanpa konstanta	ϕ_1	0,0402	0,9841	0,3251	Parameter tidak signifikan
	ϕ_2	0,0287	0,7014	0,4831	Parameter tidak signifikan

Berdasarkan Tabel 4.19, diperoleh seluruh parameter pada keempat spesifikasi model, baik *intercept* maupun koefisien AR(1) dan AR(2) memiliki *p-value* yang lebih besar dari 0,05 sehingga tidak signifikan pada taraf signifikansi 5%. Hal ini menunjukkan bahwa meskipun terdapat *lag* signifikan pada orde yang lebih tinggi pada plot ACF dan PACF, ketergantungan linier *return* ARNA terhadap *lag* rendah tidak cukup kuat secara statistik, dan komponen *mean* deterministik maupun *autoregressive* orde rendah tidak memberikan kontribusi yang berarti terhadap pergerakan *return* harian. Selanjutnya *return* ARNA dimodelkan sebagai proses AR(0), yaitu model tanpa komponen AR dan *intercept*, di mana *return* harian dianggap sepenuhnya direpresentasikan oleh komponen *error*. Sedangkan dinamika ketergantungan

waktu akan dimodelkan melalui komponen volatilitas bersyarat pada model GARCH dalam perhitungan VaR jika ARNA memiliki efek ARCH.

h) HEXA

Hasil identifikasi saham HEXA yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* signifikan pada plot ACF dan PACF muncul pada *lag* ke-12 dan 17, yang merupakan *lag* dengan orde cukup tinggi. Untuk menjaga kesederhanaan model serta konsistensi spesifikasi *mean* antar emiten, penelitian ini membatasi pemodelan hanya pada orde AR rendah. Oleh karena itu, pemodelan *return* HEXA diawali dengan beberapa spesifikasi AR orde rendah, yaitu AR(1) dan AR(2), masing-masing dengan dan tanpa *intercept*. Hasil estimasi dan uji signifikansi parameter untuk seluruh spesifikasi model AR saham HEXA disajikan pada Tabel 4.20.

Tabel 4.20 Hasil Estimasi dan Uji Signifikansi Model AR Saham HEXA

Model	Parameter	Estimasi	Z_{hitung}	$P\text{-value}$	Kesimpulan
AR(1)	μ	-0,0004	-0,6709	0,5023	Parameter tidak signifikan
	ϕ_1	0,0520	1,2821	0,1998	Parameter tidak signifikan
AR(1) tanpa konstanta	ϕ_1	0,0535	1,3038	0,1923	Parameter tidak signifikan
AR(2)	μ	-0,0004	-0,6582	0,5104	Parameter tidak signifikan
	ϕ_1	0,0516	1,2569	0,2088	Parameter tidak signifikan
	ϕ_2	0,0175	0,4259	0,6702	Parameter tidak signifikan
AR(2) tanpa konstanta	ϕ_1	0,0524	1,2766	0,2018	Parameter tidak signifikan
	ϕ_2	0,0183	0,4452	0,6562	Parameter tidak signifikan

Berdasarkan Tabel 4.20, diperoleh seluruh parameter pada keempat spesifikasi model, baik *intercept* maupun koefisien AR(1) dan AR(2) memiliki $p\text{-value}$ yang lebih besar dari 0,05 sehingga tidak signifikan pada taraf signifikansi 5%. Hal ini menunjukkan bahwa meskipun terdapat *lag* signifikan pada orde yang lebih tinggi pada plot ACF dan PACF, ketergantungan linier *return* HEXA terhadap *lag* rendah tidak cukup kuat secara statistik, dan komponen *mean* deterministik maupun *autoregressive* orde rendah tidak memberikan kontribusi yang berarti terhadap pergerakan *return* harian. Selanjutnya *return* HEXA dimodelkan sebagai proses AR(0), yaitu model tanpa komponen AR dan *intercept*, di mana *return* harian dianggap sepenuhnya direpresentasikan oleh komponen *error*. Sedangkan dinamika ketergantungan waktu akan dimodelkan melalui komponen volatilitas bersyarat pada model GARCH dalam perhitungan VaR jika HEXA memiliki efek ARCH.

i) TOTO

Hasil identifikasi saham TOTO yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* signifikan yang ditunjukkan plot ACF dan PACF muncul pada *lag* ke-1. Oleh karena itu, pemodelan *return* TOTO menggunakan spesifikasi model AR(1). Uji signifikansi parameter dilakukan pada tingkat signifikansi 5%, sehingga parameter dengan $p\text{-value}$ di bawah 0,05 dianggap berpengaruh signifikan terhadap mean return TOTO. Hasil estimasi dan uji signifikansi parameter untuk model AR(1) tersebut disajikan pada Tabel 4.21.

Tabel 4.21 Hasil Estimasi dan Uji Signifikansi Model AR Saham TOTO

Model	Parameter	Estimasi	Z_{hitung}	$P\text{-value}$	Kesimpulan
AR(1)	μ	0,0003	0,8004	0,4235	Parameter tidak signifikan
	ϕ_1	-0,1060	-2,6052	0,0092	Parameter signifikan

Berdasarkan Tabel 4.21, terlihat bahwa koefisien AR(1) terbukti signifikan pada taraf signifikansi 5%, sedangkan *intercept* memiliki $p\text{-value}$ yang lebih besar dari 0,05 sehingga

tidak signifikan secara statistik. Kondisi ini mengindikasikan bahwa komponen *mean* deterministik tidak berperan penting dalam menjelaskan pergerakan *return* harian TOTO dan rata-rata *return* saham tersebut secara praktis dapat dianggap mendekati nol. Oleh karena itu, model direestimasi dengan menspesifikasikan proses AR(1) tanpa *mean*, yaitu dengan mengasumsikan bahwa nilai harapan *return* harian TOTO sama dengan nol. Hasil estimasi model AR(1) tanpa *mean* disajikan pada Tabel 4.22.

Tabel 4.22 Hasil Reestimasi dan Uji Signifikansi Model AR Saham TOTO

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(1) tanpa konstanta	ϕ_1	-0,1051	-2,5827	0,0098	Parameter signifikan

Hasil reestimasi menunjukkan bahwa koefisien AR(1) tetap signifikan pada taraf 5%, sehingga proses AR(1) tanpa *mean* dinilai cukup untuk merepresentasikan ketergantungan *return* TOTO terhadap nilai masa lalunya tanpa perlu menambahkan komponen *intercept* yang tidak signifikan. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model TOTO disajikan pada Tabel 4.23.

Tabel 4.23 Hasil Uji *White Noise* Residual Model AR Saham TOTO

Model	χ^2_{hitung}	P -value	Keputusan	Kesimpulan
AR(1)	0,01997	0,8876	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(1) tanpa konstanta	0,0263	0,8711	Gagal Tolak H_0	Residual <i>White Noise</i>

Tabel 4.23 menunjukkan bahwa p -value lebih besar dari 0,05. Dengan demikian, residual model AR(1) dan AR(1) tanpa *mean* telah memenuhi asumsi *White Noise*. Berdasarkan hasil tersebut, model AR(1) tanpa *mean* untuk saham TOTO memenuhi dua kriteria, yaitu parameter yang signifikan secara statistik dan residual yang telah memenuhi asumsi *White Noise* sedangkan AR(1) hanya memenuhi salah satu kriteria. Karena dalam kasus ini hanya ditemukan satu spesifikasi model yang layak, maka tidak perlu dilakukan perbandingan kriteria menggunakan nilai AIC. Oleh karena itu, model AR(1) tanpa *mean* ditetapkan sebagai persamaan *mean* yang akan digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham TOTO.

j) MARK

Hasil identifikasi saham MARK yang disajikan pada Gambar 4.4 menunjukkan bahwa *lag* signifikan yang ditunjukkan plot ACF dan PACF muncul pada *lag* ke-1. Oleh karena itu, pemodelan *return* MARK menggunakan spesifikasi model AR(1). Uji signifikansi parameter dilakukan pada tingkat signifikansi 5%, sehingga parameter dengan p -value di bawah 0,05 dianggap berpengaruh signifikan terhadap mean return MARK. Hasil estimasi dan uji signifikansi parameter untuk model AR(1) tersebut disajikan pada Tabel 4.24.

Tabel 4.24 Hasil Estimasi dan Uji Signifikansi Model AR Saham MARK

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(1)	μ	0,0008	0,8593	0,3902	Parameter tidak signifikan
	ϕ_1	-0,1091	-2,6834	0,0073	Parameter signifikan

Berdasarkan Tabel 4.24, terlihat bahwa koefisien AR(1) terbukti signifikan pada taraf signifikansi 5%, sedangkan *intercept* memiliki p -value yang lebih besar dari 0,05 sehingga tidak signifikan secara statistik. Kondisi ini mengindikasikan bahwa komponen *mean* deterministik tidak berperan penting dalam menjelaskan pergerakan *return* harian MARK dan rata-rata *return* saham tersebut secara praktis dapat dianggap mendekati nol. Oleh karena itu,

model direestimasi dengan menspesifikasikan proses AR(1) tanpa *mean*, yaitu dengan mengasumsikan bahwa nilai harapan *return* harian MARK sama dengan nol. Hasil estimasi model AR(1) tanpa *mean* disajikan pada Tabel 4.25.

Tabel 4.25 Hasil Reestimasi dan Uji Signifikansi Model AR Saham MARK

Model	Parameter	Estimasi	z_{hitung}	P -value	Kesimpulan
AR(1) tanpa konstanta	ϕ_1	-0,1080	-2,6552	0,0079	Parameter signifikan

Hasil reestimasi menunjukkan bahwa koefisien AR(1) tetap signifikan pada taraf 5%, sehingga proses AR(1) tanpa *mean* dinilai cukup untuk merepresentasikan ketergantungan *return* MARK terhadap nilai masa lalunya tanpa perlu menambahkan komponen *intercept* yang tidak signifikan. Analisis dilanjutkan dengan uji diagnostik residual untuk memastikan bahwa residual masing-masing model tidak lagi mengandung autokorelasi yang berarti. Hasil uji *White Noise* residual model MARK disajikan pada Tabel 4.26.

Tabel 4.26 Hasil Uji *White Noise* Residual Model AR Saham MARK

Model	χ^2_{hitung}	P -value	Keputusan	Kesimpulan
AR(1)	0,0023	0,9611	Gagal Tolak H_0	Residual <i>White Noise</i>
AR(1) tanpa konstanta	0,0058	0,939	Gagal Tolak H_0	Residual <i>White Noise</i>

Tabel 4.26 menunjukkan bahwa p -value lebih besar dari 0,05. Dengan demikian, residual model AR(1) dan AR(1) tanpa *mean* telah memenuhi asumsi *White Noise*. Berdasarkan hasil tersebut, model AR(1) tanpa *mean* untuk saham MARK memenuhi dua kriteria, yaitu parameter yang signifikan secara statistik dan residual yang telah memenuhi asumsi *White Noise* sedangkan AR(1) hanya memenuhi salah satu kriteria. Karena dalam kasus ini hanya ditemukan satu spesifikasi model yang layak, maka tidak perlu dilakukan perbandingan kriteria menggunakan nilai AIC. Oleh karena itu, model AR(1) tanpa *mean* ditetapkan sebagai persamaan *mean* yang akan digunakan pada tahap pemodelan GARCH dan perhitungan VaR untuk saham MARK.

Dari estimasi dan uji signifikansi parameter model AR, Tabel 4.27 merupakan ringkasan model terpilih untuk seluruh emiten saham sektor industri.

Tabel 4.27 Ringkasan Model AR Terpilih

Saham	Model AR Terpilih
ASII	AR(2) tanpa konstanta
IMPC	AR([2])
UNTR	AR([2]) tanpa konstanta
SKRN	AR(0)
SINI	AR(1) tanpa konstanta
SMIL	AR(1) tanpa konstanta
ARNA	AR(0)
HEXA	AR(0)
TOTO	AR(1) tanpa konstanta
MARK	AR(1) tanpa konstanta

Selanjutnya dilakukan pengujian *Lagrange Multiplier* untuk mengecek apakah ada efek heteroskedastisitas pada residual model sebelum dilanjutkan ke pemodelan GARCH.

4.2.4 *Lagrange Multiplier Test*

Sebelum melanjutkan ke tahap pemodelan volatilitas menggunakan GARCH, diperlukan pengujian awal untuk mengetahui apakah residual dari persamaan mean masing-masing saham mengandung efek heteroskedastisitas bersyarat (*ARCH effect*). Pengujian ini dilakukan dengan

menggunakan *Lagrange Multiplier* (LM) *test* untuk ARCH, dengan hipotesis nol (H_0) tidak terdapat efek ARCH (varian residual konstan dari waktu ke waktu) dan hipotesis alternatif (H_1) terdapat efek ARCH, sehingga varians residual berubah-ubah dan layak dimodelkan menggunakan GARCH. LM *test* diterapkan pada residual model AR yang telah dipilih untuk setiap saham, dengan taraf signifikansi 5%. Ringkasan hasil LM *test* untuk seluruh saham sektor industri disajikan pada Tabel 4.28.

Tabel 4.28 Hasil *Lagrange Multiplier Test* Tiap Saham

Saham	Statistik	<i>P-value</i>	Keputusan	Kesimpulan
ASII	5,5955	0,9351	Gagal Tolak H_0	Tidak terdapat efek ARCH
IMPC	61,284	0,0000	Tolak H_0	Terdapat efek ARCH
UNTR	6,3143	0,8994	Gagal Tolak H_0	Tidak terdapat efek ARCH
SKRN	36,483	0,0003	Tolak H_0	Terdapat efek ARCH
SINI	162,86	0,0000	Tolak H_0	Terdapat efek ARCH
SMIL	123,65	0,0000	Tolak H_0	Terdapat efek ARCH
ARNA	48,279	0,0000	Tolak H_0	Terdapat efek ARCH
HEXA	2,2997	0,9988	Gagal Tolak H_0	Tidak terdapat efek ARCH
TOTO	5,1055	0,9544	Gagal Tolak H_0	Tidak terdapat efek ARCH
MARK	23,23	0,0258	Tolak H_0	Terdapat efek ARCH

Berdasarkan Tabel 4.28, terdapat 6 emiten yang mengindikasikan efek ARCH pada residual masing-masing saham yang ditunjukkan oleh nilai *p-value* $< 0,05$, sehingga pemodelan volatilitas menggunakan model GARCH menjadi relevan. Enam emiten ini adalah IMPC, SKRN, SINI, SMIL, ARNA, dan MARK. Sebaliknya, *p-value* saham ASII, UNTR, HEXA, dan TOTO berada di atas 0,05 sehingga diperoleh keputusan Gagal Tolak H_0 , mengindikasikan tidak ditemukan efek ARCH pada residual keempat emiten tersebut. Estimasi model GARCH selanjutnya akan difokuskan pada keenam saham yang menunjukkan adanya efek ARCH pada residual modelnya. Adapun skenario perhitungan VaR berdasarkan model AR-GARCH yang terpilih ditunjukkan pada Tabel 4.29.

Tabel 4.29 Skenario Perhitungan VaR

No	Model	Persamaan VaR	Emiten
1	AR-GARCH	$\widehat{VaR}_t(\tau) = \hat{\mu}_t + \hat{\sigma}_t \cdot q_{\xi,v}^{std}(\tau)$	IMPC, SINI, SMIL, ARNA, MARK
2	AR saja	$\widehat{VaR}_t(\tau) = \hat{\mu}_t + \hat{\sigma}_t \cdot q_{\xi,v}^{std}(\tau)$	ASII, UNTR, TOTO
3	GARCH saja	$\widehat{VaR}_t(\tau) = \hat{\sigma}_t \cdot q_{\xi,v}^{std}(\tau)$	SKRN
4	Tanpa AR-GARCH	$\widehat{VaR}_t(\tau) = \hat{\sigma}_t \cdot q_{\xi,v}^{std}(\tau)$	HEXA

Skenario yang dijelaskan pada Tabel 4.29 akan digunakan sebagai acuan untuk menghitung nilai VaR untuk setiap saham sektor industri berdasarkan model AR-GARCH yang sesuai dengan hasil estimasi dan signifikansi paramedel model masing-masing saham.

4.2.5 Estimasi dan Uji Signifikansi Model GARCH

Subbab ini berisi estimasi dan pemilihan mdoel GARCH untuk emiten yang terbukti memiliki efek ARCH sebagaimana ditunjukkan pada Tabel 4.27, yaitu IMPC, SKRN, SINI, SMIL, ARNA, dan MARK. Pemodelan volatilitas bersyarat untuk setiap saham dilakukan dengan menggunakan beberapa spesifikasi orde rendah guna menjaga kesederhanaan model, yaitu kombinasi GARCH(1,0), GARCH(0,1), dan GARCH(1,1) yang masing-masing dikombinasikan dengan persamaan *mean* sesuai dengan hasil pemilihan model AR pada subbab sebelumnya. Setiap spesifikasi model diestimasi dan parameter-parameter pada persamaan varians diuji signifikansinya pada taraf signifikansi 5%. Hanya koefisien dengan *p-value* kurang dari 0,05 yang dianggap memiliki pengaruh signifikan terhadap dinamika volatilitas

return. Hasil estimasi dan pengujian untuk masing-masing emiten sektor industri disajikan pada subbagian a) hingga f).

a) IMPC

Efek ARCH signifikan yang ditemukan pada IMPC menjadi dasar untuk melanjutkan pemodelan volatilitas bersyarat menggunakan model GARCH. Pemodelan dilakukan dengan menggunakan residual dari model AR([2]) yang telah ditetapkan pada Subbab 4.2.3 sebagai persamaan *mean*. Residual tersebut kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1) masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi, parameter pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%. Hasil estimasi dan uji signifikansi untuk ketiga model GARCH pada residual IMPC disajikan pada Tabel 4.30.

Tabel 4.30 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham IMPC

Model	Parameter	Estimasi	t_{hitung}	$P-value$	Kesimpulan
GARCH(1,0)	ω	0,0008	3,1503	0,0016	Parameter signifikan
	α_1	0,9989	2,7692	0,0056	Parameter signifikan
	ξ	1,0779	20,8948	0,0000	Parameter signifikan
	ν	2,4355	13,6582	0,0000	Parameter signifikan
GARCH(0,1)	ω	0,0000	22,4903	0,0000	Parameter signifikan
	β_1	0,999	6466,74	0,0000	Parameter signifikan
	ξ	1,0765	20,6705	0,0000	Parameter signifikan
	ν	2,1918	78,9870	0,0000	Parameter signifikan
GARCH(1,1)	ω	0,0001	1,8405	0,0657	Parameter tidak signifikan
	α_1	0,2858	2,7597	0,0058	Parameter signifikan
	β_1	0,7131	7,3077	0,0000	Parameter signifikan
	ξ	1,0753	21,4517	0,0000	Parameter signifikan
	ν	2,9975	9,2588	0,0000	Parameter signifikan

Dari tiga spesifikasi model pada Tabel 4.30, model GARCH(1,0) dan GARCH(0,1) memiliki seluruh parameter pada persamaan varians yang signifikan pada taraf 5%. Pada model GARCH(1,1), parameter ω tidak signifikan meskipun parameter lainnya signifikan, sehingga model ini tidak memenuhi kriteria signifikansi parameter yang digunakan dalam penelitian. Sehingga hanya model GARCH(1,0) dan GARCH(0,1) yang dipertimbangkan lebih lanjut. Untuk menentukan model yang paling sesuai, kedua model kemudian dibandingkan menggunakan kriteria nilai *Akaike's Information Criterion* (AIC) di mana model dengan nilai AIC paling kecil dipilih sebagai model terbaik. Nilai AIC masing-masing model disajikan pada Tabel 4.31.

Tabel 4.31 Perbandingan Nilai AIC Model GARCH Saham IMPC

Model	Nilai AIC
GARCH(1,0)	-4,6226
GARCH(0,1)	-4,5773

Model GARCH(1,0) memiliki nilai AIC lebih kecil dibandingkan dengan model GARCH(0,1), sehingga model GARCH(1,0) dipilih sebagai model volatilitas bersyarat untuk saham IMPC. Model volatilitas bersyarat yang terpilih kemudian dikombinasikan dengan persamaan *mean* AR([2]) yang diperoleh sebelumnya. Spesifikasi akhir untuk *return* harian saham IMPC adalah AR([2])-GARCH(1,0) dengan error berdistribusi *standardized skewed-t* (sstd) yang dituliskan sebagai berikut.

$$\hat{r}_{IMPC,t} = 0,0044 + 0,2485r_{IMPC,t-2} + \hat{a}_{IMPC,t}$$

$$a_{IMPC,t} = z_{IMPC,t} \sqrt{\sigma_{IMPC,t}^2}, \text{ dengan } z_{IMPC,t} \sim \text{sstd}(0,1, \xi, \nu)$$

$$\hat{\sigma}_{IMPC,t}^2 = 0,0008 + 0,9989a_{IMPC,t-1}^2$$

dengan $r_{IMPC,t}$ menyatakan estimasi *return* harian IMPC, $\hat{\sigma}_{IMPC,t}^2$ estimasi varians bersyarat pada waktu t , dan $z_{IMPC,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 1,0779 dan *shape* (ν) sebesar 2,4355. Selanjutnya model AR([2])-GARCH(1,0) digunakan sebagai dasar estimasi nilai VaR untuk saham IMPC.

b) SKRN

Pemodelan volatilitas bersyarat untuk saham SKRN dilakukan dengan menggunakan *return* harian yang telah dimodelkan dengan persamaan *mean* AR(0), sebagaimana dijelaskan pada Subbab 4.2.3. Model AR(0) berarti tidak terdapat komponen *autoregressive* maupun *intercept* yang signifikan pada persamaan *mean*, sehingga dinamika waktu akan ditangkap melalui persamaan varians. *Return* atau secara ekuivalen merupakan residual dari model AR(0) kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1), masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi model, parameter pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%. Ringkasan hasil estimasi dan uji signifikansi parameter untuk ketiga model GARCH pada residual saham SKRN disajikan pada Tabel 4.32.

Tabel 4.32 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SKRN

Model	Parameter	Estimasi	t_{hitung}	$P\text{-value}$	Kesimpulan
GARCH(1,0)	ω	0,0007	4,4083	0,0000	Parameter signifikan
	α_1	0,999	4,6145	0,0000	Parameter signifikan
	ξ	1,1185	22,1312	0,0000	Parameter signifikan
	ν	2,5409	17,9221	0,0000	Parameter signifikan
GARCH(0,1)	ω	0,0000	35,8228	0,0000	Parameter signifikan
	β_1	0,9923	4485,89	0,0000	Parameter signifikan
	ξ	1,0372	23,4154	0,0000	Parameter signifikan
	ν	2,6412	27,9858	0,0000	Parameter signifikan
GARCH(1,1)	ω	0,0001	2,5519	0,0107	Parameter signifikan
	α_1	0,3592	4,4171	0,0000	Parameter signifikan
	β_1	0,6398	9,6959	0,0000	Parameter signifikan
	ξ	1,1611	21,0767	0,0000	Parameter signifikan
	ν	2,7330	14,7855	0,0000	Parameter signifikan

Berdasarkan Tabel 4.32, model GARCH(1,0), GARCH(0,1), dan GARCH(1,1) memiliki parameter varians dan parameter distribusi yang signifikan pada taraf 5%, sehingga secara statistik seluruhnya layak dipertimbangkan sebagai model volatilitas bersyarat untuk saham SKRN. Hal ini menunjukkan bahwa varians *return* SKRN dipengaruhi baik oleh *shock* masa lalu (α_1) maupun oleh varians masa lalu (β_1), sementara parameter ξ dan ν yang signifikan mendukung penggunaan distribusi sstd untuk mengakomodasi asimetri dan ketebalan ekor distribusi *return*. Karena terdapat lebih dari satu model yang memenuhi kriteria signifikansi parameter, pemilihan spesifikasi akhir dilakukan dengan membandingkan nilai AIC masing-masing model yang dirangkum pada Tabel 4.32.

Tabel 4.33 Perbandingan Nilai AIC Model GARCH Saham SKRN

Model	Nilai AIC
GARCH(1,0)	-4,3315
GARCH(0,1)	-4,1438
GARCH(1,1)	-4,4030

Model GARCH(1,1) memiliki nilai AIC paling kecil dibandingkan dengan model GARCH(1,0) dan GARCH(0,1), sehingga GARCH(1,1) dipilih sebagai model volatilitas bersyarat untuk saham SKRN. Dikombinasikan dengan persamaan *mean* AR(0) yang diperoleh sebelumnya, spesifikasi akhir untuk *return* harian saham SKRN dalam penelitian ini adalah model GARCH(1,1) dengan *error* berdistribusi *standardized skewed-t* (sstd), yang dapat dituliskan sebagai berikut.

$$r_{SKRN,t} = a_{SKRN,t}$$

$$a_{SKRN,t} = z_{SKRN,t} \sqrt{\sigma_{SKRN,t}^2}, \text{ dengan } z_{SKRN,t} \sim \text{sstd}(0,1, \xi, \nu)$$

$$\hat{\sigma}_{SKRN,t}^2 = 0,0001 + 0,3592a_{SKRN,t-1}^2 + 0,6398\sigma_{SKRN,t-1}^2$$

dengan $r_{SKRN,t}$ menyatakan *return* harian SKRN, $\hat{\sigma}_{SKRN,t}^2$ estimasi varians bersyarat pada waktu t , dan $z_{SKRN,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 1,1611 dan *shape* (ν) sebesar 2,7330. Selanjutnya model GARCH(1,1) ini digunakan sebagai dasar estimasi nilai VaR untuk saham SKRN.

c) SINI

Efek ARCH signifikan yang ditemukan pada SINI menjadi dasar untuk melanjutkan pemodelan volatilitas bersyarat menggunakan model GARCH. Pemodelan dilakukan dengan menggunakan residual dari model AR(1) tanpa *intercept* yang telah ditetapkan pada Subbab 4.2.3 sebagai persamaan *mean*. Residual kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1) masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi, parameter pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%. Hasil estimasi dan uji signifikansi untuk ketiga model GARCH pada residual SINI disajikan pada Tabel 4.34.

Tabel 4.34 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SINI

Model	Parameter	Estimasi	t_{hitung}	P-value	Kesimpulan
GARCH(1,0)	ω	0,0008	5,8494	0,0000	Parameter signifikan
	α_1	0,999	5,7217	0,0000	Parameter signifikan
	ξ	1,0666	23,121	0,0000	Parameter signifikan
	ν	3,2387	10,167	0,0000	Parameter signifikan
GARCH(0,1)	ω	0,0002	1,7635	0,0778	Parameter tidak signifikan
	β_1	0,9842	351,24	0,0000	Parameter signifikan
	ξ	1,0748	23,198	0,0000	Parameter signifikan
	ν	2,1805	16,518	0,0000	Parameter signifikan
GARCH(1,1)	ω	0,0002	2,3817	0,0172	Parameter signifikan
	α_1	0,5328	6,7281	0,0000	Parameter signifikan
	β_1	0,4662	7,7719	0,0000	Parameter signifikan
	ξ	1,0589	23,044	0,0000	Parameter signifikan
	ν	3,6283	9,2789	0,0000	Parameter signifikan

Dari tiga spesifikasi model pada Tabel 4.32, model GARCH(1,0) dan GARCH(1,1) memiliki seluruh parameter pada persamaan varians yang signifikan pada taraf 5%. Pada model

GARCH(1,1), parameter ω tidak signifikan meskipun parameter lainnya signifikan, sehingga model ini tidak memenuhi kriteria signifikansi parameter yang digunakan dalam penelitian. Dengan demikian, hanya model GARCH(1,0) dan GARCH(1,1) yang dipertimbangkan lebih lanjut. Kedua model kemudian dibandingkan menggunakan kriteria nilai *Akaike's Information Criterion* (AIC) di mana model dengan nilai AIC paling kecil dipilih sebagai model terbaik. Nilai AIC masing-masing model disajikan pada Tabel 4.35.

Tabel 4.35 Perbandingan Nilai AIC Model GARCH Saham SINI

Model	Nilai AIC
GARCH(1,0)	-3,4355
GARCH(1,1)	-3,4994

Model GARCH(1,1) memiliki nilai AIC lebih kecil dibandingkan dengan model GARCH(1,0), sehingga model GARCH(1,1) dipilih sebagai model volatilitas bersyarat untuk saham SINI. Model volatilitas bersyarat yang terpilih kemudian dikombinasikan dengan persamaan *mean* AR(1) tanpa *intercept* yang diperoleh sebelumnya. Spesifikasi akhir untuk *return* harian saham SINI adalah AR(1)-GARCH(1,1) dengan *error* berdistribusi *standardized skewed-t* (sstd) yang dituliskan sebagai berikut.

$$\begin{aligned}\hat{r}_{SINI,t} &= 0,3129r_{SINI,t-1} + \hat{a}_{SINI,t} \\ a_{SINI,t} &= z_{SINI,t} \sqrt{\sigma_{SINI,t}^2} \text{ dengan } z_{SINI,t} \sim \text{sstd}(0,1,\xi,\nu) \\ \hat{\sigma}_{SINI,t}^2 &= 0,0002 + 0,5328a_{SINI,t-1}^2 + 0,4662\sigma_{SINI,t-1}^2\end{aligned}$$

dengan $r_{SINI,t}$ menyatakan *return* harian SINI, $\hat{\sigma}_{SINI,t}^2$ varians bersyarat pada waktu t , dan $z_{SINI,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 1,0589 dan *shape* (ν) sebesar 3,6283. Selanjutnya model AR(1)-GARCH(1,1) ini digunakan sebagai dasar estimasi nilai VaR untuk saham SINI.

d) SMIL

Efek ARCH signifikan yang ditemukan pada SMIL menjadi dasar untuk melanjutkan pemodelan volatilitas bersyarat menggunakan model GARCH. Pemodelan dilakukan dengan menggunakan residual dari model AR(1) tanpa *intercept* yang telah ditetapkan sebelumnya sebagai persamaan *mean*. Residual kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1) masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi, parameter-pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%. Hasil estimasi dan uji signifikansi untuk ketiga model GARCH pada residual SMIL disajikan pada Tabel 4.36.

Tabel 4.36 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SMIL

Model	Parameter	Estimasi	t_{hitung}	$P\text{-value}$	Kesimpulan
GARCH(1,0)	ω	0,0027	2,5695	0,0102	Parameter signifikan
	α_1	0,9990	2,3838	0,0171	Parameter signifikan
	ξ	0,9999	20,8554	0,0000	Parameter signifikan
	ν	2,3747	12,8294	0,0000	Parameter signifikan
GARCH(0,1)	ω	0,0001	2,4139	0,0158	Parameter signifikan
	β_1	0,9978	989,82	0,0000	Parameter signifikan
	ξ	0,9169	20,2749	0,0000	Parameter signifikan
	ν	2,1025	45,2985	0,0000	Parameter signifikan

Tabel 4.36 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham SMIL (Lanjutan)

Model	Parameter	Estimasi	t_{hitung}	P -value	Kesimpulan
GARCH(1,1)	ω	0,0017	2,2759	0,0229	Parameter signifikan
	α_1	0,7619	2,4959	0,0126	Parameter signifikan
	β_1	0,2371	1,3705	0,1705	Parameter tidak signifikan
	ξ	0,9843	19,8112	0,0000	Parameter signifikan
	ν	2,4040	13,0568	0,0000	Parameter signifikan

Dari tiga spesifikasi model pada Tabel 4.34, model GARCH(1,0) dan GARCH(0,1) memiliki seluruh parameter pada persamaan varians yang signifikan pada taraf 5%. Pada model GARCH(1,1), parameter β_1 tidak signifikan meskipun parameter lainnya signifikan, sehingga model ini tidak memenuhi kriteria signifikansi parameter yang digunakan dalam penelitian. Dengan demikian, hanya model GARCH(1,0) dan GARCH(0,1) yang dipertimbangkan lebih lanjut. Kedua model kemudian dibandingkan menggunakan kriteria nilai *Akaike's Information Criterion* (AIC) di mana model dengan nilai AIC paling kecil dipilih sebagai model terbaik. Nilai AIC masing-masing model disajikan pada Tabel 4.37.

Tabel 4.37 Perbandingan Nilai AIC Model GARCH Saham SMIL

Model	Nilai AIC
GARCH(1,0)	-3,5751
GARCH(0,1)	-3,5216

Model GARCH(1,0) memiliki nilai AIC lebih kecil dibandingkan dengan model GARCH(0,1), sehingga model GARCH(1,0) dipilih sebagai model volatilitas bersyarat untuk saham SMIL. Model volatilitas bersyarat yang terpilih kemudian dikombinasikan dengan persamaan *mean* AR(1) tanpa *intercept* yang diperoleh sebelumnya. Spesifikasi akhir untuk *return* harian saham SMIL adalah AR(1)-GARCH(1,0) dengan *error* berdistribusi *standardized skewed-t* (sstd) yang dituliskan sebagai berikut.

$$\begin{aligned}\hat{r}_{SMIL,t} &= 0,1188r_{SMIL,t-1} + \hat{a}_{SMIL,t} \\ a_{SMIL,t} &= z_{SMIL,t} \sqrt{\sigma_{SMIL,t}^2}, \text{ dengan } z_{SMIL,t} \sim \text{sstd}(0,1, \xi, \nu) \\ \hat{\sigma}_{SMIL,t}^2 &= 0,0027 + 0,999a_{SMIL,t-1}^2\end{aligned}$$

dengan $r_{SMIL,t}$ menyatakan *return* harian SMIL, $\hat{\sigma}_{SMIL,t}^2$ varians bersyarat pada waktu t , dan $z_{SMIL,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 0,9999 dan *shape* (ν) sebesar 2,3747. Selanjutnya model AR(1)-GARCH(1,0) ini digunakan sebagai dasar estimasi nilai VaR untuk saham SMIL.

e) ARNA

Pemodelan volatilitas bersyarat untuk saham ARNA dilakukan dengan menggunakan *return* harian yang telah dimodelkan dengan persamaan *mean* AR(0), yang berarti tidak terdapat komponen *autoregressive* maupun *intercept* yang signifikan pada persamaan *mean*. Sehingga dinamika waktu akan ditangkap melalui persamaan varians. *Return* atau secara ekuivalen merupakan residual dari model AR(0) kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1), masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi model, parameter pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%.

Dalam proses estimasinya, model GARCH(0,1) pada saham ARNA tidak dapat dilakukan karena algoritma optimasi gagal mencapai konvergensi (*solver failed to converge*). Kegagalan

konvergensi ini mengindikasikan bahwa spesifikasi GARCH(0,1) tidak sesuai dengan karakteristik data *return* ARNA, di mana dinamika volatilitas lebih dominan dipengaruhi oleh komponen *shock* masa lalu (α_1) dibandingkan varians masa lalu (β_1). Hal ini terbukti dari hasil estimasi GARCH(1,0) yang menunjukkan nilai $\alpha_1 = 0,999$ mendekati satu, sehingga menghilangkan α_1 pada model GARCH(0,1) menyebabkan *likelihood surface* menjadi datar dan *optimizer* tidak mampu menemukan solusi yang stabil. Oleh karena itu, model GARCH(0,1) tidak diikutsertakan dalam proses pemilihan model terbaik untuk saham ARNA. Adapun ringkasan hasil estimasi dan uji signifikansi parameter untuk model GARCH pada residual saham ARNA disajikan pada Tabel 4.38.

Tabel 4.38 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham ARNA

Model	Parameter	Estimasi	t_{hitung}	$P\text{-value}$	Kesimpulan
GARCH(1,0)	ω	0,0003	2,2506	0,0244	Parameter signifikan
	α_1	0,9990	2,0937	0,0363	Parameter signifikan
	ξ	0,9408	27,8597	0,0000	Parameter signifikan
	ν	2,2664	15,9300	0,0000	Parameter signifikan
GARCH(1,1)	ω	0,0002	2,4534	0,0142	Parameter signifikan
	α_1	0,7103	2,5237	0,0116	Parameter signifikan
	β_1	0,2887	2,2107	0,0271	Parameter signifikan
	ξ	0,9346	27,4726	0,0000	Parameter signifikan
	ν	2,3718	14,0392	0,0000	Parameter signifikan

Berdasarkan Tabel 4.36, model GARCH(1,0) dan GARCH(1,1) memiliki parameter varians dan parameter distribusi yang signifikan pada taraf 5%, sehingga secara statistik kedua model layak dipertimbangkan sebagai model volatilitas bersyarat untuk saham ARNA. Hal ini menunjukkan bahwa varians *return* ARNA dipengaruhi baik oleh *shock* masa lalu (α_1) maupun oleh varians masa lalu (β_1), sementara parameter ξ dan ν yang signifikan mendukung penggunaan distribusi sstd untuk mengakomodasi asimetri dan ketebalan ekor distribusi *return*. Karena terdapat lebih dari satu model yang memenuhi kriteria signifikansi parameter, pemilihan spesifikasi akhir dilakukan dengan membandingkan nilai AIC masing-masing model yang dirangkum pada Tabel 4.39.

Tabel 4.39 Perbandingan Nilai AIC Model GARCH Saham ARNA

Model	Nilai AIC
GARCH(1,0)	-5,9741
GARCH(1,1)	-5,9877

Model GARCH(1,1) memiliki nilai AIC lebih kecil dibandingkan dengan model GARCH(1,0), sehingga model GARCH(1,1) dipilih sebagai model volatilitas bersyarat untuk saham ARNA. Model volatilitas bersyarat yang terpilih kemudian dikombinasikan dengan persamaan *mean* AR(0). Spesifikasi akhir untuk *return* harian saham ARNA adalah GARCH(1,1) dengan *error* berdistribusi *standardized skewed-t* (sstd) yang dituliskan sebagai:

$$r_{ARNA,t} = a_{ARNA,t}$$

$$a_{ARNA,t} = z_{ARNA,t} \sqrt{\sigma_{ARNA,t}^2}, \text{ dengan } z_{ARNA,t} \sim \text{sstd}(0,1, \xi, \nu)$$

$$\hat{\sigma}_{ARNA,t}^2 = 0,0002 + 0,7103a_{ARNA,t-1}^2 + 0,2887\sigma_{ARNA,t-1}^2$$

dengan $r_{ARNA,t}$ menyatakan *return* harian ARNA, $\hat{\sigma}_{ARNA,t}^2$ estimasi varians bersyarat pada waktu t , dan $z_{ARNA,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 0,9346 dan *shape* (ν) sebesar 2,3718.

Selanjutnya model GARCH(1,1) ini digunakan sebagai dasar estimasi nilai VaR untuk saham ARNA.

f) MARK

Efek ARCH signifikan yang ditemukan pada MARK menjadi dasar untuk melanjutkan pemodelan volatilitas bersyarat menggunakan model GARCH. Pemodelan dilakukan dengan menggunakan residual dari model AR(1) tanpa *intercept* yang telah ditetapkan pada Subbab 4.2.3 sebagai persamaan *mean*. Residual kemudian dimodelkan dengan tiga spesifikasi GARCH orde rendah, yaitu GARCH(1,0), GARCH(0,1), dan GARCH(1,1) masing-masing dengan asumsi distribusi residual *standardized skewed-t* (sstd). Untuk setiap spesifikasi, parameter pada persamaan varians bersyarat diestimasi dan diuji signifikansinya pada taraf signifikansi 5%. Hasil estimasi dan uji signifikansi untuk ketiga model GARCH pada residual MARK disajikan pada Tabel 4.40.

Tabel 4.40 Hasil Estimasi dan Uji Signifikansi Model GARCH Saham MARK

Model	Parameter	Estimasi	t_{hitung}	P-value	Kesimpulan
GARCH(1,0)	ω	0,0006	7,4130	0,0000	Parameter signifikan
	α_1	0,2282	2,6181	0,0088	Parameter signifikan
	ξ	1,0168	19,1317	0,0000	Parameter signifikan
	ν	4,2271	5,1691	0,0000	Parameter signifikan
GARCH(0,1)	ω	0,0000	63,2678	0,0000	Parameter signifikan
	β_1	0,9920	6449,44	0,0000	Parameter signifikan
	ξ	1,0029	20,0151	0,0000	Parameter signifikan
	ν	4,4148	8,7347	0,0000	Parameter signifikan
GARCH(1,1)	ω	0,0002	1,8990	0,0576	Parameter tidak signifikan
	α_1	0,1869	2,6059	0,0092	Parameter signifikan
	β_1	0,6128	4,1590	0,0000	Parameter signifikan
	ξ	1,0205	18,8641	0,0000	Parameter signifikan
	ν	4,3628	5,1205	0,0000	Parameter signifikan

Dari tiga spesifikasi model pada Tabel 4.38, model GARCH(1,0) dan GARCH(0,1) memiliki seluruh parameter pada persamaan varians yang signifikan pada taraf 5%. Pada model GARCH(1,1), parameter ω tidak signifikan meskipun parameter lainnya signifikan, sehingga model ini tidak memenuhi kriteria signifikansi parameter yang digunakan dalam penelitian. Dengan demikian, hanya model GARCH(1,0) dan GARCH(0,1) yang dipertimbangkan lebih lanjut. Kedua model kemudian dibandingkan menggunakan kriteria nilai *Akaike's Information Criterion* (AIC) di mana model dengan nilai AIC paling kecil dipilih sebagai model terbaik. Nilai AIC masing-masing model disajikan pada Tabel 4.41.

Tabel 4.41 Perbandingan Nilai AIC Model GARCH Saham MARK

Model	Nilai AIC
GARCH(1,0)	-4,5825
GARCH(0,1)	-4,5554

Model GARCH(1,0) memiliki nilai AIC lebih kecil dibandingkan dengan model GARCH(0,1), sehingga model GARCH(1,0) dipilih sebagai model volatilitas bersyarat untuk saham MARK. Model volatilitas bersyarat yang terpilih kemudian dikombinasikan dengan persamaan *mean* AR(1) tanpa *intercept* yang diperoleh sebelumnya. Spesifikasi akhir untuk *return* harian saham MARK adalah AR(1)-GARCH(1,0) dengan *error* berdistribusi *standardized skewed-t* (sstd) yang dituliskan sebagai berikut.

$$\hat{r}_{MARK,t} = -0,1080r_{MARK,t-1} + \hat{a}_{MARK,t}$$

$$a_{MARK,t} = z_{MARK,t} \sqrt{\sigma_{MARK,t}^2}, \text{ dengan } z_{MARK,t} \sim \text{sstd}(0,1, \xi, v)$$

$$\hat{\sigma}_{MARK,t}^2 = 0,0006 + 0,2282a_{MARK,t-1}^2$$

dengan $r_{MARK,t}$ menyatakan *return* harian MARK, $\hat{\sigma}_{MARK,t}^2$ estimasi varians bersyarat pada waktu t , dan $z_{MARK,t}$ inovasi i.i.d. yang mengikuti distribusi *standardized skewed-t* (sstd) dengan *mean* nol, varians satu, *skew* (ξ) sebesar 1,0168 dan *shape* (v) sebesar 4,2271. Selanjutnya model AR(1)-GARCH(1,0) ini digunakan sebagai dasar estimasi nilai VaR untuk saham MARK.

4.2.6 Estimasi Nilai VaR Setiap Saham dengan AR-GARCH

Subbab ini akan dilakukan estimasi nilai *Value-at-Risk* (VaR) harian untuk masing-masing saham sektor industri dengan menggunakan model AR-GARCH yang telah diperoleh pada Subbab 4.2.3 dan 4.2.5. VaR dihitung sebagai perkiraan kerugian maksimum dalam satu hari perdagangan pada tingkat kepercayaan tertentu, dengan memanfaatkan distribusi residual sstd dari model AR-GARCH untuk menangkap karakteristik *skewness* dan *heavy tails* pada *return*.

Untuk setiap saham, dihitung VaR pada dua tingkat kuantil, yaitu 1% dan 5%, sehingga dapat dibandingkan bagaimana perubahan tingkat kepercayaan memengaruhi besarnya estimasi risiko kerugian. Perbandingan VaR pada kuantil 1% dan 5% ini memberikan gambaran yang lebih lengkap mengenai profil risiko masing-masing emiten, terutama terkait sensitivitas portofolio terhadap kejadian-kejadian ekstrem di bagian ekor kiri distribusi *return*. Hasil perhitungan dan interpretasi VaR untuk tiap saham disajikan pada subbagian a) hingga j) berikut.

a) ASII

Estimasi nilai VaR harian untuk ASII dilakukan dengan memanfaatkan model *mean* AR(2) tanpa *intercept*. Hasil uji *Lagrange Multiplier* sebelumnya menunjukkan tidak adanya efek ARCH yang signifikan pada residual, sehingga tidak dibentuk model GARCH untuk saham ASII. Dengan demikian, komponen risiko berasal dari kombinasi nilai ekspektasi *return* harian yang dinamis (μ_t) dari model AR dan standar deviasi residual yang diasumsikan konstan, di mana residual dimodelkan mengikuti distribusi *standardized skewed-t* (sstd). Berdasarkan spesifikasi tersebut, nilai VaR ASII pada kuantil 1% dan 5% kemudian disajikan ke dalam tabel statistik yang mencakup rata-rata, nilai maksimum (VaR paling kecil secara absolut), nilai minimum (VaR paling besar secara absolut), dan varians VaR sebagaimana pada Tabel 4.42.


Tabel 4.42 Estimasi Nilai VaR Saham ASII

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,04143	-0,02755	-0,05282	0,00001
5%	-0,02535	-0,01148	-0,03674	0,00001

Tabel 4.42 menunjukkan bahwa rata-rata VaR ASII pada tingkat kepercayaan 99% sebesar -0,04143, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 4,14% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham ASII, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp41.430.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi

sebesar $-0,02535$ yang berarti potensi kerugian maksimum sekitar 2,54% yaitu sekitar Rp25.350.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR ASII mencapai $-0,05282$ atau kerugian sekitar 5,28% dari nilai investasi, sedangkan nilai maksimum $-0,02755$ atau 2,75% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,03674$ atau 3,67% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,01148$ atau sekitar 1,15% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians pada kedua tingkat kepercayaan yang sama-sama bernilai 0,00001 mengindikasikan bahwa batas VaR ASII relatif stabil dari waktu ke waktu, sehingga perbedaan utama antara VaR 1% dan 5% terletak pada kedalaman kerugian yang diestimasi daripada fluktuasi batas risikonya. Visualisasi perbandingan nilai VaR terhadap *return* aktual ASII disajikan pada Gambar 4.5.



Gambar 4.5 Plot VaR ASII Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.5 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan definisi VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Sehingga secara visual dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

b) IMPC


Nilai VaR harian IMPC diperoleh dari model AR([2])-GARCH(1,0) dengan distribusi residual sstd yang telah dibentuk pada subbab sebelumnya. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham IMPC disajikan pada Tabel 4.43.

Tabel 4.43 Estimasi Nilai VaR Saham IMPC

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,07614	0,00499	-0,44432	0,00186
5%	-0,03485	0,03598	-0,21488	0,00047

Tabel 4.43 menunjukkan bahwa rata-rata VaR IMPC pada tingkat kepercayaan 99% sebesar $-0,07614$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 7,61% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham IMPC, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp76.140.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,03485$ yang berarti potensi kerugian maksimum sekitar 3,49% yaitu sekitar Rp34.850.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR IMPC mencapai $-0,44432$ atau kerugian sekitar 44,43% dari nilai investasi, sedangkan nilai maksimum $-0,00499$ atau 0,5% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,21488$ atau 21,49% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,03598$ atau sekitar 3,6% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai variansnya, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan dengan varians pada tingkat kepercayaan 99%. Hal ini mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada IMPC, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktualnya yang disajikan pada Gambar 4.6.

**Gambar 4.6** Plot VaR IMPC Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.6 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan definisi VaR, di mana VaR pada kuantil 5%

merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Sehingga dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

c) UNTR


Nilai VaR harian UNTR dilakukan dengan memanfaatkan model *mean* AR([2]) tanpa *intercept*. Hasil uji *Lagrange Multiplier* sebelumnya menunjukkan tidak adanya efek ARCH yang signifikan pada residual, sehingga tidak dibentuk model GARCH untuk saham UNTR. Dengan demikian, komponen risiko berasal dari kombinasi nilai ekspektasi *return* harian yang dinamis (μ_t) dari model AR dan standar deviasi residual yang diasumsikan konstan, di mana residual dimodelkan mengikuti distribusi *standardized skewed-t* (sstd). Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham UNTR disajikan pada Tabel 4.44.

Tabel 4.44 Estimasi Nilai VaR Saham UNTR

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,05078	-0,03068	-0,06010	0,00001
5%	-0,02863	-0,00853	-0,03795	0,00001

Tabel 4.44 menunjukkan bahwa rata-rata VaR UNTR pada tingkat kepercayaan 99% sebesar $-0,05078$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 5,08% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham UNTR, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp50.780.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,02863$ yang berarti potensi kerugian maksimum sekitar 2,86% yaitu sekitar Rp28.630.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR UNTR mencapai $-0,06010$ atau kerugian sekitar 6,01% dari nilai investasi, sedangkan nilai maksimum $-0,03068$ atau 3,07% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,03795$ atau 3,8% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,00853$ atau sekitar 0,85% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians pada kedua tingkat kepercayaan yang sama-sama bernilai 0,00001 mengindikasikan bahwa batas VaR UNTR relatif stabil dari waktu ke waktu, sehingga perbedaan utama antara VaR 1% dan 5% terletak pada kedalaman kerugian yang diestimasi daripada fluktuasi batas risikonya. Visualisasi perbandingan nilai VaR terhadap *return* aktual UNTR disajikan pada Gambar 4.7.



Gambar 4.7 Plot VaR UNTR Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.7 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan definisi VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Sehingga secara visual dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

d) SKRN


Nilai VaR harian untuk SKRN diperoleh dari model GARCH(1,1) dengan distribusi residual sstd. Pada tahap pemodelan *mean* tidak ditemukan komponen AR yang signifikan, sehingga rata-rata bersyarat *return* diasumsikan nol dan dinamika risiko sepenuhnya direpresentasikan oleh perubahan varians bersyarat. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham SKRN disajikan pada Tabel 4.45.

Tabel 4.45 Estimasi Nilai VaR Saham SKRN

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,08279	-0,03545	-0,41331	0,00367
5%	-0,04399	-0,01883	-0,21961	0,00104

Tabel 4.45 menunjukkan bahwa rata-rata VaR SKRN pada tingkat kepercayaan 99% sebesar $-0,08279$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 8,28% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham SKRN, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp82.790.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,04399$ yang berarti potensi kerugian maksimum 4,4% yaitu sekitar Rp43.990.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR SKRN mencapai $-0,41331$ atau kerugian sekitar 41,3% dari nilai investasi, sedangkan nilai maksimum $-0,03545$ atau 3,5% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,21961$ atau 21,96% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,01883$ atau sekitar 1,9% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan pada tingkat kepercayaan 99%. Hal ini mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada SKRN, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual SKRN yang disajikan pada Gambar 4.8.



Gambar 4.8 Plot VaR SKRN Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.8, garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan definisi VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Sehingga secara visual dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

e) SINI


Nilai VaR harian SINI diperoleh dari model AR(1)-GARCH(1,1) dengan distribusi residual sstd yang telah dibentuk pada subbab sebelumnya. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham SINI disajikan pada Tabel 4.46.

Tabel 4.46 Estimasi Nilai VaR Saham SINI

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,11815	-0,04627	-0,58784	0,00517
5%	-0,06590	-0,02527	-0,35375	0,00177

Tabel 4.46 menunjukkan bahwa rata-rata VaR SINI pada tingkat kepercayaan 99% sebesar $-0,11815$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 11,8% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham SINI, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp118.150.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,06590$ yang berarti potensi kerugian maksimum 6,6% yaitu sekitar Rp65.900.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR SINI mencapai $-0,58784$ atau kerugian sekitar 58,8% dari nilai investasi, sedangkan nilai maksimum $-0,04627$ atau 4,6% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,35375$ atau 35,4% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,02527$ atau sekitar 1,9% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan pada tingkat kepercayaan 99%. Hal ini mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada SINI, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual SINI yang disajikan pada Gambar 4.9.



Gambar 4.9 Plot VaR SINI Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.9 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan definisi VaR, di mana VaR pada kuantil 5%

merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Sehingga secara visual dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

f) SMIL


Nilai VaR harian SMIL diperoleh dari model AR(1)-GARCH(1,0) dengan distribusi residual sstd yang telah dibentuk pada subbab sebelumnya. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham SMIL disajikan pada Tabel 4.47.

Tabel 4.47 Estimasi Nilai VaR Saham SMIL

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,15021	-0,11422	-0,72544	0,00579
5%	-0,06971	-0,05201	-0,33074	0,00130

Tabel 4.47 menunjukkan bahwa rata-rata VaR SMIL pada tingkat kepercayaan 99% sebesar $-0,15021$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 15,02% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham SMIL, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp150.210.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,06971$ yang berarti potensi kerugian maksimum 6,97% yaitu sekitar Rp69.710.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR SMIL mencapai $-0,72544$ atau kerugian terburuk sekitar 72,5% dari nilai investasi, sedangkan nilai maksimum $-0,11422$ atau 11,4% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,33074$ atau 33,1% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,05201$ atau sekitar 5,2% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan pada tingkat kepercayaan 99%. Hal ini mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada SMIL, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual SMIL yang disajikan pada Gambar 4.10.



Gambar 4.10 Plot VaR SMIL Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.10 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan karakteristik VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian yang terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang benar-benar ekstrem. Sehingga secara visual, untuk saham SMIL dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

g) ARNA


Estimasi nilai VaR harian ARNA diperoleh dari model GARCH(1,1) dengan distribusi residual sstd yang telah dibentuk pada subbab sebelumnya. Pada tahap pemodelan *mean* tidak ditemukan komponen AR yang signifikan, sehingga rata-rata bersyarat *return* diasumsikan nol dan dinamika risiko sepenuhnya direpresentasikan oleh perubahan varians bersyarat. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham ARNA disajikan pada Tabel 4.48.

Tabel 4.48 Estimasi Nilai VaR Saham ARNA

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,04631	-0,03482	-0,16977	0,00033
5%	-0,02096	-0,01576	-0,07684	0,00007

Tabel 4.48 menunjukkan bahwa rata-rata VaR ARNA pada tingkat kepercayaan 99% sebesar $-0,04631$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 4,63% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham ARNA, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp46.310.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,02096$ yang berarti potensi kerugian maksimum 2,1% yaitu sekitar Rp20.960.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR dikedua kuantil menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR ARNA mencapai $-0,16977$ atau kerugian terburuk sekitar 16,98% dari nilai investasi, sedangkan nilai maksimum $-0,03482$ atau 3,48% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,07684$ atau 7,68% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,01576$ atau sekitar 1,58% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan pada tingkat kepercayaan 99%, mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada ARNA, perbandingan nilai VaR terhadap *return* aktual ARNA yang disajikan pada Gambar 4.11.



Gambar 4.11 Plot VaR ARNA Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.11, garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan karakteristik VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang benar-benar ekstrem. Sehingga secara visual, untuk saham ARNA dapat disimpulkan bahwa VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

h) HEXA

Hasil pemodelan pada Subbab 4.2.3 dan 4.2.5 menunjukkan bahwa *return* saham HEXA tidak memiliki komponen *mean* AR yang signifikan maupun efek ARCH yang memadai untuk dibentuk ke dalam model GARCH. Oleh karena itu, dinamika *return* HEXA dimodelkan sebagai proses i.i.d. dengan volatilitas konstan yang mengikuti distribusi *standardized skewed-t* (sstd). Secara praktis, nilai VaR harian HEXA pada tingkat kuantil tertentu dihitung berdasarkan kuantil distribusi sstd (z_τ) yang dikalikan dengan estimasi deviasi standar *return* ($\hat{\sigma}$) dan rata-rata nol, sehingga menghasilkan nilai VaR yang tetap dari hari ke hari. Hal ini menjelaskan mengapa estimasi VaR HEXA bersifat konstan sepanjang periode pengamatan


dan varians dari deret VaR bernilai nol. Ringkasan estimasi risiko VaR saham HEXA untuk kuantil 1% dan 5% disajikan pada Tabel 4.49.

Tabel 4.49 Estimasi Nilai VaR Saham HEXA

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,04510	-0,04510	-0,04510	0,00000
5%	-0,01920	-0,01920	-0,01920	0,00000

Tabel 4.49 menunjukkan bahwa rata-rata VaR HEXA pada tingkat kepercayaan 99% sebesar $-0,04510$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 4,51% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham HEXA, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp45.100.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari kerja bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,01920$ yang berarti potensi kerugian maksimum 1,92% yaitu sekitar Rp19.200.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa VaR 5% merepresentasikan batas kerugian harian yang relevan untuk 5% observasi terburuk, sedangkan VaR 1% menggambarkan batas kerugian untuk 1% observasi yang paling ekstrem di ekor kiri distribusi. Kedalaman VaR yang lebih besar pada kuantil 1% mencerminkan sifat yang lebih konservatif karena mengantisipasi skenario pasar yang jauh lebih buruk dibandingkan VaR 5%. Nilai varians VaR yang bernilai nol pada kedua tingkat kepercayaan menggambarkan bahwa nilai VaR HEXA tidak berubah dari hari ke hari, konsisten dengan pendekatan pemodelan yang tidak memasukkan dinamika volatilitas bersyarat. Untuk melihat pergerakan nilai risiko pada HEXA, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual HEXA yang disajikan pada Gambar 4.12.



Gambar 4.12 Plot VaR HEXA Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.12 menunjukkan bahwa garis VaR 5% dan VaR 1% pada saham HEXA membentuk garis horizontal tetap, sedangkan *return* aktual berfluktuasi di sekitarnya. Garis VaR 5% yang berada lebih dekat dengan sumbu nol akan lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan garis VaR 1% yang terletak lebih jauh di bawah dan hanya terlampaui pada penurunan harga yang sangat tajam. Pola ini sejalan dengan definisi VaR, di mana semakin kecil nilai kuantil, semakin rendah probabilitas pelanggaran yang diperbolehkan, tetapi kerugian yang diantisipasi ketika pelanggaran terjadi menjadi lebih besar. Dengan karakteristik VaR yang konstan dan tidak menangkap dinamika volatilitas dari waktu ke waktu,

dalam penelitian ini HEXA hanya digunakan pada tahap pengukuran VaR individual dan tidak dilanjutkan ke analisis CoVaR.

i) TOTO

Nilai VaR harian TOTO dilakukan dengan memanfaatkan model *mean* AR(1) tanpa *intercept*. Hasil uji *Lagrange Multiplier* tidak menunjukkan adanya efek ARCH yang signifikan pada residual, sehingga tidak dibentuk model GARCH untuk saham TOTO. Dengan demikian, komponen risiko berasal dari kombinasi nilai ekspektasi *return* harian yang dinamis (μ_t) dari model AR dan standar deviasi residual yang diasumsikan konstan, di mana residual dimodelkan mengikuti distribusi *standardized skewed-t* (sstd). Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham TOTO disajikan pada Tabel 4.50.


Tabel 4.50 Estimasi Nilai VaR Saham TOTO

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,02953	-0,02415	-0,03592	0,00000
5%	-0,01622	-0,01084	-0,02261	0,00000

Tabel 4.50 menunjukkan bahwa rata-rata VaR TOTO pada tingkat kepercayaan 99% sebesar $-0,02953$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 2,95% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham TOTO, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp29.530.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari kerja bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih tinggi sebesar $-0,01622$ yang berarti potensi kerugian maksimum 1,62% yaitu sekitar Rp16.220.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR TOTO mencapai $-0,03592$ atau kerugian sekitar 3,59% dari nilai investasi, sedangkan nilai maksimum $-0,02415$ atau 2,42% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,02261$ atau 2,26% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,01084$ atau sekitar 1,08% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem.

Adapun nilai varians pada kedua tingkat kepercayaan yang sama-sama menunjukkan angka yang sangat kecil mendekati nol bukan berarti batas risiko benar-benar konstan, melainkan mencerminkan bahwa fluktuasi nilai VaR TOTO dari hari ke hari sangat kecil dan relatif stabil sepanjang periode pengamatan. Dengan demikian, perbedaan utama antara VaR 1% dan VaR 5% pada saham TOTO lebih terletak pada kedalaman kerugian yang diestimasi. Untuk melihat pergerakan nilai risiko pada TOTO, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual TOTO yang disajikan pada Gambar 4.13.



Gambar 4.13 Plot VaR TOTO Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.13 menunjukkan bahwa garis VaR 5% dan VaR 1% pada saham TOTO tidak sepenuhnya membentuk garis horizontal tetap, melainkan menampilkan fluktuasi yang sangat kecil. Hal ini disebabkan oleh nilai varians *return* TOTO yang mendekati nol, sehingga meskipun secara teknis terdapat variasi, pergerakan kedua garis VaR tersebut tampak hampir konstan secara visual. Garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih sedikit. Pola ini konsisten dengan karakteristik VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang benar-benar ekstrem. Sehingga secara visual, dapat disimpulkan bahwa untuk saham TOTO VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

j) MARK

Nilai VaR harian MARK diperoleh dari model kombinasi AR(1) tanpa *intercept* dan GARCH(1,0) dengan distribusi residual sstd yang telah dibentuk pada subbab sebelumnya. Nilai VaR kemudian dirangkum dalam bentuk statistik ringkas berisi nilai rata-rata, nilai maksimum, nilai minimum, serta varians VaR untuk dua tingkat kuantil, yaitu 1% dan 5%. Ringkasan hasil estimasi nilai risiko VaR saham MARK disajikan pada Tabel 4.51.


Tabel 4.51 Estimasi Nilai VaR Saham MARK

Kuantil	Estimasi Risiko VaR			
	Mean	Max	Min	Varians
1%	-0,06887	-0,06123	-0,16574	0,00014
5%	-0,03997	-0,03492	-0,10127	0,00005

Tabel 4.51 menunjukkan bahwa rata-rata VaR MARK pada tingkat kepercayaan 99% sebesar $-0,06887$, yang artinya secara rata-rata investor berisiko mengalami kerugian maksimum sebesar 6,9% dalam satu hari perdagangan. Jika investor berinvestasi sebesar Rp1.000.000.000 pada saham MARK, maka VaR 1% mengindikasikan potensi kerugian harian sekitar Rp68.870.000 pada kondisi pasar yang tidak menguntungkan dengan peluang kejadian sekitar 1% dari seluruh hari bursa. Pada tingkat kepercayaan 95% rata-rata VaR lebih

tinggi sebesar $-0,03997$ yang berarti potensi kerugian maksimum 3,9% yaitu sekitar Rp39.970.000 untuk investasi sebesar Rp1.000.000.000.

Perbedaan nilai VaR antara kedua tingkat kepercayaan menunjukkan bahwa semakin tinggi tingkat kepercayaan yang digunakan, kerugian maksimum yang diestimasi juga semakin dalam. Pada tingkat kepercayaan 99%, nilai minimum VaR MARK mencapai $-0,16574$ atau kerugian terburuk sekitar 16,57% dari nilai investasi, sedangkan nilai maksimum $-0,06123$ atau 6,12% menggambarkan batas kerugian harian paling kecil dalam kelompok 1% observasi terburuk. Pada tingkat kepercayaan 95% batas risiko menjadi lebih moderat dengan nilai minimum VaR sekitar $-0,10127$ atau 10,13% sebagai kerugian terburuk yang tercatat, dan nilai maksimum $-0,03492$ atau sekitar 3,49% sebagai kerugian terkecil yang masih termasuk dalam kategori kejadian ekstrem. Dilihat dari nilai varians, varians VaR pada tingkat kepercayaan 95% lebih kecil dibandingkan pada tingkat kepercayaan 99%. Hal ini mengindikasikan bahwa sebaran risiko pada VaR 5% lebih terkonsentrasi dan stabil, sedangkan pada VaR 1% lebih sensitif terhadap guncangan besar di ekor distribusi. Untuk melihat pergerakan nilai risiko pada MARK, berikut merupakan visualisasi perbandingan nilai VaR terhadap *return* aktual MARK yang disajikan pada Gambar 4.14.



Gambar 4.14 Plot VaR MARK Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.14 menunjukkan bahwa garis VaR 5% berada lebih dekat dengan sumbu nol sehingga lebih sering disentuh atau dilampaui oleh *return* aktual dibandingkan dengan garis VaR 1%. Sebaliknya, pada VaR 1%, batas risiko berada lebih jauh di bawah *return* rata-rata sehingga kejadian ketika *return* aktual jatuh melewati garis VaR muncul dengan frekuensi yang lebih rendah. Pola ini konsisten dengan karakteristik VaR, di mana VaR pada kuantil 5% merepresentasikan batas kerugian terkait dengan kejadian pada 5% observasi terburuk, sedangkan VaR pada kuantil 1% menggambarkan batas kerugian untuk 1% observasi yang benar-benar ekstrem. Sehingga secara visual, dapat disimpulkan bahwa untuk saham MARK VaR 1% bersifat lebih konservatif dibandingkan VaR 5% karena hanya akan terlampaui pada saat kondisi pasar yang sangat ekstrem.

Secara keseluruhan, hasil estimasi VaR dengan pendekatan AR-GARCH dan variasinya menunjukkan bahwa profil risiko harian saham-saham sektor industri cukup heterogen baik dari sisi kedalaman maupun dinamika batas kerugian. Saham SMIL secara konsisten menempati posisi paling berisiko dengan rata-rata VaR 1% sebesar $-15,02\%$ dan VaR 5% sebesar $-6,97\%$, diikuti oleh SINI dengan rata-rata VaR 1% sebesar $-11,82\%$, kemudian SKRN dan IMPC dengan rata-rata VaR 1% masing-masing sebesar $-8,28\%$ dan $-7,61\%$, serta

MARK sebesar $-6,89\%$. Sementara itu, UNTR, ARNA, HEXA, dan ASII berada pada kelompok dengan VaR rata-rata yang lebih dangkal, sedangkan TOTO memiliki batas kerugian paling kecil dengan rata-rata VaR 1% hanya sebesar $-2,95\%$.

Perbedaan struktur model yang terbentuk mencerminkan heterogenitas karakteristik volatilitas antar emiten. Saham dengan komponen AR–GARCH penuh mencakup IMPC (AR([2])–GARCH(1,0)), SINI (AR(1)–GARCH(1,1)), SMIL (AR(1)–GARCH(1,0)), dan MARK (AR(1)–GARCH(1,0)), yang menunjukkan adanya ketergantungan autoregresif pada *mean return* sekaligus dinamika varians bersyarat yang berubah dari waktu ke waktu. Saham SKRN dan ARNA hanya memerlukan komponen GARCH(1,1) tanpa AR, yang berarti volatilitasnya bersifat dinamis namun *mean return*-nya tidak menunjukkan ketergantungan terhadap nilai masa lalu. Sebaliknya, ASII (AR(2)), UNTR (AR(2)), dan TOTO (AR(1)) hanya memerlukan komponen AR tanpa GARCH karena tidak terdeteksi efek ARCH yang signifikan pada residualnya, sehingga VaR dihitung berdasarkan dinamika *mean* dengan deviasi standar yang diasumsikan konstan. Adapun HEXA dimodelkan sebagai proses i.i.d. dengan volatilitas benar-benar konstan karena tidak memiliki komponen AR maupun GARCH yang signifikan, sehingga menghasilkan nilai VaR yang tidak berubah sama sekali sepanjang periode pengamatan dan nilai varians VaR yang bernilai tepat nol.

Pada sebagian besar saham, VaR pada kuantil 1% selalu lebih dalam dan memiliki varians yang lebih besar dibandingkan VaR 5%, sehingga menggambarkan batas kerugian yang lebih konservatif untuk kejadian-kejadian ekstrem di ekor distribusi. Sementara itu, VaR 5% merepresentasikan batas kerugian harian pada kondisi pasar yang buruk tetapi masih relatif lebih sering terjadi. Dengan karakteristik VaR HEXA yang benar-benar konstan dan tidak menangkap dinamika volatilitas dari waktu ke waktu, saham tersebut hanya digunakan pada tahap pengukuran VaR individual dan tidak dilanjutkan ke analisis CoVaR. Hasil ini menegaskan pentingnya mempertimbangkan kedua tingkat kepercayaan secara bersamaan dalam pengukuran risiko pasar, serta menjadi dasar untuk menguji keandalan model melalui prosedur *backtesting* yang akan dibahas pada Subbab selanjutnya.

4.2.7 *Backtesting Hasil Estimasi VaR*

Setelah diperoleh nilai VaR masing-masing emiten pada kuantil 1% dan 5%, dilakukan *backtesting* untuk mengevaluasi kinerja model dengan tujuan mengetahui sejauh mana estimasi VaR tersebut mampu merepresentasikan risiko kerugian yang terjadi secara aktual. Evaluasi dilakukan menggunakan *Proportion of Shortfall* (PS) dan *Kupiec Test*.

a) *Proportion Shortfall*

Proportion Shortfall dalam konteks *backtesting* dinyatakan sebagai rasio pelanggaran, yaitu proporsi ketika *return* aktual berada di bawah batas VaR. Dengan jumlah observasi sebanyak 597 hari, jumlah pelanggaran yang diharapkan dari model untuk VaR pada kuantil 1% adalah sebanyak 6 pelanggaran dan pada kuantil 5% sebanyak 30. Tabel 4.50 menyajikan uraian jumlah pelanggaran aktual, nilai *Proportion Shortfall* (PS), serta nilai absolut selisih risiko untuk tiap emiten pada dua tingkat kuantil yang digunakan.

Tabel 4.52 Hasil *Backtesting* Metode *Proportion Shortfall* pada Estimasi VaR

Saham	$\tau = 0,01$			$\tau = 0,05$		
	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko
ASII	2	0,0034	0,0066	29	0,0486	0,0014
IMPC	5	0,0084	0,0016	34	0,0570	0,0070

Tabel 4.52 Hasil *Backtesting* Metode *Proportion Shortfall* pada Estimasi VaR (Lanjutan)

Saham	$\tau = 0,01$			$\tau = 0,05$		
	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko
UNTR	4	0,0067	0,0033	26	0,0436	0,0064
SKRN	8	0,0134	0,0034	36	0,0603	0,0103
SINI	7	0,0117	0,0017	44	0,0737	0,0237
SMIL	6	0,0101	0,0001	33	0,0553	0,0053
ARNA	4	0,0067	0,0033	35	0,0586	0,0086
HEXA	6	0,0101	0,0001	33	0,0553	0,0053
TOTO	9	0,0151	0,0051	34	0,0570	0,0070
MARK	7	0,0117	0,0017	34	0,0570	0,0070

Tabel 4.52 menunjukkan bahwa pada tingkat kepercayaan 99% ($\tau = 1\%$) nilai *Proportion Shortfall* sebagian besar saham relatif kecil dan cukup dekat dengan nilai teoritis 1%. Hal ini berarti bahwa secara umum, model VaR mampu merepresentasikan frekuensi kejadian ekstrem sesuai dengan tingkat yang diharapkan. Namun, variasi deviasi cenderung terbatas karena jumlah pelanggaran yang relatif sedikit, sebagaimana terlihat dari nilai |Selisih| Risiko yang relatif kecil. Meskipun demikian, TOTO dan SKRN menjadi saham dengan proporsi pelanggaran tertinggi pada tingkat kuantil ini (sekitar 1,51% dan 1,34%), diikuti oleh SINI dan MARK. Hal ini mengindikasikan bahwa pada saham-saham ini, kerugian aktual lebih sering melampaui batas nilai VaR dari yang diperkirakan model sehingga muncul kecenderungan *underestimation* risiko pada ekor distribusi. Pada saham ASII, IMPC, UNTR, dan ARNA nilai proporsi pelanggaran berada di bawah 1%, sehingga VaR yang dihasilkan lebih konservatif meskipun nilai selisih risiko pada ASII, UNTR, dan ARNA cukup besar yang mengindikasikan bahwa estimasi model terhadap besaran kerugian ekstrem belum sepenuhnya akurat meskipun frekuensi pelanggarannya sudah berada di bawah nilai teoritis. Di sisi lain, SMIL dan HEXA menunjukkan akurasi estimasi yang lebih baik dibandingkan dengan emiten lainnya dengan |Selisih| Risiko sebesar 0,0001 yang menandakan bahwa model VaR untuk kedua saham ini andal dalam mengestimasi risiko pada kejadian yang sangat ekstrem.

Pada tingkat kepercayaan 95%, sebagian besar saham memiliki proporsi pelanggaran (*Proportion Shortfall*) yang cukup dekat dengan nilai teoritis 5%. Saham SMIL dan HEXA kembali menunjukkan akurasi estimasi yang cukup baik dengan nilai PS mendekati 0,05 dan |Selisih| Risiko sebesar 0,0053, sementara ASII mencatat selisih lebih kecil lagi, yaitu 0,0014 menjadikan ASII sebagai saham dengan estimasi paling akurat pada kuantil ini. Sebaliknya, SINI memiliki deviasi paling besar dengan proporsi pelanggaran mencapai 7,37% dan |Selisih| Risiko sebesar 0,00237 mengindikasikan model VaR menunjukkan kecenderungan *underestimation*, diikuti dengan saham SKRN dengan proporsi pelanggaran mencapai 6,03%. Sementara itu, ASII dan UNTR memperlihatkan proporsi pelanggaran dibawah 5%, sehingga VaR yang dihasilkan lebih konservatif meskipun nilai selisih risiko pada UNTR masih cukup tinggi, tetapi tidak setinggi SINI dan SKRN. Hasil ini menjadi indikasi awal mengenai akurasi frekuensi pelanggaran untuk setiap saham, yang selanjutnya akan diuji secara lebih formal menggunakan *Kupiec Test*.

b) *Kupiec Test*

Validitas model VaR kemudian dievaluasi dengan *Kupiec Test*. *Kupiec Test* membandingkan proporsi pelanggaran VaR yang terjadi secara empiris dengan tingkat pelanggaran yang diharapkan berdasarkan kuantil yang digunakan. Hipotesis nol (H_0) menyatakan bahwa proporsi pelanggaran sama dengan tingkat kuantil yang digunakan,

sedangkan hipotesis alternatif (H_1) menyatakan bahwa proporsi pelanggaran yang dihasilkan berbeda. Statistik *Kupiec test* mengikuti distribusi χ^2 dengan derajat bebas satu. Jika nilai statistik lebih besar daripada nilai kritis atau *p-value* lebih kecil dari 0,05, maka H_0 ditolak dan model VaR dinyatakan tidak valid pada tingkat kepercayaan tersebut. Tabel 4.53 menyajikan ringkasan hasil pengujian *Kupiec Test* seluruh saham pada dua tingkat kuantil yang berbeda.

Tabel 4.53 Hasil *Backtesting* Metode *Kupiec Test* pada Estimasi VaR

Saham	Kuantil	Statistik	$\chi^2_{\alpha,1}$	<i>P-value</i>	Keputusan	Kesimpulan
ASII	1%	3,592	3,841	0,058	Gagal Tolak H_0	Valid
	5%	0,026	3,841	0,873	Gagal Tolak H_0	Valid
IMPC	1%	0,169	3,841	0,681	Gagal Tolak H_0	Valid
	5%	0,582	3,841	0,445	Gagal Tolak H_0	Valid
UNTR	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	0,545	3,841	0,460	Gagal Tolak H_0	Valid
SKRN	1%	0,630	3,841	0,427	Gagal Tolak H_0	Valid
	5%	1,255	3,841	0,263	Gagal Tolak H_0	Valid
SINI	1%	0,170	3,841	0,680	Gagal Tolak H_0	Valid
	5%	6,200	3,841	0,013	Tolak H_0	Tidak Valid
SMIL	1%	0,000	3,841	0,990	Gagal Tolak H_0	Valid
	5%	0,339	3,841	0,561	Gagal Tolak H_0	Valid
ARNA	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	0,888	3,841	0,346	Gagal Tolak H_0	Valid
HEXA	1%	0,000	3,841	0,990	Gagal Tolak H_0	Valid
	5%	0,339	3,841	0,561	Gagal Tolak H_0	Valid
TOTO	1%	1,344	3,841	0,246	Gagal Tolak H_0	Valid
	5%	0,582	3,841	0,445	Gagal Tolak H_0	Valid
MARK	1%	0,170	3,841	0,680	Gagal Tolak H_0	Valid
	5%	0,582	3,841	0,445	Gagal Tolak H_0	Valid

Tabel 4.53 memperlihatkan bahwa seluruh saham pada tingkat kuantil 1%, nilai statistik *Kupiec* berada di bawah nilai kritis χ^2 dan *p-value* lebih besar dari 0,05, sehingga H_0 gagal ditolak. Oleh karena itu, model VaR untuk kesepuluh saham dinyatakan valid pada kuantil 1% karena frekuensi pelanggaran yang terjadi tidak berbeda secara signifikan dari yang diharapkan. Hasil *Kupiec test* pada kuantil 5%, sebagian besar saham juga menghasilkan keputusan gagal tolak H_0 . Satu-satunya saham pada kuantil 5% yang menghasilkan nilai *Kupiec* melampaui batas kritis dan *p-value* di bawah 0,05 adalah saham SINI, yang dapat diartikan bahwa model VaR yang dihasilkan tidak valid. Hal ini mengindikasikan bahwa model cenderung mengunderestimasi risiko pada ekor kiri distribusi sehingga lebih sering terjadi pelanggaran nilai VaR. Tidak validnya SINI ini diduga terkait dengan karakteristik *return* SINI yang menyentuh batas *Auto Rejection* BEI, mengindikasikan periode likuiditas ekstrem menyebabkan volatilitas melonjak tajam pada rentang waktu tertentu, sejalan dengan temuan Bildik dan Elekdag (2004) yang menunjukkan bahwa mekanisme *price limit* dapat menyebabkan *structural break* pada volatilitas *return* saham dalam kerangka GARCH. Ini menyebabkan model AR-GARCH yang diestimasi dari keseluruhan periode pengamatan kurang mampu mengakomodasi dinamika volatilitas secara memadai, sehingga pelanggaran VaR cenderung terkonsentrasi pada periode volatilitas ekstrem dan menyebabkan proporsi pelanggaran total melampaui batas teoritis pada kuantil 5%.

c) *Pinball Loss*

Selain evaluasi berbasis frekuensi pelanggaran melalui *Proportion Shortfall* dan *Kupiec test*, ketepatan estimasi VaR pada penelitian ini juga dievaluasi menggunakan *pinball loss* sebagaimana dijelaskan pada Subbab 2.13. Semakin kecil nilai *pinball loss* yang dihasilkan, semakin akurat model VaR dalam mengestimasi kuantil τ yang dievaluasi. Hasil perhitungan *pinball loss* untuk estimasi VaR pada kesepuluh saham disajikan pada Tabel 4.54.

Tabel 4.54 Hasil *Pinball Loss* pada Estimasi VaR

Saham	Kuantil	<i>Pinball Loss</i>
ASII	1%	0,00058
	5%	0,00176
IMPC	1%	0,00107
	5%	0,00294
UNTR	1%	0,00073
	5%	0,00217
SKRN	1%	0,00129
	5%	0,00357
SINI	1%	0,00154
	5%	0,00523
SMIL	1%	0,00214
	5%	0,00630
ARNA	1%	0,00056
	5%	0,00174
HEXA	1%	0,00084
	5%	0,00187
TOTO	1%	0,00044
	5%	0,00124
MARK	1%	0,00079
	5%	0,00293

Nilai *pinball loss* VaR pada $\tau = 1\%$ berkisar antara 0,00044 pada hingga 0,00214, sedangkan pada $\tau = 5\%$ berkisar antara 0,00124 hingga 0,00630. TOTO secara konsisten mencatat nilai *pinball loss* terendah pada kedua tingkat kuantil, menunjukkan bahwa model AR-GARCH mampu mengestimasi VaR TOTO dengan penyimpangan paling kecil terhadap *return* aktualnya dibandingkan saham lain. Sebaliknya, SMIL secara konsisten mencatat nilai *pinball loss* tertinggi pada kedua tingkat kuantil, mengindikasikan penyimpangan terbesar antara estimasi VaR dan *return* aktualnya.

Kombinasi *backtesting* menggunakan *Proportion Shortfall*, *Kupiec Test*, dan *Pinball Loss* menunjukkan bahwa evaluasi frekuensi pelanggaran dan besaran penyimpangan mengukur aspek akurasi model yang berbeda dan saling melengkapi, sehingga kombinasi ketiganya diperlukan untuk memperoleh gambaran validitas model VaR yang lebih komprehensif sebelum dilanjutkan ke estimasi risiko sistemik dan keterkaitan antar saham menggunakan *Conditional Value-at-Risk* (CoVaR) dan Δ CoVaR.

4.3 Estimasi Nilai *Conditional Value-at-Risk* dengan Pendekatan *Quantile Regression Forest* (QRF) dan Δ CoVaR

Estimasi *Conditional Value-at-Risk* (CoVaR) dalam konteks analisis risiko sistemik merupakan pendekatan yang digunakan untuk memperoleh tingkat risiko suatu saham dengan mempertimbangkan pengaruh bersama dari saham-saham lain. Adapun Δ CoVaR didefinisikan sebagai selisih antara CoVaR saat *distress* dan CoVaR saat keadaan normal, sehingga dapat

menggambarkan perubahan risiko yang muncul ketika saham mengalami guncangan dan ketika pasar dalam kondisi lebih tenang.

4.3.1 Uji Terasvirta

Sebelum masuk ke proses estimasi nilai CoVaR pada setiap saham, dilakukan pengujian nonlinearitas menggunakan Uji Terasvirta. Adapun Uji Terasvirta ini bukan sebagai syarat untuk melanjutkan proses estimasi CoVaR menggunakan *Quantile Regression Forest* (QRF), tetapi hanya sebagai informasi tambahan mengenai hubungan antara nilai *return* saham sebagai variabel respon dan nilai VaR pada saham lainnya sebagai variabel prediktor. Hasil dari Uji Terasvirta ini tidak akan menentukan apakah estimasi CoVaR berbasis QRF dapat dilanjutkan atau tidak, melainkan hanya memberikan gambaran awal mengenai pola data yang digunakan.

Hasil pengujian Terasvirta yang terlampir pada Lampiran 23, hampir seluruh saham menunjukkan nilai *p-value* yang lebih besar dari tingkat signifikansi (0,05) pada kedua tingkat kuantil, yang dapat disimpulkan tidak terdapat hubungan nonlinier antara *return* saham dan nilai VaR saham lainnya. Hanya terdapat satu pengecualian, yaitu ARNA yang menunjukkan nilai *p-value* sebesar 0,0274 yang berada di bawah tingkat signifikansi 0,05 pada kuantil 5%, mengindikasikan adanya hubungan nonlinier antara *return* ARNA dan nilai VaR saham lainnya pada kondisi pasar yang lebih moderat. Oleh karena itu, hubungan antarvariabel pada sebagian besar saham cenderung linier, namun tidak sepenuhnya berlaku pada seluruh saham dan tingkat kuantil yang digunakan.

Meskipun demikian, perlu diingat bahwa Uji Terasvirta pada penelitian ini hanya bersifat sebagai informasi tambahan dan tidak menjadi syarat dilakukannya estimasi CoVaR dengan QRF, penelitian ini tetap valid baik ketika hubungan data bersifat linier maupun nonlinier. Hal ini dikarenakan QRF merupakan pendekatan berbasis *machine learning* yang tidak memerlukan asumsi linearitas maupun asumsi distribusi tertentu pada data. Sehingga adanya hubungan nonlinier pada ARNA semakin memperkuat relevansi penggunaan QRF, karena pendekatan ini mampu mengakomodasi baik hubungan linier maupun nonlinier tanpa memerlukan asumsi distribusi tertentu pada data.

4.3.2 Estimasi Nilai CoVaR Setiap Saham dengan QRF

Proses estimasi nilai CoVaR dengan *Quantile Regression Forest* (QRF) dilakukan pada kuantil 1% dan 5% menggunakan *moving block bootstrap*. Metode *moving block bootstrap* yang digunakan pada estimasi CoVaR dengan QRF ini akan membagi data ke dalam blok-blok yang didalamnya berisi data dengan urutan observasi yang selalu dipertahankan guna mempertahankan struktur dependensi temporal yang ada dalam data *time series*. Sehingga ketika *bootstrap* acak diterapkan dalam algoritma *Random Forest*, informasi pada pola data *time series* tidak akan rusak atau hilang. Adapun pada estimasi CoVaR, HEXA tidak diikutsertakan dalam pemodelan dikarenakan nilai VaR yang dihasilkan bersifat konstan dan tidak mencerminkan dinamika risiko harian. Parameter yang digunakan dalam estimasi CoVaR dengan QRF ditunjukkan pada Tabel 4.55.

Tabel 4.55 Hyperparameter Estimasi CoVaR dengan QRF

Parameter	Nilai
<i>num.trees</i>	1.000
<i>min.node.size</i>	5
<i>honesty</i>	TRUE / 0,5
<i>MBB block size</i>	63

Pada penelitian ini, jumlah pohon ditetapkan sebesar 1.000 yang dipilih berdasarkan pertimbangan proses komputasi dan sifat konvergensi *Random Forest*, yang menunjukkan bahwa tingkat kesalahan estimasi model (*generalization error*) akan konvergen ke nilai batas tertentu dan tidak menurun seiring bertambahnya jumlah pohon (Breiman, 2001). Sehingga penambahan pohon melewati titik atau batas konvergensi tidak memberikan peningkatan akurasi yang berarti, namun meningkatkan beban komputasi pada analisis yang dilakukan. Adapun ukuran minimum *node* sebesar 5 dipilih berdasarkan *default* yang digunakan pada implementasi *Random Forest* yang mengontrol kedalaman pohon. *Honesty* merupakan mekanisme untuk memisahkan data *training* tiap pohon menjadi dua bagian subsampel, *splitting sample* dan *estimation sample*. Angka 0,5 adalah *honesty.fraction*, yaitu proporsi pembagian antara kedua subsample tersebut (50:50), dengan tujuan mengurangi bias atau *overfitting* yang muncul jika data yang sama dipakai untuk menentukan struktur pohon maupun mengestimasi nilai prediksinya sekaligus. Dengan menggunakan ukuran *block* sebesar 63 yang merepresentasikan satu kuartal atau tiga bulan hari perdagangan bursa, hasil perhitungan dan interpretasi CoVaR untuk kesembilan saham sektor industri disajikan pada subbagian a) hingga i) berikut.


a) ASII

Estimasi CoVaR dengan *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk ASII pada kuantil 1% dan 5% disajikan pada Tabel 4.56.

Tabel 4.56 Estimasi Nilai CoVaR Saham ASII

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,04374	-0,03137	-0,09754	0,00030
5%	-0,02749	-0,01923	-0,03397	0,00001

Berdasarkan Tabel 4.56, rata-rata CoVaR ASII pada tingkat kepercayaan 99% adalah sebesar $-0,04374$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 4,37% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada ASII sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp43.740.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,02749$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 2,75% atau kurang lebih Rp27.490.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional ASII lebih luas dan volatil. Sedangkan untuk risiko fluktuasi dalam estimasi CoVaR menjadi lebih rendah pada kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR ASII pada kuantil 1% memiliki minimum $-0,09754$ dan maksimum $-0,03137$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,03397$ dan maksimum $-0,01923$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* ASII. Untuk memperjelas pergerakan risiko pada saham ASII, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.15.



Gambar 4.15 Plot CoVaR ASII Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.15 menunjukkan bahwa pada kuantil 1%, garis CoVaR ASII menunjukkan fluktuasi yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR ASII bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih moderat, dibuktikan dengan sebagian besar fluktuasi *return* harian ASII masih berada di atas batas risiko meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Adapun proporsi pelanggaran pada kuantil 1% dan 5% masing-masing berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko ASII meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Penjelasan awal mengenai QRF yang tidak menghasilkan koefisien regresi secara eksplisit, menyebabkan besarnya pengaruh tiap prediktor tidak dapat diketahui langsung dari parameter model. Oleh karena itu, kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham ASII diidentifikasi melalui nilai *Variable Importance* (VI) yang dihasilkan dari model QRF. VI mengukur seberapa besar peran setiap emiten prediktor dalam mengurangi *impurity* pada proses pemisahan pohon (*splitting*) dalam algoritma *Random Forest*, sehingga memberikan gambaran kuantitatif mengenai derajat pengaruh masing-masing saham terhadap risiko sistemik ASII dibandingkan satu sama lain. Hasil perhitungan nilai VI tiap emiten terhadap ASII pada kuantil 1% dan 5% disajikan pada Tabel 4.57.

Tabel 4.57 *Variable Importance* QRF untuk CoVaR Saham ASII

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
ASII	IMPC	0,14535	IMPC	0,16883
	UNTR	0,15011	UNTR	0,14586
	SKRN	0,13671	SKRN	0,13159
	SINI	0,11904	SINI	0,10681

Tabel 4.57 *Variable Importance* QRF untuk CoVaR Saham ASII (Lanjutan)

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
ASII	SMIL	0,13957	SMIL	0,16078
	ARNA	0,10324	ARNA	0,09629
	TOTO	0,06913	TOTO	0,06855
	MARK	0,13685	MARK	0,12129

Dilihat dari Tabel 4.57, pada tingkat kepercayaan 99%, UNTR mencatat nilai VI tertinggi sebesar 0,15011, diikuti oleh IMPC, dan SMIL. Sementara itu, TOTO menjadi emiten dengan nilai VI terendah untuk saham ASII. Dominasi UNTR menunjukkan bahwa tekanan risiko pada emiten tersebut berkaitan erat terhadap pembentukan CoVaR ASII dibandingkan dengan emiten lain pada kondisi yang sangat ekstrem. Emiten IMPC kemudian menempati posisi tertinggi pada tingkat kepercayaan 95% mengungguli SMIL dan UNTR dengan nilai VI mencapai 0,16883. Pergeseran ini menunjukkan bahwa pengaruh IMPC terhadap CoVaR ASII justru lebih kuat pada kondisi pasar yang lebih moderat. TOTO kembali mencatatkan nilai VI terendah pada tingkat kepercayaan 95%, sehingga posisinya konsisten pada kedua tingkat kepercayaan. Meskipun TOTO konsisten menempati posisi terendah pada kedua tingkat kuantil, terdapat pergeseran posisi pertama pada kuantil 1% dan 5% oleh UNTR dan IMPC. Adanya pergeseran peringkat pada saham prediktor lainnya menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR ASII pada kondisi pasar sangat ekstrem tidak selalu sama dengan kondisi pasar yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham ASII selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

b) IMPC


Serupa dengan ASII, estimasi CoVaR untuk IMPC berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk IMPC pada kuantil 1% dan 5% disajikan pada Tabel 4.58.

Tabel 4.58 Estimasi Nilai CoVaR Saham IMPC

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,04656	-0,03509	-0,08333	0,00007
5%	-0,03032	-0,02210	-0,04255	0,00001

Rata-rata CoVaR IMPC pada tingkat kepercayaan 99% adalah sebesar $-0,04656$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 4,66% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada IMPC sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp46.560.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,03032$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 3,03% atau kurang lebih Rp30.320.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional IMPC lebih luas dan volatil. Sedangkan untuk risiko fluktuasi dalam estimasi CoVaR menjadi lebih rendah pada

kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR IMPC pada kuantil 1% memiliki minimum $-0,08333$ dan maksimum $-0,03509$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,04255$ dan maksimum $-0,02210$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* IMPC. Untuk memperjelas pergerakan risiko pada saham IMPC, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.16.



Gambar 4.16 Plot CoVaR IMPC Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.16 menggambarkan bahwa pada kuantil 1%, garis CoVaR IMPC menunjukkan fluktuasi dengan rentang yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR IMPC bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih normal. Ini dibuktikan dengan sebagian besar fluktuasi *return* harian IMPC masih berada di atas batas risiko, meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Proporsi pelanggaran yang ditunjukkan Gambar 4.16 melampaui batas yang ditetapkan yaitu sebesar 2,18% pada kuantil 1% dan 6,03% pada kuantil 5%, mengindikasikan bahwa model cenderung *underestimate* risiko aktual pada kedua tingkat kuantil. Hal ini tidak terlepas dari karakteristik empiris saham IMPC yang memiliki volatilitas *return* lebih tinggi, terutama menjelang akhir periode pengamatan. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko IMPC meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama halnya dengan ASII, nilai VI untuk saham IMPC dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham IMPC, dengan hasil yang disajikan pada Tabel 4.59.

Tabel 4.59 *Variable Importance* QRF untuk CoVaR Saham IMPC

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
IMPC	ASII	0,10372	ASII	0,10258
	UNTR	0,14573	UNTR	0,13597
	SKRN	0,10862	SKRN	0,13877
	SINI	0,11460	SINI	0,14164
	SMIL	0,12679	SMIL	0,08977
	ARNA	0,15486	ARNA	0,15687
	TOTO	0,09197	TOTO	0,09527
	MARK	0,15369	MARK	0,13912

Berdasarkan Tabel 4.59, pada tingkat kepercayaan 99%, ARNA mencatat nilai VI tertinggi sebesar 0,15486, diikuti MARK dan UNTR. Hal ini menunjukkan bahwa ketiga emiten ini memiliki keterkaitan paling dominan terhadap pembentukan CoVaR IMPC dibandingkan emiten lainnya pada kondisi yang sangat ekstrem. Sementara itu emiten dengan nilai VI terendah ditunjukkan oleh TOTO sebesar 0,09197. ARNA kembali menempati posisi tertinggi pada tingkat kepercayaan 95% dengan nilai VI mencapai 0,15687, memperkuat posisinya sebagai prediktor paling dominan di kedua kuantil untuk saham IMPC. Pergeseran mencolok terjadi pada SMIL, yang mengalami penurunan nilai VI dari 0,12679 pada kuantil 1% menjadi 0,08977 pada kuantil 5% sehingga menjadi prediktor dengan pengaruh paling kecil pada kuantil 5%, menandakan bahwa kontribusi SMIL terhadap risiko sistemik IMPC lebih terasa pada kondisi pasar sangat ekstrem. Sebaliknya, SINI dan SKRN mengalami kenaikan nilai VI pada kuantil 5%, mengindikasikan pengaruh keduanya lebih dominan pada kondisi risiko yang lebih moderat. Pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR IMPC pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham IMPC selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

c) UNTR


Estimasi CoVaR untuk UNTR berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk UNTR pada kuantil 1% dan 5% disajikan pada Tabel 4.60.

Tabel 4.60 Estimasi Nilai CoVaR Saham UNTR

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,05636	-0,02906	-0,14650	0,00019
5%	-0,02726	-0,02018	-0,04918	0,00001

Berdasarkan Tabel 4.60, rata-rata CoVaR UNTR pada tingkat kepercayaan 99% adalah sebesar $-0,05636$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 5,64% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada UNTR sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp56.360.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,02726$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 2,73% atau kurang lebih

Rp27.260.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional UNTR lebih luas dan volatil. Sedangkan untuk risiko fluktuasi dalam estimasi CoVaR menjadi lebih rendah pada kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR UNTR pada kuantil 1% memiliki minimum $-0,14650$ dan maksimum $-0,02906$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,04918$ dan maksimum $-0,02018$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* UNTR. Untuk memperjelas pergerakan risiko pada saham UNTR, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.17.



Gambar 4.17 Plot CoVaR UNTR Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.17 menggambarkan bahwa pada kuantil 1%, garis CoVaR UNTR menunjukkan fluktuasi dengan rentang yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih normal, dibuktikan dengan sebagian besar fluktuasi *return* harian UNTR masih berada di atas batas risiko meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Adapun proporsi pelanggaran pada kuantil 1% dan 5% masing-masing berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko UNTR meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama halnya dengan saham sebelumnya, nilai VI untuk saham UNTR dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham UNTR, dengan hasil yang disajikan pada Tabel 4.61.

Tabel 4.61 *Variable Importance* QRF untuk CoVaR Saham UNTR

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
UNTR	ASII	0,15685	ASII	0,15620
	IMPC	0,12983	IMPC	0,12088
	SKRN	0,14823	SKRN	0,15576
	SINI	0,12640	SINI	0,13004
	SMIL	0,13085	SMIL	0,13183
	ARNA	0,12413	ARNA	0,11802
	TOTO	0,07605	TOTO	0,07622
	MARK	0,10765	MARK	0,11105

Berdasarkan Tabel 4.61, pada tingkat kepercayaan 99%, ASII mencatat nilai VI tertinggi sebesar 0,15685, diikuti SKRN dan IMPC. Ini menunjukkan bahwa ketiga emiten ini memiliki keterkaitan paling dominan terhadap pembentukan CoVaR UNTR pada kondisi yang sangat ekstrem. Sementara itu, TOTO mencatat nilai VI terendah sebesar 0,07605. Pada tingkat kepercayaan 95%, ASII dan SKRN tetap mendominasi dengan nilai VI masing-masing sebesar 0,15620 dan 0,15576, di mana nilai VI saham SKRN meningkat jika dibandingkan dengan nilai pada kuantil 1%, mengindikasikan bahwa pengaruh SKRN terhadap risiko sistemik UNTR lebih kuat pada kondisi risiko yang lebih moderat. TOTO secara konsisten mencatat nilai VI terendah di kedua kuantil. Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR UNTR pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham UNTR selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

d) SKRN


Estimasi CoVaR untuk SKRN berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk SKRN pada kuantil 1% dan 5% disajikan pada Tabel 4.62.

Tabel 4.62 Estimasi Nilai CoVaR Saham SKRN

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,12668	-0,07317	-0,16942	0,00053
5%	-0,05929	-0,02941	-0,09600	0,00013

Berdasarkan Tabel 4.62, rata-rata CoVaR SKRN pada tingkat kepercayaan 99% adalah sebesar $-0,12668$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 12,67% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada SKRN sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp126.680.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,05929$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 5,93% atau kurang lebih Rp59.290.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional SKRN lebih luas dan volatil. Sedangkan untuk risiko fluktuasi dalam estimasi CoVaR menjadi lebih rendah pada

kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR SKRN pada kuantil 1% memiliki minimum $-0,16942$ dan maksimum $-0,07317$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,09600$ dan maksimum $-0,02941$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* SKRN. Untuk memperjelas pergerakan risiko pada saham SKRN, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.18.



Gambar 4.18 Plot CoVaR SKRN Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.18 menggambarkan bahwa pada kuantil 1%, garis CoVaR SKRN terlihat lebih dalam dan berfluktuasi dengan rentang yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR SKRN bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang kurang ekstrem, dibuktikan dengan sebagian besar fluktuasi *return* harian SKRN masih berada di atas batas risiko meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Adapun proporsi pelanggaran pada kuantil 1% dan 5% masing-masing berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko SKRN meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama halnya dengan saham sebelumnya, nilai VI untuk saham SKRN dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham SKRN, dengan hasil yang disajikan pada Tabel 4.63.

Tabel 4.63 *Variable Importance* QRF untuk CoVaR Saham SKRN

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
SKRN	ASII	0,12689	ASII	0,13422
	IMPC	0,13719	IMPC	0,12781

Tabel 4.63 *Variable Importance* QRF untuk CoVaR Saham SKRN (Lanjutan)

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
SKRN	UNTR	0,12738	UNTR	0,12362
	SINI	0,12469	SINI	0,11890
	SMIL	0,16280	SMIL	0,16772
	ARNA	0,14612	ARNA	0,15016
	TOTO	0,07621	TOTO	0,07222
	MARK	0,09872	MARK	0,10536

Berdasarkan Tabel 4.63, pada tingkat kepercayaan 99%, emiten SMIL mencatatkan nilai VI tertinggi sebesar 0,16280, diikuti oleh ARNA dan IMPC. Hal ini menunjukkan bahwa ketiga emiten ini memiliki keterkaitan paling dominan terhadap pembentukan CoVaR SKRN pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, SMIL masih menjadi emiten tertinggi dengan nilai VI sebesar 0,16772, mengalami kenaikan dibandingkan kuantil 1% yang mengindikasikan pengaruh SMIL terhadap risiko sistemik SKRN justru lebih kuat pada kondisi risiko yang lebih moderat. Sebaliknya, ASII, IMPC, dan ARNA mengalami pergeseran nilai VI yang lebih bervariasi antar kuantil. Sementara itu, TOTO secara konsisten juga mencatat nilai VI terendah di kedua kuantil. Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR SKRN pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham SKRN selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

e) SINI


Estimasi CoVaR untuk SINI berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk SINI pada kuantil 1% dan 5% disajikan pada Tabel 4.64.

Tabel 4.64 Estimasi Nilai CoVaR Saham SINI

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,11828	-0,09954	-0,25000	0,00112
5%	-0,09883	-0,09172	-0,10000	0,00000

Berdasarkan Tabel 4.64, rata-rata CoVaR SINI pada tingkat kepercayaan 99% adalah sebesar $-0,11828$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 11,83% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada SINI sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp118.280.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,09883$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 9,88% atau kurang lebih Rp98.830.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional SINI lebih luas dan volatil. Nilai varians CoVaR SINI pada kuantil 5% yang sangat kecil bukan berarti estimasinya benar-benar konstan, tetapi mencerminkan bahwa fluktuasi nilai CoVaR SINI pada kondisi moderat lebih kecil dan stabil sepanjang periode pengamatan. Dilihat dari nilai ekstremnya,

CoVaR SINI pada kuantil 1% memiliki minimum $-0,25000$ dan maksimum $-0,09954$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,10000$ dan maksimum $-0,09172$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* SINI. Untuk memperjelas pergerakan risiko pada saham SINI, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.19.



Gambar 4.19 Plot CoVaR SINI Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.19 menggambarkan bahwa pada kuantil 1%, garis CoVaR SINI menunjukkan varians yang lebih besar dan lebih berfluktuatif pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR SINI tampak lebih mendatar sepanjang periode pengamatan, konsisten dengan nilai variansnya yang sangat kecil mendekati nol. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih stabil dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Adapun proporsi pelanggaran pada kuantil 1% dan 5% masing-masing berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko SINI meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama halnya dengan saham sebelumnya, nilai VI untuk saham SINI dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham SINI, dengan hasil yang disajikan pada Tabel 4.65.

Tabel 4.65 Variable Importance QRF untuk CoVaR Saham SINI

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
SINI	ASII	0,11251	ASII	0,10624
	IMPC	0,12434	IMPC	0,12225
	UNTR	0,10468	UNTR	0,09646
	SKRN	0,11950	SKRN	0,11705
	SMIL	0,15658	SMIL	0,18261

Tabel 4.65 *Variable Importance* QRF untuk CoVaR Saham SINI (Lanjutan)

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
SINI	ARNA	0,14290	ARNA	0,14153
	TOTO	0,06761	TOTO	0,06498
	MARK	0,17189	MARK	0,16887

Berdasarkan Tabel 4.65, pada tingkat kepercayaan 99%, MARK mencatat nilai VI tertinggi sebesar 0,17189, diikuti SMIL dan ARNA. Hal ini menunjukkan bahwa ketiga emiten ini memiliki keterkaitan paling dominan terhadap pembentukan CoVaR SINI pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, SMIL menjadi emiten dengan nilai VI tertinggi yaitu sebesar 0,18261, meningkat cukup signifikan dibandingkan pada kuantil 1% yang menandakan pengaruh SMIL terhadap risiko sistemik SINI justru lebih kuat pada kondisi risiko yang lebih moderat. Sebaliknya, MARK dan ARNA mengalami penurunan nilai VI dari yang menandakan kontribusi kedua emiten lebih terasa pada saat kondisi yang sangat ekstrem. Sementara itu, TOTO secara konsisten mencatat nilai VI terendah di kedua kuantil (0,06761 dan 0,06498). Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR SINI pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham SINI selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

f) SMIL


Estimasi CoVaR untuk SMIL berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk SMIL pada kuantil 1% dan 5% disajikan pada Tabel 4.66.

Tabel 4.66 Estimasi Nilai CoVaR Saham SMIL

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,19864	-0,14667	-0,29814	0,00155
5%	-0,08591	-0,04505	-0,20796	0,00033

Berdasarkan Tabel 4.66, rata-rata CoVaR SMIL pada tingkat kepercayaan 99% adalah sebesar $-0,19864$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 19,9% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada SMIL sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp198.640.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,08591$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 8,6% atau kurang lebih Rp85.910.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional SMIL lebih luas dan volatil. Sedangkan untuk risiko fluktuasi dalam estimasi CoVaR menjadi lebih rendah pada kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR SMIL pada kuantil 1% memiliki minimum $-0,29814$ dan maksimum $-0,14667$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,20796$ dan maksimum $-0,04505$. Semakin

kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* SMIL. Untuk memperjelas pergerakan risiko pada saham SMIL, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.20.



Gambar 4.20 Plot CoVaR SMIL Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.20 menggambarkan bahwa pada kuantil 1%, garis CoVaR SMIL menunjukkan fluktuasi yang lebih luas dan lebih dalam pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR SMIL bergerak dekat dengan *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih normal, namun masih dengan fluktuasi yang masih cukup besar konsisten dengan nilai variansnya. Nilai pada kuantil 5% merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Proporsi pelanggaran yang ditunjukkan Gambar 4.20 pada kuantil 1% dan 5% masing-masing berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko SMIL meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama halnya dengan saham sebelumnya, nilai VI untuk saham SMIL dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham SMIL, dengan hasil yang disajikan pada Tabel 4.67.

Tabel 4.67 *Variable Importance* QRF untuk CoVaR Saham SMIL

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
SMIL	ASII	0,11650	ASII	0,11692
	IMPC	0,26421	IMPC	0,25567
	UNTR	0,15396	UNTR	0,14446
	SKRN	0,09810	SKRN	0,09735
	SINI	0,09975	SINI	0,10650
	ARNA	0,07504	ARNA	0,08240
	TOTO	0,06482	TOTO	0,07398
	MARK	0,12762	MARK	0,12271

Berdasarkan Tabel 4.67, pada tingkat kepercayaan 99%, IMPC mencatat nilai VI tertinggi sebesar 0,26421 mengindikasikan bahwa IMPC memiliki keterkaitan paling dominan terhadap pembentukan CoVaR SMIL pada kondisi yang sangat ekstrem. Sementara itu, TOTO mencatat nilai VI terendah sebesar 0,06482. Pada tingkat kepercayaan 95%, pola yang terbentuk relatif konsisten, di mana IMPC tetap mendominasi dengan nilai VI yang tidak terlalu jauh dengan nilai pada kuantil 1% . Hal ini mengindikasikan bahwa pengaruh IMPC terhadap risiko sistemik SMIL bersifat stabil pada kondisi pasar yang berbeda, baik saat kondisi sangat ekstrem maupun lebih moderat. TOTO secara konsisten mencatat nilai VI terendah di kedua kuantil. Pola VI di kedua kuantil sepenuhnya stabil tanpa ada pergeseran, menandakan bahwa hubungan antara prediktor dan CoVaR SMIL tidak berubah, baik di kondisi pasar yang sangat ekstrem maupun kondisi pasar yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham SMIL selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.


g) ARNA

Estimasi CoVaR untuk ARNA berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk ARNA pada kuantil 1% dan 5% disajikan pada Tabel 4.68.

Tabel 4.68 Estimasi Nilai CoVaR Saham ARNA

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,05543	-0,02703	-0,08209	0,00022
5%	-0,02453	-0,01527	-0,04027	0,00002

Berdasarkan Tabel 4.68, rata-rata CoVaR ARNA pada tingkat kepercayaan 99% adalah sebesar $-0,05543$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 5,54% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada ARNA sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp55.430.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,02453$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 2,45% atau kurang lebih Rp24.530.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa sebaran risiko kondisional ARNA lebih luas dan lebih volatil pada kondisi ekstrem. Sedangkan untuk risiko fluktuasinya menjadi lebih rendah pada kuantil yang lebih tinggi. Dilihat dari nilai ekstremnya, CoVaR ARNA pada kuantil 1% memiliki minimum $-0,08209$ dan maksimum $-0,02703$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,04027$ dan maksimum $-0,01527$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* ARNA. Untuk memperjelas pergerakan risiko pada saham ARNA, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.21.



Gambar 4.21 Plot CoVaR ARNA Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.21 menggambarkan bahwa pada kuantil 1%, garis CoVaR ARNA menunjukkan fluktuasi yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR ARNA bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih moderat dengan sebagian besar fluktuasi *return* harian ARNA masih berada di atas batas risiko meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Proporsi pelanggaran yang ditunjukkan Gambar 4.22 pada masing-masing kuantil berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko ARNA meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Nilai VI untuk saham ARNA dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham ARNA, dengan hasil yang disajikan pada Tabel 4.69.

Tabel 4.69 Variable Importance QRF untuk CoVaR Saham ARNA

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
ARNA	ASII	0,12252	ASII	0,12664
	IMPC	0,15799	IMPC	0,15869
	UNTR	0,13524	UNTR	0,13809
	SKRN	0,09982	SKRN	0,08963
	SINI	0,21491	SINI	0,17277
	SMIL	0,08597	SMIL	0,09493
	TOTO	0,07336	TOTO	0,08996
	MARK	0,11019	MARK	0,12930

Berdasarkan Tabel 4.69, pada tingkat kepercayaan 99%, SINI mencatat nilai VI tertinggi sebesar 0,21491, menunjukkan bahwa SINI memiliki keterkaitan paling dominan terhadap pembentukan CoVaR ARNA pada kondisi yang sangat ekstrem. Sementara itu, TOTO mencatat nilai VI terendah sebesar 0,07336. Pada tingkat kepercayaan 95%, SINI masih

menduduki posisi teratas namun mengalami penurunan nilai VI yang cukup signifikan menjadi 0,17277, mengindikasikan bahwa pengaruh SINI terhadap risiko sistemik ARNA lebih terasa pada kondisi pasar yang sangat ekstrem dibandingkan kondisi yang lebih moderat. Pada posisi nilai VI terendah, SKRN menggantikan TOTO sebagai emiten dengan nilai VI terkecil pada tingkat kuantil 5%. Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR ARNA pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham ARNA selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.


h) TOTO

Estimasi CoVaR untuk TOTO berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk TOTO pada kuantil 1% dan 5% disajikan pada Tabel 4.70.

Tabel 4.70 Estimasi Nilai CoVaR Saham TOTO

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,03438	-0,01786	-0,05085	0,00010
5%	-0,01534	-0,00917	-0,02885	0,00001

Berdasarkan Tabel 4.70, rata-rata CoVaR TOTO pada tingkat kepercayaan 99% adalah sebesar $-0,03438$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 3,44% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada TOTO sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp34.380.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,01534$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 1,53% atau kurang lebih Rp15.340.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Nilai ini juga merupakan nilai kerugian terkecil dari seluruh saham sektor industri yang masuk dalam penelitian, menunjukkan bahwa TOTO memiliki potensi kontribusi risiko sistemik paling rendah. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa pada kondisi ekstrem, sebaran risiko kondisional TOTO lebih luas dan volatil meskipun nilai keduanya tergolong kecil. Dilihat dari nilai ekstremnya, CoVaR TOTO pada kuantil 1% memiliki minimum $-0,05085$ dan maksimum $-0,01786$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,02885$ dan maksimum $-0,00917$. Semakin kecil nilai kuantil yang digunakan, nilai kerugian maksimum yang mungkin diperoleh investor akan semakin besar sehingga lebih direkomendasikan karena mengakomodasi nilai ekstrem *return* TOTO. Untuk memperjelas pergerakan risiko pada saham TOTO, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.22.



Gambar 4.22 Plot CoVaR TOTO Kuantil 1% (Kiri) dan 5% (Kanan)

Gambar 4.22 menggambarkan bahwa pada kuantil 1%, garis CoVaR TOTO menunjukkan fluktuasi yang lebih luas pada kondisi yang sangat ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5%, garis CoVaR TOTO bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih moderat, dengan sebagian besar fluktuasi *return* harian TOTO masih berada di atas batas risiko meskipun pada periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Adapun proporsi pelanggaran yang ditunjukkan Gambar 4.22 pada masing-masing kuantil berada di bawah batas yang ditetapkan, sehingga model bersifat konservatif pada kedua tingkat kuantil dan tidak meremehkan (*underestimate*) risiko aktual. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko TOTO meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

Sama seperti pada saham lainnya, VI untuk saham TOTO dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham TOTO dengan hasil yang disajikan pada Tabel 4.71.

Tabel 4.71 *Variable Importance* QRF untuk CoVaR Saham TOTO

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
TOTO	ASII	0,09583	ASII	0,10836
	IMPC	0,14762	IMPC	0,11469
	UNTR	0,09862	UNTR	0,09626
	SKRN	0,12294	SKRN	0,15519
	SINI	0,11634	SINI	0,10091
	SMIL	0,11171	SMIL	0,10224
	ARNA	0,16447	ARNA	0,16018
	MARK	0,14246	MARK	0,16217

Berdasarkan Tabel 4.71, pada tingkat kepercayaan 99%, ARNA mencatat nilai VI tertinggi sebesar 0,16447, diikuti IMPC dan MARK. Hal ini menunjukkan bahwa ketiga emiten memiliki

keterkaitan paling dominan terhadap pembentukan CoVaR TOTO pada kondisi yang sangat ekstrem. Sementara itu, ASII mencatat nilai VI terendah sebesar 0,09583. Pada tingkat kepercayaan 95%, MARK mengambil alih posisi teratas dengan nilai VI sebesar 0,16217, meningkat dari 0,14246 pada kuantil 1%, sementara ARNA turun ke posisi kedua dengan nilai 0,16018. SKRN juga mengalami kenaikan yang cukup mencolok dari 0,12294 menjadi 0,15519 yang menunjukkan pengaruhnya yang lebih kuat terhadap risiko sistemik TOTO pada kondisi risiko yang lebih moderat. Sementara itu, UNTR menggantikan ASII sebagai emiten dengan nilai VI terkecil pada tingkat kuantil 5%. Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR TOTO pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham TOTO selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.


i) MARK

Estimasi CoVaR untuk MARK berbasis *Quantile Regression Forest* (QRF) tidak menghasilkan estimasi parameter secara eksplisit, sehingga model tidak dapat dinyatakan dalam bentuk persamaan regresi. Oleh karena itu, hasil estimasi CoVaR berbasis QRF untuk MARK pada kuantil 1% dan 5% disajikan pada Tabel 4.72.

Tabel 4.72 Estimasi Nilai CoVaR Saham MARK

Kuantil	Estimasi Risiko CoVaR			
	Mean	Max	Min	Varians
1%	-0,06870	-0,05213	-0,09143	0,00007
5%	-0,04520	-0,03376	-0,06122	0,00003

Berdasarkan Tabel 4.72, rata-rata CoVaR MARK pada tingkat kepercayaan 99% adalah sebesar $-0,06870$ artinya secara rata-rata, investor berisiko mengalami kerugian kondisional sebesar 6,9% dalam satu hari kerja bursa ketika saham-saham lain di sektor industri berada pada kondisi VaR 1%-nya. Jika investor berinvestasi pada MARK sebesar Rp1.000.000.000, maka CoVaR 1% mengindikasikan potensi kerugian sekitar Rp68.700.000 pada kondisi yang sangat ekstrem. Pada tingkat kepercayaan 95%, rata-rata CoVaR meningkat menjadi $-0,04520$, yang menunjukkan potensi kerugian yang relatif lebih kecil sekitar 4,52% atau kurang lebih Rp45.200.000 untuk nilai investasi yang sama pada 5% skenario terburuk. Selain itu, nilai varians CoVaR pada kuantil 1% lebih besar dibandingkan dengan CoVaR 5% yang mengindikasikan bahwa sebaran risiko kondisional MARK lebih luas dan volatil dari waktu ke waktu pada kondisi ekstrem. Dilihat dari nilai ekstremnya, CoVaR MARK pada kuantil 1% memiliki minimum $-0,09143$ dan maksimum $-0,05213$, sedangkan pada kuantil 5% kedalaman risiko menurun dengan minimum $-0,06122$ dan maksimum $-0,03376$. Rentang yang semakin kecil ini mengonfirmasi bahwa estimasi CoVaR 5% lebih stabil dan tidak dipengaruhi oleh fluktuasi kondisi pasar yang ekstrem. Untuk memperjelas pergerakan risiko pada saham MARK, visualisasi perbandingan antara nilai aktual *return* dan CoVaR tersaji pada Gambar 4.23.



Gambar 4.23 Plot CoVaR MARK Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.23, garis CoVaR MARK pada kuantil 1% menunjukkan fluktuasi dengan rentang yang lebih luas pada kondisi ekstrem, di mana batas risiko relatif jarang disentuh oleh *return* aktual. Sementara itu, pada kuantil 5% garis CoVaR MARK bergerak lebih stabil di bawah *return* aktual dan mengikuti dinamika risiko kondisional pada kondisi pasar yang lebih moderat, dengan sebagian besar fluktuasi *return* harian MARK masih berada di atas batas risiko meskipun pada beberapa periode volatilitas tinggi garis CoVaR 5% beberapa kali dilampaui oleh *return* aktual. Hal ini konsisten dengan sifat kuantil 5% yang merepresentasikan kondisi risiko moderat, sehingga estimasi CoVaR yang dihasilkan lebih dekat ke nol dan tidak terlalu dipengaruhi oleh guncangan pasar yang ekstrem.

Proporsi pelanggaran pada kuantil 5% sebesar 4,52% berada di bawah batas yang ditetapkan sehingga model bersifat konservatif, sedangkan pada kuantil 1% proporsi sebesar 1,34% melampaui batas 1% yang mengindikasikan model cenderung meremehkan risiko aktual pada kondisi pasar yang sangat ekstrem. Perbedaan nilai antara CoVaR 1% dan 5% menegaskan bahwa risiko MARK meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR 1% sebagai ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat. Dengan catatan beberapa kejadian aktual masih jatuh di luar jangkauan estimasi model disebabkan oleh dinamika risiko MARK pada kondisi ekstrem kurang terpolat dengan baik karena adanya indikasi *underestimate* risiko aktual.

Nilai VI untuk saham MARK dihitung untuk mengidentifikasi kontribusi relatif masing-masing emiten prediktor terhadap CoVaR saham MARK, dengan hasil yang disajikan pada Tabel 4.73.

Tabel 4.73 *Variable Importance* QRF untuk CoVaR Saham MARK

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	Nilai VI	Prediktor	Nilai VI
MARK	ASII	0,09628	ASII	0,09646
	IMPC	0,13044	IMPC	0,12461
	UNTR	0,11040	UNTR	0,09850
	SKRN	0,09092	SKRN	0,09607
	SINI	0,14685	SINI	0,15577
	SMIL	0,08420	SMIL	0,11169
	ARNA	0,16931	ARNA	0,15849
	TOTO	0,17160	TOTO	0,15841

Berdasarkan Tabel 4.73, pada tingkat kepercayaan 99% TOTO mencatat nilai VI tertinggi sebesar 0,17160, diikuti ARNA dan SINI. Ini menunjukkan dominasi ketiga emiten terhadap pembentukan CoVaR MARK pada kondisi yang sangat ekstrem. Sementara itu, SMIL mencatat nilai VI terendah sebesar 0,08420. Pada tingkat kepercayaan 95%, ARNA mengambil alih posisi teratas dengan nilai VI sebesar 0,15849, diikuti oleh TOTO dan SINI. Pergeseran yang cukup mencolok terjadi pada SMIL yang mengalami kenaikan nilai VI dari 0,08420 menjadi 0,11169 yang mengindikasikan pengaruhnya terhadap risiko sistemik MARK lebih terasa pada kondisi risiko yang lebih moderat. Emiten yang mencatat nilai VI terendah pada kuantil 5% adalah SKRN, yaitu sebesar 0,09607. Adanya pergeseran pola VI antara kedua kuantil menunjukkan kemampuan QRF dalam menangkap perbedaan derajat pengaruh masing-masing emiten prediktor pada kondisi pasar yang berbeda, di mana hubungan antara prediktor dan CoVaR MARK pada kondisi sangat ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Nilai VI yang diperoleh dari model CoVaR QRF saham MARK selanjutnya akan dinormalisasi menggunakan *min-max scaling* untuk membentuk *prior inclusion probability* sebagai *informative prior* dalam proses MCMC pada tahap estimasi CoVaR SSVS.

4.3.3 Backtesting Hasil Estimasi CoVaR

Setelah diperoleh estimasi CoVaR pada kuantil 1% dan 5% untuk seluruh emiten sektor industri, langkah selanjutnya adalah mengevaluasi seberapa baik model mampu menangkap risiko kerugian kondisional yang sesungguhnya terjadi di pasar melalui proses *backtesting*. Evaluasi dilakukan menggunakan dua pendekatan statistik, yaitu *Proportion Shortfall* dan *Kupiec Test* berikut.

a) *Proportion Shortfall*

Proportion Shortfall dalam konteks *backtesting* dinyatakan sebagai rasio pelanggaran, yaitu proporsi ketika *return* aktual berada di bawah batas CoVaR serta selisih absolutnya terhadap tingkat kuantil teoritis. Dengan jumlah observasi sebanyak 597 hari, jumlah pelanggaran yang diharapkan dari model untuk CoVaR pada kuantil 1% adalah sebanyak 6 pelanggaran dan pada kuantil 5% sebanyak 30. Tabel 4.74 menyajikan uraian jumlah pelanggaran aktual, nilai *Proportion Shortfall* (PS), serta nilai absolut selisih risiko untuk tiap emiten pada dua tingkat kuantil yang digunakan.

Tabel 4.74 Hasil *Backtesting* Metode *Proportion Shortfall* pada Estimasi CoVaR

Saham	$\tau = 0,01$			$\tau = 0,05$		
	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko
ASII	5	0,0084	0,0016	26	0,0436	0,0064
IMPC	13	0,0218	0,0118	36	0,0603	0,0103
UNTR	4	0,0067	0,0033	29	0,0486	0,0014
SKRN	5	0,0084	0,0016	28	0,0469	0,0031
SINI	4	0,0067	0,0033	23	0,0385	0,0115
SMIL	3	0,0050	0,0050	29	0,0486	0,0014
ARNA	4	0,0067	0,0033	23	0,0385	0,0115
TOTO	4	0,0067	0,0033	24	0,0402	0,0098
MARK	8	0,0134	0,0034	27	0,0452	0,0048

Tabel 4.74 menunjukkan pada tingkat kepercayaan 99% ($\tau = 1\%$), variasi deviasi terlihat lebih jelas karena pengujiannya yang berfokus pada kejadian ekstrem. Dilihat dari nilai *Proportion Shortfall*, sebagian besar berada di bawah nilai teoritis 1% yang berarti bahwa

secara umum, model CoVaR pada kuantil 1% mampu merepresentasikan frekuensi kejadian ekstrem sesuai dengan tingkat yang diharapkan. ASII dan SKRN menunjukkan akurasi estimasi terbaik ditunjukkan oleh nilai *Proportion Shortfall* kedua saham sebesar 0,0084 paling dekat dengan nilai teoritis dengan |Selisih| Risiko sebesar 0,0016. Hal ini mengindikasikan bahwa model CoVaR kedua saham andal dalam mengestimasi risiko pada kejadian yang sangat ekstrem. Pada saham UNTR, SINI, ARNA, dan TOTO nilai proporsi pelanggaran berada di bawah 1% (0,0067), sehingga menghasilkan model CoVaR yang konservatif meskipun nilai |Selisih| Risiko masih cukup besar (0,0033) mengindikasikan bahwa estimasi model terhadap besaran kerugian ekstrem belum sepenuhnya akurat meskipun frekuensi pelanggarannya sudah berada di bawah nilai teoritis. SMIL mencatat proporsi pelanggaran terendah sebesar 0,0050 dengan |Selisih| Risiko lebih besar (0,0050), menandakan model yang lebih konservatif namun dengan jarak yang lebih jauh dari nilai teoritis 1%. Sementara itu, IMPC menjadi saham dengan proporsi pelanggaran tertinggi pada tingkat kuantil ini (sekitar 2,18%) dua kali lipat melampaui nilai teoritisnya, diikuti oleh MARK (sekitar 1,34%) menandakan bahwa pada kedua saham ini, kerugian aktual lebih sering melampaui batas nilai CoVaR dari yang diperkirakan model sehingga muncul kecenderungan *underestimation* risiko pada ekor distribusi yang cukup signifikan, terutama pada IMPC dengan akurasi estimasi CoVaR paling rendah di antara seluruh saham yang diuji.

Pada tingkat kepercayaan 95% ($\tau = 5\%$), sebagian besar saham memiliki proporsi pelanggaran (*Proportion Shortfall*) dekat dengan nilai teoritis 5% dengan variasi yang lebih kecil, namun secara rata-rata nilai |Selisih| Risiko lebih besar dibandingkan kuantil 1%. UNTR dan SMIL menunjukkan akurasi terbaik dengan nilai *Proportion Shortfall* sebesar 0,0486 dan |Selisih| Risiko terkecil sebesar 0,0014, yang menjadikan UNTR dan SMIL sebagai saham dengan estimasi CoVaR paling akurat pada tingkat kuantil ini. SKRN dan MARK mencatat estimasi yang cukup konservatif dengan nilai *Proportion Shortfall* masih dekat dengan nilai teoritis dengan |Selisih| Risiko masing-masing sebesar 0,0031 dan 0,0048. Adapun ASII, SINI, ARNA, dan TOTO juga menunjukkan proporsi pelanggaran di bawah 5% yang menandakan bahwa estimasi yang dihasilkan juga cukup konservatif, meskipun SINI dan ARNA mencatat nilai |Selisih| Risiko yang relatif besar (0,0115) mengindikasikan jaraknya yang cukup jauh dari nilai teoritis. Sementara itu, IMPC konsisten mencatat proporsi pelanggaran tertinggi (sekitar 6,03%) yang mengindikasikan model CoVaR IMPC menunjukkan kecenderungan *underestimation* karena kerugian aktual lebih sering melampaui batas CoVaR dari nilai teoritis yang ditentukan. Secara keseluruhan, nilai |Selisih| Risiko emiten pada kuantil 1% relatif lebih kecil dibandingkan dengan kuantil 5%, mengindikasikan bahwa estimasi risiko kerugian kondisional justru lebih akurat pada kondisi pasar yang sangat ekstrem. Hasil *Proportion Shortfall* ini menjadi indikasi awal mengenai akurasi frekuensi pelanggaran untuk setiap saham, yang selanjutnya akan diuji secara lebih formal menggunakan *Kupiec Test*.

b) Kupiec Test

Validitas model CoVaR kemudian dievaluasi dengan *Kupiec Test*. *Kupiec Test* membandingkan proporsi pelanggaran CoVaR yang terjadi secara empiris dengan tingkat pelanggaran yang diharapkan berdasarkan kuantil yang digunakan. Hipotesis nol (H_0) menyatakan bahwa proporsi pelanggaran sama dengan tingkat kuantil yang digunakan, sedangkan hipotesis alternatif (H_1) menyatakan bahwa proporsi pelanggaran yang dihasilkan berbeda. Statistik *Kupiec test* mengikuti distribusi χ^2 dengan derajat bebas satu. Jika nilai statistik lebih besar daripada nilai kritis atau *p-value* lebih kecil dari 0,05, maka H_0 ditolak dan

model CoVaR dinyatakan tidak valid pada tingkat kepercayaan tersebut. Tabel 4.75 menyajikan ringkasan hasil pengujian *Kupiec Test* seluruh saham pada dua tingkat kuantil yang berbeda.

Tabel 4.75 Hasil *Backtesting* Metode *Kupiec Test* pada Estimasi CoVaR

Saham	Kuantil	Statistik	$\chi^2_{\alpha,1}$	P-value	Keputusan	Kesimpulan
ASII	1%	0,169	3,841	0,681	Gagal Tolak H_0	Valid
	5%	0,545	3,841	0,460	Gagal Tolak H_0	Valid
IMPC	1%	6,257	3,841	0,012	Tolak H_0	Tidak Valid
	5%	1,255	3,841	0,263	Gagal Tolak H_0	Valid
UNTR	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	0,026	3,841	0,873	Gagal Tolak H_0	Valid
SKRN	1%	0,169	3,841	0,681	Gagal Tolak H_0	Valid
	5%	0,123	3,841	0,726	Gagal Tolak H_0	Valid
SINI	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	1,791	3,841	0,181	Gagal Tolak H_0	Valid
SMIL	1%	1,826	3,841	0,177	Gagal Tolak H_0	Valid
	5%	0,026	3,841	0,873	Gagal Tolak H_0	Valid
ARNA	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	1,791	3,841	0,181	Gagal Tolak H_0	Valid
TOTO	1%	0,743	3,841	0,389	Gagal Tolak H_0	Valid
	5%	1,290	3,841	0,256	Gagal Tolak H_0	Valid
MARK	1%	0,630	3,841	0,427	Gagal Tolak H_0	Valid
	5%	0,296	3,841	0,587	Gagal Tolak H_0	Valid

Tabel 4.75 memperlihatkan bahwa seluruh saham pada tingkat kuantil 5%, nilai statistik *Kupiec* berada di bawah nilai kritis χ^2 dan *p-value* lebih besar dari 0,05, sehingga H_0 gagal ditolak. Oleh karena itu, estimasi model CoVaR untuk seluruh saham dinyatakan valid pada kuantil 5% karena frekuensi pelanggaran yang terjadi tidak berbeda secara signifikan dari yang diharapkan. Sementara pada kuantil 1%, sebagian besar saham juga menghasilkan keputusan gagal tolak H_0 . Satu-satunya saham pada kuantil 1% yang menghasilkan nilai *Kupiec* melampaui batas kritis dan *p-value* di bawah 0,01 adalah saham IMPC, yang mengindikasikan bahwa pada saham IMPC cenderung meremehkan (*underestimate*) risiko pada ekor kiri distribusi sehingga lebih sering terjadi pelanggaran nilai CoVaR.

Tidak validnya IMPC pada kuantil 1% berkaitan dengan karakteristik *return* IMPC yang memiliki *skewness* dan kurtosis besar, mengindikasikan distribusi *return* yang asimetris dan *heavy-tailed*. Karakteristik ini diperkuat oleh *return* IMPC yang menyentuh batas *Auto Rejection Atas* (ARA) BEI, di mana *return* memiliki fluktuasi yang cukup tinggi menjelang akhir periode pengamatan, sejalan dengan temuan Bildik dan Elekdag (2004) mengenai *structural break* pada volatilitas *return* akibat *price limit* dalam kerangka GARCH. Kombinasi karakteristik distribusi *return* yang ekstrem dengan konsentrasi volatilitas pada periode tertentu menyebabkan estimasi CoVaR IMPC pada kuantil paling ekstrem 1% menjadi lebih rentan terhadap *underestimation* dibandingkan kuantil 5%, yang mengakibatkan tidak valid pada hasil pengujian *Kupiec*.

c) *Pinball Loss*

Selain evaluasi berbasis frekuensi pelanggaran melalui *Proportion Shortfall* dan *Kupiec test*, ketepatan estimasi CoVaR QRF pada penelitian ini juga dievaluasi menggunakan *pinball loss* sebagaimana dijelaskan pada Subbab 2.13. Hasil perhitungan *pinball loss* untuk estimasi VaR pada kesepuluh saham disajikan pada Tabel 4.76.

Tabel 4.76 Hasil *Pinball Loss* pada Estimasi CoVaR

Saham	Kuantil	<i>Pinball Loss</i>
ASII	1%	0,00063
	5%	0,00178
IMPC	1%	0,00100
	5%	0,00275
UNTR	1%	0,00078
	5%	0,00220
SKRN	1%	0,00148
	5%	0,00472
SINI	1%	0,00174
	5%	0,00582
SMIL	1%	0,00227
	5%	0,00724
ARNA	1%	0,00079
	5%	0,00188
TOTO	1%	0,00044
	5%	0,00123
MARK	1%	0,00082
	5%	0,00311

Berdasarkan Tabel 4.76, nilai *pinball loss* CoVaR pada $\tau = 1\%$ berkisar antara 0,00044 hingga 0,00227, sedangkan pada $\tau = 5\%$ berkisar antara 0,00123 hingga 0,00724. TOTO kembali menjadi saham dengan *pinball loss* terendah pada kedua tingkat kuantil, sementara SMIL kembali mencatat nilai tertinggi, konsisten dengan pola hasil *pinball loss* pada VaR, mengindikasikan bahwa urutan akurasi antarsaham relatif stabil baik pada pendekatan VaR individual maupun CoVaR bersyarat. Secara umum, urutan besaran *pinball loss* CoVaR antarsaham mengikuti pola yang serupa dengan VaR, dengan TOTO, ASII, dan ARNA secara konsisten menghasilkan penyimpangan estimasi yang kecil, sedangkan SMIL, SINI, dan SKRN secara konsisten menghasilkan penyimpangan yang lebih besar pada kedua tingkat kuantil yang dievaluasi.

Kombinasi *backtesting* menggunakan *Proportion Shortfall*, *Kupiec Test*, dan *Pinball Loss* menunjukkan bahwa evaluasi frekuensi pelanggaran dan besaran penyimpangan mengukur aspek akurasi model yang berbeda dan saling melengkapi, sehingga kombinasi ketiganya diperlukan untuk memperoleh gambaran validitas model VaR yang lebih komprehensif. Setelah diperoleh hasil validitas model CoVaR, dilanjutkan analisis pengukuran ΔCoVaR untuk mengetahui tambahan kontribusi risiko sistemik yang muncul ketika masing-masing saham berada pada kondisi *distress* dibandingkan dengan kondisi normalnya.

4.3.4 *Delta Conditional Value-at-Risk (ΔCoVaR)*

Delta Conditional Value-at-Risk (ΔCoVaR) didefinisikan sebagai selisih antara nilai CoVaR suatu saham ketika berada pada kondisi *distress*, yaitu saat *return*nya berada di sekitar nilai VaRnya dan nilai CoVaR ketika saham berada pada kondisi normal atau mediannya. ΔCoVaR tidak hanya mencerminkan besarnya risiko absolut seperti pada CoVaR, tetapi juga mengukur tambahan risiko kondisional akibat kondisi suatu saham yang memburuk terhadap saham lain di sektor yang sama. Semakin negatif nilai ΔCoVaR yang dihasilkan maka semakin besar pula kontribusi saham tersebut terhadap peningkatan risiko sistemik pada saat pasar berada pada kondisi *distress*. Hasil estimasi ΔCoVaR untuk seluruh emiten sektor industri pada kuantil 1% dan 5% disajikan pada Tabel 4.77.


Tabel 4.77 Estimasi Nilai Risiko ΔCoVaR Saham Sektor Industri

Saham	Kuantil	Mean	Max	Min	Varians
ASII	1%	0,00066	0,06420	-0,06357	0,00048
	5%	0,00013	0,00921	-0,00857	0,00001
IMPC	1%	-0,00013	0,04078	-0,04078	0,00005
	5%	0,00025	0,00882	-0,00993	0,00001
UNTR	1%	-0,00035	0,09732	-0,09732	0,00026
	5%	0,00010	0,01893	-0,02289	0,00001
SKRN	1%	-0,00208	0,07220	-0,07851	0,00063
	5%	0,00118	0,05768	-0,04266	0,00022
SINI	1%	0,00190	0,15000	-0,15000	0,00147
	5%	0,00004	0,00641	-0,00209	0,00000
SMIL	1%	0,00270	0,14901	-0,15047	0,00158
	5%	0,00101	0,08158	-0,09433	0,00048
ARNA	1%	0,00277	0,04505	-0,04182	0,00031
	5%	0,00009	0,01626	-0,01378	0,00002
TOTO	1%	0,00062	0,03250	-0,03198	0,00013
	5%	-0,00024	0,00925	-0,01050	0,00001
MARK	1%	0,00064	0,02921	-0,02921	0,00006
	5%	0,00046	0,01416	-0,01492	0,00002


Berdasarkan Tabel 4.77, nilai ΔCoVaR pada kuantil 1% yang menggambarkan kondisi yang lebih ekstrem membuat perubahan risiko terlihat lebih tajam dan umumnya lebih volatil, terlihat dari nilai varians yang lebih besar dibandingkan pada kuantil 5% pada seluruh saham. Saham yang paling menonjol dalam peningkatan risiko adalah SKRN, UNTR, dan IMPC, karena ketiganya memiliki rata-rata ΔCoVaR negatif, yang berarti pada kondisi ekstrem potensi kerugian (*downside risk*) emiten-emiten ini cenderung memburuk dibanding kondisi normal. UNTR juga mencatat nilai minimum yang cukup ekstrem, yaitu sekitar -0,09732 menandakan bahwa terjadi penurunan *tail return* jauh lebih dalam pada periode tertentu. Sementara itu, meskipun SINI dan SMIL memiliki rata-rata positif, namun tidak berarti keduanya tidak berkontribusi pada risiko sistemik. Nilai rata-rata ΔCoVaR positif pada SINI dan SMIL mengindikasikan bahwa secara rata-rata *downside risk* kondisional tidak meningkat dibanding kondisi normal, yang disebabkan oleh karakteristik distribusi *return* keduanya yang sangat volatil, di mana pola lonjakan (*spike*) *return* yang ekstrem, baik positif maupun negatif menyebabkan kuantil kondisional saat *distress* yang diestimasi QRF tidak selalu lebih dalam dibanding kondisi median secara rata-rata. Keduanya mencatat rentang nilai maksimum dan minimum yang sangat lebar, di mana SINI (0,15000 hingga -0,15000) dan SMIL (0,14901 hingga -0,15047) dengan varians yang tinggi, menandakan bahwa respons terhadap kondisi *distress* tidak seragam sepanjang periode pengamatan dan terdapat periode tertentu ketika risiko kondisional meningkat tajam. Di sisi lain, ASII, ARNA, TOTO, dan MARK menunjukkan rata-rata positif pada kuantil 1% dengan varians yang relatif kecil, mengindikasikan bahwa secara rata-rata *downside risk* tidak meningkat dibandingkan dengan kondisi normal.

Pada kuantil 5%, sebagian besar saham memiliki rata-rata ΔCoVaR yang kecil dan cenderung positif, antara lain ASII, IMPC, UNTR, SKRN, SINI, SMIL, ARNA, dan MARK yang mengindikasikan bahwa secara rata-rata *downside risk* tidak meningkat pada kondisi pasar moderat. Sementara itu, TOTO menunjukkan nilai rata-rata negatif, yang mengindikasikan bahwa pada kuantil 5% cenderung mengalami peningkatan risiko dibanding kondisi normal meskipun dengan besaran (*magnitude*) yang sangat kecil. Varians pada kuantil 5% secara keseluruhan jauh lebih kecil dibandingkan kuantil 1%, mencerminkan bahwa respons risiko

sistemik pada kondisi pasar moderat lebih terkendali dan seragam. Namun, adanya nilai minimum negatif pada hampir semua saham menunjukkan bahwa meskipun rata-ratanya terlihat aman, tetap ada periode tertentu ketika risiko kondisional memburuk. Dengan kata lain, kuantil 5% memberi sinyal bahwa risiko sistemik bersifat episodik, tidak selalu muncul konsisten di setiap waktu. Untuk memperjelas dinamika kontribusi risiko sistemik antar waktu, visualisasi pergerakan ΔCoVaR masing-masing saham disajikan pada Gambar 4.25.



Gambar 4.24 Plot ΔCoVaR Saham Sektor Industri



Gambar 4.24 Plot ΔCoVaR Saham Sektor Industri (Lanjutan)

Gambar 4.24 memperlihatkan ukuran ΔCoVaR berfluktuasi di sekitar nol tetapi dengan pola yang berbeda antar kuantil, di mana ΔCoVaR 1% cenderung lebih volatil dan memiliki deviasi yang lebih besar dibandingkan ΔCoVaR 5% karena merepresentasikan kondisi *distress* yang lebih ekstrem. Pola ini konsisten di seluruh saham yang dianalisis, dengan ΔCoVaR 5% yang pada sebagian besar saham hampir tidak terlihat bergerak jauh dari nol sepanjang periode pengamatan.

SKRN menjadi saham dengan fluktuasi paling besar karena baik ΔCoVaR pada kuantil 1% maupun 5% bergerak cukup jauh dari nol secara konsisten, mengindikasikan peningkatan risiko kondisional yang muncul pada kondisi sangat ekstrem maupun kondisi moderat. SINI juga menunjukkan pola serupa dengan ΔCoVaR 1% yang sangat volatil dan menunjukkan lonjakan terbesar pada awal periode, sedangkan pada ΔCoVaR 5% mengalami pergerakan yang stabil di sekitar nol. Hal ini menandakan peningkatan risiko kondisional SINI hanya muncul secara signifikan pada kondisi ekstrem dan cenderung terkendali pada kondisi moderat. SMIL memperlihatkan lonjakan ΔCoVaR 1% yang mencolok sekitar Maret 2025 bersamaan dengan lonjakan *return* aktual yang sangat besar, mengindikasikan bahwa pada periode tersebut mendorong peningkatan risiko kondisional yang lebih ekstrem dibandingkan periode lainnya.

Garis ΔCoVaR 1% pada saham UNTR beberapa kali bergerak tajam ke bawah nol terutama pada awal periode dan sekitar April 2025, mengindikasikan bahwa pada kondisi ekstrem tertentu potensi kerugian kondisional UNTR meningkat cukup dalam meskipun secara rata-rata tidak selalu memburuk. ASII dan MARK menunjukkan pola yang relatif serupa, di mana pola ΔCoVaR 1% berfluktuasi secara moderat di sekitar nol sementara ΔCoVaR 5% hampir tidak bergerak, menandakan tambahan risiko sistemik yang lebih terkendali. ARNA memperlihatkan fluktuasi ΔCoVaR 1% yang cukup teratur sepanjang periode dengan beberapa penurunan tajam, sementara ΔCoVaR 5% tetap mendekati nol. Sebaliknya, TOTO memperlihatkan pergerakan paling stabil di antara seluruh saham, dibuktikan dengan ΔCoVaR 1% dan 5% bergerak rapat di sekitar nol dengan rentang fluktuasi yang sempit, menunjukkan tambahan risiko sistemik yang paling kecil di antara saham-saham lainnya. Adapun IMPC menunjukkan pola yang berbeda, di mana aktual *return*-nya mengalami lonjakan besar terutama pada periode September hingga Desember 2025, tetapi garis ΔCoVaR 1% dan 5% justru tetap relatif datar di sekitar nol sepanjang periode tersebut. Hal ini mengindikasikan bahwa model CoVaR tidak mampu menangkap lonjakan risiko ekstrem yang sesungguhnya terjadi pada IMPC. Temuan ini konsisten dengan hasil *backtesting* CoVaR bahwa model CoVaR untuk IMPC cenderung mengalami *underestimation* risiko yang signifikan pada kuantil 1%.

Secara umum, ΔCoVaR memberikan gambaran yang lebih struktural mengenai sejauh mana risiko kondisional berubah ketika terjadi *distress*, sehingga memberikan informasi yang lebih relevan mengenai dinamika risiko sistemik sepanjang periode pengamatan. Perbedaan antara kuantil 1% dan 5% menegaskan bahwa dampak *spillover* paling signifikan umumnya terlihat jelas pada kondisi pasar yang ekstrem.

4.4 Estimasi Nilai CoVaR SSVS

Pada penelitian ini, pendekatan CoVaR tidak hanya diestimasi dengan pendekatan *Quantile Regression Forest* (QRF) saja, tetapi juga menggunakan metode *Stochastic Search Variable Selection* (SSVS) untuk memilih variabel secara Bayesian. Dalam pemodelannya, variabel dependen (Y) berupa *return* harian saham, sedangkan variabel independennya (X) berupa nilai VaR saham lain. CoVaR SSVS didefinisikan sebagai estimasi kuantil kondisional *return* saham yang dibentuk berdasarkan kombinasi prediktor berupa VaR saham lain yang memiliki probabilitas inklusi tinggi, sehingga hasil pemodelan menjadi lebih ringkas dan terhindar dari penggunaan prediktor yang kurang informatif. SSVS menggunakan *hierarchical mixture prior* di mana setiap prediktor dikaitkan dengan variabel laten biner yang akan menentukan apakah emiten tersebut dimasukkan ke dalam model atau tidak. Nilai *Posterior Inclusion Probability* (PIP) kemudian dihitung melalui iterasi MCMC sebagai ukuran kontribusi masing-masing prediktor terhadap risiko kondisional.

Dalam konteks CoVaR QRF, penggunaan SSVS memiliki keunggulan dalam memanfaatkan informasi *Variable Importance* (VI) yang dihasilkan dari tahap estimasi CoVaR QRF sebelumnya sebagai *informative prior*. Dengan proses ini, emiten yang terbukti memiliki pengaruh lebih tinggi akan mendapatkan probabilitas inklusi awal yang lebih tinggi dalam proses SSVS, sehingga konvergensi MCMC dapat dicapai lebih cepat. Kombinasi fleksibilitas QRF dalam menangkap hubungan non linier dan SSVS yang selektif dalam memilih prediktor akan menghasilkan model CoVaR yang lebih sederhana tetapi tetap informatif.

4.4.1 Pre-processing Data CoVaR SSVS

Proses estimasi CoVaR SSVS diawali dengan dua tahap *pre-processing* data yang dilakukan sebelum masuk ke seleksi variabel estimasi CoVaR dengan SSVS, yaitu transformasi skala data dan penetapan *Prior* probabilitas inklusi untuk setiap prediktor.

a) Transformasi Skala Data

Karakteristik nilai VaR dan CoVaR yang digunakan dalam estimasi SSVS bernilai sangat kecil dan berada di sekitar nol berpotensi menyebabkan masalah numerik dalam proses estimasi MCMC. Ketika perbedaan nilai *pinball loss* antara model dengan dan tanpa suatu prediktor menjadi sangat kecil secara absolut, mekanisme *Adaptive Metropolis-within-Gibbs* tidak mampu membedakan kontribusi masing-masing prediktor secara berarti. Hal ini menyebabkan seluruh nilai *Posterior Inclusion Probability* (PIP) mendekati nol dan tidak ada satu pun prediktor yang teridentifikasi memiliki kontribusi signifikan terhadap model.

Untuk mengatasi permasalahan skala pada data, data VaR dan CoVaR QRF terlebih dahulu dikalikan dengan 100 sebelum dimasukkan ke dalam proses estimasi SSVS, sehingga nilainya berada dalam satuan persen. Transformasi ini bersifat linier karena hanya mengubah skala data tanpa mengubah arah hubungan, korelasi, maupun struktur ketergantungan antarvariabel. Dengan skala numerik yang lebih besar, perbedaan *pinball loss* antara model dengan dan tanpa prediktor tertentu menjadi cukup besar untuk dapat dideteksi oleh algoritma MCMC, sehingga nilai PIP antar prediktor menjadi lebih bervariasi dan proses seleksi variabel dapat berjalan dengan baik. Transformasi skala data hanya berlaku pada seleksi variabel dengan SSVS. Setelah prediktor yang relevan terpilih, model QRF final dilatih ulang menggunakan VaR dan *return* dengan skala asli, sehingga akan menghasilkan nilai CoVaR SSVS yang konsisten dengan skala *return* dan selanjutnya digunakan dalam evaluasi model pada *backtesting*.

b) Penetapan Prior Probabilitas Inklusi

Sebagaimana telah dijelaskan pada Subbab 4.3, nilai *Variable Importance* (VI) setiap emiten prediktor telah diperoleh pada masing-masing model CoVaR berbasis QRF. Berdasarkan informasi tersebut, ditetapkan nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor untuk proses MCMC pada SSVS. Nilai p_i menunjukkan seberapa besar keyakinan awal bahwa suatu emiten prediktor perlu dimasukkan ke dalam model sebelum data dianalisis lebih lanjut. Pada penelitian ini, p_i tidak ditetapkan secara seragam untuk semua prediktor, melainkan ditentukan berdasarkan nilai VI yang telah diperoleh dari model CoVaR QRF pada Subbab 4.3. Pendekatan ini dikenal sebagai *empirical Bayes*, yaitu dengan memanfaatkan informasi empiris yang diperoleh langsung dari data untuk membentuk *prior* yang lebih informatif. Dengan pendekatan ini, emiten yang terbukti memiliki pengaruh lebih besar terhadap risiko kondisional suatu saham pada tahap CoVaR QRF akan mendapatkan nilai p_i yang lebih tinggi, sehingga peluang awal terpilih dalam seleksi variabel SSVS juga menjadi lebih besar.

Nilai VI setiap emiten prediktor i kemudian diagregasi dengan cara menghitung rata-rata nilai VI di seluruh model CoVaR QRF di mana emiten i berperan sebagai prediktor terhadap saham lain. Hasil rata-rata VI selanjutnya dinormalisasi menggunakan *min-max scaling* yang dituliskan seperti pada persamaan 4.1.

$$p_i = 0,1 + 0,8 \times \frac{VI_i - \min(VI)}{\max(VI) - \min(VI)} \quad (4.1)$$

dengan VI_i adalah nilai rata-rata VI yang telah diagregasi untuk prediktor i .

Rentang $[0,1; 0,9]$ dipilih untuk menghindari kondisi *degenerate*, yaitu kondisi dimana p_i berbasis *empirical Bayes* jatuh tepat pada $p_i = 0$ atau $p_i = 1$. Scott dan Berger (2010) menunjukkan bahwa kondisi *degenerate* merupakan permasalahan nyata dalam pendekatan *empirical Bayes* untuk seleksi variabel, karena estimasi yang jatuh ke titik ekstrem tersebut menyebabkan variabel tidak lagi dapat dievaluasi ulang secara probabilistik dalam proses MCMC. Variabel dengan $p_i = 0$ tidak akan pernah terpilih dan $p_i = 1$ akan selalu terpilih tanpa melalui proses evaluasi. Pemilihan batas 10% pada kedua sisi ini merupakan keputusan pada desain penelitian ini untuk memastikan ruang eksplorasi MCMC tetap memadai.

4.4.2 Estimasi Nilai CoVaR SSVS Setiap Saham

Estimasi CoVaR SSVS menggunakan pendekatan SSVS-QRF dengan algoritma *Adaptive Metropolis-within-Gibbs*. Pada tahap seleksi variabel, variabel respons (Y) yang digunakan adalah nilai CoVaR QRF emiten i , sedangkan variabel prediktor (X) berupa nilai VaR saham selain i pada kuantil yang sama. Seluruh data akan di transformasi ke satuan persen sebelum estimasi dan dikembalikan ke skala desimal setelah estimasi selesai. Proses SSVS kemudian menghitung nilai *Posterior Inclusion Probability* (PIP) untuk setiap prediktor melalui iterasi MCMC dengan memanfaatkan *prior* p_i berbasis VI yang telah ditetapkan sebelumnya. Adapaun *hyperparameter* yang digunakan dalam proses MCMC pada seleksi variabel SSVS adalah sebagai berikut.

Tabel 4.78 *Hyperparameter* Seleksi Variabel pada Estimasi CoVaR SSVS

Parameter	Nilai
MCMC <i>max</i>	1.500
MCMC <i>min</i>	400
<i>conv threshold</i>	0,05
<i>burn-in</i>	20% iterasi awal, min. 100 iterasi
PIP <i>threshold</i>	$\geq 0,5$

Proses MCMC dijalankan dengan batas maksimum 1.500 iterasi dan batas minimum 400 iterasi sebelum pengecekan konvergensi. Pada penelitian ini, konvergensi tercapai apabila perubahan maksimum PIP antar iterasi $< 0,05$. *Burn-in period* ditetapkan secara dinamis sebesar 20% dari iterasi dengan batas minimum absolut sebanyak 100 iterasi. Penetapan jumlah iterasi didasarkan pada pertimbangan keseimbangan antara efisiensi komputasi dan kecukupan sampel *posterior* yang dihasilkan. Mengingat estimasi CoVaR SSVS dilakukan secara individual untuk sembilan saham pada dua tingkat kuantil berbeda, penggunaan iterasi yang terlalu besar akan menyebabkan beban komputasi yang sangat tinggi. Penetapan batas minimum 400 iterasi *post-burnin* juga didasarkan pada pertimbangan bahwa jumlah sampel sudah cukup untuk menghasilkan estimasi *posterior* yang stabil apabila konvergensi telah tercapai, yang nantinya akan ditunjukkan dengan stabilnya nilai *Running PIP* menjelang akhir iterasi pada seluruh model yang diestimasi. Selain itu, pengecekan konvergensi berbasis perubahan PIP maksimum dengan *threshold* 0,05 dilakukan untuk memastikan bahwa iterasi berhenti secara adaptif ketika rantai MCMC sudah benar-benar stabil, sehingga jumlah iterasi yang digunakan tidak ditentukan secara sembarangan, namun ditentukan secara empiris berdasarkan dinamika rantai pada setiap model. Pendekatan ini sejalan dengan prinsip *adaptive* MCMC yang memprioritaskan konvergensi aktual dibandingkan jumlah iterasi yang ditetapkan secara tetap, sehingga efisiensi komputasi dapat terjaga tanpa mengurangi keandalan hasil estimasi *posterior* yang diperoleh. Pemilihan prediktor dalam model akhir ditentukan berdasarkan *threshold*

moderat $PIP \geq 0,5$, sehingga hanya emiten dengan probabilitas inklusi yang cukup tinggi yang digunakan dalam pembentukan CoVaR SSVS.

Setelah variabel terpilih melalui SSVS, model QRF final dilatih ulang hanya menggunakan prediktor terpilih dengan variabel respons berupa *return* harian serta prediktor berupa VaR emiten terpilih dalam skala data asli. Model kemudian dilatih dengan *moving block bootstrap* sebanyak 1.000 pohon yang sudah cukup untuk menghasilkan estimasi kuantil yang stabil, mengingat penambahan pohon umumnya tidak memberikan peningkatan akurasi yang signifikan namun meningkatkan beban komputasi, serta ukuran blok sebesar 63 yang mencerminkan jumlah hari kerja bursa dalam satu kuartal untuk mempertahankan dependensi temporal pada data *return* saham. Selanjutnya, hasil estimasi CoVaR SSVS dievaluasi menggunakan *backtesting* untuk memastikan bahwa tingkat pelanggaran yang dihasilkan konsisten dengan tingkat kuantil yang ditetapkan, sehingga hasil estimasi dapat digunakan sebagai dasar interpretasi risiko sistemik secara lebih andal. Estimasi dilakukan pada dua tingkat kuantil, yaitu 1% dan 5%. Hasil estimasi CoVaR SSVS untuk setiap saham selanjutnya disajikan pada subbagian a) hingga i).

a) ASII

Proses estimasi CoVaR SSVS untuk saham ASII menggunakan nilai VaR saham selain ASII sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.79.


Tabel 4.79 Nilai *Prior* Saham ASII

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
UNTR	0,9000	IMPC	0,9000
IMPC	0,8530	SMIL	0,8358
SMIL	0,7959	UNTR	0,7168
MARK	0,7690	SKRN	0,6029
SKRN	0,7676	MARK	0,5207
SINI	0,5931	SINI	0,4052
ARNA	0,4370	ARNA	0,3213
TOTO	0,1000	TOTO	0,1000

Pada kuantil 1%, UNTR memperoleh p_i tertinggi sebesar 0,9000 diikuti IMPC dan SMIL yang masing-masing memiliki nilai p_i sebesar 0,8530 dan 0,7959, yang mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional ASII pada kondisi ekstrem. Pada kuantil 5%, IMPC menggeser UNTR sebagai emiten dengan nilai p_i tertinggi sebesar 0,9000 diikuti SMIL dan UNTR, sejalan dengan pergeseran dominasi prediktor yang sebelumnya diidentifikasi pada tahap CoVaR QRF. Sementara itu, TOTO konsisten memperoleh p_i terendah di kedua kuantil dengan nilai sebesar 0,1000 yang mengindikasikan keyakinan awal paling rendah terhadap kontribusi TOTO sebagai prediktor risiko kondisional ASII. Nilai p_i yang diperoleh digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP* (*post-burnin*). *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila

kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham ASII disajikan pada Gambar 4.25.



Gambar 4.25 *Running PIP* Saham ASII

Berdasarkan Gambar 4.25, rantai MCMC untuk saham ASII baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan-perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham ASII pada kuantil 1% dan 5% disajikan pada Tabel 4.80.

Tabel 4.80 Nilai PIP Prediktor untuk CoVaR SSVS Saham ASII

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
ASII	UNTR	0,8925	IMPC	0,9125
	IMPC	0,8375	SMIL	0,8100
	SMIL	0,8050	UNTR	0,7350
	MARK	0,7525	SKRN	0,6075
	SKRN	0,7425	MARK	0,5250
	SINI	0,5875	SINI	0,3850
	ARNA	0,4450	ARNA	0,3650
	TOTO	0,0925	TOTO	0,1000

Hasil PIP emiten prediktor untuk saham ASII menunjukkan bahwa pada tingkat kepercayaan 99%, terdapat 6 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu UNTR, IMPC, SMIL, MARK, SKRN, dan SINI. Keenam emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham ASII pada kondisi pasar ekstrem. UNTR mencatat nilai PIP tertinggi sebesar 0,8925 yang mengindikasikan bahwa UNTR paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkan UNTR sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap ASII pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana UNTR mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, ARNA dan

TOTO yang memiliki PIP $< 0,5$ mengindikasikan bahwa kontribusi keduanya belum cukup kuat terhadap risiko kondisional ASII.


Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 5 emiten, yaitu IMPC, SMIL, UNTR, SKRN, dan MARK. Pergeseran terlihat pada IMPC yang menggeser posisi UNTR sebagai prediktor dengan nilai PIP tertinggi, bahkan melampaui *threshold* konservatif 0,9 yang semakin memperkuat posisi IMPC sebagai emiten dengan keterkaitan risiko sistemik paling signifikan terhadap ASII pada kondisi pasar moderat. Sementara itu, SINI tidak terpilih pada kuantil 5% dengan nilai PIP $< 0,5$ mengindikasikan bahwa keterkaitan risiko antara SINI dan ASII lebih relevan pada kondisi pasar yang sangat ekstrem. ARNA dan TOTO kembali menjadi prediktor yang tidak terpilih, sehingga keduanya konsisten tidak berkontribusi signifikan terhadap risiko kondisional ASII pada kedua tingkat kuantil. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antara emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik ASII pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham ASII disajikan pada Tabel 4.81.

Tabel 4.81 Estimasi Nilai CoVaR SSVS Saham ASII

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,04053	-0,02772	-0,09754	0,00045
5%	-0,02705	-0,01905	-0,03548	0,00001

Berdasarkan Tabel 4.81, rata-rata CoVaR SSVS ASII pada tingkat kepercayaan 99% adalah sebesar $-0,04053$ dengan varians 0,00045, yang artinya ketika investor berinvestasi sebesar Rp1.000.000.000 pada ASII, maka investor berisiko mengalami kerugian kondisional sebesar 4,05% atau sekitar Rp40.530.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,02705$ dengan varians menurun menjadi 0,00001, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp27.050.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang relatif lebih terkendali. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS pada kuantil 1% sedikit lebih dangkal ($-0,04053$ vs $-0,04374$), sedangkan pada kuantil 5%, rata-rata CoVaR SSVS relatif mendekati nilai rata-rata CoVaR QRF ($-0,02705$ vs $-0,02749$). Pendekatan SSVS menghasilkan estimasi yang masih sebanding dengan CoVaR QRF, namun lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional ASII lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham ASII, visualisasi perbandingan keduanya disajikan pada Gambar 4.26.



Gambar 4.26 Plot CoVaR SSVS ASII Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.26, pada kuantil 1% garis CoVaR SSVS bergerak relatif stabil dengan sesekali berfluktuasi lebih dalam pada periode volatilitas tinggi, sehingga batas risiko relatif jarang dilanggar oleh *return* aktual. Tercatat proporsi pelanggaran sebesar 2,01% dengan pelanggaran terbesar berada di sekitar periode Juni 2024 di mana *return* aktual turun tajam hingga sekitar -10%. Sedangkan pada kuantil 5%, garis CoVaR SSVS bergerak lebih stabil dan lebih dekat dengan nol, menandakan estimasi batas risiko yang lebih moderat. Proporsi pelanggaran yang berada di bawah batas teoritis menunjukkan bahwa model pada kuantil ini bersifat konservatif sehingga tidak meremehkan risiko aktual. Secara keseluruhan, kedua kurva CoVaR SSVS merepresentasikan batas kerugian kondisional yang relatif stabil, dan hanya pada periode tertentu batas risiko tersebut dilampaui secara signifikan oleh *return* aktual. Perbedaan kedalaman CoVaR SSVS IMPC di kedua kuantil menegaskan bahwa CoVaR SSVS 1% mencerminkan ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR SSVS 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

b) IMPC

Proses estimasi CoVaR SSVS untuk saham IMPC menggunakan nilai VaR saham selain IMPC sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.82.


Tabel 4.82 Nilai *Prior* Saham IMPC

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
ARNA	0,9000	ARNA	0,9000
MARK	0,8851	SINI	0,7184
UNTR	0,7839	MARK	0,6884
SMIL	0,5429	SKRN	0,6842
SINI	0,3879	UNTR	0,6508
SKRN	0,3118	ASII	0,2527
ASII	0,2495	TOTO	0,1656
TOTO	0,1000	SMIL	0,1000

Berdasarkan Tabel 4.82, ARNA memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti MARK (0,8851) dan UNTR (0,7839), mencerminkan bahwa ketiga emiten ini memiliki

bukti empiris paling kuat sebagai prediktor risiko kondisional IMPC pada kondisi ekstrem. Pada kuantil 5%, ARNA kembali memperoleh p_i tertinggi sebesar 0,9000 diikuti SINI (0,7184) dan MARK (0,6884). Hasil ini menunjukkan bahwa ARNA konsisten mendominasi di kedua kuantil sejalan dengan hasil VI pada tahap CoVaR QRF sebelumnya. Sementara itu, TOTO menempati posisi p_i terendah pada kuantil 1% (0,1000) dan SMIL pada kuantil 5% (0,1100), mengindikasikan keyakinan awal paling rendah terhadap kontribusi kedua emiten tersebut. Nilai p_i yang diperoleh selanjutnya digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Evaluasi konvergensi rantai MCMC dilakukan melalui *trace plot* γ_i dan *Running PIP* (*post-burnin*). *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham IMPC disajikan pada Gambar 4.27.



Gambar 4.27 *Running PIP* Saham IMPC

Berdasarkan Gambar 4.27, rantai MCMC untuk saham IMPC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham IMPC pada kuantil 1% dan 5% disajikan pada Tabel 4.83.

Tabel 4.83 Nilai PIP Prediktor untuk CoVaR SSVS Saham IMPC

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
IMPC	ARNA	0,9050	ARNA	0,9050
	MARK	0,8975	SINI	0,7675
	UNTR	0,7625	MARK	0,7025
	SMIL	0,5525	SKRN	0,6800

Tabel 4.83 Nilai PIP Prediktor untuk CoVaR SSVS Saham IMPC (Lanjutan)

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
IMPC	SINI	0,4125	UNTR	0,6275
	SKRN	0,3450	ASII	0,2600
	ASII	0,2700	TOTO	0,1525
	TOTO	0,1150	SMIL	0,1100

Hasil PIP emiten prediktor untuk saham IMPC menunjukkan bahwa pada tingkat kepercayaan 99%, terdapat 4 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu ARNA, MARK, UNTR, dan SMIL. Keempat emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham IMPC pada kondisi pasar ekstrem. ARNA mencatat nilai PIP tertinggi sebesar 0,9050, mengindikasikan bahwa ARNA paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkan ARNA sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap IMPC pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana ARNA mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, SINI, SKRN, ASII, dan TOTO memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusi keempat saham tersebut belum cukup kuat terhadap risiko kondisional IMPC pada kondisi pasar yang sangat ekstrem.

Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 5 emiten, yaitu ARNA, SINI, MARK, SKRN, dan UNTR. ARNA kembali mencatat nilai PIP tertinggi sebesar 0,9050 dan konsisten melampaui *threshold* konservatif 0,9 pada kedua kuantil, yang semakin memperkuat posisinya sebagai emiten dengan keterkaitan risiko sistemik paling signifikan terhadap IMPC. Pergeseran paling mencolok terjadi pada SKRN dan SINI yang tidak terpilih pada kuantil 1% namun masuk sebagai prediktor pada kuantil 5% dengan PIP masing-masing sebesar 0,6800 dan 0,7675, mengindikasikan bahwa keterkaitan risiko kedua emiten terhadap IMPC lebih relevan pada kondisi pasar yang lebih moderat. Sebaliknya, SMIL tidak terpilih pada kuantil 5% dengan PIP turun drastis menjadi 0,1100, menunjukkan bahwa pengaruh SMIL terhadap risiko kondisional IMPC hanya signifikan pada kondisi pasar yang sangat ekstrem. ASII dan TOTO kembali menjadi prediktor yang tidak terpilih pada kedua kuantil sehingga keduanya konsisten tidak berkontribusi signifikan terhadap risiko kondisional IMPC. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik IMPC pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.


Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham IMPC disajikan pada Tabel 4.84.

Tabel 4.84 Estimasi Nilai CoVaR SSVS Saham IMPC

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,06202	-0,03636	-0,15000	0,00063
5%	-0,02850	-0,02010	-0,04000	0,00001

Berdasarkan Tabel 4.84, rata-rata CoVaR SSVS IMPC pada tingkat kepercayaan 99% adalah sebesar $-0,06202$ dengan varians 0,00063, yang artinya ketika investor berinvestasi sebesar Rp1.000.000.000 pada IMPC, maka investor berisiko mengalami kerugian kondisional

sebesar 6,20% atau sekitar Rp62.020.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,02850$ dengan varians menurun menjadi $0,00001$, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp28.500.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang relatif lebih terkendali. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS pada kuantil 1% lebih negatif ($-0,06202$ vs $-0,04656$), sedangkan pada kuantil 5%, rata-rata CoVaR SSVS sedikit lebih dangkal dibandingkan dengan CoVaR QRF ($-0,02850$ vs $-0,03032$). Sehingga pendekatan SSVS menghasilkan estimasi risiko kerugian kondisional yang lebih dalam pada kondisi ekstrem, namun relatif sebanding dengan CoVaR QRF pada kondisi yang lebih moderat. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham IMPC, visualisasi perbandingan keduanya disajikan pada Gambar 4.28.



Gambar 4.28 Plot CoVaR SSVS IMPC Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.28, pada kuantil 1% garis CoVaR SSVS bergerak stabil dengan sesekali berfluktuasi lebih dalam pada periode volatilitas tinggi. Pelanggaran terbesar berada di akhir 2025 di mana *return* aktual turun tajam mendekati -20%. Sedangkan pada kuantil 5%, garis CoVaR SSVS bergerak lebih stabil dan lebih dekat dengan nol, menandakan estimasi batas risiko yang lebih moderat dengan sesekali turun lebih dalam pada periode ketika volatilitas meningkat sebelum kemudian kembali ke level normal. Proporsi pelanggaran di kedua kuantil berada di atas batas teoritis menunjukkan adanya kecenderungan *underestimate* risiko aktual saham IMPC. Perbedaan kedalaman CoVaR SSVS IMPC di kedua kuantil menegaskan bahwa CoVaR SSVS 1% mencerminkan ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR SSVS 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

c) UNTR


Proses estimasi CoVaR SSVS untuk saham UNTR menggunakan nilai VaR saham selain UNTR sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.85.

Tabel 4.85 Nilai *Prior* Saham UNTR

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
ASII	0,9000	ASII	0,9000
SKRN	0,8147	SKRN	0,8956
SMIL	0,6426	SMIL	0,6562
SINI	0,5985	SINI	0,6383
IMPC	0,6325	IMPC	0,5467
ARNA	0,5760	ARNA	0,5181
MARK	0,4129	MARK	0,4484
TOTO	0,1000	TOTO	0,1000

Berdasarkan Tabel 4.85, ASII memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti SKRN (0,8147) dan SMIL (0,6426), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional UNTR pada kondisi ekstrem. Pada kuantil 5%, ASII kembali memperoleh p_i tertinggi sebesar 0,9000 diikuti SKRN (0,8956) dan SMIL (0,6562). Hasil ini menunjukkan bahwa ASII konsisten mendominasi di kedua kuantil sejalan dengan hasil VI pada tahap CoVaR QRF sebelumnya. Sementara itu, TOTO konsisten memperoleh p_i terendah di kedua kuantil dengan nilai sebesar 0,1000, mengindikasikan keyakinan awal paling rendah terhadap kontribusi TOTO sebagai prediktor risiko kondisional UNTR. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP (post-burnin)*. *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham UNTR disajikan pada Gambar 4.29.

**Gambar 4.29** *Running PIP* Saham UNTR

Berdasarkan Gambar 4.29, rantai MCMC untuk saham UNTR baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang

sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham UNTR pada kuantil 1% dan 5% disajikan pada Tabel 4.86.

Tabel 4.86 Nilai PIP Prediktor untuk CoVaR SSVS Saham UNTR

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
UNTR	ASII	0,8850	ASII	0,9150
	SKRN	0,8325	SKRN	0,8975
	SMIL	0,6625	SMIL	0,6550
	SINI	0,6225	SINI	0,6250
	IMPC	0,6150	IMPC	0,5275
	ARNA	0,5375	ARNA	0,4900
	MARK	0,4050	MARK	0,4775
	TOTO	0,1125	TOTO	0,1025

Hasil PIP emiten prediktor untuk saham UNTR menunjukkan bahwa pada tingkat kepercayaan 99%, terdapat 6 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu ASII, SKRN, SMIL, SINI, IMPC, dan ARNA. Keenam emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham UNTR pada kondisi pasar ekstrem. ASII mencatat nilai PIP tertinggi sebesar 0,8850, mengindikasikan bahwa ASII paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkan ASII sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap UNTR pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana ASII mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, MARK dan TOTO yang memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusi keduanya belum cukup kuat terhadap risiko kondisional UNTR pada kondisi pasar yang sangat ekstrem.

Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 5 emiten, yaitu ASII, SKRN, SMIL, SINI, dan IMPC. ASII kembali mencatat nilai PIP tertinggi sebesar 0,9050, melampaui *threshold* konservatif 0,9 pada kuantil 5%, yang semakin memperkuat posisinya sebagai emiten dengan keterkaitan risiko sistemik paling signifikan terhadap UNTR. Pergeseran paling mencolok terjadi pada ARNA yang tidak terpilih pada kuantil 5% dengan PIP turun menjadi 0,4900, mengindikasikan bahwa keterkaitan risiko ARNA terhadap UNTR lebih relevan pada kondisi pasar yang sangat ekstrem dibandingkan kondisi yang lebih moderat. MARK dan TOTO kembali menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional UNTR. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik UNTR pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.


Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham UNTR disajikan pada Tabel 4.87.

Tabel 4.87 Estimasi Nilai CoVaR SSVS Saham UNTR

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,04758	-0,02571	-0,14650	0,00041
5%	-0,02698	-0,01741	-0,06000	0,00003

Berdasarkan Tabel 4.87, rata-rata CoVaR SSVS UNTR pada tingkat kepercayaan 99% adalah sebesar $-0,04758$ dengan varians 0,00041, yang artinya ketika investor berinvestasi sebesar Rp1.000.000.000 pada UNTR, investor berisiko mengalami kerugian kondisional

sebesar 4,76% atau sekitar Rp47.580.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,02698$ dengan varians menurun menjadi 0,00003, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp26.980.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang relatif lebih terkendali. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS pada kuantil 1% lebih dangkal ($-0,04758$ vs $-0,05636$), sedangkan pada kuantil 5%, rata-rata CoVaR SSVS relatif mendekati nilai rata-rata CoVaR QRF ($-0,02698$ vs $-0,02726$). Pendekatan SSVS menghasilkan estimasi yang lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional UNTR lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham UNTR, visualisasi perbandingan keduanya disajikan pada Gambar 4.30.



Gambar 4.30 Plot CoVaR SSVS UNTR Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.30, pada kuantil 1%, garis CoVaR SSVS UNTR bergerak lebih dalam dan pada beberapa periode tampak menurun dengan pelanggaran terbesar mendekati -20% , sehingga merepresentasikan kondisi yang lebih ekstrem. Sedangkan pada kuantil 5% garis CoVaR SSVS umumnya berada pada batas kerugian moderat dan terlihat cukup stabil, dengan sesekali turun lebih dalam pada periode ketika volatilitas meningkat sebelum kemudian kembali ke level normal. Hal ini menunjukkan bahwa untuk kondisi risiko yang relatif sering terjadi, CoVaR SSVS 5% berperan sebagai ambang kerugian kondisional yang stabil namun tetap mampu menyesuaikan diri ketika muncul tekanan yang lebih kuat. Perbedaan kedalaman antara CoVaR SSVS pada kuantil 1% dan 5% menegaskan bahwa risiko UNTR meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR SSVS 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR SSVS 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

d) SKRN

Proses estimasi CoVaR SSVS untuk saham SKRN menggunakan nilai VaR saham selain SKRN sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten


prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.88.

Tabel 4.88 Nilai *Prior* Saham SKRN

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
SMIL	0,9000	SMIL	0,9000
ARNA	0,7459	ARNA	0,7529
IMPC	0,6634	ASII	0,6194
UNTR	0,5728	IMPC	0,5657
ASII	0,5682	UNTR	0,5306
SINI	0,5479	SINI	0,4910
MARK	0,3080	MARK	0,3776
TOTO	0,1000	TOTO	0,1000

Berdasarkan Tabel 4.88, SMIL memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti ARNA (0,7459) dan IMPC (0,6634), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional SKRN pada kondisi ekstrem. Pada kuantil 5%, SMIL kembali memperoleh p_i tertinggi sebesar 0,9000 diikuti ARNA (0,7529) dan ASII (0,6194). Hasil ini menunjukkan bahwa SMIL konsisten mendominasi di kedua kuantil sejalan dengan hasil VI pada tahap CoVaR QRF sebelumnya. Sementara itu, TOTO konsisten memperoleh p_i terendah di kedua kuantil dengan nilai sebesar 0,1000, mengindikasikan keyakinan awal paling rendah terhadap kontribusi TOTO sebagai prediktor risiko kondisional SKRN. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP (post-burnin)*. *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham SKRN disajikan pada Gambar 4.31.



Gambar 4.31 *Running PIP* Saham SKRN

Berdasarkan Gambar 4.31, rantai MCMC untuk saham SKRN baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan

sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham SKRN pada kuantil 1% dan 5% disajikan pada Tabel 4.89.

Tabel 4.89 Nilai PIP Prediktor untuk CoVaR SSVS Saham SKRN

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
SKRN	SMIL	0,8975	SMIL	0,9225
	ARNA	0,7600	ARNA	0,7500
	IMPC	0,6600	ASII	0,6200
	UNTR	0,6050	IMPC	0,5300
	ASII	0,5325	SINI	0,4875
	SINI	0,5150	UNTR	0,4475
	MARK	0,2850	MARK	0,3775
	TOTO	0,1125	TOTO	0,0975

Berdasarkan Tabel 4.89, pada tingkat kepercayaan 99%, terdapat 6 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu SMIL, ARNA, IMPC, UNTR, ASII, dan SINI. Keenam emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham SKRN pada kondisi pasar ekstrem. SMIL mencatat nilai PIP tertinggi sebesar 0,8975, mengindikasikan bahwa SMIL paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkan SMIL sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap SKRN pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana SMIL mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, MARK dan TOTO memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusi keduanya belum cukup kuat terhadap risiko kondisional SKRN pada kondisi pasar yang sangat ekstrem.


Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 4 emiten, yaitu SMIL, ARNA, ASII, dan IMPC. SMIL kembali mencatat nilai PIP tertinggi sebesar 0,9225, melampaui *threshold* konservatif 0,9 pada kuantil 5%, yang semakin memperkuat posisinya sebagai emiten dengan keterkaitan risiko sistemik paling signifikan terhadap SKRN. Pergeseran paling mencolok terjadi pada SINI dan UNTR yang tidak terpilih pada kuantil 5% dengan $PIP < 0,5$, mengindikasikan bahwa keterkaitan risiko kedua saham terhadap SKRN lebih relevan pada kondisi pasar yang sangat ekstrem dibandingkan kondisi yang lebih moderat. MARK dan TOTO kembali menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional UNTR. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik UNTR pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham SKRN disajikan pada Tabel 4.90.

Tabel 4.90 Estimasi Nilai CoVaR SSVS Saham SKRN

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,10862	-0,05747	-0,13077	0,00020
5%	-0,04449	-0,01935	-0,16942	0,00029

Berdasarkan Tabel 4.90, pada tingkat kepercayaan 99% rata-rata CoVaR SSVS SKRN sebesar $-0,10862$ dengan varians $0,00020$, yang artinya ketika investor berinvestasi sebesar Rp1.000.000.000 pada SKRN, investor berisiko mengalami kerugian kondisional sebesar 10,86% atau sekitar Rp108.620.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,04449$ dengan varians meningkat menjadi $0,00029$, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp44.490.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang lebih berfluktuasi dibandingkan pada kondisi ekstrem. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS pada kuantil 1% lebih dangkal ($-0,10862$ vs $-0,12668$), sedangkan pada kuantil 5%, rata-rata CoVaR SSVS juga relatif lebih dangkal ($-0,04449$ vs $-0,05929$). Pendekatan SSVS menghasilkan estimasi yang lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional SKRN lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham SKRN, visualisasi perbandingan keduanya disajikan pada Gambar 4.32.

**Gambar 4.32** Plot CoVaR SSVS SKRN Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.32, garis CoVaR SSVS SKRN pada kuantil 1% bergerak lebih dalam dan pada beberapa periode tampak menurun dengan pelanggaran terbesar mendekati -20% , sehingga merepresentasikan kondisi yang lebih ekstrem. Sedangkan pada kuantil 5% garis CoVaR SSVS umumnya berada pada batas kerugian moderat dan terlihat cukup stabil, di mana sesekali turun lebih dalam pada periode ketika kondisi volatilitas pasar meningkat sebelum kemudian kembali ke level normal. Perbedaan kedalaman antara CoVaR SSVS pada kuantil 1% dan 5% menegaskan bahwa risiko SKRN meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan CoVaR SSVS 1% sebagai ukuran risiko yang lebih konservatif dan sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan CoVaR SSVS 5% mencerminkan dinamika risiko ketika berada pada kondisi yang lebih moderat.

e) SINI


Proses estimasi CoVaR SSVS untuk saham SINI menggunakan nilai VaR saham selain SINI sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.91.

Tabel 4.91 Nilai *Prior* Saham SINI

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
MARK	0,9000	SMIL	0,9000
SMIL	0,7825	MARK	0,8066
ARNA	0,6776	ARNA	0,6206
IMPC	0,5352	IMPC	0,4895
SKRN	0,4981	SKRN	0,4541
ASII	0,4445	ASII	0,3806
UNTR	0,3844	UNTR	0,3141
TOTO	0,1000	TOTO	0,1000

Berdasarkan Tabel 4.91, MARK memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti SMIL (0,7825) dan ARNA (0,6776), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional SINI pada kondisi ekstrem. Pada kuantil 5%, SMIL menggeser posisi MARK sebagai emiten dengan nilai p_i tertinggi sebesar 0,9000 diikuti MARK (0,8066) dan ARNA (0,6206). Hasil ini sejalan dengan pergeseran signifikansi prediktor yang sebelumnya diidentifikasi pada tahap CoVaR QRF. Sementara itu, TOTO konsisten memperoleh p_i terendah di kedua kuantil dengan nilai sebesar 0,1000, mengindikasikan keyakinan awal paling rendah terhadap kontribusi TOTO sebagai prediktor risiko kondisional SINI. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP (post-burnin)*. *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham SINI disajikan pada Gambar 4.33.



Gambar 4.33 *Running PIP* Saham SINI

Hasil visualisasi kurva *Running PIP* saham SINI menunjukkan bahwa rantai MCMC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan-perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham SINI pada kuantil 1% dan 5% disajikan pada Tabel 4.92.

Tabel 4.92 Nilai PIP Prediktor untuk CoVaR SSVS Saham SINI

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
SINI	MARK	0,8875	SMIL	0,8850
	SMIL	0,7875	MARK	0,8100
	ARNA	0,6825	ARNA	0,6600
	IMPC	0,5625	IMPC	0,4725
	SKRN	0,5175	SKRN	0,4650
	ASII	0,4325	ASII	0,4175
	UNTR	0,4075	UNTR	0,3200
	TOTO	0,0900	TOTO	0,1025

Berdasarkan Tabel 4.92, pada tingkat kepercayaan 99%, terdapat 5 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu MARK, SMIL, ARNA, IMPC, dan SKRN. Kelima emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham SINI pada kondisi pasar ekstrem. MARK mencatat nilai PIP tertinggi sebesar 0,8875, mengindikasikan bahwa MARK paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkan MARK sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap SINI pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana MARK mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, ASII, UNTR, dan TOTO memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusi ketiganya belum cukup kuat terhadap risiko kondisional SINI pada kondisi pasar yang sangat ekstrem.


Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 3 emiten, yaitu SMIL, MARK, dan ARNA. SMIL menggeser MARK sebagai prediktor dengan nilai PIP tertinggi, yaitu sebesar 0,8850 mengindikasikan bahwa pada kondisi pasar yang lebih moderat SMIL menjadi emiten dengan keterkaitan risiko paling signifikan terhadap SINI. Adapun IMPC dan SKRN pada kuantil 5% tidak terpilih dengan nilai PIP masing-masing turun menjadi 0,4725 dan 0,4650. Sementara itu, ASII, UNTR, dan TOTO kembali menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional SINI. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik SINI pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham SINI disajikan pada Tabel 4.93.

Tabel 4.93 Estimasi Nilai CoVaR SSVS Saham SINI

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,09958	-0,09764	-0,10000	0,00000
5%	-0,08792	-0,02740	-0,10000	0,00025

Berdasarkan Tabel 4.93, pada tingkat kepercayaan 99% rata-rata CoVaR SSVS SINI adalah $-0,09958$ dengan varians $0,00000$, yang artinya ketika berinvestasi sebesar Rp1.000.000.000 pada SINI, investor berisiko mengalami kerugian kondisional sebesar 9,96% atau sekitar Rp99.580.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya. Varians yang mendekati nol mengindikasikan bahwa estimasi bergerak sangat stabil sepanjang periode pengamatan. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,08792$ dengan varians meningkat menjadi $0,00025$, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp87.920.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang lebih berfluktuasi. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS baik pada kuantil 1% dan 5% lebih dangkal ($-0,09958$ vs $-0,11828$) dan ($-0,08792$ vs $-0,09883$). Pendekatan SSVS menghasilkan estimasi yang lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional SINI lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham SINI, visualisasi perbandingan keduanya disajikan pada Gambar 4.34.

**Gambar 4.34** Plot CoVaR SSVS SINI Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.34, garis CoVaR SSVS SINI pada kuantil 1% bergerak sangat stabil mendekati garis lurus di sekitar -10% , konsisten dengan nilai variansnya yang mendekati nol. Hasil ini menunjukkan bahwa model mengestimasi batas risiko kondisional SINI secara konsisten di kisaran yang sama, sehingga kurang responsif dengan perubahan kondisi pasar. Sedangkan pada kuantil 5% garis CoVaR SSVS lebih berfluktuatif dibanding kuantil 1% dengan kisaran yang tidak terlalu jauh. Perbedaan kedalaman antara CoVaR SSVS pada kuantil 1% dan 5% ini menegaskan bahwa meskipun pada kuantil 1% merepresentasikan kondisi yang lebih ekstrem, estimasinya justru bergerak lebih stabil dibandingkan kuantil 5% yang lebih dinamis dalam mencerminkan perubahan kondisi risiko pasar dari waktu ke waktu pada kondisi yang lebih moderat.

f) SMIL

Estimasi CoVaR SSVS untuk saham SMIL menggunakan nilai VaR saham selain SMIL sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan,


ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.94.

Tabel 4.94 Nilai *Prior* Saham SMIL

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
IMPC	0,9000	IMPC	0,9000
UNTR	0,4577	UNTR	0,4103
MARK	0,3520	MARK	0,3146
ASII	0,3074	ASII	0,2891
SINI	0,2401	SINI	0,2432
SKRN	0,2335	AKRN	0,2029
ARNA	0,1410	ARNA	0,1371
TOTO	0,1000	TOTO	0,1000

Berdasarkan Tabel 4.94, IMPC memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti UNTR (0,4577) dan MARK (0,3520), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional SMIL pada kondisi ekstrem. Pada kuantil 5%, IMPC kembali memperoleh p_i tertinggi sebesar 0,9000 diikuti UNTR (0,4103) dan MARK (0,3146). Hasil ini menunjukkan bahwa IMPC konsisten mendominasi di kedua kuantil sejalan dengan hasil VI pada tahap CoVaR QRF sebelumnya. Tidak terdapat pergeseran di seluruh prediktor, baik pada kuantil 1% dan 5%, dengan IMPC, UNTR, dan MARK secara konsisten menempati tiga urutan tertinggi di kedua kuantil dengan perbedaan nilai p_i yang relatif kecil. Hal ini mengindikasikan bahwa struktur keterkaitan risiko kondisional SMIL bersifat stabil dan tidak bergantung pada kondisi pasar. Sementara itu, TOTO konsisten memperoleh p_i terendah di kedua kuantil dengan nilai sebesar 0,1000, mengindikasikan keyakinan awal paling rendah terhadap kontribusi TOTO sebagai prediktor risiko kondisional SINI. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP* (*post-burnin*). *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham SMIL disajikan pada Gambar 4.35.



Gambar 4.35 *Running PIP* Saham SMIL

Berdasarkan Gambar 4.35, kurva *Running* PIP saham SMIL menunjukkan bahwa rantai MCMC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan-perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham SMIL pada kuantil 1% dan 5% disajikan pada Tabel 4.95.

Tabel 4.95 Nilai PIP Prediktor untuk CoVaR SSVS Saham SMIL

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
SMIL	IMPC	0,9250	IMPC	0,9200
	UNTR	0,4650	UNTR	0,4225
	MARK	0,3950	MARK	0,3100
	ASII	0,2725	ASII	0,3075
	SINI	0,2375	SINI	0,2825
	SKRN	0,2325	SKRN	0,2025
	ARNA	0,1425	ARNA	0,1375
	TOTO	0,1400	TOTO	0,0825

Berdasarkan Tabel 4.95, hasil PIP menunjukkan pola yang berbeda dibandingkan saham lainnya. Pada tingkat kepercayaan 99%, hanya IMPC yang terpilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham SMIL pada kondisi pasar ekstrem. IMPC mencatat nilai PIP sebesar 0,9250, menjadikannya sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap SMIL pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana SMIL mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, 7 saham lainnya memiliki PIP < 0,5 mengindikasikan bahwa kontribusi emiten-emiten tersebut belum cukup kuat terhadap risiko kondisional SMIL pada kondisi pasar yang sangat ekstrem.

Pola yang sama terjadi pada tingkat kepercayaan 95%, di mana hanya IMPC yang memiliki PIP di atas *threshold*, yaitu sebesar 0,9200, mengindikasikan konsistensi dominasi IMPC sebagai satu-satunya prediktor signifikan terhadap risiko kondisional SMIL pada kedua tingkat kuantil. Dengan hanya satu prediktor terpilih pada kedua kuantil, model CoVaR SSVS SMIL menjadi model yang paling *parsimonious* dibandingkan saham lainnya dalam penelitian ini, yang mengindikasikan bahwa risiko kondisional SMIL sepenuhnya dijelaskan oleh saham IMPC.


Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham SMIL disajikan pada Tabel 4.96.

Tabel 4.96 Estimasi Nilai CoVaR SSVS Saham SMIL

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,14269	-0,03759	-0,29814	0,00429
5%	-0,09061	-0,02823	-0,29814	0,00320

Berdasarkan Tabel 4.96, pada tingkat kepercayaan 99%, rata-rata CoVaR SSVS SMIL sebesar - 0,14269 dengan varians 0,00429, yang artinya ketika berinvestasi sebesar

Rp1.000.000.000 pada SMIL, investor berisiko mengalami kerugian kondisional sebesar 14,27% atau sekitar Rp142.690.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang sangat berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,09061$ dengan varians menurun menjadi 0,00320, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp90.610.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang masih sangat berfluktuasi. Nilai varians pada kedua kuantil merupakan yang tertinggi dibandingkan dengan saham lainnya, yang mencerminkan bahwa estimasi risiko kondisional SMIL sangat berfluktuasi dari waktu ke waktu sesuai dengan karakteristik saham SMIL yang sangat volatil. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS pada kuantil 1% lebih dangkal ($-0,14269$ vs $-0,19864$), sedangkan pada kuantil 5%, rata-rata CoVaR SSVS menunjukkan nilai lebih negatif ($-0,09061$ vs $-0,08591$), yang mencerminkan batas risiko kondisional yang lebih konservatif. Pendekatan SSVS tidak selalu menghasilkan estimasi risiko yang lebih besar atau dalam secara rata-rata, melainkan bersifat selektif sesuai dengan tingkat kuantil yang digunakan. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham SMIL pada kuantil 1% dan 5%, visualisasi perbandingan keduanya disajikan pada Gambar 4.36.



Gambar 4.36 Plot CoVaR SSVS SMIL Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.36, berbeda dengan saham lainnya yang cenderung stabil, garis CoVaR SSVS saham SMIL di kedua kuantil menunjukkan fluktuasi yang sangat tinggi sepanjang periode pengamatan. Pada kuantil 1%, garis CoVaR SSVS bergerak sangat dinamis dengan sesekali turun sangat dalam mendekati -20% hingga -30% pada beberapa periode, mencerminkan sensitivitas estimasi risiko SMIL yang tinggi terhadap kondisi IMPC sebagai satu-satunya prediktor terpilih. Pada kuantil 5%, pola serupa terjadi dengan garis CoVaR SSVS yang sangat berfluktuasi, dengan proporsi pelanggaran sebesar 7,37% yang jauh melampaui tingkat kuantil nominal 5%. Tingginya proporsi pelanggaran pada kedua kuantil menunjukkan bahwa model CoVaR SSVS cenderung meremehkan risiko aktual SMIL, yang mengindikasikan bahwa dinamika risiko SMIL tidak sepenuhnya dapat dijelaskan hanya melalui kondisi VaR saham IMPC saja.

g) ARNA

Estimasi CoVaR SSVS untuk saham ARNA menggunakan nilai VaR saham selain ARNA sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan,


ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.97.

Tabel 4.97 Nilai *Prior* Saham ARNA

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
SINI	0,9000	SINI	0,9000
IMPC	0,5783	IMPC	0,7645
UNTR	0,4497	UNTR	0,5663
ASII	0,3778	MARK	0,4817
MARK	0,3082	ASII	0,4561
SKRN	0,2495	SMIL	0,1510
SMIL	0,1713	TOTO	0,1032
TOTO	0,1000	SKRN	0,1000

Berdasarkan Tabel 4.97, SINI memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti IMPC (0,5783) dan UNTR (0,4497), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional ARNA pada kondisi ekstrem. Pada kuantil 5%, SINI kembali memperoleh p_i tertinggi sebesar 0,9000 diikuti IMPC (0,7645) dan UNTR (0,5663), mengindikasikan bahwa SINI konsisten mendominasi di kedua kuantil sejalan dengan hasil VI pada tahap CoVaR QRF sebelumnya. Sementara itu, TOTO menempati posisi p_i terendah pada kuantil 1% dan SKRN pada kuantil 5%, mengindikasikan keyakinan awal paling rendah terhadap kontribusi kedua emiten tersebut. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP (post-burnin)*. *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham ARNA disajikan pada Gambar 4.37.



Gambar 4.37 *Running PIP* Saham ARNA

Berdasarkan Gambar 4.37, kurva *Running PIP* saham ARNA menunjukkan bahwa rantai MCMC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP

maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan-perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham ARNA pada kuantil 1% dan 5% disajikan pada Tabel 4.98.

Tabel 4.98 Nilai PIP Prediktor untuk CoVaR SSVS Saham ARNA

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
ARNA	SINI	0,8975	SINI	0,8800
	IMPC	0,5850	IMPC	0,7625
	UNTR	0,4175	UNTR	0,5650
	ASII	0,3200	MARK	0,4900
	MARK	0,3125	ASII	0,4725
	SKRN	0,2900	SMIL	0,1400
	SMIL	0,1650	TOTO	0,1150
	TOTO	0,1100	SKRN	0,1125

Tabel 4.98 menunjukkan bahwa pada tingkat kepercayaan 99%, hanya SINI dan IMPC yang memiliki nilai $PIP \geq 0,5$ sehingga kedua emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham ARNA pada kondisi pasar ekstrem. SINI mencatat nilai PIP tertinggi sebesar 0,8975 yang menunjukkan SINI paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkannya sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap ARNA pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana SINI mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, keenam saham lainnya memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusinya belum cukup kuat terhadap risiko kondisional ARNA pada kondisi pasar yang sangat ekstrem.

Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 3 emiten, yaitu SINI, IMPC, dan UNTR. UNTR masuk sebagai prediktor terpilih dengan nilai PIP sebesar 0,5650, mengindikasikan keterkaitan risiko UNTR terhadap ARNA lebih relevan pada kondisi pasar yang lebih moderat. SINI dan IMPC memperkuat posisi keduanya sebagai emiten dengan keterkaitan risiko sistemik paling signifikan terhadap ARNA. Sementara itu, MARK, ASII, SMIL, TOTO, dan SKRN kembali menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional ARNA. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik ARNA pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.


Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham ARNA disajikan pada Tabel 4.99.

Tabel 4.99 Estimasi Nilai CoVaR SSVS Saham ARNA

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,04769	-0,01887	-0,08209	0,00044
5%	-0,01966	-0,01389	-0,08209	0,00002

Berdasarkan Tabel 4.99, rata-rata CoVaR SSVS ARNA pada tingkat kepercayaan 99% adalah sebesar $-0,04769$ dengan varians 0,00044, yang artinya ketika berinvestasi sebesar

Rp1.000.000.000 pada ARNA, investor berisiko mengalami kerugian kondisional sebesar 4,77% atau sekitar Rp47.690.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup berfluktuasi. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,01966$ dengan varians menurun menjadi 0,00002, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp19.660.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang relatif lebih terkendali. Nilai minimum pada kedua kuantil menunjukkan nilai yang identik yaitu $-0,08209$, menunjukkan bahwa kerugian kondisional terparah yang dihasilkan model pada kondisi pasar paling buruk baik pada kuantil 1% maupun 5% adalah sama. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS baik pada kuantil 1% dan 5% lebih dangkal ($-0,04769$ vs $-0,05543$) dan ($-0,01966$ vs $-0,02453$). Pendekatan SSVS menghasilkan estimasi yang lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional ARNA lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham ARNA, visualisasi perbandingan keduanya disajikan pada Gambar 4.38.



Gambar 4.38 Plot CoVaR SSVS ARNA Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.38, garis CoVaR SSVS ARNA pada kuantil 1% bergerak relatif stabil sepanjang periode pengamatan dengan sesekali berfluktuasi lebih dalam pada periode volatilitas tinggi. Hal ini menunjukkan bahwa untuk kondisi risiko yang sangat ekstrem, CoVaR SSVS 1% berperan sebagai ambang kerugian kondisional saham ARNA yang cukup stabil namun tetap responsif terhadap perubahan kondisi pasar. Sedangkan pada kuantil 5% garis CoVaR SSVS bergerak sangat dekat dengan nol dan hampir flat sepanjang periode, mencerminkan estimasi batas risiko yang sangat moderat. Perbedaan kedalaman antara CoVaR SSVS pada kuantil 1% dan 5% ini menegaskan bahwa risiko ARNA meningkat signifikan ketika berada pada kondisi ekstrem, yang menjadikan kuantil 1% sebagai ukuran risiko yang lebih sensitif terhadap kejadian ekstrem di ekor distribusi, sedangkan kuantil 5% mencerminkan dinamika risiko ARNA pada kondisi yang lebih moderat.

h) TOTO

Estimasi CoVaR SSVS untuk saham TOTO menggunakan nilai VaR saham selain TOTO sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor


berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.100.

Tabel 4.100 Nilai *Prior* Saham TOTO

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
ARNA	0,9000	MARK	0,9000
IMPC	0,7036	ARNA	0,8758
MARK	0,6435	SKRN	0,8153
SKRN	0,4160	IMPC	0,3237
SINI	0,3390	ASII	0,2469
SMIL	0,2851	SMIL	0,1726
UNTR	0,1325	SINI	0,1564
ASII	0,1000	UNTR	0,1000

Berdasarkan Tabel 4.100, ARNA memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti IMPC (0,7036) dan MARK (0,6435), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional TOTO pada kondisi ekstrem. Pada kuantil 5%, MARK menggeser posisi ARNA sebagai emiten dengan nilai p_i tertinggi sebesar 0,9000 diikuti ARNA (0,8758) dan SKRN (0,8153). Hasil ini sejalan dengan pergeseran signifikansi prediktor yang sebelumnya diidentifikasi pada tahap CoVaR QRF. Sementara itu, ASII menempati posisi p_i terendah pada kuantil 1% dan UNTR pada kuantil 5%, mengindikasikan keyakinan awal paling rendah terhadap kontribusi kedua emiten sebagai prediktor risiko kondisional TOTO. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP (post-burnin)*. *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham TOTO disajikan pada Gambar 4.39.



Gambar 4.39 *Running PIP* Saham TOTO

Berdasarkan Gambar 4.39, kurva *Running PIP* saham TOTO menunjukkan bahwa rantai MCMC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP

maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan-perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham TOTO pada kuantil 1% dan 5% disajikan pada Tabel 4.101.

Tabel 4.101 Nilai PIP Prediktor untuk CoVaR SSVS Saham TOTO

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
TOTO	ARNA	0,9225	MARK	0,8925
	IMPC	0,6700	ARNA	0,8375
	MARK	0,6600	SKRN	0,7850
	SKRN	0,4000	IMPC	0,3025
	SINI	0,3625	ASII	0,2650
	SMIL	0,2850	SMIL	0,1550
	UNTR	0,1475	SINI	0,1450
	ASII	0,0850	UNTR	0,0800

Berdasarkan Tabel 4.101, pada tingkat kepercayaan 99%, terdapat 3 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu ARNA, IMPC, dan MARK. Ketiga emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham TOTO pada kondisi pasar ekstrem. ARNA mencatat nilai PIP tertinggi sebesar 0,9225, mengindikasikan bahwa ARNA paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkannya sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap TOTO pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana SMIL mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, SKRN, SINI, SMIL, UNTR, dan ASII memiliki $PIP < 0,5$ mengindikasikan bahwa kontribusi kelima saham belum cukup kuat terhadap risiko kondisional TOTO pada kondisi pasar yang sangat ekstrem.


Pada tingkat kepercayaan 95%, prediktor yang terpilih tetap sama yaitu 3 emiten, namun dengan komposisi yang berbeda. Ketiga emiten yang terpilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham TOTO pada kondisi yang lebih moderat adalah MARK, ARNA, dan SKRN. MARK menggeser posisi ARNA sebagai prediktor dengan nilai PIP tertinggi (0,8925) pada kuantil 5%. Sementara itu, SKRN yang sebelumnya tidak terpilih pada kuantil 1% masuk sebagai prediktor terpilih dengan PIP meningkat signifikan menjadi 0,7850. IMPC tidak terpilih pada kuantil 5% dengan PIP turun drastis menjadi 0,3025, mengindikasikan bahwa keterkaitan risiko IMPC terhadap TOTO lebih relevan pada kondisi pasar yang sangat ekstrem. Adapun SINI, SMIL, UNTR, dan ASII konsisten tidak terpilih pada kedua kuantil, menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional TOTO. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik TOTO pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham TOTO disajikan pada Tabel 4.102.

Tabel 4.102 Estimasi Nilai CoVaR SSVS Saham TOTO

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,02955	-0,00971	-0,05085	0,00009
5%	-0,01501	-0,00901	-0,05085	0,00003

Berdasarkan Tabel 4.102, rata-rata CoVaR SSVS TOTO pada tingkat kepercayaan 99% adalah sebesar $-0,02955$ dengan varians $0,00009$, yang artinya ketika berinvestasi sebesar Rp1.000.000.000 pada TOTO, investor berisiko mengalami kerugian kondisional sebesar 2,96% atau sekitar Rp29.550.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang cukup stabil. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,01501$ dengan varians menurun menjadi $0,00003$, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp15.010.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko yang relatif lebih stabil dan terkendali. Sementara itu, nilai minimum CoVaR SSVS pada kedua kuantil menunjukkan nilai yang sama ($-0,05085$), yang mengindikasikan bahwa estimasi kerugian terparah yang dihasilkan model tidak berbeda antara kondisi ekstrem maupun moderat. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS baik pada kuantil 1% dan 5% lebih dangkal ($-0,02955$ vs $-0,03438$) dan ($-0,01501$ vs $-0,01534$). Pendekatan SSVS menghasilkan estimasi yang lebih dangkal pada kedua tingkat kuantil karena hanya menggunakan prediktor dengan kontribusi signifikan, sehingga pengaruh emiten yang kurang relevan tidak lagi mendorong estimasi risiko kondisional TOTO lebih dalam. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham TOTO, visualisasi perbandingan keduanya disajikan pada Gambar 4.40.

**Gambar 4.40** Plot CoVaR SSVS TOTO Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.40, garis CoVaR SSVS TOTO pada kedua kuantil bergerak sangat stabil dan sangat dekat dengan nol sepanjang periode pengamatan, mencerminkan potensi kerugian kondisional TOTO yang tergolong kecil dan stabil dibandingkan saham lainnya dalam penelitian ini. Pada kuantil 1%, garis CoVaR SSVS bergerak dengan fluktuasi yang sangat kecil, di mana *return* aktual sesekali menembus batas risiko dengan proporsi pelanggaran sebesar sedikit di atas batas 1%. Sedangkan pada kuantil 5%, garis CoVaR SSVS juga bergerak sangat dekat dengan nol namun sedikit lebih dangkal, dengan proporsi pelanggaran berada di bawah batas teoritis, menunjukkan bahwa model pada kuantil ini bersifat konservatif dan tidak meremehkan risiko aktual TOTO. Perbedaan kedalaman yang tidak terlalu besar antara CoVaR

SSVS TOTO pada kuantil 1% dan 5%, mencerminkan profil risiko kondisional TOTO yang relatif konsisten pada kondisi ekstrem maupun moderat dengan estimasi kerugian yang tergolong rendah dibandingkan saham lain.

i) MARK


Estimasi CoVaR SSVS untuk saham MARK menggunakan nilai VaR saham selain MARK sebagai kandidat prediktor pada tingkat kuantil yang sama. Sebelum proses MCMC dijalankan, ditetapkan terlebih dahulu nilai *prior* probabilitas inklusi (p_i) untuk setiap emiten prediktor berdasarkan nilai VI yang diperoleh dari tahap CoVaR QRF melalui normalisasi *min-max scaling* yang hasilnya ditunjukkan pada Tabel 4.103.

Tabel 4.103 Nilai *Prior* Saham MARK

$\tau = 0,01$		$\tau = 0,05$	
Prediktor	p_i	Prediktor	p_i
TOTO	0,9000	ARNA	0,9000
ARNA	0,8790	TOTO	0,8990
SINI	0,6735	SINI	0,8651
IMPC	0,5232	IMPC	0,4658
UNTR	0,3398	SMIL	0,3002
ASII	0,2106	ASII	0,1050
SKRN	0,1615	UNTR	0,1311
SMIL	0,1000	SKRN	0,1000

Berdasarkan Tabel 4.103, TOTO memperoleh p_i tertinggi sebesar 0,9000 pada kuantil 1%, diikuti ARNA (0,8790) dan SINI (0,6735), mencerminkan bahwa ketiga emiten ini memiliki bukti empiris paling kuat sebagai prediktor risiko kondisional MARK pada kondisi ekstrem. Pada kuantil 5%, ARNA menggeser posisi TOTO sebagai emiten dengan nilai p_i tertinggi sebesar 0,9000 diikuti TOTO (0,8990) dan SINI (0,8651). Hasil ini sejalan dengan pergeseran signifikansi prediktor yang sebelumnya diidentifikasi pada tahap CoVaR QRF. Sementara itu, SMIL menempati posisi p_i terendah pada kuantil 1% dan SKRN pada kuantil 5%, mengindikasikan keyakinan awal paling rendah terhadap kontribusi kedua emiten sebagai prediktor risiko kondisional MARK. Nilai p_i yang diperoleh akan digunakan sebagai *informative prior* dalam proses iterasi MCMC.

Selanjutnya dilakukan evaluasi konvergensi rantai MCMC melalui *trace plot* γ_i dan *Running PIP* (*post-burnin*). *Trace plot* γ_i menunjukkan pergerakan status inklusi setiap prediktor sepanjang iterasi, sedangkan *Running PIP* menunjukkan rata-rata kumulatif nilai PIP yang dihitung secara bertahap dari iterasi *post-burnin* pertama hingga iterasi terakhir. Apabila kurva *Running PIP* sudah stabil dan tidak lagi berubah secara berarti menjelang akhir iterasi, maka konvergensi dinyatakan telah tercapai. Visualisasi *Running PIP* untuk saham MARK disajikan pada Gambar 4.41.



Gambar 4.41 *Running PIP Saham MARK*

Berdasarkan Gambar 4.41, kurva *Running PIP* saham MARK menunjukkan bahwa rantai MCMC baik pada kuantil 1% dan 5% sama-sama mencapai konvergensi pada iterasi ke-500 dengan *burn-in* final sebesar 100 iterasi (20%) dan 400 sampel *post-burnin* yang akan digunakan dalam perhitungan nilai PIP. Konvergensi dinyatakan tercapai ketika perubahan PIP maksimum antarinterval pengecekan sudah berada di bawah *threshold* 0,05. Meskipun pada iterasi *post-burnin* awal nilai PIP seluruh prediktor masih berfluktuasi, nilai PIP kemudian stabil secara bertahap setelah sekitar 150 iterasi *post-burnin* dan tidak lagi mengalami perubahan perubahan hingga akhir iterasi, sehingga hasil PIP yang diperoleh dianggap representatif terhadap distribusi posterior yang sebenarnya. Ringkasan nilai PIP seluruh emiten prediktor untuk saham MARK pada kuantil 1% dan 5% disajikan pada Tabel 4.104.

Tabel 4.104 Nilai PIP Prediktor untuk CoVaR SSVS Saham MARK

Saham	$\tau = 0,01$		$\tau = 0,05$	
	Prediktor	PIP	Prediktor	PIP
MARK	TOTO	0,9300	ARNA	0,9125
	ARNA	0,8825	TOTO	0,9075
	SINI	0,6600	SINI	0,8825
	IMPC	0,5025	IMPC	0,4875
	UNTR	0,3175	SMIL	0,3225
	ASII	0,2300	ASII	0,1175
	SKRN	0,1250	UNTR	0,1150
	SMIL	0,1075	SKRN	0,0975

Berdasarkan Tabel 4.104, pada tingkat kepercayaan 99%, terdapat 4 emiten yang memiliki nilai $PIP \geq 0,5$ yaitu TOTO, ARNA, SINI, dan IMPC. Keempat emiten ini dipilih sebagai prediktor signifikan dalam estimasi CoVaR SSVS saham MARK pada kondisi pasar ekstrem. TOTO mencatat nilai PIP tertinggi sebesar 0,9300, mengindikasikan bahwa TOTO paling konsisten terpilih sebagai prediktor yang relevan sepanjang iterasi MCMC, sehingga menempatkannya sebagai emiten dengan sumber keterkaitan risiko sistemik paling kuat terhadap MARK pada kuantil 1%. Hal ini sejalan dengan hasil perhitungan nilai VI pada tahap CoVaR QRF sebelumnya, di mana MARK mencatat nilai VI tertinggi pada kuantil 1% sehingga bukti empiris dari tahap QRF terbukti konsisten dengan hasil seleksi variabel pada tahap SSVS. Sementara itu, UNTR, ASII, SKRN, dan SMIL mencatat nilai $PIP < 0,5$ yang mengindikasikan bahwa kontribusi ketiganya belum cukup kuat terhadap risiko kondisional SINI pada kondisi pasar yang sangat ekstrem.

Pada tingkat kepercayaan 95%, prediktor yang terpilih berubah menjadi 3 emiten, yaitu ARNA, TOTO, dan SINI. ARNA menggeser TOTO sebagai prediktor dengan nilai PIP


tertinggi, yaitu sebesar 0,9125 mengindikasikan bahwa pada kondisi pasar yang lebih moderat ARNA menjadi emiten dengan keterkaitan risiko paling signifikan terhadap MARK. Adapun IMPC pada kuantil 5% tidak terpilih dengan nilai PIP turun menjadi 0,4875. Sementara itu, UNTR, ASII, SKRN, dan SMIL kembali menunjukkan kontribusi yang tidak signifikan terhadap risiko kondisional MARK. Adanya perbedaan prediktor yang terpilih pada kuantil 1% dan 5% menunjukkan kemampuan SSVS dalam menangkap perbedaan struktur keterkaitan risiko antar emiten yang bergantung pada kondisi pasar, di mana hubungan risiko sistemik MARK pada kondisi ekstrem tidak selalu sama dengan kondisi yang lebih moderat.

Setelah variabel prediktor terpilih, model QRF dilatih ulang dengan hanya menggunakan prediktor terpilih pada masing-masing kuantil. Hasil estimasi CoVaR SSVS saham MARK disajikan pada Tabel 4.105.

Tabel 4.105 Estimasi Nilai CoVaR SSVS Saham MARK

Kuantil	Estimasi Risiko CoVaR SSVS			
	Mean	Max	Min	Varians
1%	-0,06512	-0,05213	-0,08108	0,00008
5%	-0,03916	-0,02150	-0,07359	0,00012

Pada tingkat kepercayaan 99%, rata-rata CoVaR SSVS saham MARK menunjukkan angka sebesar $-0,06512$ dengan varians $0,00008$, yang artinya ketika berinvestasi sebesar Rp1.000.000.000 pada MARK, investor berisiko mengalami kerugian kondisional sebesar 6,51% atau sekitar Rp65.120.000 dalam satu hari kerja bursa ketika emiten-emiten prediktor terpilih berada pada kondisi VaR 1% nya dengan sebaran risiko yang stabil. Pada tingkat kepercayaan 95%, rata-rata CoVaR SSVS menjadi $-0,03916$ dengan varians meningkat menjadi $0,00012$, sehingga potensi kerugian kondisional yang dialami investor adalah sebesar Rp39.160.000 pada kondisi pasar yang lebih moderat dengan sebaran risiko lebih berfluktuasi namun masih cukup stabil dan terkendali. Jika dibandingkan dengan CoVaR QRF tanpa seleksi variabel, rata-rata CoVaR SSVS baik pada kuantil 1% dan 5% lebih dangkal dengan perbedaan yang tidak terlalu jauh ($-0,06512$ vs $-0,06870$) dan ($-0,03916$ vs $-0,04520$). Sehingga secara umum pendekatan SSVS menghasilkan estimasi yang sangat dekat dengan CoVaR QRF untuk saham MARK, dengan perbedaan yang kecil pada kedua tingkat kuantil. Untuk memperjelas pergerakan estimasi CoVaR SSVS terhadap *return* aktual saham MARK, visualisasi perbandingan keduanya disajikan pada Gambar 4.42.



Gambar 4.42 Plot CoVaR SSVS MARK Kuantil 1% (Kiri) dan 5% (Kanan)

Berdasarkan Gambar 4.42, pada kuantil 1%, garis CoVaR SSVS saham MARK bergerak relatif stabil di sepanjang periode pengamatan dengan fluktuasi yang tidak terlalu besar. Ini menunjukkan bahwa untuk kondisi risiko yang sangat ekstrem, CoVaR SSVS 1% berperan sebagai ambang kerugian kondisional saham MARK yang stabil namun tetap responsif terhadap perubahan kondisi pasar. Sedangkan pada tingkat kuantil 5%, garis CoVaR SSVS bergerak stabil dan lebih dekat ke nol, mencerminkan estimasi batas risiko yang lebih moderat. Perbedaan kedalaman yang tidak terlalu besar antara CoVaR SSVS TOTO pada kuantil 1% dan 5%, mencerminkan profil risiko kondisional MARK yang relatif konsisten pada kondisi ekstrem maupun moderat.

4.4.3 Backtesting Hasil Estimasi CoVaR SSVS

Setelah diperoleh estimasi CoVaR SSVS pada kuantil 1% dan 5% untuk masing-masing saham sektor industri, langkah selanjutnya adalah mengevaluasi seberapa baik model mampu menangkap risiko kerugian kondisional yang sesungguhnya terjadi di pasar melalui proses *backtesting*. Evaluasi dilakukan menggunakan dua pendekatan statistik, yaitu *Proportion Shortfall* dan *Kupiec Test* yang diterapkan pada deret pelanggaran CoVaR SSVS di kedua tingkat kuantil untuk menilai apakah model estimasi CoVaR SSVS yang lebih *parsimonious* benar-benar memberikan estimasi risiko yang andal sebagai dasar pengukuran risiko sistemik.

a) *Proportion Shortfall*

Proportion Shortfall dalam konteks *backtesting* dinyatakan sebagai rasio pelanggaran, yaitu proporsi ketika *return* aktual berada di bawah batas CoVaR SSVS serta selisih absolutnya terhadap tingkat kuantil teoritis. Dengan jumlah observasi sebanyak 597 hari, jumlah pelanggaran yang diharapkan dari model untuk CoVaR SSVS pada kuantil 1% adalah sebanyak 6 pelanggaran dan pada kuantil 5% sebanyak 30. Tabel 4.106 menyajikan uraian jumlah pelanggaran aktual, nilai *Proportion Shortfall* (PS), serta nilai absolut selisih risiko untuk tiap emiten pada dua tingkat kuantil yang digunakan.

Tabel 4.106 Hasil *Proportion Shortfall* pada Estimasi CoVaR SSVS

Saham	$\tau = 0,01$			$\tau = 0,05$		
	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko
ASII	12	0,0201	0,0101	21	0,0352	0,0148
IMPC	9	0,0151	0,0051	38	0,0637	0,0137
UNTR	8	0,0134	0,0034	38	0,0637	0,0137
SKRN	9	0,0151	0,0051	44	0,0737	0,0237
SINI	15	0,0251	0,0151	38	0,0637	0,0137
SMIL	18	0,0302	0,0202	44	0,0737	0,0237
ARNA	9	0,0151	0,0051	38	0,0637	0,0137
TOTO	9	0,0151	0,0051	28	0,0469	0,0031
MARK	11	0,0184	0,0084	35	0,0586	0,0086

Tabel 4.106 menunjukkan pada tingkat kepercayaan 99% ($\tau = 1\%$), variasi deviasi terlihat lebih jelas karena pengujiannya yang berfokus pada kejadian ekstrem. Dilihat dari nilai *Proportion Shortfall*, sebagian besar berada di atas nilai teoritis 1% yang mengindikasikan adanya kecenderungan *underestimate* pada model CoVaR SSVS di kondisi ekstrem. Adapun UNTR menunjukkan akurasi estimasi paling dekat dengan nilai teoritis, yaitu sebesar 0,0134, dengan |Selisih| Risiko sebesar 0,0034. Hal ini mengindikasikan bahwa model CoVaR UNTR andal dalam mengestimasi risiko pada kejadian yang sangat ekstrem meskipun dengan kecenderungan *underestimation* yang kecil. Pada saham IMPC, SKRN, ARNA, dan TOTO

nilai proporsi pelanggaran berada di angka 0,0151 dengan |Selisih| Risiko 0,0051, menunjukkan deviasi yang moderat dan seragam. ASII dan MARK mencatat proporsi pelanggaran masing-masing sebesar 0,0201 dan 0,0184, mengindikasikan kecenderungan *underestimate* yang lebih besar. Sementara itu, SMIL dan SINI mencatat proporsi pelanggaran tertinggi masing-masing sebesar 0,0302 dan 0,0251 dengan |Selisih| Risiko 0,0202 dan 0,0151, menjadikan keduanya sebagai saham dengan kecenderungan *underestimate* paling besar pada kuantil 1%.

Pada tingkat kepercayaan 95% ($\tau = 5\%$), sebagian besar saham juga memiliki proporsi pelanggaran (*Proportion Shortfall*) di atas nilai teoritis 5%. TOTO menunjukkan akurasi terbaik dengan nilai *Proportion Shortfall* sebesar 0,0469 dan |Selisih| Risiko terkecil sebesar 0,0031, menjadikan TOTO sebagai saham dengan estimasi CoVaR SSVS paling akurat pada kuantil ini. MARK mencatat |Selisih| Risiko sebesar 0,0086, diikuti IMPC, UNTR, SINI, dan ARNA yang secara konsisten mencatat proporsi pelanggaran sebesar 0,0637 dengan |Selisih| Risiko 0,0137. Nilai yang seragam tersebut mengindikasikan bahwa keempat saham memiliki tingkat *underestimate* yang sama pada kondisi yang moderat. ASII mencatat |Selisih| Risiko sebesar 0,0148, mengindikasikan tingkat *underestimate* yang lebih tinggi dibanding kelima saham sebelumnya. Sementara itu, SKRN dan SMIL mencatat proporsi pelanggaran tertinggi sebesar 0,0737 dengan |Selisih| Risiko terbesar 0,0237, mengindikasikan kecenderungan *underestimate* paling besar di antara seluruh saham yang diuji pada kuantil 5%. Hasil *Proportion Shortfall* ini menjadi indikasi awal mengenai akurasi frekuensi pelanggaran untuk setiap saham, yang selanjutnya akan diuji menggunakan *Kupiec Test*.

b) *Kupiec Test*

Validitas model CoVaR SSVS kemudian dievaluasi dengan *Kupiec Test*. *Kupiec Test* membandingkan proporsi pelanggaran CoVaR SSVS yang terjadi secara empiris dengan tingkat pelanggaran yang diharapkan berdasarkan kuantil yang digunakan. Hipotesis nol (H_0) menyatakan bahwa proporsi pelanggaran sama dengan tingkat kuantil yang digunakan, sedangkan hipotesis alternatif (H_1) menyatakan bahwa proporsi pelanggaran yang dihasilkan berbeda. Statistik *Kupiec test* mengikuti distribusi χ^2 dengan derajat bebas satu. Jika nilai statistik lebih besar daripada nilai kritis atau *p-value* lebih kecil dari 0,05, maka H_0 ditolak dan model CoVaR dinyatakan tidak valid pada tingkat kepercayaan tersebut. Ringkasan hasil pengujian *Kupiec Test* seluruh saham pada dua tingkat kuantil yang berbeda disajikan pada Tabel 4.107.

Tabel 4.107 Hasil *Kupiec Test* pada Estimasi CoVaR SSVS

Saham	Kuantil	Statistik	$\chi^2_{\alpha,1}$	<i>P-value</i>	Keputusan	Kesimpulan
ASII	1%	4,758	3,841	0,029	Tolak H_0	Tidak Valid
	5%	3,068	3,841	0,080	Gagal Tolak H_0	Valid
IMPC	1%	1,344	3,841	0,246	Gagal Tolak H_0	Valid
	5%	2,164	3,841	0,141	Gagal Tolak H_0	Valid
UNTR	1%	0,630	3,841	0,427	Gagal Tolak H_0	Valid
	5%	2,164	3,841	0,141	Gagal Tolak H_0	Valid
SKRN	1%	1,344	3,841	0,246	Gagal Tolak H_0	Valid
	5%	6,200	3,841	0,013	Tolak H_0	Tidak Valid
SINI	1%	9,718	3,841	0,002	Tolak H_0	Tidak Valid
	5%	2,164	3,841	0,141	Gagal Tolak H_0	Valid
SMIL	1%	15,917	3,841	0,000	Tolak H_0	Tidak Valid
	5%	6,200	3,841	0,013	Tolak H_0	Tidak Valid
ARNA	1%	1,344	3,841	0,246	Gagal Tolak H_0	Valid
	5%	2,164	3,841	0,141	Gagal Tolak H_0	Valid

Tabel 4.107 Hasil *Kupiec Test* pada Estimasi CoVaR SSVS (Lanjutan)

Saham	Kuantil	Statistik	$\chi^2_{\alpha,1}$	<i>P-value</i>	Keputusan	Kesimpulan
TOTO	1%	1,344	3,841	0,246	Gagal Tolak H_0	Valid
	5%	0,123	3,841	0,726	Gagal Tolak H_0	Valid
MARK	1%	3,428	3,841	0,064	Gagal Tolak H_0	Valid
	5%	0,888	3,841	0,346	Gagal Tolak H_0	Valid

Hasil *Kupiec Test* pada estimasi CoVaR SSVS menunjukkan pola validitas yang berbeda antara kedua tingkat kuantil dan antar saham. Pada tingkat kepercayaan 95%, sebagian besar saham menghasilkan model yang valid, antara lain ASII, IMPC, UNTR, SINI, ARNA, TOTO, dan MARK dengan nilai statistik *Kupiec* di bawah nilai kritis χ^2 dan *p-value* di atas 0,05. Sehingga diperoleh keputusan gagal tolak H_0 dan model CoVaR SSVS ketujuh saham tersebut dinyatakan valid pada kuantil 5%. Sebaliknya, SKRN dan SMIL menunjukkan nilai statistik *Kupiec* yang sama sebesar 6,200 dengan *p-value* lebih kecil dari 0,05, yaitu sebesar 0,013 sehingga diperoleh keputusan tolak H_0 dan model dinyatakan tidak valid. Hasil ini konsisten dengan temuan *Proportion Shortfall* sebelumnya, di mana keduanya mencatat deviasi terbesar, paling jauh dari nilai teoritis. Sementara pada tingkat kepercayaan 99%, hasil *Kupiec Test* menunjukkan bahwa terdapat tiga saham yang tidak lolos uji validitas. SMIL mencatat statistik *Kupiec* tertinggi sebesar 15,917 dengan *p-value* mendekati nol, menjadikannya sebagai saham dengan tingkat akurasi estimasi paling rendah di antara seluruh saham pada kuantil ini. Nilai statistik yang sangat tinggi ini mengindikasikan bahwa model CoVaR SSVS SMIL dengan satu prediktor tunggal belum mampu merepresentasikan risiko kondisional SMIL pada kondisi ekstrem. SINI dan ASII masing-masing mencatat statistik *Kupiec* sebesar 9,718 dengan *p-value* 0,002 dan 4,758 dengan *p-value* 0,029, sehingga diperoleh keputusan tolak H_0 dan model CoVaR SSVS keduanya dinyatakan tidak valid pada kuantil 1%, konsisten dengan nilai *Proportion Shortfall* keduanya yang juga mencatat deviasi cukup besar dari nilai teoritis. Sementara itu, IMPC, UNTR, SKRN, ARNA, TOTO, dan MARK diperoleh keputusan gagal tolak H_0 dengan *p-value* di atas 0,05 sehingga model CoVaR SSVS keenamnya dinyatakan valid pada kuantil 1%. Secara keseluruhan, *Kupiec Test* menegaskan bahwa kinerja CoVaR SSVS bersifat heterogen antar saham dan kuantil. Saham seperti IMPC, UNTR, ARNA, TOTO, dan MARK konsisten valid pada kedua tingkat kuantil, menunjukkan bahwa seleksi prediktor melalui SSVS menghasilkan model yang akurat secara statistik pada saham-saham tersebut. SMIL menjadi emiten dengan akurasi paling rendah karena tidak valid pada kedua kuantil, mengindikasikan bahwa ketergantungan model hanya pada satu prediktor yaitu IMPC tidak cukup untuk menangkap dinamika risiko kondisional SMIL secara akurat. Meskipun pendekatan SSVS mampu menghasilkan model yang lebih *parsimonious*, kalibrasi probabilitas pelanggaran tidak selalu lebih baik dibandingkan CoVaR QRF biasa, khususnya pada saham dengan volatilitas tinggi dan struktur keterkaitan risiko yang kompleks.

c) *Pinball Loss*

Ketepatan estimasi CoVaR SSVS pada penelitian ini selanjutnya dievaluasi menggunakan *pinball loss* sebagaimana dijelaskan pada Subbab 2.13. Semakin kecil nilai *pinball loss* yang dihasilkan, semakin akurat model CoVaR SSVS dalam mengestimasi kuantil τ yang dievaluasi. Hasil perhitungan *pinball loss* untuk estimasi CoVaR SSVS pada kesepuluh saham disajikan pada Tabel 4.108.

Tabel 4.108 Hasil *Pinball Loss* pada Estimasi CoVaR SSVS

Saham	Kuantil	<i>Pinball Loss</i>
ASII	1%	0,00070
	5%	0,00178
IMPC	1%	0,00098
	5%	0,00283
UNTR	1%	0,00076
	5%	0,00225
SKRN	1%	0,00148
	5%	0,00491
SINI	1%	0,00164
	5%	0,00608
SMIL	1%	0,00321
	5%	0,00906
ARNA	1%	0,00090
	5%	0,00187
TOTO	1%	0,00046
	5%	0,00129
MARK	1%	0,00088
	5%	0,00327

Berdasarkan Tabel 4.108, nilai *pinball loss* CoVaR SSVS pada $\tau = 1\%$ berkisar antara 0,00046 hingga 0,00321, sedangkan pada $\tau = 5\%$ berkisar antara 0,00129 hingga 0,00906. TOTO kembali menjadi saham dengan *pinball loss* terendah pada kedua tingkat kuantil, sementara SMIL kembali mencatat nilai tertinggi, konsisten dengan pola hasil *pinball loss* pada VaR dan CoVaR, mengindikasikan bahwa urutan akurasi antarsaham relatif stabil baik pada pendekatan VaR, CoVaR, maupun CoVaR SSVS. Jika dibandingkan dengan CoVaR QRF, nilai *pinball loss* CoVaR SSVS sebagian besar saham lebih tinggi dan hanya beberapa saham yang menunjukkan penurunan nilai *pinball loss* setelah seleksi variabel. Secara umum, urutan besaran *pinball loss* CoVaR antarsaham mengikuti pola yang serupa dengan VaR, dengan TOTO, ASII, dan ARNA secara konsisten menghasilkan penyimpangan estimasi yang kecil, sedangkan SMIL, SINI, dan SKRN secara konsisten menghasilkan penyimpangan yang lebih besar pada kedua tingkat kuantil yang dievaluasi. Selanjutnya dari hasil *backtesting* ketiga model estimasi, dilakukan perbandingan akurasi tiga model risiko, yaitu VaR, CoVaR, dan CoVaR SSVS yang dibahas pada subbab 4.5.

4.5 Perbandingan Akurasi Model VaR, CoVaR, dan CoVaR SSVS

Subbab ini membahas perbandingan akurasi tiga model risiko, yaitu VaR, CoVaR, dan CoVaR SSVS. VaR digunakan untuk mengukur risiko kerugian ekor kiri pada masing-masing saham secara individu, sedangkan CoVaR menangkap risiko kerugian kondisional suatu saham ketika saham lain berada dalam kondisi distress, sehingga lebih mencerminkan risiko sistemik. Kemudian CoVaR SSVS mengembangkan pendekatan CoVaR dengan menambahkan mekanisme seleksi variabel berbasis Bayesian sehingga hanya keterkaitan antar saham yang paling relevan yang digunakan dalam estimasi. Dari sudut pandang investor dan pengelola portofolio, penting untuk mengetahui model mana yang paling akurat dalam menggambarkan frekuensi dan kedalaman kerugian ekstrem, baik pada tingkat kuantil 1% maupun 5%, karena hal ini akan memengaruhi penentuan batas risiko dan alokasi modal. Oleh karena itu, dilakukan perbandingan tingkat akurasi ketiga model berdasarkan hasil *backtesting* menggunakan

Proportion Shortfall, *Kupiec test*, serta *pinball loss* untuk kedua kuantil, dengan ringkasan perbandingan disajikan pada Tabel 4.109.

Tabel 4.109 Perbandingan *Proportion Shortfall* pada VaR, CoVaR, dan CoVaR SSVS

Saham	Model	$\tau = 0,01$			$\tau = 0,05$		
		Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko	Jumlah Pelanggaran	<i>Proportion Shortfall</i>	Selisih Risiko
ASII	VaR	2	0,0034	0,0066	29	0,0486	0,0014
	CoVaR	5	0,0084	0,0016	26	0,0436	0,0064
	CoVaR SSVS	12	0,0201	0,0101	21	0,0352	0,0148
IMPC	VaR	5	0,0084	0,0016	34	0,0570	0,0070
	CoVaR	13	0,0218	0,0118	36	0,0603	0,0103
	CoVaR SSVS	9	0,0151	0,0051	38	0,0637	0,0137
UNTR	VaR	4	0,0067	0,0033	26	0,0436	0,0064
	CoVaR	4	0,0067	0,0033	29	0,0486	0,0014
	CoVaR SSVS	8	0,0134	0,0034	38	0,0637	0,0137
SKRN	VaR	8	0,0134	0,0034	36	0,0603	0,0103
	CoVaR	5	0,0084	0,0016	28	0,0469	0,0031
	CoVaR SSVS	9	0,0151	0,0051	44	0,0737	0,0237
SINI	VaR	7	0,0117	0,0017	44	0,0737	0,0237
	CoVaR	4	0,0067	0,0033	23	0,0385	0,0115
	CoVaR SSVS	15	0,0251	0,0151	38	0,0637	0,0137
SMIL	VaR	6	0,0101	0,0001	33	0,0553	0,0053
	CoVaR	3	0,0050	0,0050	29	0,0486	0,0014
	CoVaR SSVS	18	0,0302	0,0202	44	0,0737	0,0237
ARNA	VaR	4	0,0067	0,0033	35	0,0586	0,0086
	CoVaR	4	0,0067	0,0033	23	0,0385	0,0115
	CoVaR SSVS	9	0,0151	0,0051	38	0,0637	0,0137
TOTO	VaR	9	0,0151	0,0051	34	0,0570	0,0070
	CoVaR	4	0,0067	0,0033	24	0,0402	0,0098
	CoVaR SSVS	9	0,0151	0,0051	28	0,0469	0,0031
MARK	VaR	7	0,0117	0,0017	34	0,0570	0,0070
	CoVaR	8	0,0134	0,0034	27	0,0452	0,0048
	CoVaR SSVS	11	0,0184	0,0084	35	0,0586	0,0086

Berdasarkan Tabel 4.109, perbandingan kinerja VaR, CoVaR, dan CoVaR SSVS secara keseluruhan menunjukkan pola yang cukup jelas dalam hal kemampuan kalibrasi risiko di seluruh saham dan tingkat kuantil. Pada tingkat kepercayaan 99%, CoVaR konvensional menunjukkan kinerja terbaik untuk sebagian besar saham dengan nilai |Selisih| Risiko yang paling kecil, khususnya pada ASII dan SKRN (masing-masing sebesar 0,0016), yang mengindikasikan bahwa CoVaR konvensional paling akurat dalam merepresentasikan frekuensi pelanggaran pada kondisi pasar yang sangat ekstrem. VaR unggul pada beberapa saham seperti IMPC (0,0016), SINI (0,0017), SMIL (0,0001), dan MARK (0,0017), sedangkan CoVaR SSVS secara umum mencatat nilai |Selisih| Risiko yang paling besar di antara ketiga model pada kuantil ini, dengan deviasi tertinggi pada SMIL (0,0202) dan SINI (0,0151). Hal ini mengindikasikan bahwa pada kondisi ekstrem, seleksi prediktor melalui SSVS belum tentu menghasilkan kalibrasi yang lebih baik dibandingkan model yang menggunakan seluruh prediktor, khususnya pada saham-saham dengan struktur keterkaitan risiko yang kompleks.

Pada tingkat kepercayaan 95%, CoVaR konvensional masih menunjukkan dominasi sebagai model dengan kalibrasi terbaik untuk sebagian besar saham dibandingkan dengan dua pemodelan lain, antara lain UNTR (0,0014), SKRN (0,0031), SINI (0,0115), SMIL (0,0014), dan MARK (0,0048). VaR unggul pada ASII (0,0014) dan IMPC (0,0070), sedangkan CoVaR SSVS hanya unggul pada satu saham yaitu TOTO dengan |Selisih| Risiko terkecil sebesar 0,0031. Secara keseluruhan, CoVaR SSVS mencatat nilai |Selisih| Risiko yang lebih besar

dibandingkan CoVaR konvensional pada hampir seluruh saham di kedua tingkat kuantil, di mana SKRN dan SMIL menjadi saham dengan deviasi paling besar (0,0237) dari nilai teoritis yang ditetapkan. Dengan demikian, meskipun pendekatan SSVS menghasilkan model yang lebih sederhana, kalibrasi probabilitas pelanggaran CoVaR SSVS tidak selalu lebih baik dibandingkan CoVaR konvensional, melainkan bersifat selektif sesuai dengan karakteristik dari masing-masing saham yang digunakan.

Tabel 4.110 Perbandingan *Kupiec Test* pada VaR, CoVaR, dan CoVaR SSVS

Saham	Model	$\tau = 1\%$		$\tau = 5\%$	
		<i>P-value</i>	Kesimpulan	<i>P-value</i>	Kesimpulan
ASII	VaR	0,058	Valid	0,873	Valid
	CoVaR	0,681	Valid	0,460	Valid
	CoVaR SSVS	0,029	Tidak Valid	0,080	Valid
IMPC	VaR	0,681	Valid	0,445	Valid
	CoVaR	0,012	Tidak Valid	0,263	Valid
	CoVaR SSVS	0,246	Valid	0,141	Valid
UNTR	VaR	0,389	Valid	0,460	Valid
	CoVaR	0,389	Valid	0,873	Valid
	CoVaR SSVS	0,427	Valid	0,141	Valid
SKRN	VaR	0,427	Valid	0,263	Valid
	CoVaR	0,681	Valid	0,726	Valid
	CoVaR SSVS	0,246	Valid	0,013	Tidak Valid
SINI	VaR	0,680	Valid	0,013	Tidak Valid
	CoVaR	0,389	Valid	0,181	Valid
	CoVaR SSVS	0,002	Tidak Valid	0,141	Valid
SMIL	VaR	0,990	Valid	0,561	Valid
	CoVaR	0,177	Valid	0,873	Valid
	CoVaR SSVS	0,000	Tidak Valid	0,013	Tidak Valid
ARNA	VaR	0,389	Valid	0,346	Valid
	CoVaR	0,389	Valid	0,181	Valid
	CoVaR SSVS	0,246	Valid	0,141	Valid
TOTO	VaR	0,246	Valid	0,445	Valid
	CoVaR	0,389	Valid	0,256	Valid
	CoVaR SSVS	0,246	Valid	0,726	Valid
MARK	VaR	0,680	Valid	0,445	Valid
	CoVaR	0,427	Valid	0,587	Valid
	CoVaR SSVS	0,064	Valid	0,346	Valid

Selanjutnya dari perbandingan hasil *Kupiec Test* pada ketiga model yang disajikan pada Tabel 4.110, hasilnya menunjukkan pola validitas yang beragam antar model dan tingkat kuantil. Pada tingkat kepercayaan 99%, VaR dan CoVaR konvensional menunjukkan kinerja yang lebih konsisten dibandingkan CoVaR SSVS. Hampir seluruh saham pada model VaR dan CoVaR konvensional dinyatakan valid pada kuantil 1%, kecuali CoVaR IMPC yang dinyatakan tidak valid dengan nilai *p-value* sebesar 0,012. Sebaliknya, CoVaR SSVS mencatat tiga saham yang tidak valid yaitu ASII, SINI, dan SMIL, mengindikasikan bahwa seleksi variabel prediktor melalui SSVS pada ketiga saham belum mampu menghasilkan kalibrasi frekuensi pelanggaran yang sesuai dengan tingkat kuantil teoritis pada kondisi pasar yang sangat ekstrem.

Pada tingkat kepercayaan 95%, CoVaR konvensional menunjukkan konsistensi validitas tertinggi di mana estimasi model seluruh saham dinyatakan valid. Pada model VaR, ditemukan keputusan tidak valid hanya pada saham SINI, sedangkan CoVaR SSVS tidak valid pada SKRN dan SMIL, ini konsisten dengan hasil *Proportion Shortfall* sebelumnya yang menunjukkan bahwa kedua saham tersebut memiliki deviasi terbesar dari nilai teoritis pada kuantil 5%.

Sementara itu, UNTR, ARNA, TOTO, dan MARK secara konsisten dinyatakan valid pada ketiga model di kedua tingkat kuantil, yang mengindikasikan bahwa ketiga pendekatan pengukuran risiko yang diterapkan pada keempat saham ini menghasilkan kalibrasi frekuensi pelanggaran yang andal dan sesuai dengan tingkat kuantil teoritis.

Sebagai evaluasi tambahan, perbandingan ketiga model juga dilakukan menggunakan *pinball loss* yang mengukur rata-rata kesalahan estimasi kuantil secara keseluruhan, di mana nilai yang lebih kecil mengindikasikan akurasi estimasi yang lebih baik. Perbandingan nilai *pinball loss* ketiga model ditunjukkan pada Tabel 4.111.

Tabel 4.111 Perbandingan Nilai *Pinball Loss* pada VaR, CoVaR, dan CoVaR SSVS

Saham	Model	$\tau = 1\%$	$\tau = 5\%$
		<i>Pinball Loss</i>	<i>Pinball Loss</i>
ASII	VaR	0,00058	0,00176
	CoVaR	0,00063	0,00178
	CoVaR SSVS	0,00070	0,00178
IMPC	VaR	0,00107	0,00294
	CoVaR	0,00100	0,00275
	CoVaR SSVS	0,00098	0,00283
UNTR	VaR	0,00073	0,00217
	CoVaR	0,00078	0,00220
	CoVaR SSVS	0,00076	0,00225
SKRN	VaR	0,00129	0,00357
	CoVaR	0,00148	0,00472
	CoVaR SSVS	0,00148	0,00491
SINI	VaR	0,00154	0,00523
	CoVaR	0,00174	0,00582
	CoVaR SSVS	0,00164	0,00608
SMIL	VaR	0,00214	0,00630
	CoVaR	0,00227	0,00724
	CoVaR SSVS	0,00321	0,00906
ARNA	VaR	0,00056	0,00174
	CoVaR	0,00079	0,00188
	CoVaR SSVS	0,00090	0,00187
TOTO	VaR	0,00044	0,00124
	CoVaR	0,00044	0,00123
	CoVaR SSVS	0,00046	0,00129
MARK	VaR	0,00079	0,00293
	CoVaR	0,00082	0,00311
	CoVaR SSVS	0,00088	0,00327

Perbandingan *pinball loss* antara ketiga model tidak bersifat langsung karena masing-masing model mengestimasi target yang berbeda dan perlu diinterpretasikan secara hati-hati. VaR mengestimasi kuantil *return* saham secara individual dengan target yang lebih sederhana dan langsung dapat diverifikasi dari data observasi, sedangkan CoVaR dan CoVaR SSVS mengestimasi kuantil *return* kondisional yang bergantung pada kondisi emiten lain sehingga kompleksitas estimasinya lebih tinggi. Dengan demikian, keunggulan VaR dalam hasil *pinball loss* tidak mencerminkan sebagai model terbaik secara keseluruhan, melainkan mencerminkan perbedaan dimensi risiko yang diukur. VaR mengukur risiko individual, sedangkan CoVaR dan CoVaR SSVS dirancang untuk mengukur risiko sistemik yang melibatkan keterkaitan antar emiten.

Berdasarkan Tabel 4.111, pada kedua tingkat kuantil, CoVaR SSVS secara umum mencatat nilai *pinball loss* yang lebih besar dibandingkan CoVaR konvensional pada sebagian besar

saham, dengan pengecualian pada saham IMPC, UNTR, dan SINI. Sedangkan pada tingkat kepercayaan 95%, CoVaR SSVS menghasilkan *pinball loss* lebih kecil dibandingkan CoVaR konvensional hanya pada ARNA dengan selisih yang sangat kecil. SMIL mencatat selisih terbesar antara CoVaR SSVS dan CoVaR di kedua tingkat kuantil, mengindikasikan bahwa model dengan satu prediktor pada SMIL menghasilkan akurasi estimasi kuantil yang paling rendah di antara seluruh saham, konsisten dengan hasil *backtesting* yang menunjukkan bahwa model SMIL dengan hanya menggunakan satu prediktor menghasilkan kalibrasi paling rendah. Secara keseluruhan, perbandingan *pinball loss* mengonfirmasi bahwa seleksi variabel dengan SSVS tidak konsisten meningkatkan akurasi estimasi meskipun menghasilkan model yang lebih *parsimonious*.

Secara keseluruhan, CoVaR konvensional menunjukkan konsistensi validitas *Kupiec Test* tertinggi karena hanya satu saham yang tidak valid di kuantil 1% dan seluruh saham valid di kuantil 5%. VaR juga relatif konsisten dengan hanya satu saham yang tidak valid di kuantil 5%. CoVaR SSVS menunjukkan ketidakvalidan terbanyak terutama pada kuantil 1%, namun tetap valid pada sebagian besar saham di kedua kuantil. Dari sisi *pinball loss*, hasilnya tidak mencerminkan model VaR sebagai model terbaik secara keseluruhan, melainkan mencerminkan perbedaan dimensi risiko yang diukur antara ketiga pendekatan. CoVaR SSVS secara umum menghasilkan nilai yang lebih besar dibandingkan CoVaR konvensional, mengindikasikan bahwa seleksi variabel melalui SSVS tidak secara konsisten meningkatkan akurasi estimasi risiko kondisional. SMIL secara konsisten menjadi saham dengan performa terburuk, yang mengindikasikan bahwa karakteristik saham SMIL yang sangat volatil dan keterkaitan risiko yang terkonsentrasi hanya pada satu prediktor menjadi tantangan utama bagi seluruh model pengukuran risiko yang digunakan. Oleh karena itu, penambahan tahap seleksi variabel melalui SSVS pada model CoVaR tidak meningkatkan akurasi maupun validitas estimasi risiko kondisional. Meskipun SSVS berhasil menghasilkan model yang lebih sederhana dengan hanya memasukkan prediktor yang terbukti relevan, proses eliminasi prediktor yang dianggap kurang signifikan justru pada beberapa saham menyebabkan hilangnya informasi risiko yang sebenarnya masih berkontribusi terhadap dinamika *return* kondisional, sehingga estimasi yang dihasilkan menjadi kurang akurat dibandingkan model yang menggunakan seluruh prediktor. Hal ini terjadi karena PIP pada SSVS mengukur apakah suatu prediktor masuk ke dalam model berdasarkan kriteria Bayesian, bukan secara langsung mengukur kontribusinya terhadap peningkatan akurasi. Variabel dengan nilai PIP $< 0,5$ tetap berpotensi memiliki kontribusi, walaupun tidak cukup dominan untuk melewati ambang batas seleksi. Sehingga ketika variabel tersebut dibuang model memang menjadi lebih sederhana. Namun, dapat menyebabkan hilangnya informasi prediktif yang masih relevan terhadap *return* kondisional dan informasi yang muncul melalui interaksi dengan prediktor lain, yang berdampak pada peningkatan bias. Akibatnya, kinerja prediksi secara keseluruhan justru menurun, yang tercermin dari nilai *pinball loss* yang lebih tinggi dibandingkan model yang menggunakan seluruh prediktor.

Hal ini mengindikasikan bahwa dalam konteks pengukuran risiko sistemik, model yang lebih sederhana tidak selalu menghasilkan estimasi yang lebih baik. Sehingga keunggulan SSVS terletak pada kemampuannya dalam mengidentifikasi struktur keterkaitan risiko yang paling relevan, bukan pada peningkatan akurasi estimasi model secara statistik.

BAB 5

KESIMPULAN

5.1 Kesimpulan

Berdasarkan hasil analisis risiko yang telah dilakukan, diperoleh kesimpulan sebagai berikut.

1. Karakteristik data *return* kesepuluh saham sektor industri di BEI yang digunakan pada penelitian ini menunjukkan pola yang heterogen baik dari nilai rata-rata *return*, standar deviasi, *skewness*, hingga kurtosis. Secara umum, rata-rata *return* harian seluruh saham kecil dan mendekati nol yang mencerminkan bahwa pergerakan harga didominasi oleh fluktuasi jangka pendek tanpa kecenderungan tren yang kuat. Dilihat dari tingkat volatilitasnya, SMIL dan SINI menunjukkan fluktuasi tertinggi diikuti SKRN, sementara TOTO mencatat volatilitas terendah di antara seluruh saham yang dianalisis. Sementara itu, seluruh saham memiliki nilai kurtosis >3 yang mengindikasikan distribusi *return* bersifat *leptokurtic* dengan ekor distribusi yang lebih tebal (*fat tails*) jika dibandingkan dengan distribusi normal. Adanya *skewness* dan *heavy tail* pada data *return* mengindikasikan bahwa distribusi *standardized skewed Student-t* (sstd) lebih sesuai digunakan dalam pemodelan AR-GARCH untuk mengakomodasi asimetri dan ekor tebal pada distribusi *return* saham sektor industri.
2. Estimasi risiko individu saham sektor industri menggunakan VaR dengan pendekatan AR-GARCH menunjukkan bahwa estimasi VaR pada kuantil 1% secara konsisten lebih dalam dibandingkan kuantil 5%, yang mengindikasikan bahwa potensi kerugian pada kondisi pasar sangat ekstrem lebih besar dibandingkan kondisi pasar yang lebih moderat. Pemilihan model terbaik untuk masing-masing saham menghasilkan kombinasi yang beragam, mengindikasikan bahwa tidak semua saham menunjukkan efek *mean* maupun volatilitas bersyarat yang sama kuatnya sehingga pemodelan perlu menyesuaikan karakteristik data masing-masing emiten. SMIL dan SINI mencatat rata-rata VaR tertinggi yang mengindikasikan potensi kerugian individual terbesar, sedangkan TOTO mencatat rata-rata VaR terendah yang mencerminkan potensi kerugian individual paling kecil di antara seluruh saham. Hasil *backtesting* menunjukkan bahwa sebagian besar saham memiliki jumlah pelanggaran aktual yang relatif mendekati proporsi teoritis pada kedua tingkat kuantil. Pengujian *Kupiec Test* menunjukkan bahwa hampir seluruh saham dinyatakan valid pada kedua tingkat kuantil, kecuali SINI pada kuantil 5% yang menunjukkan kecenderungan *underestimation* risiko pada kondisi pasar yang lebih moderat. Secara keseluruhan, model VaR AR-GARCH yang dibentuk mampu merepresentasikan risiko individu *return* saham sektor industri secara memadai dan konsisten dengan tingkat kuantil yang ditetapkan.
3. Pengukuran risiko sistemik menggunakan CoVaR berbasis QRF dan Δ CoVaR dilakukan pada sembilan saham karena karakteristik VaR HEXA yang konstan dan tidak menangkap dinamika volatilitas dari waktu ke waktu sehingga tidak memadai sebagai prediktor dalam pembentukan model risiko sistemik. Hasil estimasi CoVaR QRF pada kuantil 1% cenderung lebih dalam dibandingkan kuantil 5% dengan varians yang lebih besar, mengindikasikan adanya risiko sistemik yang lebih besar dan bervariasi pada kondisi pasar yang semakin ekstrem. Secara rata-rata, seluruh saham mencatat nilai CoVaR yang lebih

negatif dibandingkan VaR individual, mengonfirmasi bahwa keterkaitan risiko antar emiten memperburuk potensi kerugian suatu saham ketika emiten lain berada dalam kondisi *distress*. Hasil *Variable Importance* pada model QRF menunjukkan bahwa beberapa saham sebagai sumber transmisi risiko utama di sektor industri. Hasil *backtesting* menunjukkan bahwa model CoVaR berbasis QRF menunjukkan seluruh saham dinyatakan valid pada kuantil 5% sedangkan pada kuantil 1%, hanya IMPC yang dinyatakan tidak valid, mengindikasikan kecenderungan *underestimate* risiko akibat distribusi *return* yang volatil dan adanya lonjakan ekstrem pada akhir periode pengamatan. Sementara itu, hasil estimasi ΔCoVaR memberikan informasi tambahan dalam memahami risiko sistemik dengan menggambarkan seberapa besar peningkatan risiko kondisional suatu saham ketika emiten lain berpindah dari kondisi normal ke kondisi *distress*.

4. Penerapan SSVS pada model CoVaR berbasis QRF berhasil mengidentifikasi emiten-emiten yang memiliki keterkaitan risiko paling relevan pada kondisi pasar ekstrem melalui nilai *Posterior Inclusion Probability* (PIP) dan menyederhanakan model estimasi menjadi lebih sederhana. Komposisi prediktor terpilih bervariasi antar saham dan tingkat kuantil, yang mengindikasikan bahwa struktur keterkaitan risiko sistemik di sektor industri bersifat heterogen dan bergantung pada kondisi pasar. Hasil *backtesting* menggunakan *Proportion Shortfall* dan *Kupiec Test* menunjukkan bahwa CoVaR SSVS valid untuk sebagian besar saham, namun terdapat tiga saham pada kuantil 1% dan dua saham pada kuantil 5% yang tidak valid, mengindikasikan bahwa seleksi prediktor pada saham-saham tersebut belum mampu menghasilkan kalibrasi frekuensi pelanggaran yang sesuai dengan tingkat kuantil teoritis. Keunggulan VaR dalam *pinball loss* tidak mencerminkan bahwa VaR adalah model yang lebih baik secara keseluruhan, melainkan mencerminkan perbedaan mendasar dalam dimensi risiko yang diukur. SSVS lebih tepat digunakan sebagai metode identifikasi sumber *spillover* risiko sistemik karena tidak konsisten dalam meningkatkan akurasi model CoVaR. Hal ini mencerminkan bahwa pada konteks risiko sistemik, model yang lebih sederhana tidak selalu memiliki akurasi yang lebih baik.

5.2 Saran

Berdasarkan hasil analisis dan keterbatasan yang ditemukan dalam penelitian, berikut beberapa saran yang dapat penulis berikan sebagai bahan pertimbangan bagi penelitian selanjutnya.

1. Model volatilitas dapat dikembangkan dengan mencoba variasi lain seperti EGARCH, TGARCH, maupun GJR-GARCH yang mampu menangkap dinamika dan kompleksitas volatilitas *return* secara lebih akurat.
2. Memperluas variabel penelitian dengan memasukkan variabel makroekonomi dan keuangan seperti nilai tukar, suku bunga, IHSG, maupun indikator likuiditas pasar, sehingga model risiko sistemik yang dihasilkan tidak hanya menangkap keterkaitan antar saham tetapi juga mampu mengakomodasi pengaruh kondisi makroekonomi dan pasar keuangan.
3. Mempertimbangkan pendekatan *time-varying* CoVaR yang memungkinkan struktur keterkaitan risiko antar emiten berubah secara adaptif dari waktu ke waktu, karena keterkaitan risiko dalam praktiknya tidak selalu konstan dan dapat berubah tergantung pada kondisi pasar ekstrem maupun moderat.

4. Melakukan studi simulasi untuk mengevaluasi secara formal validitas VI sebelum digunakan sebagai informasi nilai *prior* dalam seleksi variabel SSVS.
5. Menggunakan metode seleksi variabel Bayesian lain, seperti *Bayesian LASSO* atau *Spike-and-Slab Regression* sebagai alternatif SSVS untuk mengevaluasi apakah metode seleksi variabel yang berbeda menghasilkan estimasi CoVaR yang lebih akurat.

(Halaman ini sengaja dikosongkan)

DAFTAR PUSTAKA

- Acharya, V. V., Pedersen, L. H., Philippon, T., & Richardson, M. (2017). Measuring Systemic Risk. *Review of Financial Studies*, 30(1), 2–47. <https://doi.org/10.1093/rfs/hhw088>
- Adrian, T., & Brunnermeier, M. K. (2016). CoVaR. *The American Economic Review*, 106(7), 1705–1741. <https://doi.org/10.1257/aer.20120555>
- Andreani, M., & Petrella, L. (2020). Dynamic Quantile Regression Forest. *Book of Short Papers SIS 2020*.
- Ardhini, L., & Prastyo, D. D. (2024). Analisis Risiko Saham Subsektor Rumah Makan dan Ritel Pakaian & Tekstil di Bursa Efek Indonesia Menggunakan Conditional Value-at-Risk dengan Pendekatan ARMA-GARCH dan Extreme Value Theory. *Jurnal Sains Dan Seni ITS*, 13(5). <https://doi.org/10.12962/j23373520.v13i5.151031>
- Asih, N. K., Achsani, N. A., Novianti, T., & Haymans Manurung, A. (2024). Volatility of Companies with Low ESG Scores in the Indonesian Capital Market: Impact of Domestic and Global Factors. *International Journal of Social Science and Business*, 8(4), 672–681. <https://doi.org/10.23887/ijssb.v8i4.88286>
- Badan Pusat Statistika. (2024). *Produk Domestik Bruto Indonesia 2020-2024*. <https://www.bps.go.id/id/publication/2024/10/09/7290b829d2eaa972e4968d19/produk-domestik-bruto-indonesia-triwulanan-2020-2024.html>
- Bainter, S. A., McCauley, T. G., Wager, T., & Losin, E. A. R. (2020). Improving Practices for Selecting a Subset of Important Predictors in Psychology: An Application to Predicting Pain. *Advances in Methods and Practices in Psychological Science*, 3(1), 66–80. <https://doi.org/10.1177/2515245919885617>
- Barbieri, M. M., & Berger, J. O. (2004). Optimal Predictive Model Selection. *Annals of Statistics*, 32(3), 870–897. <https://doi.org/10.1214/009053604000000238>
- Biktimirov, E. N., Barnes, T., & Barnes, T. H. (2003). Definitions of Return. In *Journal of Accounting and Finance Research* (Vol. 11, Number 4). <https://www.researchgate.net/publication/259391710>

- Billio, M., Getmansky, M., Lo, A. W., & Pelizzon, L. (2012). Econometric measures of connectedness and systemic risk in the finance and insurance sectors. *Journal of Financial Economics*, 104(3), 535–559. <https://doi.org/10.1016/j.jfineco.2011.12.010>
- Bodie, Z., Kane, A., & Marcus, A. J. (2014). *Investments* (10th ed.). Gwar Hill Education.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. In *Journal of Econometrics* (Vol. 31).
- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Brownlees, C., & Engle, R. (2017). *Working Paper Series SRISK: a conditional capital shortfall measure of systemic risk*. <https://doi.org/10.2849/814038>
- Caraka, R. E., Yasin, H., Prahutama, A., Statistika, M. J., Undip, F., Pengajar, S., & Statistika, J. (2015). Pemodelan General Regression Neural Network (GRNN) pada Data Return Indeks Harga Saham Euro 50. *Jurnal Gaussian*, 4(2), 181–192. <http://ejournal-sl.undip.ac.id/index.php/gaussian>
- Castillo-Mateo, J., Asín, J., Cebrián, A. C., Mateo-Lázaro, J., & Abaurrea, J. (2023). Bayesian Variable Selection in Generalized Extreme Value Regression: Modeling Annual Maximum Temperature. *Mathematics*, 11(3). <https://doi.org/10.3390/math11030759>
- Castoe, M. (2020). *Predicting Stock Market Price Direction with Uncertainty Using Quantile Regression Forest*.
- Chan, N. H., & Wong, H. Y. (2015). Simulation Techniques in Financial Risk Management: Second Edition. In *Simulation Techniques in Financial Risk Management: Second Edition*. <https://doi.org/10.1002/9781118735954>
- Chipman, H. A., George, E. I., & McCulloch, R. E. (2010). BART: Bayesian Additive Regression Trees. *Annals of Applied Statistics*, 6(1), 266–298. <https://doi.org/10.1214/09-AOAS285>
- Cont, R. (2001). *Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues*. <http://www.cmap.polytechnique.fr/>
- Cryer, J., & Chan, K. (2008). *Time Series Analysis With Applications in R* (2nd Edition). Springer Science dan Businiess Media.

- Dastkhan, H. (2024). A review of systemic risk definition in financial systems: a special focus on network analysis. *International Journal of Markets and Business Systems*, 1(1), 1. <https://doi.org/10.1504/ijmabs.2023.10055708>
- Engle, R. (1982). A General Approach to Lagrange Multiplier Model Diagnostics. *Journal of Econometrics*, 20(1). [https://doi.org/10.1016/0304-4076\(82\)90104-X](https://doi.org/10.1016/0304-4076(82)90104-X)
- Engle, R. (2001). GARCH 101: The Use of ARCH/GARCH Models in Applied Econometrics. In *Journal of Economic Perspectives* (Vol. 15, Number 4).
- Fadila, A., Nugraheni, S., & Sholihah, D. R. (2022). Volatility Spillover on IDX Energy Sector. *Jurnal Riset Akuntansi Dan Keuangan*, 10(2), 199–208. <https://doi.org/10.17509/jrak.v10i2.39168>
- Feinstein, Z., Rudloff, B., & Weber, S. (2016). *Measures of Systemic Risk*. <https://doi.org/10.1137/16M1066087>
- Fernandez, C., & Steel, M. F. J. (1996). On Bayesian Modelling Of Fat Tails and Skewness. *SSRN Electronic Journal*. <https://doi.org/10.2139/SSRN.821>
- Fissler, T., & Hoga, Y. (2022). *Backtesting Systemic Risk Forecasts using Multi-Objective Elicitability*.
- Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., Rubin, D. B., Carlin, J., Stern, H., Rubin, D., & Dunson, D. (2013). *Bayesian Data Analysis* (Third Edition). Chapman and Hall/CRC. <https://www.routledge.com/Bayesian-Data-Analysis/Gelman-Carlin-Stern-Dunson-Vehtari-Rubin/p/book/9781439840955>
- Gelman, A., & Rubin, D. B. (1992). Inference from Iterative Simulation Using Multiple Sequences. *Statistical Science*, 7(4), 457–472. <https://doi.org/10.1214/ss/1177011136>
- Genuer, R., Poggi, J. M., & Tuleau-Malot, C. (2010). Variable Selection using Random Forests. *Pattern Recognition Letters*, 31(14), 2225–2236. <https://doi.org/10.1016/j.patrec.2010.03.014>
- George, E. I., & McCulloch, R. E. (1993). Approaches for Bayesian Variable Selection. In *Statistica Sinica* (Vol. 7).

- Girardi, G., & Tolga, E. A. (2013). Systemic risk measurement: Multivariate GARCH estimation of CoVaR. *Journal of Banking and Finance*, 37(8), 3169–3180. <https://doi.org/10.1016/j.jbankfin.2013.02.027>
- Green, P. J. (1995). Reversible Jump Markov Chain Monte Carlo Computation and Bayesian Model Determination. In *Biometrika* (Vol. 82, Number 4).
- Gregorutti, B., Michel, B., & Saint-Pierre, P. (2017). Correlation and *Variable Importance* in Random Forests. *Statistics and Computing*, 27(3), 659–678. <https://doi.org/10.1007/s11222-016-9646-1>
- Gujarati, D. N., & Porter, D. C. (2009). *Basic Econometrics* (5th ed). McGraw-Hill Companies.
- Hamonangan, Y. E., & Wisuda, H. P. (2022). Pemahaman Investasi pada Generasi Milenial di Indonesia. *Jurnal Ilman: Jurnal Ilmu Manajemen*, 10(2), 29–40. <https://journals.stimsukmamedan.ac.id/index.php/ilman>
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining. Concepts and Techniques, 3rd Edition (The Morgan Kaufmann Series in Data Management Systems)*. <https://doi.org/10.1016/C2009-0-61819-5>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *Springer Series in Statistics The Elements of Statistical Learning Data Mining, Inference, and Prediction: Series in Statistics* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Hidayatullah, S. R., Elfiswandi, E., & Yenni, Z. (2022). Factors that Determine Stock Returns Moderated by Stock Trading Volume in Manufacturing Companies Listed on The Indonesia Stock Exchange for The 2017-2021 Period. *International Journal of Contemporary Accounting*, 4(2), 115–132. <https://doi.org/10.25105/ijca.v4i2.15155>
- Hippel, P. T. von. (2005). Mean, Median, and Skew: Correcting a Textbook Rule. *Journal of Statistics Education*, 13(2). <https://doi.org/10.1080/10691898.2005.11910556>
- Holton, G. A. (2003). *Value-at-Risk Theory and Practice*. <http://www.academicpress.com>
- Ishwaran, H., & Rao, J. S. (2005). Spike and Slab Variable Selection: Frequentist and Bayesian Strategies. In *Annals of Statistics* (Vol. 33, Number 2, pp. 730–773). <https://doi.org/10.1214/0090536040000001147>
- Jorion, P. (2007). *Value-at-Risk: The New Benchmark for Managing Financial Risk* (Vol. 3).

- Kass, R. E., & Raftery, A. E. (1995). Bayes Factors. *Journal of the American Statistical Association*, 90(430), 773–795. <https://doi.org/10.1080/01621459.1995.10476572>
- Keilbar, G., & Wang, W. (2022). Modelling Systemic Risk using Neural Network Quantile Regression. *Empirical Economics*, 62(1), 93–118. <https://doi.org/10.1007/s00181-021-02035-1>
- Koenker, R., & Bassett, G. (1978). Regression Quantiles. *Econometrica*.
- Künsch, H. (1989). The Jackknife and The Bootstrap for General Stationary Observations. *The Annals of Statistics*, 17(3), 1217–1241. <https://doi.org/10.1214/aos/1176347265>
- Kupiec, P. H. (1995). Techniques for Verifying The Accuracy of Risk Measurement Models. *The Journal of Derivatives*, 3(2), 73–84. www.ijjournals.com
- Lambert, P., & Laurent, S. (2001). *Modelling Financial Time Series Using GARCH-type Models with A Skewed Student Distribution for The Innovations*.
- Lambert, P., & Laurent, S. (2002). *Modelling Skewness Dynamics in Series of Financial Data Using Skewed Location-Scale Distributions*.
- Lin, Y., & Jeon, Y. (2006). Random Forests and Adaptive Nearest Neighbors. *Journal of the American Statistical Association*, 101(474), 578–590. <https://doi.org/10.1198/016214505000001230>
- Liu, T., Nakajima, T., & Hamori, S. (2022). The Impact of Economic Uncertainty Caused by COVID-19 on Renewable Energy Stocks. *Empirical Economics*, 62(4), 1495–1515. <https://doi.org/10.1007/s00181-021-02087-3>
- Meinshausen, N. (2006). Quantile Regression Forests. In *Journal of Machine Learning Research* (Vol. 7).
- Mitchell, T. J., & Beauchamp, J. J. (1988). Bayesian Variable Selection in Linear Regression. *Journal of the American Statistical Association*, 83(404), 1023–1032. <https://doi.org/10.1080/01621459.1988.10478694>
- Mokni, K., Mighri, Z., & Mansouri, F. (2009). On the Effect of Subprime Crisis on Value-at-Risk Estimation: GARCH Family Models Approach. *International Journal of Economics and Finance*, 1(2).

- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis* (5th ed.). John Wiley & Sons.
- Nainggolan, T., Wulandari, W., & Alfiana. (2023). The Impact of Fundamental Factors on The Share Price Of Manufacturing Companies in the Pulp and Paper Sub-Sector on the Indonesian Stock Exchange 2017-2021. *Proceedings Conference on Economics and Business Innovation*, 3(1). www.idx.co.id
- Narayan, P. K., & Sharma, S. S. (2011). New Evidence on Oil Price and Firm Returns. *Journal of Banking and Finance*, 35(12), 3253–3262. <https://doi.org/10.1016/j.jbankfin.2011.05.010>
- Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-40065-5>
- Nwakuya, M. T., & Nwabueze, J. C. (2018). Application of Box-Cox Transformation as a Corrective Measure to Heteroscedasticity Using an Economic Data. *American Journal of Mathematics and Statistics*, 8(1), 8–12. <https://doi.org/10.5923/j.ajms.20180801.02>
- O'Hara, R. B., & Sillanpää, M. J. (2009). A Review of Bayesian Variable Selection Methods: What, How and Which. In *Bayesian Analysis* (Vol. 4, Number 1, pp. 85–118). <https://doi.org/10.1214/09-BA403>
- Otoritas Jasa Keuangan. (2024). *Siaran Pers Pasar Modal Indonesia Resilien Sepanjang 2024 Penutupan Perdagangan Bursa Efek Indonesia Tahun 2024*.
- Perrakis, K., & Ntzoufras, I. (2015). Stochastic Search Variable Selection (SSVS) . In *Wiley StatsRef: Statistics Reference Online* (pp. 1–6). Wiley. <https://doi.org/10.1002/9781118445112.stat07829>
- Prabowo, H., Suhartono, & Prastyo, D. D. (2020). The Performance of Ramsey Test, White Test and Terasvirta Test in Detecting Nonlinearity. *Inferensi*, 3(1), 2721–3862.
- Pribadi, I., & Nursiam. (2024). The Influence of Liquidity, Profitability, Leverage, and Economic Value Added on Stock Returns (Empirical Study on Basic and Chemical Industry Sector Manufacturing Companies Listed on The IDX in 2020-2022). *Jurnal Akuntansi Dan Pajak*, 25(1), 1–11. <http://jurnal.stie-aas.ac.id/index.php/jap>

- Purwanto, D. (2025). *Estimasi Conditional Value-at-Risk pada Return Saham Perbankan di Indonesia dengan Pendekatan Peaks Over Threshold dan Quantile Regression Forest*.
- Reboredo, J. C., & Ugolini, A. (2015). Systemic risk in European sovereign debt markets: A CoVaR-copula approach. *Journal of International Money and Finance*, 51, 214–244. <https://doi.org/10.1016/j.jimonfin.2014.12.002>
- Robert, C. P., & Casella, G. (2004). *Monte Carlo Statistical Methods*. Springer. <https://doi.org/10.1007/978-1-4757-4145-2>
- Rockafellar, R. T., & Royset, J. O. (2015). *Superquantile/CVaR Risk Measures: Second-Order Theory*.
- Ročková, V., & George, E. I. (2018). The Spike-and-Slab LASSO. *Journal of the American Statistical Association*, 113(521), 431–444. <https://doi.org/10.1080/01621459.2016.1260469>
- Rockova, V., & McAlinn, K. (2020). Dynamic Variable Selection with Spike-and-Slab Process Priors. *Bayesian Analysis*, 16(1), 233–269. <https://doi.org/10.1214/20-BA1199>
- Schmoch, U. (2020). Mean Values of Skewed Distributions in The Bibliometric Assessment of Research Units. *Scientometrics*, 125(2), 925–935. <https://doi.org/10.1007/s11192-020-03476-8>
- Schwert, G. W. (1989). Why Does Stock Market Volatility Change Over Time? *The Journal of Finance*, 44(5), 1115–1153. <https://doi.org/10.1111/j.1540-6261.1989.tb02647.x>
- Scornet, E. (2016). Random Forests and Kernel Methods. *IEEE Transactions on Information Theory*, 62(3). <https://doi.org/10.1109/TIT.2016.2514489>
- Scott, J. G., & Berger, J. O. (2010). Bayes and Empirical-Bayes Multiplicity Adjustment in The Variable-Selection Problem. *Annals of Statistics*, 38(5), 2587–2619. <https://doi.org/10.1214/10-AOS792>
- Sitorus, T. F. B., Purba, M. I., Simbolon, W. N. B., Siregar, M. E., & Aliah, N. (2023). The Impact of Liquidity, Return on Assets, and Company Growth on Stock Prices in Manufacturing Companies Listed on the Indonesia Stock Exchange. *Journal of Economics and Business Letters*, 3(3), 7–13. <https://doi.org/10.55942/jebbl.v3i3.208>

- Strobl, C., Boulesteix, A. L., Zeileis, A., & Hothorn, T. (2007). Bias in Random Forest *Variable Importance* Measures: Illustrations, Sources and a Solution. *BMC Bioinformatics*, 8. <https://doi.org/10.1186/1471-2105-8-25>
- Tibshirani, R. (1996). Regression Shrinkage and Selection via the Lasso. In *J. R. Statist. Soc. B* (Vol. 58, Number 1). <https://academic.oup.com/jrsssb/article/58/1/267/7027929>
- Trimono, Maruddani, D. A. I., & Ispriyanti, D. (2017). Pemodelan Harga Saham Dengan Geometric Brownian Motion Dan Value At Risk PT Ciputra Development Tbk. *JURNAL GAUSSIAN*, 6(2), 261–270. <http://ejournal-s1.undip.ac.id/index.php/gaussian>
- Tsay, R. S. (2010). Analysis of Financial Time Series Third Edition. *Financial Analysts Journal*, 62(6). <https://doi.org/10.2469/faj.v62.n6.4360>
- Velásquez-Gaviria, D., Mora-Valencia, A., & Perote, J. (2020). A Comparison of The Risk Quantification in Traditional and Renewable Energy Markets. *Energies*, 13(11). <https://doi.org/10.3390/en13112805>
- Walpole, R., Myers, R., Myers Sharon, & Ye Keying. (2012). *Probability & Statistics for Engineers & Scientists* (Vol. 9).
- Wei, W. (2006). *Time Series Analysis Univariate and Multivariate Methods* (Second Edition). Pearson Education, Inc.
- Wicklin, R. (2021). *The Moving Block Bootstrap for Time Series*. SAS Blogs. <https://blogs.sas.com/content/iml/2021/01/13/moving-block-bootstrap-sas.html>
- Yu, K., Chen, C. W. S., Reed, C., & Dunson, D. B. (2013). Bayesian Variable Selection in Quantile Regression. In *Statistics and Its Interface* (Vol. 6).

LAMPIRAN

Lampiran 1 Data Harga Penutupan 10 Saham Sektor Industri

Tanggal	ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	HEXA	TOTO	MARK
03/07/2023	6825	380	23050	575	1430	171	890	5950	232	620
04/07/2023	6775	370	23100	680	1395	168	895	6150	234	610
05/07/2023	6775	368	23700	715	1500	163	910	6075	236	650
06/07/2023	6800	360	24050	675	1520	145	910	6200	236	640
07/07/2023	6825	360	23750	755	1515	143	910	6200	234	625
10/07/2023	6775	356	24100	645	1490	139	920	6375	242	645
11/07/2023	6800	348	24475	580	1495	144	925	6325	242	650
12/07/2023	6775	344	24000	630	1500	146	920	6350	238	645
13/07/2023	6800	340	24150	775	1505	147	915	6275	240	640
14/07/2023	6750	334	24150	755	1485	146	905	6325	240	660
17/07/2023	6675	336	24225	785	1485	142	905	6375	240	690
18/07/2023	6575	336	24250	715	1495	140	910	6325	240	685
20/07/2023	6525	346	24375	670	1540	142	920	6350	238	645
21/07/2023	6450	340	24500	675	1545	143	925	6400	240	670
24/07/2023	6550	342	25400	655	1480	143	925	6425	240	650
25/07/2023	6500	336	25400	635	1430	145	925	6525	238	675
26/07/2023	6600	336	26400	645	1415	146	925	6600	240	670
27/07/2023	6525	336	26375	615	1385	144	900	6575	238	660
28/07/2023	6625	338	26650	640	1325	143	830	6500	234	615
31/07/2023	6850	336	27525	630	1340	146	845	6700	232	635
01/08/2023	6875	340	27525	685	1370	148	810	6650	232	630
02/08/2023	6850	340	26725	665	1395	147	835	6625	232	620
03/08/2023	6825	344	27150	670	1395	149	835	6625	232	595
04/08/2023	6800	344	27325	660	1400	151	830	6675	230	595
07/08/2023	6875	344	27425	630	1400	153	825	6675	232	605
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
28/11/2025	6550	3150	28000	630	10000	482	535	4570	274	845
01/12/2025	6375	3100	27975	600	10000	498	540	4560	272	860
02/12/2025	6625	3230	28525	605	10000	424	535	4550	268	845
03/12/2025	6600	3180	28700	605	10000	412	535	4520	274	865
04/12/2025	6725	3440	30675	615	10000	412	535	4560	278	845
05/12/2025	6700	3790	30850	620	10000	410	535	4540	276	825
08/12/2025	6725	3800	29350	615	10000	410	540	4530	276	835
09/12/2025	6600	3740	29500	605	10000	414	540	4480	276	820
10/12/2025	6625	3670	30000	610	9000	406	535	4440	280	775
11/12/2025	6450	3780	29425	585	8100	400	535	4400	276	745
12/12/2025	6600	3680	28875	565	8900	360	535	4330	274	800
15/12/2025	6600	3620	28350	570	9775	360	535	4230	274	770
16/12/2025	6600	3670	28150	560	9700	378	540	4230	272	785
17/12/2025	6600	3740	28050	570	9200	332	540	4240	274	805
18/12/2025	6500	3700	28975	550	8900	332	540	4240	272	800
19/12/2025	6525	3640	29800	565	9775	334	535	4220	272	795
22/12/2025	6575	3630	29975	555	10750	348	535	4170	270	825
23/12/2025	6500	3940	29800	560	11825	350	525	4290	270	810
24/12/2025	6625	3840	29650	560	13000	364	525	4330	270	820
29/12/2025	6675	4020	29600	560	14300	354	525	4340	270	825
30/12/2025	6700	3930	29500	545	14500	362	530	4300	272	825

Lampiran 2 Data Return 10 Saham Sektor Industri

Tanggal	ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	HEXA	TOTO	MARK
04/07/2023	-0,0073	-0,0263	0,0022	0,1826	-0,0245	-0,0175	0,0056	0,0336	0,0086	-0,0161
05/07/2023	0,0000	-0,0054	0,0260	0,0515	0,0753	-0,0298	0,0168	-0,0122	0,0085	0,0656
06/07/2023	0,0037	-0,0217	0,0148	-0,0559	0,0133	-0,1104	0,0000	0,0206	0,0000	-0,0154
07/07/2023	0,0037	0,0000	-0,0125	0,1185	-0,0033	-0,0138	0,0000	0,0000	-0,0085	-0,0234
10/07/2023	-0,0073	-0,0111	0,0147	-0,1457	-0,0165	-0,0280	0,0110	0,0282	0,0342	0,0320
11/07/2023	0,0037	-0,0225	0,0156	-0,1008	0,0034	0,0360	0,0054	-0,0078	0,0000	0,0078
12/07/2023	-0,0037	-0,0115	-0,0194	0,0862	0,0033	0,0139	-0,0054	0,0040	-0,0165	-0,0077
13/07/2023	0,0037	-0,0116	0,0063	0,2302	0,0033	0,0068	-0,0054	-0,0118	0,0084	-0,0078
14/07/2023	-0,0074	-0,0176	0,0000	-0,0258	-0,0133	-0,0068	-0,0109	0,0080	0,0000	0,0313
17/07/2023	-0,0111	0,0060	0,0031	0,0397	0,0000	-0,0274	0,0000	0,0079	0,0000	0,0455
18/07/2023	-0,0150	0,0000	0,0010	-0,0892	0,0067	-0,0141	0,0055	-0,0078	0,0000	-0,0072
20/07/2023	-0,0076	0,0298	0,0052	-0,0629	0,0301	0,0143	0,0110	0,0040	-0,0083	-0,0584
21/07/2023	-0,0115	-0,0173	0,0051	0,0075	0,0032	0,0070	0,0054	0,0079	0,0084	0,0388
24/07/2023	0,0155	0,0059	0,0367	-0,0296	-0,0421	0,0000	0,0000	0,0039	0,0000	-0,0299
25/07/2023	-0,0076	-0,0175	0,0000	-0,0305	-0,0338	0,0140	0,0000	0,0156	-0,0083	0,0385
26/07/2023	0,0154	0,0000	0,0394	0,0157	-0,0105	0,0069	0,0000	0,0115	0,0084	-0,0074
27/07/2023	-0,0114	0,0000	-0,0009	-0,0465	-0,0212	-0,0137	-0,0270	-0,0038	-0,0083	-0,0149
28/07/2023	0,0153	0,0060	0,0104	0,0407	-0,0433	-0,0069	-0,0778	-0,0114	-0,0168	-0,0682
31/07/2023	0,0340	-0,0059	0,0328	-0,0156	0,0113	0,0210	0,0181	0,0308	-0,0085	0,0325
01/08/2023	0,0036	0,0119	0,0000	0,0873	0,0224	0,0137	-0,0414	-0,0075	0,0000	-0,0079
02/08/2023	-0,0036	0,0000	-0,0291	-0,0292	0,0182	-0,0068	0,0309	-0,0038	0,0000	-0,0159
03/08/2023	-0,0036	0,0118	0,0159	0,0075	0,0000	0,0136	0,0000	0,0000	0,0000	-0,0403
04/08/2023	-0,0037	0,0000	0,0064	-0,0149	0,0036	0,0134	-0,0060	0,0075	-0,0086	0,0000
07/08/2023	0,0110	0,0000	0,0037	-0,0455	0,0000	0,0132	-0,0060	0,0000	0,0087	0,0168
08/08/2023	-0,0036	-0,0116	0,0036	-0,0317	-0,0107	0,0000	-0,0121	0,0075	-0,0086	0,0083
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
28/11/2025	-0,0038	0,0096	-0,0123	-0,0233	0,0000	-0,0282	0,0000	0,0022	0,0000	0,0497
01/12/2025	-0,0267	-0,0159	-0,0009	-0,0476	0,0000	0,0332	0,0093	-0,0022	-0,0073	0,0178
02/12/2025	0,0392	0,0419	0,0197	0,0083	0,0000	-0,1486	-0,0093	-0,0022	-0,0147	-0,0174
03/12/2025	-0,0038	-0,0155	0,0061	0,0000	0,0000	-0,0283	0,0000	-0,0066	0,0224	0,0237
04/12/2025	0,0189	0,0818	0,0688	0,0165	0,0000	0,0000	0,0000	0,0088	0,0146	-0,0231
05/12/2025	-0,0037	0,1017	0,0057	0,0081	0,0000	-0,0049	0,0000	-0,0044	-0,0072	-0,0237
08/12/2025	0,0037	0,0026	-0,0486	-0,0081	0,0000	0,0000	0,0093	-0,0022	0,0000	0,0121
09/12/2025	-0,0186	-0,0158	0,0051	-0,0163	0,0000	0,0098	0,0000	-0,0110	0,0000	-0,0180
10/12/2025	0,0038	-0,0187	0,0169	0,0083	-0,1000	-0,0193	-0,0093	-0,0089	0,0145	-0,0549
11/12/2025	-0,0264	0,0300	-0,0192	-0,0410	-0,1000	-0,0148	0,0000	-0,0090	-0,0143	-0,0387
12/12/2025	0,0233	-0,0265	-0,0187	-0,0342	0,0988	-0,1000	0,0000	-0,0159	-0,0072	0,0738
15/12/2025	0,0000	-0,0163	-0,0182	0,0088	0,0983	0,0000	0,0000	-0,0231	0,0000	-0,0375
16/12/2025	0,0000	0,0138	-0,0071	-0,0175	-0,0077	0,0500	0,0093	0,0000	-0,0073	0,0195
17/12/2025	0,0000	0,0191	-0,0036	0,0179	-0,0515	-0,1217	0,0000	0,0024	0,0074	0,0255
18/12/2025	-0,0152	-0,0107	0,0330	-0,0351	-0,0326	0,0000	0,0000	0,0000	-0,0073	-0,0062
19/12/2025	0,0038	-0,0162	0,0285	0,0273	0,0983	0,0060	-0,0093	-0,0047	0,0000	-0,0063
22/12/2025	0,0077	-0,0027	0,0059	-0,0177	0,0997	0,0419	0,0000	-0,0118	-0,0074	0,0377
23/12/2025	-0,0114	0,0854	-0,0058	0,0090	0,1000	0,0057	-0,0187	0,0288	0,0000	-0,0182
24/12/2025	0,0192	-0,0254	-0,0050	0,0000	0,0994	0,0400	0,0000	0,0093	0,0000	0,0123
29/12/2025	0,0075	0,0469	-0,0017	0,0000	0,1000	-0,0275	0,0000	0,0023	0,0000	0,0061
30/12/2025	0,0037	-0,0224	-0,0034	-0,0268	0,0140	0,0226	0,0095	-0,0092	0,0074	0,0000

Lampiran 3 Syntax Download Data

```
library(quantmod)
library(xts)
# Definisi Periode Penelitian
awal = as.Date("2023-07-03")
akhir = as.Date("2025-12-31")
# Fungsi untuk mengambil data
get_clean_data <- function(symbol) {
  # Ambil data dengan buffer untuk memastikan mendapatkan periode yang diinginkan
  data <- tryCatch({
```

```

getSymbols(symbol, src = 'yahoo', from = awal-5, to = akhir+5, auto.assign = FALSE)
}, error = function(e) {
  message(paste("Error mengambil data", symbol, ":", e$message))
  return (NULL)
})

if (!is.null(data)) {
  # Ambil closing price
  close_data <- Cl(data)

  # Filter hanya periode yang diinginkan
  close_data <- close_data[index(close_data) >= awal & index(close_data) <= akhir]

  return (close_data)
} else {
  return (NULL)
}
}

# Ambil data semua saham
symbols <- c("ASII.JK", "IMPC.JK", "UNTR.JK", "SKRN.JK", "SINI.JK",
             "SMIL.JK", "ARNA.JK", "HEXA.JK", "TOTO.JK", "MARK.JK")
data_list <- list()
for (symbol in symbols) {
  cat("Mengambil data untuk", symbol, "\n")
  data <- get_clean_data(symbol)
  if (!is.null(data)) {
    data_list[[symbol]] <- data
  }
}

# Gabungkan semua data
if (length(data_list) > 0) {
  all_data <- do.call(merge, data_list)

  # HAPUS BARIS DENGAN SEMUA NA (hari libur seperti 18 Agustus 2025)
  # Cek baris yang semua nilainya NA
  all_na_rows <- apply(all_data, 1, function(x) all(is.na(x)))

  # Hapus baris yang semua NA
  all_data_clean <- all_data[!all_na_rows, ]

  # Pastikan kita punya data sampai 30 September
  cat("\nTanggal terakhir dalam data:", as.character(tail(index(all_data_clean), 1)), "\n")

  # Ubah menjadi data frame
  data_saham <- data.frame(
    Tanggal = index(all_data_clean),
    all_data_clean,
    row.names = NULL
  )
}

```

```

# Ganti nama kolom
colnames(data_saham) <- c("Tanggal", gsub(".JK.Close", "", colnames(all_data_clean)))

# Tampilkan hasil
cat("Periode data:", as.character(min(data_saham$Tanggal)), "sampai",
    as.character(max(data_saham$Tanggal)), "\n")
cat("Jumlah observasi:", nrow(data_saham), "\n\n")

# Cek apakah ada tanggal 30 September 2025
if (as.Date("2025-12-31") %in% data_saham$Tanggal) {
  cat("✓ Data untuk 31 Desember 2025 berhasil diambil\n")
} else {
  cat("X Data untuk 31 Desember 2025 TIDAK ditemukan\n")
}

# Cek apakah tanggal 18 Agustus 2025 masih ada
if (as.Date("2025-08-18") %in% data_saham$Tanggal) {
  cat("X Tanggal 18 Agustus 2025 masih ada dalam data\n")
} else {
  cat("✓ Tanggal 18 Agustus 2025 berhasil dihapus\n")
}

print(head(data_saham))
print(tail(data_saham))

} else {
  cat("Tidak ada data yang berhasil diambil\n")
}

```

Lampiran 4 *Syntax Plot Time Series Data Harga Saham*

```

# Visualisasi Pergerakan Harga Saham -----
library(ggplot2)
library(reshape2)
library(RColorBrewer)
library(scales)

colnames(data_saham)[1] <- "Tanggal"
data_long <- melt(data_saham, id.vars = "Tanggal", variable.name = "Saham",
  value.name = "Harga")
# Plot Time Series
warna_plot <- c(
  "ASII" = "#00FFFF",
  "IMPC" = "#FF1493",
  "UNTR" = "#0000FF",
  "SKRN" = "#FFD700",
  "SINI" = "#7FFF00",
  "SMIL" = "#A52A2A",
  "ARNA" = "#FF7F50",
  "HEXA" = "#8A2BE2",

```

```

"TOTO" = "#C700FF",
"MARK" = "#7FFFD4"
)
# Buat plot
ggplot(data_long, aes(x = Tanggal, y = Harga, color = Saham)) +
  geom_line(size = 0.8) +
  scale_color_manual(values = warna_plot) +
  scale_y_continuous(
    labels = scales::comma,
    n.breaks = 10
  ) +
  scale_x_date(
    date_breaks = "3 months",
    date_labels = "%b %Y",
    expand = c(0.02, 0)
  ) +
  labs(
    title = "Pergerakan Harga Saham Sektor Industri",
    subtitle = "Periode Juli 2023 - Desember 2025",
    x = "Tanggal",
    y = "Harga Penutupan (IDR)",
    color = "Kode Saham"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 16, margin = margin(b = 10)),
    plot.subtitle = element_text(hjust = 0.5, size = 12, margin = margin(b = 15)),
    axis.text.x = element_text(angle = 45, hjust = 1, vjust = 1),
    axis.text.y = element_text(size = 10),
    axis.title = element_text(face = "bold"),
    legend.title = element_text(face = "bold", size = 11),
    legend.text = element_text(size = 10),
    legend.position = "bottom",
    legend.key.size = unit(0.8, "lines"),
    panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
    panel.grid.minor = element_blank(),
    plot.margin = margin(15, 15, 15, 15)
  ) +
  guides(color = guide_legend(nrow = 2))

```

Lampiran 5 *Syntax* Perhitungan Data Return Saham

```

## Function Return Saham
rett <- function(x) {
  x <- na.omit(as.numeric(x))
  if (length(x) < 2) return (rep(NA, length(x)))
  a <- rep(0, length(x))
  for (i in 2:length(x)) {
    a[i] <- (x[i] - x[i-1]) / x[i-1]
  }
}

```

```

return (a[-1])
}

# Hitung return untuk semua saham
r_ASII <- rett(data_saham$ASII)
r_IMPC <- rett(data_saham$IMPC)
r_UNTR <- rett(data_saham$UNTR)
r_SKRN <- rett(data_saham$SKRN)
r_SINI <- rett(data_saham$SINI)
r_SMIL <- rett(data_saham$SMIL)
r_ARNA <- rett(data_saham$ARNA)
r_HEXAX <- rett(data_saham$HEXA)
r_TOTO <- rett(data_saham$TOTO)
r_MARK <- rett(data_saham$MARK)

# Cari panjang terpendek agar seragam
min_len <- min(
  length(r_ASII), length(r_IMPC), length(r_UNTR), length(r_SKRN),length(r_SINI),
  length(r_SMIL), length(r_ARNA), length(r_HEXAX),length(r_TOTO), length(r_MARK)
)
# Ambil tanggal sesuai panjang return
tanggal_return <- data_saham$Tanggal[-1] # hapus hari pertama (karena diff)
tanggal_return <- tail(tanggal_return , min_len)

## Buat Data Frame Return -----
return_df <- data.frame(
  Tanggal = as.Date(tanggal_return ),
  ASII = tail(r_ASII, min_len),
  IMPC = tail(r_IMPC, min_len),
  UNTR = tail(r_UNTR, min_len),
  SKRN = tail(r_SKRN, min_len),
  SINI = tail(r_SINI, min_len),
  SMIL = tail(r_SMIL, min_len),
  ARNA = tail(r_ARNA, min_len),
  HEXA = tail(r_HEXAX, min_len),
  TOTO = tail(r_TOTO, min_len),
  MARK = tail(r_MARK, min_len)
)
head(return_df)

```

Lampiran 6 *Syntax Plot Time Series Data Return Saham*

```

# Transformasi Data Return ke Format Long
library(dplyr)
library(tidyr)

return_long <- return_df %>%
  pivot_longer(-Tanggal, names_to = "Saham", values_to = "Return") # PERBAIKAN:
  hapus spasi di "Return "

```

```

# Return semua emiten digabung
all_returns_global <- unlist(return_df[, -1]) # semua kolom kecuali Tanggal
ymin <- min(all_returns_global, na.rm = TRUE)
ymax <- max(all_returns_global, na.rm = TRUE)

# Fungsi untuk plot return per saham
plot_return_per_saham <- function(kode_saham) {
  return_long_filtered <- return_long %>% filter(Saham == kode_saham)

  p <- ggplot(return_long_filtered, aes(x = Tanggal, y = Return)) +
    geom_line(color = warna_plot[kode_saham], linewidth = 0.8) + # PERBAIKAN: size ->
    linewidth
    geom_hline(yintercept = 0, linetype = "dashed", color = "red", alpha = 0.7) +
    scale_x_date(
      date_breaks = "3 months",
      date_labels = "%b %Y",
      expand = c(0.02, 0)
    ) +
    scale_y_continuous(
      labels = scales::percent
    ) +
    coord_cartesian(ylim = c(ymin, ymax)) +
    labs(title = paste("Return Harian", kode_saham),
         subtitle = "Periode Juli 2023 - Desember 2025",
         x = "Tanggal",
         y = "Return Harian"
    ) +
    theme_minimal(base_size = 12) +
    theme(
      plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
      plot.subtitle = element_text(hjust = 0.5, size = 10, margin = margin(b = 10)),
      axis.text.x = element_text(angle = 45, hjust = 1),
      axis.title = element_text(face = "bold"),
      panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
      panel.grid.minor = element_blank()
    )

  print(p)
  return(p)
}

# Menampilkan plot return untuk tiap saham
plot_return_per_saham("ASII")
plot_return_per_saham("IMPC")
plot_return_per_saham("UNTR")
plot_return_per_saham("SKRN")
plot_return_per_saham("SINI")
plot_return_per_saham("SMIL")
plot_return_per_saham("ARNA")

```

```
plot_return_per_saham("HEXA")
plot_return_per_saham("TOTO")
plot_return_per_saham("MARK")
```

Lampiran 7 *Syntax* Statistika Deskriptif Data *Return* Saham

```
# Buat dataframe return saja (tanpa tanggal)
rets <- return_df[, -1] # buang kolom Tanggal
# Statistika Deskriptif Return Saham
library(moments)
statdes <- sapply(rets, function(x) {
  c(
    Observasi = length(na.omit(x)),
    Mean = mean(x, na.rm = TRUE),
    StDev = sd(x, na.rm = TRUE),
    Variance = var(x, na.rm = TRUE),
    Minimum = min(x, na.rm = TRUE),
    Maximum = max(x, na.rm = TRUE),
    Range = max(x, na.rm = TRUE) - min(x, na.rm = TRUE),
    Skewness = skewness(x, na.rm = TRUE),
    Kurtosis = kurtosis(x, na.rm = TRUE))
})
statdes_tabel <- as.data.frame(t(statdes))
statdes_tabel <- round(statdes_tabel, 4)
statdes_tabel <- tibble::rownames_to_column(statdes_tabel, var = "Saham")

print(statdes_tabel)
```

Lampiran 8 *Syntax* *Boxplot* Data *Return* Saham

```
ggplot(return_long, aes(x = Saham, y = Return, fill = Saham)) +
  geom_boxplot(
    outlier.shape = 21,
    outlier.size = 1,
    outlier.fill = "darkgray",
    outlier.color = "black",
    color = "black",
    alpha = 0.8
  ) +
  scale_fill_manual(values = warna_plot) + # Menggunakan warna yang sama dengan plot
  sebelumnya
  scale_y_continuous(
    labels = scales::percent # Format persentase untuk return
  ) +
  labs(
    title = "Boxplot Return Saham Sektor Industri",
    subtitle = "Periode Juli 2023 - Desember 2025",
    x = "Kode Saham",
    y = "Return Harian"
  ) +
  theme_minimal(base_size = 12) +
```

```

theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  plot.subtitle = element_text(hjust = 0.5, size = 10, margin = margin(b = 10)),
  axis.text.x = element_text(angle = 45, hjust = 1, face = "bold"),
  axis.title = element_text(face = "bold"),
  legend.position = "none",
  panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
  panel.grid.minor = element_blank()
) +
geom_hline(yintercept = 0, linetype = "dashed", color = "blue", alpha = 0.5)

```

Lampiran 9 *Syntax Uji Stasioneritas dalam Mean*

```

## Stasioneritas dalam Mean (ADF test) -----
library(tseries)
hasil_adf <- lapply(rets, function(x) {
  adf.test(na.omit(x))
})
for (i in 1:length(hasil_adf)) {
  cat("\n=====\\n")
  cat("Hasil ADF untuk:", names(return_df)[i+1], "\\n")
  print(hasil_adf[[i]])
}
# Ringkasan dalam tabel
p_values <- sapply(rets, function(x) {
  adf.test(na.omit(x))$p.value
})
df_stats <- sapply(hasil_adf, function(res) as.numeric(res$statistic))
tabel_adf <- data.frame(
  Saham = names(p_values),
  DF_stat = round(df_stats, 4),
  p_value = round(p_values, 5),
  Keputusan = ifelse(p_values < 0.05,
    "Tolak H0",
    "Gagal Tolak H0"),
  Kesimpulan = ifelse(p_values < 0.05,
    "Stasioner",
    "Tidak Stasioner")
)
print(tabel_adf)

```

Lampiran 10 *Syntax Uji Stasioneritas dalam Varians*

```

## Stasioneritas dalam Varians (Box-Cox Transformation) -----
library(MASS) # untuk fungsi boxcox()
library(forecast) # untuk BoxCox.lambda()

# Inisialisasi tabel hasil
tabel_boxcox <- data.frame(
  Saham = character(),
  Lambda = numeric(),

```

```

CI_Lower = numeric(),
CI_Upper = numeric(),
Keputusan = character(),
Kesimpulan = character(),
stringsAsFactors = FALSE
)

for (nm in names(rets)) {
  x <- na.omit(rets[[nm]])

  # Gunakan return kuadrat (proksi volatilitas) untuk uji stasioneritas dalam varians
  x <- x^2

  # Return kuadrat selalu >= 0, tambahkan konstanta kecil agar semua nilai positif (syarat Box-Cox)
  shift <- ifelse(min(x) <= 0, abs(min(x)) + 1e-10, 0)
  x_pos <- x + shift

  # Estimasi lambda optimal menggunakan MASS::boxcox
  bc <- boxcox(x_pos ~ 1, lambda = seq(-3, 3, by = 0.01), plotit = FALSE)

  # Lambda optimal = nilai lambda dengan log-likelihood tertinggi
  lambda_opt <- bc$x[which.max(bc$y)]

  # Confidence interval lambda (di mana log-likelihood >= max - qchisq/2)
  ci_idx <- bc$y >= max(bc$y) - qchisq(0.95, 1) / 2
  ci_lower <- min(bc$x[ci_idx])
  ci_upper <- max(bc$x[ci_idx])

  # Keputusan:  $\lambda = 1$  ada di dalam CI  $\rightarrow$  stasioner dalam varians
  stasioner_var <- (ci_lower <= 1 & 1 <= ci_upper)
  keputusan <- ifelse(stasioner_var, "Tolak H0", "Gagal Tolak H0")
  kesimpulan <- ifelse(stasioner_var,
    "Stasioner dalam Varians",
    "Tidak Stasioner dalam Varians")

  tabel_boxcox <- rbind(tabel_boxcox, data.frame(
    Saham = nm,
    Lambda = round(lambda_opt, 4),
    CI_Lower = round(ci_lower, 4),
    CI_Upper = round(ci_upper, 4),
    Keputusan = keputusan,
    Kesimpulan = kesimpulan,
    stringsAsFactors = FALSE
  ))

  cat("Saham:", nm, "(Return Kuadrat)\n")
  cat(" Lambda optimal : ", round(lambda_opt, 4), "\n")
  cat(" 95% CI lambda : [", round(ci_lower, 4), ", ", round(ci_upper, 4), "]\n")
  cat("  $\lambda = 1$  dalam CI? : ", ifelse(stasioner_var, "Ya", "Tidak"), "\n")
}

```

```

cat(" Keputusan      :", keputusan, "\n")
cat(" Kesimpulan      :", kesimpulan, "\n\n")
}

cat("\n--- Ringkasan Uji Stasioneritas dalam Varians (Box-Cox, data: Return Kuadrat) ---\n")
print(tabel_boxcox, row.names = FALSE)

```

Lampiran 11 Hasil Uji Stasioneritas dalam Varians

Saham	Lambda	CI_lower	CI_upper	Keputusan	Kesimpulan
ASII	0,20	0,19	0,22	Gagal Tolak H_0	Tidak Stasioner
IMPC	0,12	0,11	0,13	Gagal Tolak H_0	Tidak Stasioner
UNTR	0,17	0,16	0,19	Gagal Tolak H_0	Tidak Stasioner
SKRN	0,13	0,12	0,14	Gagal Tolak H_0	Tidak Stasioner
SINI	0,12	0,11	0,13	Gagal Tolak H_0	Tidak Stasioner
SMIL	0,15	0,14	0,16	Gagal Tolak H_0	Tidak Stasioner
ARNA	0,05	0,04	0,07	Gagal Tolak H_0	Tidak Stasioner
HEXA	0,15	0,14	0,16	Gagal Tolak H_0	Tidak Stasioner
TOTO	0,07	0,06	0,08	Gagal Tolak H_0	Tidak Stasioner
MARK	0,19	0,18	0,21	Gagal Tolak H_0	Tidak Stasioner

Lampiran 12 Syntax Plot ACF dan PACF Data Return Saham

```

all_acf_values <- c()
all_pacf_values <- c()

for(nm in names(rets)) {
  seri <- na.omit(rets[[nm]])

  # Hitung ACF dan PACF tanpa plot
  acf_result <- acf(seri, lag.max = 25, plot = FALSE)
  pacf_result <- pacf(seri, lag.max = 25, plot = FALSE)

  # Kumpulkan semua nilai
  all_acf_values <- c(all_acf_values, acf_result$acf)
  all_pacf_values <- c(all_pacf_values, pacf_result$acf)
}

# Tentukan ylim yang sama untuk semua plot
ylim_acf <- c(min(all_acf_values), max(all_acf_values))
ylim_pacf <- c(min(all_pacf_values), max(all_pacf_values))

# Atau gunakan ylim yang simetris (lebih umum untuk ACF/PACF)
max_abs_acf <- max(abs(all_acf_values))
max_abs_pacf <- max(abs(all_pacf_values))
ylim_acf <- c(-max_abs_acf, max_abs_acf)
ylim_pacf <- c(-max_abs_pacf, max_abs_pacf)

# Plot ACF dan PACF
par(mfrow = c(1, 2))

```

```

for(nm in names(rets)) {
  seri <- na.omit(rets[[nm]])

  # Plot ACF
  acf(seri,
      main = paste("ACF Return", nm),
      lag.max = 30,
      ylim = ylim_acf)

  # Plot PACF
  pacf(seri,
      main = paste("PACF Return", nm),
      lag.max = 30,
      ylim = ylim_pacf)
}

```

Lampiran 13 Syntax Pemodelan AR

```

#### Model AR ASII -----
# Fit Model
model_arASII1T <- arima(rets$ASII, order = c(1,0,0), include.mean = TRUE);
model_arASII1T
model_arASII2T <- arima(rets$ASII, order = c(2,0,0), include.mean = TRUE);
model_arASII2T
model_arASII1F <- arima(rets$ASII, order = c(1,0,0), include.mean = FALSE);
model_arASII1F
model_arASII2F <- arima(rets$ASII, order = c(2,0,0), include.mean = FALSE);
model_arASII2F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arASII1T), 4) # signifikan AR(1)
round(coeftest(model_arASII2T), 4) # signifikan AR(1) AR(2)
round(coeftest(model_arASII1F), 4) # signifikan
round(coeftest(model_arASII2F), 4) # signifikan
# Diagnostic Check model AR
res_ASII1T <- model_arASII1T$residuals
res_ASII2T <- model_arASII2T$residuals
res_ASII1F <- model_arASII1F$residuals
res_ASII2F <- model_arASII2F$residuals
# Uji White Noise
Box.test(res_ASII1T, type = "Ljung-Box") # White Noise
Box.test(res_ASII2T, type = "Ljung-Box") # White Noise
Box.test(res_ASII1F, type = "Ljung-Box") # White Noise
Box.test(res_ASII2F, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arASII1F)
AIC(model_arASII2F) #INI
# ARCH - LM Test
library(FinTS)

```

```

ArchTest(res_ASII2F) # gada ada efek ARCH

### Model AR IMPC -----
# Fit Model
model_arIMPC2T <- arima(rets$IMPC, order = c(2,0,0), include.mean = TRUE);
model_arIMPC2T
model_arIMPC2F <- arima(rets$IMPC, order = c(2,0,0), include.mean = FALSE);
model_arIMPC2F
model_arIMPC2SST <- arima(rets$IMPC, order = c(2,0,0), fixed = c(0, NA,
NA), include.mean = TRUE);
model_arIMPC2SST # (AR1, AR2, mu)
model_arIMPC2SSF <- arima(rets$IMPC, order = c(2,0,0), fixed = c(0, NA), include.mean
= FALSE);
model_arIMPC2SSF # (AR1, AR2)
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arIMPC2T), 4) # signifikan AR(2) mean
round(coeftest(model_arIMPC2F), 4) # signifikan AR(2)
round(coeftest(model_arIMPC2SST), 4) # signifikan
round(coeftest(model_arIMPC2SSF), 4) ##ini ttp pake ga ya? soalnya subset w/intercept
signifikan semua
# Diagnostic Check model AR
res_IMPC2T <- model_arIMPC2T$residuals
res_IMPC2F <- model_arIMPC2F$residuals
res_IMPC2SST <- model_arIMPC2SST$residuals
res_IMPC2SSF <- model_arIMPC2SSF$residuals
# Uji White Noise
Box.test(res_IMPC2T, type = "Ljung-Box") # White Noise
Box.test(res_IMPC2F, type = "Ljung-Box") # White Noise
Box.test(res_IMPC2SST, type = "Ljung-Box") # White Noise
Box.test(res_IMPC2SSF, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arIMPC2T)
AIC(model_arIMPC2F)
AIC(model_arIMPC2SST) #INI
AIC(model_arIMPC2SSF)
# ARCH - LM Test
library(FinTS)
ArchTest(res_IMPC2SST) # ADA efek ARCH

### Model AR UNTR -----
# Fit Model
model_arUNTR2T <- arima(rets$UNTR, order = c(2,0,0), include.mean = TRUE);
model_arUNTR2T
model_arUNTR2F <- arima(rets$UNTR, order = c(2,0,0), include.mean = FALSE);
model_arUNTR2F
model_arUNTR2SST <- arima(rets$UNTR, order = c(2,0,0), fixed = c(0, NA,
NA), include.mean = TRUE);
model_arUNTR2SST # (AR1, AR2, mu)

```

```

model_arUNTR2SSF <- arima(rets$UNTR, order = c(2,0,0), fixed = c(0, NA), include.mean
= FALSE);
model_arUNTR2SSF # (AR1, AR2)
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arUNTR2T), 4) # signifikan AR(2)
round(coeftest(model_arUNTR2F), 4) # signifikan AR(2)
round(coeftest(model_arUNTR2SST), 4) # signifikan AR(2)
round(coeftest(model_arUNTR2SSF), 4) # signifikan
# Diagnostic Check model AR
res_UNTR2T <- model_arUNTR2T$residuals
res_UNTR2F <- model_arUNTR2F$residuals
res_UNTR2SST <- model_arUNTR2SST$residuals
res_UNTR2SSF <- model_arUNTR2SSF$residuals
# Uji White Noise
Box.test(res_UNTR2T, type = "Ljung-Box") # White Noise
Box.test(res_UNTR2F, type = "Ljung-Box") # White Noise
Box.test(res_UNTR2SST, type = "Ljung-Box") # White Noise
Box.test(res_UNTR2SSF, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arUNTR2T)
AIC(model_arUNTR2F)
AIC(model_arUNTR2SST)
AIC(model_arUNTR2SSF) #INI
# ARCH - LM Test
library(FinTS)
ArchTest(res_UNTR2SSF) # gaada efek ARCH

#### Model AR SKRN -----
# Fit Model
model_arSKRN1T <- arima(rets$SKRN, order = c(1,0,0), include.mean = TRUE);
model_arSKRN1T
model_arSKRN2T <- arima(rets$SKRN, order = c(2,0,0), include.mean = TRUE);
model_arSKRN2T
model_arSKRN1F <- arima(rets$SKRN, order = c(1,0,0), include.mean = FALSE);
model_arSKRN1F
model_arSKRN2F <- arima(rets$SKRN, order = c(2,0,0), include.mean = FALSE);
model_arSKRN2F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arSKRN1T), 4) # ga signifikan
round(coeftest(model_arSKRN2T), 4) # ga signifikan
round(coeftest(model_arSKRN1F), 4) # ga signifikan
round(coeftest(model_arSKRN2F), 4) # ga signifikan
# ARCH - LM Test
library(FinTS)
ArchTest(rets$SKRN) # ADA efek ARCH

#### Model AR SINI -----

```

```

# Fit Model
model_arSINI1T <- arima(rets$SINI, order = c(1,0,0), include.mean = TRUE);
model_arSINI1T
model_arSINI1F <- arima(rets$SINI, order = c(1,0,0), include.mean = FALSE);
model_arSINI1F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arSINI1T), 4) # signifikan AR(1)
round(coeftest(model_arSINI1F), 4) # signifikan
# Diagnostic Check model AR
res_SINI1T <- model_arSINI1T$residuals
res_SINI1F <- model_arSINI1F$residuals
# Uji White Noise
Box.test(res_SINI1T, type = "Ljung-Box") # White Noise
Box.test(res_SINI1F, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arSINI1T)
AIC(model_arSINI1F) #INI
# ARCH - LM Test
library(FinTS)
ArchTest(res_SINI1F) #ADA efek ARCH

### Model AR SMIL -----
# Fit Model
model_arSMIL1T <- arima(rets$SMIL, order = c(1,0,0), include.mean = TRUE);
model_arSMIL1T
model_arSMIL1F <- arima(rets$SMIL, order = c(1,0,0), include.mean = FALSE);
model_arSMIL1F
model_arSMIL2T <- arima(rets$SMIL, order = c(2,0,0), include.mean = TRUE);
model_arSMIL2T
model_arSMIL2F <- arima(rets$SMIL, order = c(2,0,0), include.mean = FALSE);
model_arSMIL2F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arSMIL1T), 4) # signifikan AR(1)
round(coeftest(model_arSMIL1F), 4) # signifikan
round(coeftest(model_arSMIL2T), 4) # signifikan AR(1)
round(coeftest(model_arSMIL2F), 4) # signifikan AR(1)
# Diagnostic Check model AR
res_SMIL1T <- model_arSMIL1T$residuals
res_SMIL1F <- model_arSMIL1F$residuals
res_SMIL2T <- model_arSMIL2T$residuals
res_SMIL2F <- model_arSMIL2F$residuals
# Uji White Noise
Box.test(res_SMIL1T, type = "Ljung-Box") # White Noise
Box.test(res_SMIL1F, type = "Ljung-Box") # White Noise
Box.test(res_SMIL2T, type = "Ljung-Box") # White Noise
Box.test(res_SMIL2F, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC

```

```

AIC(model_arSMIL1T)
AIC(model_arSMIL1F) #INI
AIC(model_arSMIL2T)
AIC(model_arSMIL2F)
# ARCH - LM Test
library(FinTS)
ArchTest(res_SMIL1F) #ADA efek ARCH

#### Model AR ARNA -----
# Fit Model
model_arARNA1T <- arima(rets$ARNA, order = c(1,0,0), include.mean = TRUE);
model_arARNA1T
model_arARNA1F <- arima(rets$ARNA, order = c(1,0,0), include.mean = FALSE);
model_arARNA1F
model_arARNA2T <- arima(rets$ARNA, order = c(2,0,0), include.mean = TRUE);
model_arARNA2T
model_arARNA2F <- arima(rets$ARNA, order = c(2,0,0), include.mean = FALSE);
model_arARNA2F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arARNA1T), 4) # ga signifikan
round(coeftest(model_arARNA1F), 4) # ga signifikan
round(coeftest(model_arARNA2T), 4) # ga signifikan
round(coeftest(model_arARNA2F), 4) # ga signifikan
# ARCH - LM Test
library(FinTS)
ArchTest(rets$ARNA) #ADA efek ARCH

#### Model AR HEXA -----
# Fit Model
model_arHEXA1T <- arima(rets$HEXA, order = c(1,0,0), include.mean = TRUE);
model_arHEXA1T
model_arHEXA1F <- arima(rets$HEXA, order = c(1,0,0), include.mean = FALSE);
model_arHEXA1F
model_arHEXA2T <- arima(rets$HEXA, order = c(2,0,0), include.mean = TRUE);
model_arHEXA2T
model_arHEXA2F <- arima(rets$HEXA, order = c(2,0,0), include.mean = FALSE);
model_arHEXA2F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arHEXA1T), 4) # ga signifikan
round(coeftest(model_arHEXA1F), 4) # ga signifikan
round(coeftest(model_arHEXA2T), 4) # ga signifikan
round(coeftest(model_arHEXA2F), 4) # ga signifikan
# ARCH - LM Test
library(FinTS)
ArchTest(rets$HEXA) #gaada efek ARCH

# Karena tidak ada AR dan efek ARCH,

```

```
# maka model VaRnya nanti hanya invers CDF dari distribusi normal dengan  $\mu = \bar{x}$ 
return dan  $\sigma^2 = s^2$  return
```

```
### Model AR TOTO -----
# Fit Model
model_arTOTO1T <- arima(rets$TOTO, order = c(1,0,0), include.mean = TRUE);
model_arTOTO1T
model_arTOTO1F <- arima(rets$TOTO, order = c(1,0,0), include.mean = FALSE);
model_arTOTO1F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arTOTO1T), 4) # signifikan AR(1)
round(coeftest(model_arTOTO1F), 4) # signifikan
# Diagnostic Check model AR
res_TOTO1T <- model_arTOTO1T$residuals
res_TOTO1F <- model_arTOTO1F$residuals
# Uji White Noise
Box.test(res_TOTO1T, type = "Ljung-Box") # White Noise
Box.test(res_TOTO1F, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arTOTO1T)
AIC(model_arTOTO1F) #INI
# ARCH - LM Test
library(FinTS)
ArchTest(res_TOTO1F) #gaada efek ARCH

### Model AR MARK -----
# Fit Model
model_arMARK1T <- arima(rets$MARK, order = c(1,0,0), include.mean = TRUE);
model_arMARK1T
model_arMARK1F <- arima(rets$MARK, order = c(1,0,0), include.mean = FALSE);
model_arMARK1F
# Cek Signifikansi Parameter
library(lmtest)
round(coeftest(model_arMARK1T), 4) # signifikan AR(1)
round(coeftest(model_arMARK1F), 4) # signifikan
# Diagnostic Check model AR
res_MARK1T <- model_arMARK1T$residuals
res_MARK1F <- model_arMARK1F$residuals
# Uji White Noise
Box.test(res_MARK1T, type = "Ljung-Box") # White Noise
Box.test(res_MARK1F, type = "Ljung-Box") # White Noise
# Pemilihan model terbaik berdasarkan kriteria AIC
AIC(model_arMARK1T)
AIC(model_arMARK1F) #INI
# ARCH - LM Test
library(FinTS)
ArchTest(res_MARK1F) #ADA efek ARCH
```

Lampiran 14 Syntax Ringkasan Uji Lagrange Multiplier

```
arch_results <- list(
  ASII = ArchTest(res_ASII2F),
  IMPC = ArchTest(res_IMPC2SST),
  UNTR = ArchTest(res_UNTR2SSF),
  SKRN = ArchTest(rets$SKRN),
  SINI = ArchTest(res_SINI1F),
  SMIL = ArchTest(res_SMIL1F),
  ARNA = ArchTest(rets$ARNA),
  HEXA = ArchTest(rets$HEXA),
  TOTO = ArchTest(res_TOTO1F),
  MARK = ArchTest(res_MARK1F)
)

arch_summary <- do.call(rbind, lapply(names(arch_results), function(x) {
  data.frame(
    Emiten = x,
    Chi_Sq = round(arch_results[[x]]$statistic, 4),
    P_Value = round(arch_results[[x]]$p.value, 4),
    Kesimpulan = ifelse(arch_results[[x]]$p.value < 0.05, "Ada Efek ARCH *", "Tidak Ada
Efek ARCH"),
    row.names = NULL
  )
}))
print(arch_summary)
```

Lampiran 15 Syntax Pemodelan GARCH

```
### Function Model GARCH -----
library(rugarch)
### AR(0) include mean -----
spec_garchT_01 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(0,1)),
  mean.model = list(armaOrder = c(0,0), include.mean = TRUE), # AR(0)
  distribution.model = "sstd"
)
spec_garchT_10 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,0)),
  mean.model = list(armaOrder = c(0,0), include.mean = TRUE), # AR(0)
  distribution.model = "sstd"
)
spec_garchT_11 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,1)),
  mean.model = list(armaOrder = c(0,0), include.mean = TRUE), # AR(0)
  distribution.model = "sstd"
)
### AR(0) tidak include mean -----
spec_garchF_01 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(0,1)),
  mean.model = list(armaOrder = c(0,0), include.mean = FALSE), # AR(0)
```

```

distribution.model = "sstd"
)
spec_garchF_10 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,0)),
  mean.model = list(armaOrder = c(0,0), include.mean = FALSE), # AR(0)
  distribution.model = "sstd"
)
spec_garchF_11 <- ugarchspec(
  variance.model = list(model = "sGARCH", garchOrder = c(1,1)),
  mean.model = list(armaOrder = c(0,0), include.mean = FALSE),
  distribution.model = "sstd"
)

### Model GARCH IMPC -----
model_garchIMPC10 <- ugarchfit(spec = spec_garchT_10, data = res_IMPC2SST);
model_garchIMPC10
model_garchIMPC01 <- ugarchfit(spec = spec_garchT_01, data = res_IMPC2SST);
model_garchIMPC01
model_garchIMPC11 <- ugarchfit(spec = spec_garchT_11, data = res_IMPC2SST);
model_garchIMPC11

### Model GARCH SKRN -----
model_garchSKRN10 <- ugarchfit(spec = spec_garchT_10, data = rets$SKRN);
model_garchSKRN10
model_garchSKRN01 <- ugarchfit(spec = spec_garchT_01, data = rets$SKRN);
model_garchSKRN01
model_garchSKRN11 <- ugarchfit(spec = spec_garchT_11, data = rets$SKRN);
model_garchSKRN11

### Model GARCH SINI -----
model_garchSINI10 <- ugarchfit(spec = spec_garchT_10, data = res_SINI1F);
model_garchSINI10
model_garchSINI01 <- ugarchfit(spec = spec_garchT_01, data = res_SINI1F);
model_garchSINI01
model_garchSINI11 <- ugarchfit(spec = spec_garchT_11, data = res_SINI1F);
model_garchSINI11

### Model GARCH SMIL -----
model_garchSMIL10 <- ugarchfit(spec = spec_garchT_10, data = res_SMIL1F);
model_garchSMIL10
model_garchSMIL01 <- ugarchfit(spec = spec_garchT_01, data = res_SMIL1F);
model_garchSMIL01
model_garchSMIL11 <- ugarchfit(spec = spec_garchT_11, data = res_SMIL1F);
model_garchSMIL11

### Model GARCH ARNA -----
model_garchARNA10 <- ugarchfit(spec = spec_garchT_10, data = rets$ARNA);
model_garchARNA10
model_garchARNA01 <- ugarchfit(spec = spec_garchT_01, data = rets$ARNA);

```

```

model_garchARNA01
model_garchARNA11 <- ugarchfit(spec = spec_garchT_11, data = rets$ARNA);
model_garchARNA11

#### Model GARCH MARK -----
model_garchMARK10 <- ugarchfit(spec = spec_garchT_10, data = res_MARK1F);
model_garchMARK10
model_garchMARK01 <- ugarchfit(spec = spec_garchT_01, data = res_MARK1F);
model_garchMARK01
model_garchMARK11 <- ugarchfit(spec = spec_garchT_11, data = res_MARK1F);
model_garchMARK11

```

Lampiran 16 *Syntax* Estimasi VaR dengan AR-GARCH

```

res = data.frame(
  ASII = res_ASII2F,
  IMPC = res_IMPC2SST,
  UNTR = res_UNTR2SSF,
  SKRN = rets$SKRN,
  SINI = res_SINI1F,
  SMIL = res_SMIL1F,
  ARNA = rets$ARNA,
  HEXA = rets$HEXA,
  TOTO = res_TOTO1F,
  MARK = res_MARK1F
)
head(res)
library(forecast)
estimate_var_argarch <- function(res_saham, model_ar, model_garch, tau) {
  n = length(res_saham)
  mean.garch = fitted(model_ar)
  sd.garch = sigma(model_garch)
  qdist.garch = qdist("sstd", tau, mu = 0, sigma = 1,
    skew = coef(model_garch)["skew"],
    shape = coef(model_garch)["shape"])
  VaR.garch1 = mean.garch + as.numeric(sd.garch*qdist.garch)
  return (VaR.garch1)
}
estimate_var_no_argarch <- function(res_saham, tau) {
  n = length(res_saham)
  fit <- fitdist("sstd", res_saham)
  mean.garch = 0
  sd.garch = fit$pars["sigma"]
  qdist.garch = qdist("sstd", tau, mu = 0, sigma = 1,
    skew = fit$pars["skew"],
    shape = fit$pars["shape"])
  VaR.garch2 = mean.garch + as.numeric(sd.garch*qdist.garch)
  return (ts(rep(VaR.garch2, n)))
}
estimate_var_garch <- function(res_saham, model_garch, tau) {

```

```

n = length(res_saham)
mean.garch = 0
sd.garch = sigma(model_garch)
qdist.garch = qdist("sstd", tau, mu = 0, sigma = 1,
                    skew = coef(model_garch)["skew"],
                    shape = coef(model_garch)["shape"])
VaR.garch3 = mean.garch + as.numeric(sd.garch*qdist.garch)
return (VaR.garch3)
}
estimate_var_ar <- function(res_saham, model_ar, tau) {
  n = length(res_saham)
  fit <- fitdist("sstd", res_saham)
  mean.garch = fitted(model_ar)
  sd.garch = fit$pars["sigma"]
  qdist.garch = qdist("sstd", tau, mu = 0, sigma = 1,
                      skew = fit$pars["skew"],
                      shape = fit$pars["shape"])
  VaR.garch4 = mean.garch + (sd.garch*qdist.garch)
  return (VaR.garch4)
}

## VaR per Saham -----
### VaR Saham ASII -----
VaR_ASII1 <- estimate_var_ar(res$ASII, model_arASII2F, 0.01)
VaR_ASII5 <- estimate_var_ar(res$ASII, model_arASII2F, 0.05)

### VaR Saham IMPC -----
VaR_IMPC1 <- estimate_var_argarch(res$IMPC, model_arIMPC2SST,
model_garchIMPC10, 0.01)
VaR_IMPC5 <- estimate_var_argarch(res$IMPC, model_arIMPC2SST,
model_garchIMPC10, 0.05)

### VaR Saham UNTR -----
VaR_UNTR1 <- estimate_var_ar(res$UNTR, model_arUNTR2SSF, 0.01)
VaR_UNTR5 <- estimate_var_ar(res$UNTR, model_arUNTR2SSF, 0.05)

### VaR Saham SKRN -----
VaR_SKRN1 <- estimate_var_garch(res$SKRN, model_garchSKRN11, 0.01)
VaR_SKRN5 <- estimate_var_garch(res$SKRN, model_garchSKRN11, 0.05)

### VaR Saham SINI -----
VaR_SINI1 <- estimate_var_argarch(res$SINI, model_arSINI1F, model_garchSINI11,
0.01)
VaR_SINI5 <- estimate_var_argarch(res$SINI, model_arSINI1F, model_garchSINI11,
0.05)

### VaR Saham SMIL -----
VaR_SMIL1 <- estimate_var_argarch(res$SMIL, model_arSMIL1F, model_garchSMIL10,
0.01)

```

```

VaR_SMIL5 <- estimate_var_argarch(res$SMIL, model_arSMIL1F, model_garchSMIL10,
0.05)

### VaR Saham ARNA -----
VaR_ARNA1 <- estimate_var_garch(res$ARNA, model_garchARNA11, 0.01)
VaR_ARNA5 <- estimate_var_garch(res$ARNA, model_garchARNA11, 0.05)

### VaR Saham HEXA -----
VaR_HEX1 <- estimate_var_no_argarch(res$HEXA, 0.01)
VaR_HEX5 <- estimate_var_no_argarch(res$HEXA, 0.05)

### VaR Saham TOTO -----
VaR_TOTO1 <- estimate_var_ar(res$TOTO, model_arTOTO1F, 0.01)
VaR_TOTO5 <- estimate_var_ar(res$TOTO, model_arTOTO1F, 0.05)

### VaR Saham MARK -----
VaR_MARK1 <- estimate_var_argarch(res$MARK, model_arMARK1F,
model_garchMARK10, 0.01)
VaR_MARK5 <- estimate_var_argarch(res$MARK, model_arMARK1F,
model_garchMARK10, 0.05)

### Gabungkan jadi data frame -----
#### DATAFRAME VaR 1% -----
VaR01 <- data.frame(VaR_ASII1, VaR_IMPC1, VaR_UNTR1, VaR_SKRN1, VaR_SINI1,
VaR_SMIL1, VaR_ARNA1, VaR_HEX1, VaR_TOTO1, VaR_MARK1,
row.names = NULL)
colnames(VaR01) <- c("ASII", "IMPC", "UNTR", "SKRN", "SINI",
"SMIL", "ARNA", "HEXA", "TOTO", "MARK")
head(VaR01)

#### DATAFRAME VaR 5% -----
VaR05 <- data.frame(VaR_ASII5, VaR_IMPC5, VaR_UNTR5, VaR_SKRN5, VaR_SINI5,
VaR_SMIL5, VaR_ARNA5, VaR_HEX5, VaR_TOTO5, VaR_MARK5,
row.names = NULL)
colnames(VaR05) <- c("ASII", "IMPC", "UNTR", "SKRN", "SINI",
"SMIL", "ARNA", "HEXA", "TOTO", "MARK")
head(VaR05)

```

Lampiran 17 Hasil Estimasi VaR Kuantil 1%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	HEXA	TOTO	MARK
-0,0415	-0,0653	-0,0507	-0,0964	-0,1332	-0,1223	-0,0358	-0,0451	-0,0295	-0,0670
-0,0406	-0,0808	-0,0505	-0,2499	-0,1137	-0,1278	-0,0378	-0,0451	-0,0304	-0,0638
-0,0406	-0,0658	-0,0510	-0,2116	-0,1482	-0,1398	-0,0511	-0,0451	-0,0304	-0,1067
-0,0419	-0,0681	-0,0543	-0,1858	-0,1196	-0,2881	-0,0402	-0,0451	-0,0295	-0,0614
-0,0423	-0,0625	-0,0527	-0,2146	-0,0934	-0,1181	-0,0364	-0,0451	-0,0286	-0,0676
-0,0409	-0,0589	-0,0490	-0,2574	-0,0829	-0,1380	-0,0432	-0,0451	-0,0331	-0,0748
-0,0410	-0,0786	-0,0527	-0,2456	-0,0636	-0,1358	-0,0398	-0,0451	-0,0295	-0,0641
-0,0413	-0,0664	-0,0528	-0,2267	-0,0548	-0,1149	-0,0371	-0,0451	-0,0278	-0,0619
-0,0415	-0,0620	-0,0480	-0,3501	-0,0502	-0,1151	-0,0362	-0,0451	-0,0304	-0,0623
-0,0409	-0,0692	-0,0516	-0,2829	-0,0604	-0,1197	-0,0399	-0,0451	-0,0295	-0,0753
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0414	-0,0675	-0,0481	-0,0744	-0,2421	-0,2694	-0,0351	-0,0451	-0,0287	-0,1134
-0,0441	-0,0842	-0,0481	-0,0640	-0,1953	-0,1172	-0,0349	-0,0451	-0,0295	-0,0688
-0,0414	-0,0736	-0,0482	-0,0602	-0,1763	-0,1489	-0,0410	-0,0451	-0,0287	-0,0666
-0,0414	-0,0695	-0,0497	-0,0571	-0,1703	-0,3322	-0,0367	-0,0451	-0,0303	-0,0729
-0,0394	-0,0609	-0,0502	-0,0686	-0,1253	-0,1181	-0,0354	-0,0451	-0,0287	-0,0616
-0,0402	-0,0764	-0,0552	-0,0682	-0,1861	-0,1153	-0,0382	-0,0451	-0,0295	-0,0621
-0,0428	-0,0612	-0,0546	-0,0632	-0,1663	-0,1375	-0,0358	-0,0451	-0,0287	-0,0805
-0,0408	-0,1956	-0,0515	-0,0558	-0,1563	-0,1155	-0,0492	-0,0451	-0,0295	-0,0629
-0,0426	-0,0578	-0,0499	-0,0494	-0,1507	-0,1353	-0,0395	-0,0451	-0,0295	-0,0644
-0,0446	-0,0827	-0,0500	-0,0448	-0,1489	-0,1451	-0,0362	-0,0451	-0,0295	-0,0631

Lampiran 18 Hasil Estimasi VaR Kuantil 5%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	HEXA	TOTO	MARK
-0,0254	-0,0301	-0,0285	-0,0512	-0,0756	-0,0569	-0,0162	-0,0192	-0,0161	-0,0389
-0,0245	-0,0373	-0,0283	-0,1328	-0,0674	-0,0606	-0,0171	-0,0192	-0,0171	-0,0363
-0,0245	-0,0337	-0,0288	-0,1124	-0,0733	-0,0669	-0,0231	-0,0192	-0,0171	-0,0649
-0,0258	-0,0322	-0,0321	-0,0987	-0,0656	-0,1410	-0,0182	-0,0192	-0,0162	-0,0349
-0,0262	-0,0315	-0,0306	-0,1140	-0,0531	-0,0558	-0,0165	-0,0192	-0,0153	-0,0381
-0,0248	-0,0270	-0,0268	-0,1368	-0,0490	-0,0660	-0,0195	-0,0192	-0,0198	-0,0448
-0,0250	-0,0380	-0,0306	-0,1305	-0,0354	-0,0609	-0,0180	-0,0192	-0,0162	-0,0375
-0,0253	-0,0335	-0,0307	-0,1205	-0,0304	-0,0526	-0,0168	-0,0192	-0,0144	-0,0356
-0,0254	-0,0300	-0,0259	-0,1860	-0,0278	-0,0531	-0,0164	-0,0192	-0,0171	-0,0358
-0,0248	-0,0335	-0,0294	-0,1503	-0,0359	-0,0561	-0,0181	-0,0192	-0,0162	-0,0451
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0253	-0,0274	-0,0259	-0,0395	-0,1231	-0,1317	-0,0159	-0,0192	-0,0154	-0,0691
-0,0280	-0,0427	-0,0260	-0,0340	-0,0967	-0,0545	-0,0158	-0,0192	-0,0162	-0,0382
-0,0253	-0,0362	-0,0261	-0,0320	-0,1005	-0,0661	-0,0185	-0,0192	-0,0154	-0,0395
-0,0253	-0,0304	-0,0276	-0,0303	-0,1030	-0,1623	-0,0166	-0,0192	-0,0170	-0,0434
-0,0233	-0,0255	-0,0281	-0,0365	-0,0751	-0,0550	-0,0160	-0,0192	-0,0154	-0,0354
-0,0241	-0,0369	-0,0331	-0,0362	-0,0915	-0,0532	-0,0173	-0,0192	-0,0162	-0,0357
-0,0268	-0,0302	-0,0324	-0,0336	-0,0802	-0,0613	-0,0162	-0,0192	-0,0154	-0,0484
-0,0247	-0,0940	-0,0294	-0,0297	-0,0745	-0,0534	-0,0223	-0,0192	-0,0162	-0,0356
-0,0265	-0,0156	-0,0278	-0,0262	-0,0714	-0,0604	-0,0179	-0,0192	-0,0162	-0,0379
-0,0285	-0,0418	-0,0279	-0,0238	-0,0703	-0,0693	-0,0164	-0,0192	-0,0162	-0,0369

Lampiran 19 Syntax Statistika Deskriptif VaR Kuantil 1% dan 5%

```

### Kuantil 1% -----
# Buat list VaR & return per saham
var_list_1 <- list(
  ASII = VaR_ASII1,
  IMPC = VaR_IMPC1,
  UNTR = VaR_UNTR1,
  SKRN = VaR_SKRN1,
  SINI = VaR_SINI1,
  SMIL = VaR_SMIL1,
  ARNA = VaR_ARNA1,
  HEXA = VaR_HEXA1,
  TOTO = VaR_TOTO1,
  MARK = VaR_MARK1
)
return_list_1 <- lapply(names(var_list_1), function(sym) {

```

```

    tail(return_df[[sym]], length(var_list_1[[sym]]))
  })
names(return_list_1) <- names(var_list_1)

# Membuat Tabel Statdes
summary_list_1 <- lapply(names(var_list_1), function(sym) {
  VaR <- var_list_1[[sym]]
  ret <- return_list_1[[sym]]
  vio <- ret < VaR
  data.frame(
    Saham = sym,
    Mean_VaR = round(mean(VaR, na.rm = TRUE), 5),
    Max_VaR = round(max(VaR, na.rm = TRUE), 5),
    Min_VaR = round(min(VaR, na.rm = TRUE), 5),
    Varians_VaR = round(var(VaR, na.rm = TRUE), 5),
    stringsAsFactors = FALSE
  )
})
df_summary_var_1 <- bind_rows(summary_list_1)
print(df_summary_var_1)

#### Kuantil 5% -----
# Buat list VaR & return per saham
var_list_5 <- list(
  ASII = VaR_ASII5,
  IMPC = VaR_IMPC5,
  UNTR = VaR_UNTR5,
  SKRN = VaR_SKRN5,
  SINI = VaR_SINI5,
  SMIL = VaR_SMIL5,
  ARNA = VaR_ARNA5,
  HEXA = VaR_HEX5,
  TOTO = VaR_TOTO5,
  MARK = VaR_MARK5
)
return_list_5 <- lapply(names(var_list_5), function(sym) {
  tail(return_df[[sym]], length(var_list_5[[sym]]))
})
names(return_list_5) <- names(var_list_5)

# Membuat Tabel Statdes
summary_list_5 <- lapply(names(var_list_5), function(sym) {
  VaR <- var_list_5[[sym]]
  ret <- return_list_5[[sym]]
  vio <- ret < VaR

  data.frame(
    Saham = sym,
    Mean_VaR = round(mean(VaR, na.rm = TRUE), 5),

```

```

Max_VaR = round(max(VaR, na.rm = TRUE), 5),
Min_VaR = round(min(VaR, na.rm = TRUE), 5),
Varians_VaR = round(var(VaR, na.rm = TRUE), 5),
stringsAsFactors = FALSE
)
})
df_summary_var_5 <- bind_rows(summary_list_5)
print(df_summary_var_5)

```

Lampiran 20 Syntax Plot VaR 1% dan 5% vs Actual Return

```

# Fungsi untuk scale Y
nice_breaks <- function(ylim, n = 8) {
  rng <- ylim[2] - ylim[1]
  step_raw <- rng / n
  nice_steps <- c(0.005, 0.01, 0.02, 0.025, 0.05, 0.10, 0.15, 0.20, 0.25, 0.50)
  step <- nice_steps[which.min(abs(nice_steps - step_raw))]
  seq(ceiling(ylim[1] / step) * step, floor(ylim[2] / step) * step, by = step)
}

# Function untuk membuat plot VaR
plot_var_vs_return_ggplot <- function(saham, comparison_data, tau = 0.05, ylim = NULL)
{
  # Tentukan label berdasarkan tau
  var_label <- ifelse(tau == 0.01, "VaR 1%", "VaR 5%")
  title_tau <- ifelse(tau == 0.01, "1%", "5%")

  # Siapkan data untuk saham tertentu
  plot_data <- data.frame(
    Tanggal = comparison_data$Tanggal,
    VaR = comparison_data[[paste0(saham, "_VaR")]],
    Return = comparison_data[[paste0(saham, "_Return")]]
  )

  # Identifikasi violations (return < VaR)
  plot_data$Violation <- plot_data$Return < plot_data$VaR
  violations_data <- plot_data[plot_data$Violation, ]

  # Buat plot
  p <- ggplot(plot_data, aes(x = Tanggal)) +
    # Garis return aktual
    geom_line(aes(y = Return, color = "Actual Return "), linewidth = 0.8, alpha = 0.8) +
    # Garis VaR
    geom_line(aes(y = VaR, color = var_label), linewidth = 0.8, alpha = 0.8) +
    # Titik violation (return < VaR)
    {if(nrow(violations_data) > 0) {
      geom_point(data = violations_data,
        aes(y = Return, shape = "Violation"),
        color = "black", size = 3, stroke = 1.5, fill = NA)
    }} +

```

```

# Warna dan shape
scale_color_manual(
  values = c("Actual Return " = "blue", "VaR 5%" = "red", "VaR 1%" = "red"),
  name = "Line Type"
) +
{if(nrow(violations_data) > 0) {
  scale_shape_manual(
    values = c("Violation" = 1),
    name = ""
  )
}} +
scale_y_continuous(
  labels = scales::percent_format(accuracy = 0.1),
  breaks = if (!is.null(ylim)) nice_breaks(ylim) else scales::pretty_breaks(n = 8)
) +
coord_cartesian(ylim = ylim) +
scale_x_date(
  date_breaks = "3 months",
  date_labels = "%b %Y",
  expand = c(0.02, 0)
) +
labs(
  title = paste("Perbandingan VaR", title_tau, "vs Actual Return -", saham),
  subtitle = paste("Violations:", nrow(violations_data),
    "(", round(nrow(violations_data)/nrow(plot_data)*100, 2), "%)"),
  x = "Tanggal", y = "Return / VaR"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
  plot.subtitle = element_text(hjust = 0.5, size = 11, color = "darkred"),
  axis.text.x = element_text(angle = 45, hjust = 1),
  axis.title = element_text(face = "bold"),
  legend.position = "bottom",
  legend.box = "horizontal",
  panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
  panel.grid.minor = element_blank()
) +
guides(
  color = guide_legend(order = 1),
  shape = guide_legend(order = 2)
)

return(p)
}

# Untuk Kuantil 1%
comparison_data_01 <- data.frame(
  Tanggal = tail(return_df$Tanggal, nrow(VaR01))

```

```

)

for(saham in names(VaR01)) {
  comparison_data_01[[paste0(saham, "_VaR")]] <- VaR01[[saham]]
  comparison_data_01[[paste0(saham, "_Return")]] <- tail(return_df[[saham]],
nrow(VaR01))
}

# Untuk Kuantil 5%
comparison_data_05 <- data.frame(
  Tanggal = tail(return_df$Tanggal, nrow(VaR05))
)

for(saham in names(VaR05)) {
  comparison_data_05[[paste0(saham, "_VaR")]] <- VaR05[[saham]]
  comparison_data_05[[paste0(saham, "_Return")]] <- tail(return_df[[saham]],
nrow(VaR05))
}

#### Plot VaR Kuantil 1% -----
saham_list <- c("ASII", "IMPC", "UNTR", "SKRN", "SINI", "SMIL", "ARNA",
"HEXA", "TOTO", "MARK")
all_var01 <- unlist(VaR01)
ylim_var01 <- c(
  min(c(all_returns_global, all_var01), na.rm = TRUE),
  max(c(all_returns_global, all_var01), na.rm = TRUE)
)

for(saham in saham_list) {
  p <- plot_var_vs_return_ggplot(saham, comparison_data_01, tau = 0.01, ylim =
ylim_var01)
  print(p)
}

#### Plot VaR Kuantil 5% -----
all_var05 <- unlist(VaR05)
ylim_var05 <- c(
  min(c(all_returns_global, all_var05), na.rm = TRUE),
  max(c(all_returns_global, all_var05), na.rm = TRUE)
)

for(saham in saham_list) {
  p <- plot_var_vs_return_ggplot(saham, comparison_data_05, tau = 0.05, ylim =
ylim_var05)
  print(p)
}

```

Lampiran 21 *Syntax Proportion Shortfall VaR Kuantil 1% dan 5%*

```

####A. Proportion Shortfall VaR -----
proportion_shortfall_var <- function(actual_losses, VaR, tau) {

```

```

exceedances <- actual_losses < VaR
exceedance_ratio <- sum(exceedances) / length(exceedances)
proportion_exceedances <- length(actual_losses) * tau
actual_exceedances <- sum(exceedances)
selisih <- abs(tau - exceedance_ratio)

ps_result <- list(
  Proportion_Shortfall = round(exceedance_ratio, 4),
  Jumlah_Pelanggaran = actual_exceedances,
  Selisih_Resiko = round(selisih, 4),
  Proportion_Pelanggaran = round(proportion_exceedances),
  Total_Observasi = length(exceedances)
)
return(ps_result)
}

#### Kuantil 1% -----
ps_var_ASII1 <- proportion_shortfall_var(tail(rets$ASII, length(VaR_ASII1)), VaR_ASII1,
0.01)
ps_var_IMPC1 <- proportion_shortfall_var(tail(rets$IMPC, length(VaR_IMPC1)),
VaR_IMPC1, 0.01)
ps_var_UNTR1 <- proportion_shortfall_var(tail(rets$UNTR, length(VaR_UNTR1)),
VaR_UNTR1, 0.01)
ps_var_SKRN1 <- proportion_shortfall_var(tail(rets$SKRN, length(VaR_SKRN1)),
VaR_SKRN1, 0.01)
ps_var_SINI1 <- proportion_shortfall_var(tail(rets$SINI, length(VaR_SINI1)), VaR_SINI1,
0.01)
ps_var_SMIL1 <- proportion_shortfall_var(tail(rets$SMIL, length(VaR_SMIL1)),
VaR_SMIL1, 0.01)
ps_var_ARNA1 <- proportion_shortfall_var(tail(rets$ARNA, length(VaR_ARNA1)),
VaR_ARNA1, 0.01)
ps_var_HEX1 <- proportion_shortfall_var(tail(rets$HEXA, length(VaR_HEX1)),
VaR_HEX1, 0.01)
ps_var_TOTO1 <- proportion_shortfall_var(tail(rets$TOTO, length(VaR_TOTO1)),
VaR_TOTO1, 0.01)
ps_var_MARK1 <- proportion_shortfall_var(tail(rets$MARK, length(VaR_MARK1)),
VaR_MARK1, 0.01)

# Tampilkan hasil
df_proportion_shortfall_var1 <- rbind(
  data.frame(Saham = "ASII", as.data.frame(ps_var_ASII1)),
  data.frame(Saham = "IMPC", as.data.frame(ps_var_IMPC1)),
  data.frame(Saham = "UNTR", as.data.frame(ps_var_UNTR1)),
  data.frame(Saham = "SKRN", as.data.frame(ps_var_SKRN1)),
  data.frame(Saham = "SINI", as.data.frame(ps_var_SINI1)),
  data.frame(Saham = "SMIL", as.data.frame(ps_var_SMIL1)),
  data.frame(Saham = "ARNA", as.data.frame(ps_var_ARNA1)),
  data.frame(Saham = "HEXA", as.data.frame(ps_var_HEX1)),
  data.frame(Saham = "TOTO", as.data.frame(ps_var_TOTO1)),

```

```

data.frame(Saham = "MARK", as.data.frame(ps_var_MARK1))
)
print(df_proportion_shortfall_var1)

##### Kuantil 5% -----
ps_var_ASII5 <- proportion_shortfall_var(tail(rets$ASII, length(VaR_ASII5)), VaR_ASII5,
0.05)
ps_var_IMPC5 <- proportion_shortfall_var(tail(rets$IMPC, length(VaR_IMPC5)),
VaR_IMPC5, 0.05)
ps_var_UNTR5 <- proportion_shortfall_var(tail(rets$UNTR, length(VaR_UNTR5)),
VaR_UNTR5, 0.05)
ps_var_SKRN5 <- proportion_shortfall_var(tail(rets$SKRN, length(VaR_SKRN5)),
VaR_SKRN5, 0.05)
ps_var_SINI5 <- proportion_shortfall_var(tail(rets$SINI, length(VaR_SINI5)), VaR_SINI5,
0.05)
ps_var_SMIL5 <- proportion_shortfall_var(tail(rets$SMIL, length(VaR_SMIL5)),
VaR_SMIL5, 0.05)
ps_var_ARNA5 <- proportion_shortfall_var(tail(rets$ARNA, length(VaR_ARNA5)),
VaR_ARNA5, 0.05)
ps_var_HEXA5 <- proportion_shortfall_var(tail(rets$HEXA, length(VaR_HEXA5)),
VaR_HEXA5, 0.05)
ps_var_TOTO5 <- proportion_shortfall_var(tail(rets$TOTO, length(VaR_TOTO5)),
VaR_TOTO5, 0.05)
ps_var_MARK5 <- proportion_shortfall_var(tail(rets$MARK, length(VaR_MARK5)),
VaR_MARK5, 0.05)

# Tampilkan hasil
df_proportion_shortfall_var5 <- rbind(
data.frame(Saham = "ASII", as.data.frame(ps_var_ASII5)),
data.frame(Saham = "IMPC", as.data.frame(ps_var_IMPC5)),
data.frame(Saham = "UNTR", as.data.frame(ps_var_UNTR5)),
data.frame(Saham = "SKRN", as.data.frame(ps_var_SKRN5)),
data.frame(Saham = "SINI", as.data.frame(ps_var_SINI5)),
data.frame(Saham = "SMIL", as.data.frame(ps_var_SMIL5)),
data.frame(Saham = "ARNA", as.data.frame(ps_var_ARNA5)),
data.frame(Saham = "HEXA", as.data.frame(ps_var_HEXA5)),
data.frame(Saham = "TOTO", as.data.frame(ps_var_TOTO5)),
data.frame(Saham = "MARK", as.data.frame(ps_var_MARK5))
)
print(df_proportion_shortfall_var5)

```

Lampiran 22 Syntax Kupiec Test VaR Kuantil 1% dan 5%

```

####B. Kupiec Test VaR -----
Kupiec <- function(y, VaR, tau, verbose = TRUE, test = "PoF", tipe, alpha) {
y = tail(y, length(VaR))
N = length(y)
hit = numeric(N)
hit[y < VaR] = 1
numOfFails = sum(hit)

```

```

n = which(hit == 1)[1]
p = tau

if (test == "PoF"){
  lr = -2*log((((1-p)^(N - numOfFails))*(p^numOfFails))/((1 - numOfFails/N)^(N -
numOfFails)*(numOfFails/N)^numOfFails))
} else if (test == "TUFF"){
  lr = -2*log((p*(1 - p)^(n - 1))/((1/n)*(1 - 1/n)^(n - 1)))
}

if (lr > qchisq(alpha, 1, lower.tail = FALSE)){
  if (verbose) cat("Tolak H0 : method not accurate at:", p*100, "% level\n")
  return(round(c(1 - pchisq(lr, df = 1), lr, qchisq(alpha, 1, lower.tail = FALSE), ifelse(test
== "PoF", numOfFails, n)), 3))
} else {
  if (verbose) cat("Gagal Tolak H0 : method accurate at:", p*100, "% level\n")
  return(round(c(1 - pchisq(lr, df = 1), lr, qchisq(alpha, 1, lower.tail = FALSE), ifelse(test
== "PoF", numOfFails, n)), 3))
}
}

##### Kuantil 1% -----
Kupiec_results_1 <- lapply(names(var_list_1), function(sym) {
  y <- tail(return_df[[sym]], length(var_list_1[[sym]]))
  VaR <- var_list_1[[sym]]

  hasil <- Kupiec(y, VaR, tau = 0.01, verbose = FALSE, test = "PoF", tipe = NULL, alpha =
0.05)

  data.frame(
    Saham = sym,
    p_value = hasil[1],
    LR_stat = hasil[2],
    Chi_Crit = hasil[3],
    Jumlah_Pelanggaran = hasil[4],
    Hasil_Uji = ifelse(hasil[2] > hasil[3], "Tolak H0", "Gagal Tolak H0")
  )
})

# Tampilkan hasil
df_Kupiec_test_1 <- bind_rows(Kupiec_results_1)
print(df_Kupiec_test_1)

##### Kuantil 5% -----
Kupiec_results_5 <- lapply(names(var_list_5), function(sym) {
  y <- tail(return_df[[sym]], length(var_list_5[[sym]]))
  VaR <- var_list_5[[sym]]

```

```

hasil <- Kupiec(y, VaR, tau = 0.05, verbose = FALSE, test = "PoF", tipe = NULL, alpha =
0.05)

data.frame(
  Saham = sym,
  p_value = hasil[1],
  LR_stat = hasil[2],
  Chi_Crit = hasil[3],
  Jumlah_Pelanggaran = hasil[4],
  Hasil_Uji = ifelse(hasil[2] > hasil[3], "Tolak H0", "Gagal Tolak H0")
)
})

# Tampilkan hasil
df_Kupiec_test_5 <- bind_rows(Kupiec_results_5)
print(df_Kupiec_test_5)

```

Lampiran 23 Syntax dan Output Uji Terasvirta

```

saham_names_aktif <- c("ASII", "IMPC", "UNTR", "SKRN", "SINI",
                        "SMIL", "ARNA", "TOTO", "MARK") # tanpa HEXA
saham_covar <- saham_names_aktif
VaR01_aktif <- VaR01[, saham_names_aktif]
VaR05_aktif <- VaR05[, saham_names_aktif]

cat("\nDimensi VaR01_aktif:", dim(VaR01_aktif), "\n")
cat("Dimensi VaR05_aktif:", dim(VaR05_aktif), "\n")

# Fungsi Uji Terasvirta per emiten
uji_terasvirta <- function(y, X, saham_name, quantile_level, alpha = 0.05) {
  n <- min(length(y), nrow(X))
  y <- tail(as.numeric(y), n)
  X_mat <- as.matrix(tail(X, n))
  p <- ncol(X_mat)

  df_lin <- as.data.frame(X_mat)
  colnames(df_lin) <- paste0("VaR_", colnames(X_mat))
  df_lin$Y <- y
  model_lin <- lm(
    as.formula(paste("Y ~", paste(paste0("VaR_", colnames(X_mat)), collapse = " + "))),
    data = df_lin
  )
  resid_lin <- as.numeric(residuals(model_lin))

  df_ext <- df_lin
  for (j in 1:p) {
    base <- paste0("VaR_", colnames(X_mat)[j])
    df_ext[[paste0(base, "_sq")]] <- df_ext[[base]]^2
    df_ext[[paste0(base, "_cu")]] <- df_ext[[base]]^3
  }
}

```

```

m <- 2 * p

df_ext$resid <- resid_lin
all_pred <- setdiff(colnames(df_ext), c("Y", "resid"))
model_ext <- lm(
  as.formula(paste("resid ~", paste(all_pred, collapse = " + "))),
  data = df_ext
)

R2 <- summary(model_ext)$r.squared
X2_hit <- n * R2
X2_krit <- qchisq(1 - alpha, df = m)
p_value <- 1 - pchisq(X2_hit, df = m)
keputusan <- ifelse(X2_hit > X2_krit || p_value < alpha, "Tolak H0", "Gagal Tolak H0")
kesimpulan <- ifelse(keputusan == "Tolak H0", "NON-LINEAR", "LINEAR")

list(
  Saham = saham_name,
  Quantile = paste0(quantile_level * 100, "%"),
  n = n,
  p_pred = p,
  df_m = m,
  R2 = round(R2, 6),
  X2_hitung = round(X2_hit, 4),
  X2_kritis = round(X2_krit, 4),
  p_value = round(p_value, 6),
  Keputusan = keputusan,
  Kesimpulan = kesimpulan
)
}

run_terasvirta_all <- function(rets, VaR_df, saham_list, quantile_level, alpha = 0.05) {
  lapply(saham_list, function(saham) {
    col_idx <- which(colnames(VaR_df) == saham)
    X_pred <- if (length(col_idx) > 0) VaR_df[, -col_idx, drop = FALSE] else VaR_df
    n_obs <- min(length(rets[[saham]]), nrow(X_pred))
    cat(sprintf(" Terasvirta: %-6s | tau=%s\n", saham,
      paste0(quantile_level * 100, "%")))
    tryCatch(
      uji_terasvirta(
        tail(as.numeric(rets[[saham]]), n_obs),
        tail(X_pred, n_obs),
        saham, quantile_level, alpha
      ),
      error = function(e) {
        cat(" ERROR:", e$message, "\n")
        list(Saham = saham, Quantile = paste0(quantile_level * 100, "%"),
          n = NA, p_pred = NA, df_m = NA, R2 = NA,
          X2_hitung = NA, X2_kritis = NA, p_value = NA,

```

```

        Keputusan = "ERROR", Kesimpulan = e$message)
    }
  )
}) |> setNames(saham_list)
}

list_to_df_tera <- function(lst) {
  do.call(rbind, lapply(lst, function(x) data.frame(
    Saham      = x$Saham,
    Quantile   = x$Quantile,
    n          = x$n,
    p_pred     = x$p_pred,
    df_m       = x$df_m,
    R2         = x$R2,
    X2_hitung  = x$X2_hitung,
    X2_kritis  = x$X2_kritis,
    p_value    = x$p_value,
    Keputusan  = x$Keputusan,
    Kesimpulan = x$Kesimpulan,
    stringsAsFactors = FALSE
  )))
}
cat("\n"); cat(strrep("=", 70))
cat("\nUJI TERASVIRTA — H0: LINEAR | H1: NON-LINEAR | alpha = 5%\n")
cat(strrep("=", 70), "\n")

cat("\n[Kuantil 5%]\n")
hasil_tera_05 <- run_terasvirta_all(rets, VaR05_aktif, saham_covar, 0.05)
df_tera_05    <- list_to_df_tera(hasil_tera_05)
print(df_tera_05, row.names = FALSE)

cat("\n[Kuantil 1%]\n")
hasil_tera_01 <- run_terasvirta_all(rets, VaR01_aktif, saham_covar, 0.01)
df_tera_01    <- list_to_df_tera(hasil_tera_01)
print(df_tera_01, row.names = FALSE)

df_tera_all <- rbind(df_tera_05, df_tera_01)

Output:
> print(df_tera_05, row.names = FALSE)

```

Saham	Quantile	n	p_pred	df_m	R2	X2_hitung	X2_kritis	p_value	Keputusan	Kesimpulan
ASII	5%	597	8	16	0.038541	23.0091	26.2962	0.113491	Gagal Tolak H0	LINEAR
IMPC	5%	597	8	16	0.017026	10.1646	26.2962	0.857891	Gagal Tolak H0	LINEAR
UNTR	5%	597	8	16	0.030792	18.3827	26.2962	0.301968	Gagal Tolak H0	LINEAR
SKRN	5%	597	8	16	0.023179	13.8378	26.2962	0.610795	Gagal Tolak H0	LINEAR
SINI	5%	597	8	16	0.032218	19.2344	26.2962	0.256698	Gagal Tolak H0	LINEAR
SMIL	5%	597	8	16	0.028437	16.9767	26.2962	0.387106	Gagal Tolak H0	LINEAR
ARNA	5%	597	8	16	0.037761	22.5435	26.2962	0.126495	Gagal Tolak H0	LINEAR
TOTO	5%	597	8	16	0.032381	19.3313	26.2962	0.251859	Gagal Tolak H0	LINEAR
MARK	5%	597	8	16	0.029197	17.4307	26.2962	0.358272	Gagal Tolak H0	LINEAR

```
> print(df_tera_01, row.names = FALSE)
```

Saham	Quantile	n	p_pred	df_m	R2	X2_hitung	X2_kritis	p_value	Keputusan	Kesimpulan
ASII	1%	597	8	16	0.036456	21.7642	26.2962	0.150971	Gagal Tolak H0	LINEAR
IMPC	1%	597	8	16	0.015080	9.0025	26.2962	0.913310	Gagal Tolak H0	LINEAR
UNTR	1%	597	8	16	0.032036	19.1255	26.2962	0.262207	Gagal Tolak H0	LINEAR
SKRN	1%	597	8	16	0.023049	13.7600	26.2962	0.616587	Gagal Tolak H0	LINEAR
SINI	1%	597	8	16	0.028944	17.2793	26.2962	0.367749	Gagal Tolak H0	LINEAR
SMIL	1%	597	8	16	0.028150	16.8053	26.2962	0.398305	Gagal Tolak H0	LINEAR
ARNA	1%	597	8	16	0.047758	28.5114	26.2962	0.027447	Tolak H0	NON-LINEAR
TOTO	1%	597	8	16	0.031216	18.6358	26.2962	0.288001	Gagal Tolak H0	LINEAR
MARK	1%	597	8	16	0.027801	16.5973	26.2962	0.412103	Gagal Tolak H0	LINEAR

Lampiran 24 Syntax Estimasi VaR 50%

```
VaR_ASII50 <- estimate_var_ar(res$ASII, model_arASII2F, 0.50)
VaR_IMPC50 <- estimate_var_argarch(res$IMPC, model_arIMPC2SST,
model_garchIMPC10, 0.50)
VaR_UNTR50 <- estimate_var_ar(res$UNTR, model_arUNTR2SSF, 0.50)
VaR_SKRN50 <- estimate_var_garch(res$SKRN, model_garchSKRN11, 0.50)
VaR_SINI50 <- estimate_var_argarch(res$SINI, model_arSINI1F, model_garchSINI11,
0.50)
VaR_SMIL50 <- estimate_var_argarch(res$SMIL, model_arSMIL1F,
model_garchSMIL10, 0.50)
VaR_ARNA50 <- estimate_var_garch(res$ARNA, model_garchARNA11, 0.50)
VaR_HEXA50 <- estimate_var_no_argarch(res$HEXA, 0.50)
VaR_TOTO50 <- estimate_var_ar(res$TOTO, model_arTOTO1F, 0.50)
VaR_MARK50 <- estimate_var_argarch(res$MARK, model_arMARK1F,
model_garchMARK10, 0.50)

# Gabung ke 1 data frame
VaR50 <- data.frame(
  ASII = VaR_ASII50, IMPC = VaR_IMPC50, UNTR = VaR_UNTR50, SKRN =
VaR_SKRN50,
  SINI = VaR_SINI50, SMIL = VaR_SMIL50, ARNA = VaR_ARNA50, HEXA =
VaR_HEXA50,
  TOTO = VaR_TOTO50, MARK = VaR_MARK50,
  row.names = NULL
)
head(VaR50)
```

Lampiran 25 Syntax Estimasi CoVaR dengan QRF

```
# Persiapan Data untuk CoVaR
return_data <- as.data.frame(rets)
n_obs <- nrow(return_data)

## CoVaR QRF (Quantile Regression Forest) -----
library(grf)
library(dplyr)
library(ggplot2)

### Moving Block Bootstrap -----
moving_block_bootstrap <- function(data, block_size) {
  n <- length(data)
```

```

bootstrap_sample <- numeric(n)
for (i in seq(1, n, by = block_size)) {
  if (i + block_size - 1 > n) {
    remaining <- n - i + 1
    start_index <- sample(seq(1, n - remaining + 1), 1)
    bootstrap_sample[i:n] <- data[start_index:(start_index + remaining - 1)]
    break
  }
  start_index <- sample(seq(1, n - block_size + 1), 1)
  bootstrap_sample[i:(i + block_size - 1)] <- data[start_index:(start_index + block_size - 1)]
}
return(bootstrap_sample)
}

### Fungsi CoVaR QRF -----
# y_i = return saham i
# VaR_all = data frame VaR semua saham (distress tau)
# col = indeks kolom saham i dalam VaR_all
# VaR_i_50 = VaR saham i tau=0.50 (kondisi normal, untuk Delta CoVaR)
# tau = kuantil (0.01 atau 0.05)
covarr_qrf <- function(y_i,
                       VaR_all,
                       col,
                       VaR_i_50,
                       tau,
                       num.trees = 1000,
                       block_size = 63,
                       seed = 123) {

  saham_nama <- colnames(VaR_all)[col]
  cat("\n", rep("=", 60), "\n")
  cat("Fitting QRF CoVaR untuk saham:", saham_nama, "| tau =", tau, "\n")
  cat(rep("=", 60), "\n")

  n <- length(y_i)
  VaR_i_50 <- tail(as.numeric(VaR_i_50), n)

  # Prediktor = VaR saham LAIN (exclude saham i)
  X_other <- as.matrix(VaR_all[, -col])

  # Bootstrap X dan y
  set.seed(seed)
  X_boot <- apply(X_other, 2, moving_block_bootstrap, block_size = block_size)
  y_boot <- moving_block_bootstrap(y_i, block_size = block_size)

  # Fit QRF
  qrf_model <- quantile_forest(
    X = X_boot,
    Y = y_boot,

```

```

num.trees      = num.trees,
quantiles      = c(tau, 0.5),
sample.fraction = 0.5,
mtry           = min(ceiling(sqrt(ncol(X_boot)) + 20), ncol(X_boot)),
min.node.size  = 5,
honesty        = TRUE,
honesty.fraction = 0.5,
honesty.prune.leaves = TRUE,
seed           = seed
)

# Prediksi kondisi distress (kuantil tau) dan normal (kuantil 0.5)
pred_distress <- predict(qrf_model, newdata = X_other, quantiles = tau)
pred_normal   <- predict(qrf_model, newdata = X_other, quantiles = 0.5)

covar_i <- as.numeric(pred_distress$predictions)
normal_i <- as.numeric(pred_normal$predictions)
delta_i <- covar_i - normal_i #  $\Delta\text{CoVaR} = \text{CoVaR}(\text{distress}) - \text{CoVaR}(\text{normal})$ 

# Variable Importance (dikumpulkan, ditampilkan di seksi SSVS sebagai Prior)
imp <- variable_importance(qrf_model)
imp_df <- data.frame(Saham = colnames(VaR_all)[-col], Importance = round(imp,5))

return(list(
  covar    = covar_i,
  normal   = normal_i,
  delta    = delta_i,
  importance = imp_df,
  model    = qrf_model
))
}

#### Estimasi CoVaR semua Saham -----
saham_names <- colnames(return_data)

# exclude HEXA — sudah didefinisikan di section #7 sebagai saham_names_aktif
saham_names <- saham_names_aktif

# VaR01_aktif & VaR05_aktif sudah didefinisikan di section #7 (Terasvirta)
cat("Kolom prediktor CoVaR (tanpa HEXA):", paste(colnames(VaR01_aktif), collapse = ",
"), "\n")

covar_results_01 <- list()
covar_results_05 <- list()
importance_raw_01 <- list() # kumpulkan importance per saham, tau 1%
importance_raw_05 <- list() # kumpulkan importance per saham, tau 5%

for (i in seq_along(saham_names)) {
  saham <- saham_names[i]

```

```

cat("\n", rep("=", 70), "\n")
cat("PROCESSING SAHAM:", saham, "\n")
cat(rep("=", 70), "\n")

y_i    <- tail(as.numeric(return_data[[saham]]), n_obs) # return saham i
var_50_i <- tail(as.numeric(VaR50[[saham]]), n_obs)      # VaR 50% saham i

# Cari indeks kolom di matriks aktif (tanpa HEXA)
col_in_var01 <- which(colnames(VaR01_aktif) == saham)
col_in_var05 <- which(colnames(VaR05_aktif) == saham)

# CoVaR kuantil 1%
res_01 <- covarr_qrf(
  y_i    = y_i,
  VaR_all = VaR01_aktif,
  col     = col_in_var01,
  VaR_i_50 = var_50_i,
  tau     = 0.01,
  seed    = 123
)

# CoVaR kuantil 5%
res_05 <- covarr_qrf(
  y_i    = y_i,
  VaR_all = VaR05_aktif,
  col     = col_in_var05,
  VaR_i_50 = var_50_i,
  tau     = 0.05,
  seed    = 123
)

covar_results_01[[saham]] <- res_01$covar
covar_results_05[[saham]] <- res_05$covar
importance_raw_01[[saham]] <- res_01$importance # data.frame: Saham, Importance
importance_raw_05[[saham]] <- res_05$importance

# Tampilkan Variable Importance per saham agar bisa dipantau saat Running
cat("\n [VI tau=1%] Saham:", saham, "\n"); print(res_01$importance)
cat("\n [VI tau=5%] Saham:", saham, "\n"); print(res_05$importance)
}

# Gabungkan importance ke satu tabel (dibutuhkan oleh SSVS sebagai Prior)
# vi_df_01/05: kolom Saham (=saham target), Saham (=prediktor), Importance
vi_df_01 <- do.call(rbind, lapply(names(importance_raw_01), function(s) {
  df <- importance_raw_01[[s]]
  df$Saham_Target <- s
  # Rename kolom "Saham" -> "Variable" agar konsisten
  colnames(df)[colnames(df) == "Saham"] <- "Variable"
  df[, c("Saham_Target", "Variable", "Importance")]

```

```

}))
vi_df_05 <- do.call(rbind, lapply(names(importance_raw_05), function(s) {
  df <- importance_raw_05[[s]]
  df$Saham_Target <- s
  colnames(df)[colnames(df) == "Saham"] <- "Variable"
  df[, c("Saham_Target", "Variable", "Importance")]
}))
rownames(vi_df_01) <- NULL
rownames(vi_df_05) <- NULL

# Fungsi Prior per saham
# Mengambil VI spesifik per saham target
get_Prior_per_saham <- function(vi_df, saham_target, saham_minus_i) {
  vi_saham <- vi_df[vi_df$Saham_Target == saham_target, ]
  vi_saham <- vi_saham[vi_saham$Variable %in% saham_minus_i, ]
  if (nrow(vi_saham) == 0) {
    cat(sprintf(" [WARNING] VI tidak ditemukan untuk %s, pakai Prior 0.5\n",
saham_target))
    Prior <- setNames(rep(0.5, length(saham_minus_i)), saham_minus_i)
  } else {
    Prior <- setNames(vi_saham$Importance, vi_saham$Variable)
    missing_vars <- setdiff(saham_minus_i, names(Prior))
    if (length(missing_vars) > 0) {
      Prior[missing_vars] <- 0.5
      cat(sprintf(" [INFO] VI hilang untuk: %s, diisi 0.5\n",
        paste(missing_vars, collapse = ", ")))
    }
    Prior <- Prior[saham_minus_i]
  }
  return(Prior)
}

cat("\n=== Variable Importance CoVaR tau=1% ===\n"); print(vi_df_01)
cat("\n=== Variable Importance CoVaR tau=5% ===\n"); print(vi_df_05)

# Bentuk Data Frame CoVaR
CoVaR_01 <- as.data.frame(covar_results_01)
CoVaR_05 <- as.data.frame(covar_results_05)

colnames(CoVaR_01) <- paste0("CoVaR_", saham_names)
colnames(CoVaR_05) <- paste0("CoVaR_", saham_names)

cat("\nCoVaR 1%:\n"); print(head(CoVaR_01))
cat("\nCoVaR 5%:\n"); print(head(CoVaR_05))

```

Lampiran 26 Hasil *Variable Importance* QRF Kuantil 1% dan 5%

$\tau = 1\%$			$\tau = 5\%$		
Saham Target	Variable	Importance	Saham Target	Variable	Importance
ASII	IMPC	0.14535	ASII	IMPC	0.16883
ASII	UNTR	0.15011	ASII	UNTR	0.14586

ASII	SKRN	0.13671	ASII	SKRN	0.13159
ASII	SINI	0.11904	ASII	SINI	0.10681
ASII	SMIL	0.13957	ASII	SMIL	0.16078
ASII	ARNA	0.10324	ASII	ARNA	0.09629
ASII	TOTO	0.06913	ASII	TOTO	0.06855
ASII	MARK	0.13685	ASII	MARK	0.12129
IMPC	ASII	0.10372	IMPC	ASII	0.10258
IMPC	UNTR	0.14573	IMPC	UNTR	0.13597
IMPC	SKRN	0.10862	IMPC	SKRN	0.13877
IMPC	SINI	0.11460	IMPC	SINI	0.14164
IMPC	SMIL	0.12679	IMPC	SMIL	0.08977
IMPC	ARNA	0.15486	IMPC	ARNA	0.15687
IMPC	TOTO	0.09197	IMPC	TOTO	0.09527
IMPC	MARK	0.15369	IMPC	MARK	0.13912
UNTR	ASII	0.15685	UNTR	ASII	0.15620
UNTR	IMPC	0.12983	UNTR	IMPC	0.12088
UNTR	SKRN	0.14823	UNTR	SKRN	0.15576
UNTR	SINI	0.12640	UNTR	SINI	0.13004
UNTR	SMIL	0.13085	UNTR	SMIL	0.13183
UNTR	ARNA	0.12413	UNTR	ARNA	0.11802
UNTR	TOTO	0.07605	UNTR	TOTO	0.07622
UNTR	MARK	0.10765	UNTR	MARK	0.11105
SKRN	ASII	0.12689	SKRN	ASII	0.13422
SKRN	IMPC	0.13719	SKRN	IMPC	0.12781
SKRN	UNTR	0.12738	SKRN	UNTR	0.12362
SKRN	SINI	0.12469	SKRN	SINI	0.11890
SKRN	SMIL	0.16280	SKRN	SMIL	0.16772
SKRN	ARNA	0.14612	SKRN	ARNA	0.15016
SKRN	TOTO	0.07621	SKRN	TOTO	0.07222
SKRN	MARK	0.09872	SKRN	MARK	0.10536
SINI	ASII	0.11251	SINI	ASII	0.10624
SINI	IMPC	0.12434	SINI	IMPC	0.12225
SINI	UNTR	0.10468	SINI	UNTR	0.09646
SINI	SKRN	0.11950	SINI	SKRN	0.11705
SINI	SMIL	0.15658	SINI	SMIL	0.18261
SINI	ARNA	0.14290	SINI	ARNA	0.14153
SINI	TOTO	0.06761	SINI	TOTO	0.06498
SINI	MARK	0.17189	SINI	MARK	0.16887
SMIL	ASII	0.11650	SMIL	ASII	0.11692
SMIL	IMPC	0.26421	SMIL	IMPC	0.25567
SMIL	UNTR	0.15396	SMIL	UNTR	0.14446
SMIL	SKRN	0.09810	SMIL	SKRN	0.09735
SMIL	SINI	0.09975	SMIL	SINI	0.10650
SMIL	ARNA	0.07504	SMIL	ARNA	0.08240
SMIL	TOTO	0.06482	SMIL	TOTO	0.07398
SMIL	MARK	0.12762	SMIL	MARK	0.12271
ARNA	ASII	0.12252	ARNA	ASII	0.12664
ARNA	IMPC	0.15799	ARNA	IMPC	0.15869
ARNA	UNTR	0.13524	ARNA	UNTR	0.13809
ARNA	SKRN	0.09982	ARNA	SKRN	0.08963
ARNA	SINI	0.21491	ARNA	SINI	0.17277
ARNA	SMIL	0.08597	ARNA	SMIL	0.09493
ARNA	TOTO	0.07336	ARNA	TOTO	0.08996
ARNA	MARK	0.11019	ARNA	MARK	0.12930
TOTO	ASII	0.09583	TOTO	ASII	0.10836
TOTO	IMPC	0.14762	TOTO	IMPC	0.11469
TOTO	UNTR	0.09862	TOTO	UNTR	0.09626
TOTO	SKRN	0.12294	TOTO	SKRN	0.15519
TOTO	SINI	0.11634	TOTO	SINI	0.10091

TOTO	SMIL	0.11171	TOTO	SMIL	0.10224
TOTO	ARNA	0.16447	TOTO	ARNA	0.16018
TOTO	MARK	0.14246	TOTO	MARK	0.16217
MARK	ASII	0.09628	MARK	ASII	0.09646
MARK	IMPC	0.13044	MARK	IMPC	0.12461
MARK	UNTR	0.11040	MARK	UNTR	0.09850
MARK	SKRN	0.09092	MARK	SKRN	0.09607
MARK	SINI	0.14685	MARK	SINI	0.15577
MARK	SMIL	0.08420	MARK	SMIL	0.11169
MARK	ARNA	0.16931	MARK	ARNA	0.15849
MARK	TOTO	0.17160	MARK	TOTO	0.1584

Lampiran 27 Hasil Estimasi CoVaR Kuantil 1%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
-0,0391	-0,0595	-0,0492	-0,1285	-0,1189	-0,1495	-0,0403	-0,0374	-0,0659
-0,0391	-0,0476	-0,0492	-0,1457	-0,2500	-0,1786	-0,0403	-0,0189	-0,0688
-0,0392	-0,0405	-0,0492	-0,1694	-0,1189	-0,2186	-0,0270	-0,0288	-0,0622
-0,0401	-0,0476	-0,0600	-0,1139	-0,1533	-0,1786	-0,0403	-0,0374	-0,0656
-0,0391	-0,0405	-0,0600	-0,1285	-0,1189	-0,1786	-0,0414	-0,0263	-0,0659
-0,0340	-0,0426	-0,0492	-0,1457	-0,1533	-0,2186	-0,0370	-0,0189	-0,0659
-0,0391	-0,0473	-0,0492	-0,1694	-0,1533	-0,1491	-0,0414	-0,0189	-0,0656
-0,0975	-0,0476	-0,1465	-0,1106	-0,1000	-0,1491	-0,0414	-0,0183	-0,0682
-0,0391	-0,0476	-0,0647	-0,1457	-0,1533	-0,1495	-0,0375	-0,0179	-0,0688
-0,0391	-0,0426	-0,0492	-0,1457	-0,2500	-0,1786	-0,0414	-0,0288	-0,0656
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0340	-0,0400	-0,0478	-0,1457	-0,1000	-0,2186	-0,0403	-0,0183	-0,0914
-0,0391	-0,0395	-0,0459	-0,1285	-0,1533	-0,2500	-0,0403	-0,0263	-0,0781
-0,0391	-0,0357	-0,0492	-0,1285	-0,2500	-0,2186	-0,0403	-0,0374	-0,0914
-0,0340	-0,0426	-0,0492	-0,1457	-0,2500	-0,2260	-0,0629	-0,0374	-0,0781
-0,0392	-0,0595	-0,0600	-0,1139	-0,1000	-0,1491	-0,0629	-0,0288	-0,0736
-0,0392	-0,0476	-0,0478	-0,1106	-0,1000	-0,2260	-0,0815	-0,0374	-0,0688
-0,0340	-0,0476	-0,0492	-0,1285	-0,1000	-0,2080	-0,0414	-0,0288	-0,0659
-0,0391	-0,0405	-0,0492	-0,1285	-0,1189	-0,2260	-0,0411	-0,0508	-0,0659
-0,0333	-0,0426	-0,0492	-0,1285	-0,1000	-0,1786	-0,0588	-0,0374	-0,0622
-0,0392	-0,0476	-0,0492	-0,0972	-0,1533	-0,2500	-0,0588	-0,0459	-0,0659

Lampiran 28 Hasil Estimasi CoVaR Kuantil 5%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
-0,0286	-0,0316	-0,0261	-0,0328	-0,0995	-0,0724	-0,0167	-0,0171	-0,0521
-0,0298	-0,0354	-0,0331	-0,0466	-0,0998	-0,0724	-0,0195	-0,0097	-0,0521
-0,0298	-0,0357	-0,0249	-0,0697	-0,0989	-0,0909	-0,0153	-0,0165	-0,0415
-0,0283	-0,0357	-0,0401	-0,0615	-0,0990	-0,0728	-0,0164	-0,0098	-0,0521
-0,0242	-0,0357	-0,0261	-0,0615	-0,1000	-0,0545	-0,0194	-0,0165	-0,0521
-0,0242	-0,0354	-0,0331	-0,0575	-0,0991	-0,0826	-0,0194	-0,0097	-0,0394
-0,0242	-0,0357	-0,0291	-0,0615	-0,0998	-0,0651	-0,0233	-0,0098	-0,0484
-0,0286	-0,0395	-0,0245	-0,0615	-0,0998	-0,0738	-0,0195	-0,0095	-0,0521
-0,0283	-0,0324	-0,0272	-0,0629	-0,1000	-0,1042	-0,0248	-0,0093	-0,0521
-0,0242	-0,0357	-0,0245	-0,0563	-0,1000	-0,0651	-0,0207	-0,0165	-0,0484
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0286	-0,0248	-0,0249	-0,0629	-0,0982	-0,0621	-0,0159	-0,0098	-0,0524
-0,0286	-0,0237	-0,0264	-0,0488	-0,0991	-0,0727	-0,0233	-0,0096	-0,0484
-0,0306	-0,0298	-0,0256	-0,0575	-0,0995	-0,0957	-0,0189	-0,0179	-0,0444
-0,0286	-0,0313	-0,0263	-0,0488	-0,0989	-0,0728	-0,0203	-0,0172	-0,0521
-0,0286	-0,0298	-0,0263	-0,0489	-0,0982	-0,0728	-0,0233	-0,0169	-0,0484

-0,0284	-0,0357	-0,0255	-0,0647	-0,0990	-0,0738	-0,0248	-0,0182	-0,0521
-0,0286	-0,0316	-0,0249	-0,0575	-0,0988	-0,0909	-0,0164	-0,0174	-0,0521
-0,0240	-0,0301	-0,0256	-0,0697	-0,0989	-0,1467	-0,0236	-0,0179	-0,0484
-0,0224	-0,0313	-0,0263	-0,0563	-0,0976	-0,0728	-0,0331	-0,0179	-0,0379
-0,0242	-0,0313	-0,0288	-0,0449	-0,1000	-0,0915	-0,0325	-0,0171	-0,0444

Lampiran 29 Syntax Statistika Deskriptif CoVaR Kuantil 1% dan 5%

```
statdes_covar <- function(covar_df, saham_names, label) {
  cat("\n==== Statistika Deskriptif CoVaR", label, "====\n")
  tabel <- do.call(rbind, lapply(saham_names, function(s) {
    v <- covar_df[[paste0("CoVaR_", s)]]
    data.frame(Saham = s,
               Mean = round(mean(v), 5),
               Max = round(max(v), 5),
               Min = round(min(v), 5),
               Varians = round(var(v), 5))
  )))
  print(tabel)
  return(invisible(tabel))
}

statdes_covar(CoVaR_01, saham_names, "Kuantil 1%")
statdes_covar(CoVaR_05, saham_names, "Kuantil 5%")
```

Lampiran 30 Syntax Plot CoVaR 1% dan 5% vs Actual Return

```
# Buat comparison data: return saham i (bukan return sistem!)
comparison_data_covar_01 <- data.frame(Tanggal = tail(return_df$Tanggal, n_obs))
comparison_data_covar_05 <- data.frame(Tanggal = tail(return_df$Tanggal, n_obs))

for (saham in saham_names) {
  comparison_data_covar_01[[paste0(saham, "_CoVaR")]] <-
  CoVaR_01[[paste0("CoVaR_", saham)]]
  comparison_data_covar_01[[paste0(saham, "_Return")]] <- tail(return_df[[saham]], n_obs)
  comparison_data_covar_05[[paste0(saham, "_CoVaR")]] <-
  CoVaR_05[[paste0("CoVaR_", saham)]]
  comparison_data_covar_05[[paste0(saham, "_Return")]] <- tail(return_df[[saham]], n_obs)
}

# Fungsi plot CoVaR vs actual return
plot_covar_vs_return_ggplot <- function(saham, comparison_data, tau = 0.05, ylim =
NULL) {
  covar_label <- ifelse(tau == 0.05, "CoVaR 5%", "CoVaR 1%")
  title_tau <- ifelse(tau == 0.05, "5%", "1%")

  plot_data <- data.frame(
    Tanggal = comparison_data$Tanggal,
    CoVaR = comparison_data[[paste0(saham, "_CoVaR")]],
    Return = comparison_data[[paste0(saham, "_Return")]]
  )
  plot_data$Violation <- plot_data$Return < plot_data$CoVaR
```

```

violations_data <- plot_data[plot_data$Violation, ]

p <- ggplot(plot_data, aes(x = Tanggal)) +
  geom_line(aes(y = Return, color = "Actual Return"), linewidth = 0.8, alpha = 0.8) +
  geom_line(aes(y = CoVaR, color = covar_label), linewidth = 0.8, alpha = 0.8) +
  {if (nrow(violations_data) > 0)
    geom_point(data = violations_data, aes(y = Return, shape = "Violation"),
              color = "black", size = 3, stroke = 1.5, fill = NA)} +
  scale_color_manual(
    values = c("Actual Return" = "blue", "CoVaR 5%" = "orange", "CoVaR 1%" = "orange"),
    name = "Line Type") +
  {if (nrow(violations_data) > 0)
    scale_shape_manual(values = c("Violation" = 1), name = "")} +
  scale_y_continuous(labels = scales::percent_format(accuracy = 0.1),
                     breaks = if (!is.null(ylim)) nice_breaks(ylim) else scales::pretty_breaks(n = 8))
+
  coord_cartesian(ylim = ylim) +
  scale_x_date(date_breaks = "3 months", date_labels = "%b %Y",
               expand = c(0.02, 0)) +
  labs(
    title = paste("Perbandingan CoVaR", title_tau, "vs Actual Return -", saham),
    subtitle = paste("Violations:", nrow(violations_data),
                    "(", round(nrow(violations_data) / nrow(plot_data) * 100, 2), "%)"),
    x = "Tanggal", y = "Return / CoVaR"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    plot.subtitle = element_text(hjust = 0.5, size = 11, color = "darkred"),
    axis.text.x = element_text(angle = 45, hjust = 1),
    axis.title = element_text(face = "bold"),
    legend.position = "bottom",
    panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
    panel.grid.minor = element_blank()
  ) +
  guides(color = guide_legend(order = 1), shape = guide_legend(order = 2))
return(p)
}

#### Plot CoVaR Kuantil 1% -----
# ylim CoVaR 1%: min/max dari (return semua emiten, CoVaR 1% semua emiten)
all_covar01 <- unlist(CoVaR_01)
ylim_covar01 <- c(
  min(c(all_returns_global, all_covar01), na.rm = TRUE),
  max(c(all_returns_global, all_covar01), na.rm = TRUE)
)
for (saham in saham_names) {
  print(plot_covar_vs_return_ggplot(saham, comparison_data_covar_01, 0.01, ylim =
ylim_covar01))
}

```

```

}

### Plot CoVaR Kuantil 5% -----
# ylim CoVaR 5%: min/max dari (return semua emiten, CoVaR 5% semua emiten)
all_covar05 <- unlist(CoVaR_05)
ylim_covar05 <- c(
  min(c(all_returns_global, all_covar05), na.rm = TRUE),
  max(c(all_returns_global, all_covar05), na.rm = TRUE)
)
for (saham in saham_names) {
  print(plot_covar_vs_return_ggplot(saham, comparison_data_covar_05, 0.05, ylim =
ylim_covar05))
}

```

Lampiran 31 Syntax Proportion Shortfall CoVaR Kuantil 1% dan 5%

```

####A. Proportion Shortfall CoVaR -----
proportion_shortfall_covar <- function(actual_return_i, CoVaR_i, tau) {
  # Align panjang vektor
  n_min <- min(length(actual_return_i), length(CoVaR_i))
  actual_return_i <- tail(as.numeric(actual_return_i), n_min)
  CoVaR_i <- tail(as.numeric(CoVaR_i), n_min)
  exceedances <- actual_return_i < CoVaR_i
  exceedance_ratio <- sum(exceedances) / length(exceedances)
  actual_exceed <- sum(exceedances)
  selisih <- abs(tau - exceedance_ratio)
  list(
    Proportion_Shortfall = round(exceedance_ratio, 4),
    Jumlah_Pelanggaran = actual_exceed,
    Selisih_Resiko = round(selisih, 4),
    Proportion_Pelanggaran = round(length(actual_return_i) * tau),
    Total_Observasi = length(actual_return_i)
  )
}

ps_covar_01 <- list()
ps_covar_05 <- list()

for (saham in saham_names) {
  y_i <- tail(return_df[[saham]], n_obs) # return saham i
  ps_covar_01[[saham]] <- proportion_shortfall_covar(
    y_i, CoVaR_01[[paste0("CoVaR_", saham)]], 0.01)
  ps_covar_05[[saham]] <- proportion_shortfall_covar(
    y_i, CoVaR_05[[paste0("CoVaR_", saham)]], 0.05)
}

##### Kuantil 1% -----
df_ps_covar_01 <- do.call(rbind, lapply(names(ps_covar_01), function(s)
  data.frame(Saham = s, as.data.frame(ps_covar_01[[s]])))
)

```

```

print(df_ps_covar_01)

##### Kuantil 5% -----
df_ps_covar_05 <- do.call(rbind, lapply(names(ps_covar_05), function(s)
  data.frame(Saham = s, as.data.frame(ps_covar_05[[s]])))
)
print(df_ps_covar_05)

```

Lampiran 32 Syntax Kupiec Test CoVaR Kuantil 1% dan 5%

```

####B. Kupiec test CoVaR -----
Kupiec_CoVaR <- function(y_i, CoVaR_i, tau, verbose = TRUE, alpha = 0.05) {
  n_min <- min(length(y_i), length(CoVaR_i))
  y_i <- tail(as.numeric(y_i), n_min)
  CoVaR_i <- tail(as.numeric(CoVaR_i), n_min)
  N <- n_min
  hit <- numeric(N)
  hit[y_i < CoVaR_i] <- 1
  numOfFails <- sum(hit)
  p <- tau

  lr <- if (numOfFails == 0 || numOfFails == N) 0 else
    -2 * log(
      (((1-p)^(N - numOfFails)) * (p^numOfFails)) /
      ((1 - numOfFails/N)^(N - numOfFails)) * (numOfFails/N)^numOfFails
    )

  chi_crit <- qchisq(alpha, 1, lower.tail = FALSE)
  p_value <- 1 - pchisq(lr, df = 1)
  keputusan <- ifelse(lr > chi_crit, "Tolak H0", "Gagal Tolak H0")

  if (verbose) cat(keputusan, "| tau =", tau*100, "% | violations =", numOfFails,
    "| LR =", round(lr, 4), "| p-value =", round(p_value, 4), "\n")

  return(data.frame(
    p_value = round(p_value, 3),
    LR_stat = round(lr, 3),
    Chi_Crit = round(chi_crit, 3),
    Jumlah_Pelanggaran = numOfFails,
    Expected_Pelanggaran = round(N * tau),
    Total_Observasi = N,
    Hasil_Uji = keputusan
  ))
}
kupiec_covar_01 <- list()
kupiec_covar_05 <- list()

##### Kupiec Test CoVaR 1% -----
kupiec_covar_01 <- list()
for (saham in saham_names) {

```

```

y_i <- tail(return_df[[saham]], n_obs)

kupiec_covar_01[[saham]] <- data.frame(
  Saham = saham,
  Kupiec_CoVaR(y_i, CoVaR_01[[paste0("CoVaR_", saham)]], tau = 0.01)
)
}

df_kupiec_covar_01 <- do.call(rbind, kupiec_covar_01)
rownames(df_kupiec_covar_01) <- NULL
print(df_kupiec_covar_01)

##### Kupiec Test CoVaR 5% -----
kupiec_covar_05 <- list()
for (saham in saham_names) {
  y_i <- tail(return_df[[saham]], n_obs)

  kupiec_covar_05[[saham]] <- data.frame(
    Saham = saham,
    Kupiec_CoVaR(y_i, CoVaR_05[[paste0("CoVaR_", saham)]], tau = 0.05)
  )
}

df_kupiec_covar_05 <- do.call(rbind, kupiec_covar_05)
rownames(df_kupiec_covar_05) <- NULL

print(df_kupiec_covar_05)

```

Lampiran 33 Syntax Δ CoVaR Kuantil 1% dan 5%

```

VaR50_aktif <- VaR50[, saham_names]
head(VaR50_aktif)

# CoVaR kondisi NORMAL (tau = 0.01, predictor = VaR50 → pasar di kondisi median)
cat("\n--- Menghitung CoVaR Normal tau=0.01 (predictor = VaR50) ---\n")
covar_ASII1_50 <- covarr_qrf(tail(return_data$ASII, n_obs), VaR50_aktif, 1,
tail(VaR50_aktif$ASII, n_obs), 0.01, seed = 123)
covar_IMPC1_50 <- covarr_qrf(tail(return_data$IMPC, n_obs), VaR50_aktif, 2,
tail(VaR50_aktif$IMPC, n_obs), 0.01, seed = 123)
covar_UNTR1_50 <- covarr_qrf(tail(return_data$UNTR, n_obs), VaR50_aktif, 3,
tail(VaR50_aktif$UNTR, n_obs), 0.01, seed = 123)
covar_SKRN1_50 <- covarr_qrf(tail(return_data$SKRN, n_obs), VaR50_aktif, 4,
tail(VaR50_aktif$SKRN, n_obs), 0.01, seed = 123)
covar_SINI1_50 <- covarr_qrf(tail(return_data$SINI, n_obs), VaR50_aktif, 5,
tail(VaR50_aktif$SINI, n_obs), 0.01, seed = 123)
covar_SMIL1_50 <- covarr_qrf(tail(return_data$SMIL, n_obs), VaR50_aktif, 6,
tail(VaR50_aktif$SMIL, n_obs), 0.01, seed = 123)
covar_ARNA1_50 <- covarr_qrf(tail(return_data$ARNA, n_obs), VaR50_aktif, 7,
tail(VaR50_aktif$ARNA, n_obs), 0.01, seed = 123)

```

```

covar_TOTO1_50 <- covarr_qrf(tail(return_data$TOTO, n_obs), VaR50_aktif, 8,
tail(VaR50_aktif$TOTO, n_obs), 0.01, seed = 123)
covar_MARK1_50 <- covarr_qrf(tail(return_data$MARK, n_obs), VaR50_aktif, 9,
tail(VaR50_aktif$MARK, n_obs), 0.01, seed = 123)

# CoVaR kondisi NORMAL (tau = 0.05, predictor = VaR50 → pasar di kondisi median)
cat("\n--- Menghitung CoVaR Normal tau=0.05 (predictor = VaR50) ---\n")
covar_ASII5_50 <- covarr_qrf(tail(return_data$ASII, n_obs), VaR50_aktif, 1,
tail(VaR50_aktif$ASII, n_obs), 0.05, seed = 123)
covar_IMPC5_50 <- covarr_qrf(tail(return_data$IMPC, n_obs), VaR50_aktif, 2,
tail(VaR50_aktif$IMPC, n_obs), 0.05, seed = 123)
covar_UNTR5_50 <- covarr_qrf(tail(return_data$UNTR, n_obs), VaR50_aktif, 3,
tail(VaR50_aktif$UNTR, n_obs), 0.05, seed = 123)
covar_SKRN5_50 <- covarr_qrf(tail(return_data$SKRN, n_obs), VaR50_aktif, 4,
tail(VaR50_aktif$SKRN, n_obs), 0.05, seed = 123)
covar_SINI5_50 <- covarr_qrf(tail(return_data$SINI, n_obs), VaR50_aktif, 5,
tail(VaR50_aktif$SINI, n_obs), 0.05, seed = 123)
covar_SMIL5_50 <- covarr_qrf(tail(return_data$SMIL, n_obs), VaR50_aktif, 6,
tail(VaR50_aktif$SMIL, n_obs), 0.05, seed = 123)
covar_ARNA5_50 <- covarr_qrf(tail(return_data$ARNA, n_obs), VaR50_aktif, 7,
tail(VaR50_aktif$ARNA, n_obs), 0.05, seed = 123)
covar_TOTO5_50 <- covarr_qrf(tail(return_data$TOTO, n_obs), VaR50_aktif, 8,
tail(VaR50_aktif$TOTO, n_obs), 0.05, seed = 123)
covar_MARK5_50 <- covarr_qrf(tail(return_data$MARK, n_obs), VaR50_aktif, 9,
tail(VaR50_aktif$MARK, n_obs), 0.05, seed = 123)

## Delta CoVaR kuantil 1% -----
# ΔCoVaR = CoVaR(distress, predictor=VaR01) - CoVaR(normal, predictor=VaR50)
delta_covar_ASII1 <- covar_results_01[["ASII"]] - covar_ASII1_50$covar
delta_covar_IMPC1 <- covar_results_01[["IMPC"]] - covar_IMPC1_50$covar
delta_covar_UNTR1 <- covar_results_01[["UNTR"]] - covar_UNTR1_50$covar
delta_covar_SKRN1 <- covar_results_01[["SKRN"]] - covar_SKRN1_50$covar
delta_covar_SINI1 <- covar_results_01[["SINI"]] - covar_SINI1_50$covar
delta_covar_SMIL1 <- covar_results_01[["SMIL"]] - covar_SMIL1_50$covar
delta_covar_ARNA1 <- covar_results_01[["ARNA"]] - covar_ARNA1_50$covar
delta_covar_TOTO1 <- covar_results_01[["TOTO"]] - covar_TOTO1_50$covar
delta_covar_MARK1 <- covar_results_01[["MARK"]] - covar_MARK1_50$covar

delta_covar01 <- data.frame(
  ASII = delta_covar_ASII1,
  IMPC = delta_covar_IMPC1,
  UNTR = delta_covar_UNTR1,
  SKRN = delta_covar_SKRN1,
  SINI = delta_covar_SINI1,
  SMIL = delta_covar_SMIL1,
  ARNA = delta_covar_ARNA1,
  TOTO = delta_covar_TOTO1,
  MARK = delta_covar_MARK1
)

```

```

print(head(delta_covar01))

## Delta CoVaR kuantil 5% -----
# ΔCoVaR = CoVaR(distress, predictor=VaR05) - CoVaR(normal, predictor=VaR50)
delta_covar_ASII5 <- covar_results_05[["ASII"]] - covar_ASII5_50$covar
delta_covar_IMPC5 <- covar_results_05[["IMPC"]] - covar_IMPC5_50$covar
delta_covar_UNTR5 <- covar_results_05[["UNTR"]] - covar_UNTR5_50$covar
delta_covar_SKRN5 <- covar_results_05[["SKRN"]] - covar_SKRN5_50$covar
delta_covar_SINI5 <- covar_results_05[["SINI"]] - covar_SINI5_50$covar
delta_covar_SMIL5 <- covar_results_05[["SMIL"]] - covar_SMIL5_50$covar
delta_covar_ARNA5 <- covar_results_05[["ARNA"]] - covar_ARNA5_50$covar
delta_covar_TOTO5 <- covar_results_05[["TOTO"]] - covar_TOTO5_50$covar
delta_covar_MARK5 <- covar_results_05[["MARK"]] - covar_MARK5_50$covar

delta_covar05 <- data.frame(
  ASII = delta_covar_ASII5,
  IMPC = delta_covar_IMPC5,
  UNTR = delta_covar_UNTR5,
  SKRN = delta_covar_SKRN5,
  SINI = delta_covar_SINI5,
  SMIL = delta_covar_SMIL5,
  ARNA = delta_covar_ARNA5,
  TOTO = delta_covar_TOTO5,
  MARK = delta_covar_MARK5
)
print(head(delta_covar05))

```

Lampiran 34 Hasil ΔCoVaR Kuantil 1%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
0,0000	0,0000	0,0142	-0,0313	0,0344	-0,0018	0,0012	0,0000	0,0255
0,0584	0,0000	0,0142	-0,0318	-0,0967	-0,0291	-0,0032	0,0000	-0,0028
0,0000	0,0021	0,0108	0,0000	0,0000	-0,0106	0,0105	0,0139	0,0066
0,0493	0,0000	0,0865	-0,0033	0,0000	0,0000	0,0012	0,0054	0,0000
0,0584	0,0072	0,0047	-0,0179	0,0000	0,0000	0,0000	-0,0076	-0,0004
0,0051	0,0048	-0,0014	0,0000	0,0000	-0,0106	0,0032	0,0185	0,0028
0,0001	0,0003	0,0142	-0,0409	0,0967	0,0294	0,0000	0,0320	0,0000
-0,0081	-0,0003	-0,0832	0,0000	0,0000	0,0294	0,0000	0,0003	0,0000
0,0010	0,0000	0,0000	0,0000	0,0000	0,0000	0,0028	0,0008	0,0000
0,0001	0,0048	0,0000	0,0237	0,0000	0,0294	0,0407	0,0170	0,0000
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
0,0000	0,0000	0,0122	-0,0485	0,0000	-0,0400	0,0186	0,0244	-0,0226
0,0001	0,0005	0,0033	-0,0376	-0,0344	0,0481	0,0008	-0,0074	0,0000
0,0000	0,0068	-0,0070	0,0172	0,0000	-0,0106	0,0412	0,0000	0,0000
0,0061	0,0000	0,0000	-0,0485	-0,1500	-0,0180	-0,0041	0,0054	0,0133
-0,0001	-0,0118	0,0000	0,0000	0,0189	-0,0025	-0,0041	-0,0098	0,0178
0,0000	0,0000	0,0014	0,0000	0,0000	0,0722	-0,0401	-0,0185	0,0000
0,0051	0,0000	0,0000	-0,0179	0,0000	0,0902	-0,0012	0,0170	0,0028
0,0001	0,0000	0,0108	-0,0179	-0,0189	0,0000	-0,0008	-0,0135	0,0000
0,0006	0,0051	0,0000	0,0000	0,0000	0,0400	0,0041	0,0054	0,0114
0,0000	-0,0051	0,0108	0,0000	0,0000	0,0481	-0,0186	-0,0085	0,0028

Lampiran 35 Hasil ΔCoVaR Kuantil 5%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
-0,0003	0,0078	-0,0005	0,0161	-0,0006	0,0005	0,0081	-0,0073	-0,0037
0,0016	0,0004	-0,0077	0,0005	-0,0009	0,0233	0,0000	-0,0004	-0,0128
0,0008	-0,0026	0,0082	0,0000	0,0011	-0,0181	0,0006	-0,0067	0,0107
-0,0006	-0,0026	0,0000	-0,0053	0,0000	0,0049	0,0069	-0,0001	0,0000
0,0044	-0,0026	-0,0007	-0,0128	-0,0010	0,0496	0,0001	-0,0072	0,0000
-0,0003	-0,0022	-0,0086	0,0122	0,0000	0,0000	-0,0009	0,0000	0,0043
0,0000	0,0006	0,0000	0,0110	0,0000	-0,0075	-0,0039	-0,0001	0,0000
-0,0001	-0,0031	0,0012	0,0000	-0,0008	0,0000	0,0000	-0,0002	0,0000
0,0001	0,0000	0,0059	-0,0055	-0,0002	0,0000	-0,0053	0,0000	0,0000
-0,0009	0,0000	0,0000	0,0067	0,0000	-0,0030	-0,0044	0,0006	-0,0039
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
0,0012	-0,0012	0,0014	-0,0163	-0,0055	0,0027	0,0048	0,0076	-0,0112
-0,0003	0,0015	0,0005	-0,0023	-0,0003	0,0377	0,0015	-0,0004	0,0000
-0,0020	0,0000	0,0005	0,0157	0,0002	-0,0047	0,0006	-0,0006	0,0032
0,0000	-0,0023	-0,0014	0,0209	-0,0007	0,0000	0,0034	0,0001	-0,0109
0,0000	0,0000	-0,0029	0,0086	0,0004	-0,0014	0,0009	-0,0071	-0,0008
0,0001	-0,0026	0,0014	0,0049	-0,0001	0,0000	-0,0041	-0,0011	0,0002
0,0012	0,0015	0,0015	-0,0087	0,0000	0,0195	0,0031	-0,0001	0,0000
0,0002	0,0000	0,0073	-0,0049	-0,0007	-0,0362	-0,0011	-0,0008	0,0000
0,0009	0,0004	0,0009	0,0000	0,0019	0,0376	-0,0006	0,0003	0,0071
0,0083	-0,0042	0,0043	0,0018	0,0000	0,0189	-0,0093	-0,0074	-0,0007

Lampiran 36 Syntax Statistika Deskriptif ΔCoVaR Kuantil 1% dan 5%

```

statdes_deltacovar <- function(delta_df, saham_names, label) {
  cat("\n=== Statistika Deskriptif Delta CoVaR", label, "===\n")
  tabel <- do.call(rbind, lapply(saham_names, function(s) {
    v <- delta_df[[s]]
    data.frame(Saham = s,
               Mean   = round(mean(v), 5),
               Max    = round(max(v), 5),
               Min    = round(min(v), 5),
               Varians = round(var(v), 5))
  )))
  print(tabel)
  return(invisible(tabel))
}

```

```
statdes_deltacovar(delta_covar01, saham_names, "Kuantil 1%")
```

```
statdes_deltacovar(delta_covar05, saham_names, "Kuantil 5%")
```

Lampiran 37 Syntax Plot ΔCoVaR 1% dan 5% vs Actual Return

```

## Plot Delta CoVaR -----
plot_delta_covar_ggplot <- function(saham, return_df, delta_covar01, delta_covar05, n_obs,
ylim = NULL) {
  plot_data <- data.frame(
    Tanggal    = tail(return_df$Tanggal, n_obs),
    Return     = tail(return_df[[saham]], n_obs),
    DeltaCoVaR_1 = delta_covar01[[saham]],
    DeltaCoVaR_5 = delta_covar05[[saham]]
  )
}

```

```

)

p <- ggplot(plot_data, aes(x = Tanggal)) +
  geom_line(aes(y = Return, color = "Actual Return"), linewidth = 0.8, alpha = 0.8) +
  geom_line(aes(y = DeltaCoVaR_1, color = "ΔCoVaR 1%"), linewidth = 0.8, alpha =
0.8) +
  geom_line(aes(y = DeltaCoVaR_5, color = "ΔCoVaR 5%"), linewidth = 0.8, alpha =
0.8) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50", linewidth = 0.4) +
  scale_color_manual(
    values = c("Actual Return" = "#00BAFF",
              "ΔCoVaR 1%" = "orange",
              "ΔCoVaR 5%" = "red"),
    name = "Line Type") +
  scale_y_continuous(labels = scales::percent_format(accuracy = 0.1),
                     breaks = if (!is.null(ylim)) nice_breaks(ylim) else scales::pretty_breaks(n = 8))
+
  coord_cartesian(ylim = ylim) +
  scale_x_date(date_breaks = "3 months", date_labels = "%b %Y",
              expand = c(0.02, 0)) +
  labs(
    title = paste("Perbandingan ΔCoVaR 1% vs ΔCoVaR 5% vs Actual Return -", saham),
    subtitle = "ΔCoVaR = CoVaR(distress) - CoVaR(normal)",
    x = "Tanggal", y = "Return / ΔCoVaR"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    plot.subtitle = element_text(hjust = 0.5, size = 11, color = "darkred"),
    axis.text.x = element_text(angle = 45, hjust = 1),
    axis.title = element_text(face = "bold"),
    legend.position = "bottom",
    panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
    panel.grid.minor = element_blank()
  )
return(p)
}

# ylim Delta CoVaR: min/max dari (return semua emiten, ΔCoVaR 1% semua emiten,
ΔCoVaR 5% semua emiten)
all_delta01 <- unlist(delta_covar01)
all_delta05 <- unlist(delta_covar05)
ylim_delta <- c(
  min(c(all_returns_global, all_delta01, all_delta05), na.rm = TRUE),
  max(c(all_returns_global, all_delta01, all_delta05), na.rm = TRUE)
)
for (saham in saham_names) {
  print(plot_delta_covar_ggplot(saham, return_df, delta_covar01, delta_covar05, n_obs, ylim
= ylim_delta))
}

```

```
}
```

Lampiran 38 Syntax Estimasi CoVaR SSVS

```
library(quantregForest)
library(randomForest)
library(ggplot2)
library(reshape2)
library(dplyr)

## Fungsi Pinball Loss -----
pinball_loss <- function(y, y_pred, tau) {
  u <- y - y_pred
  mean(u * (tau - as.numeric(u < 0)), na.rm = TRUE)
}

##Fungsi QRF dengan MOVING BLOCK BOOTSTRAP (MBB) -----
qrf_dengan_bootstrap <- function(X, Y, quantiles = c(0.05, 0.01),
                                num.trees = 1000, block_size = 63) {
  if (is.matrix(X))
    X_boot <- apply(X, 2, moving_block_bootstrap, block_size = block_size)
  else
    X_boot <- matrix(moving_block_bootstrap(as.numeric(X), block_size), ncol = 1)
  Y_boot <- moving_block_bootstrap(as.numeric(Y), block_size)
  quantile_forest(X = X_boot, Y = Y_boot, quantiles = quantiles,
                  num.trees = num.trees, min.node.size = 5,
                  honesty = TRUE, honesty.fraction = 0.5)
}

## Fungsi SSVS-QRF Adaptive -----
ssvs_qrf_adaptive <- function(y,
                              X,
                              tau = 0.05,
                              Prior_pi,
                              ntree = 150,
                              mcmc_max = 1500,
                              mcmc_min = 400,
                              burnin_pct = 0.20,
                              min_burnin = 100,
                              check_interval = 100,
                              conv_threshold = 0.05,
                              lambda = NULL,
                              seed = 123,
                              verbose = TRUE) {

  set.seed(seed)
  y <- as.numeric(y)
  X <- as.matrix(X)
  n <- length(y)
  p <- ncol(X)
```

```

var_names <- colnames(X)

### --- Prior: min-max scaling VI ke [0.1, 0.9] -----
p_i <- Prior_pi[var_names]
p_i[is.na(p_i)] <- 0.5
p_range <- max(p_i) - min(p_i)
if (p_range > 0) {
  p_i <- 0.1 + 0.8 * (p_i - min(p_i)) / p_range
} else {
  p_i <- rep(0.5, p)
}
names(p_i) <- var_names

if (verbose) {
  cat("\n", strep("=", 70), "\n")
  cat("SSVS-QRF ADAPTIVE | tau =", tau, "\n")
  cat("MCMC max:", mcmc_max, "| MCMC min:", mcmc_min,
      "| Burn-in:", paste0(burnin_pct * 100, "% (min ", min_burnin, ")"), "\n")
  cat("Conv threshold:", conv_threshold,
      "| Check interval:", check_interval, "\n")
  cat("Lambda:", ifelse(is.null(lambda), "Adaptif (0.5/p_aktif)", lambda), "\n")
  cat("Prediktor (p):", p, "\n")
  cat("Prior p_i:\n"); print(round(sort(p_i, decreasing = TRUE), 4))
  cat(strep("=", 70), "\n\n")
}

### --- Inisialisasi -----
gamma_current <- rep(1L, p)
names(gamma_current) <- var_names
gamma_chain <- matrix(0L, nrow = mcmc_max, ncol = p)
colnames(gamma_chain) <- var_names

PIP_old <- rep(0, p)
converged <- FALSE
final_iter <- mcmc_max
conv_iter <- NA

if (verbose) cat(">>> Menjalankan MCMC Metropolis-within-Gibbs (Adaptive)...\n\n")

### --- MCMC Loop -----
for (m in 1:mcmc_max) {

  # Pastikan minimal 1 variabel aktif
  if (sum(gamma_current) == 0) gamma_current[which.max(p_i)] <- 1L

  for (i in 1:p) {

    ## Model dengan  $\gamma_i = 1$  [Pers. 2.84]
    gamma_with <- gamma_current; gamma_with[i] <- 1L

```

```

idx_with <- which(gamma_with == 1)
qrf_with <- quantregForest(x = as.matrix(X[, idx_with, drop = FALSE]),
                          y = y, ntree = ntree)
pred_with <- as.numeric(predict(qrf_with,
                              newdata = as.matrix(X[, idx_with, drop = FALSE]),
                              what = tau))
loss_with <- pinball_loss(y, pred_with, tau)

## Model dengan  $\gamma_i = 0$ 
gamma_without <- gamma_current; gamma_without[i] <- 0L
idx_without <- which(gamma_without == 1)
if (length(idx_without) > 0) {
  qrf_without <- quantregForest(x = as.matrix(X[, idx_without, drop = FALSE]),
                              y = y, ntree = ntree)
  pred_without <- as.numeric(predict(qrf_without,
                                    newdata = as.matrix(X[, idx_without, drop = FALSE]),
                                    what = tau))
  loss_without <- pinball_loss(y, pred_without, tau)
} else {
  loss_without <- loss_with + abs(loss_with) + 1
}

## Lambda adaptif: penalti mengecil saat lebih sedikit variabel aktif
lam_i <- if (is.null(lambda)) 0.5 / max(1L, sum(gamma_with)) else lambda

## Likelihood Ratio (safe: cegah overflow/underflow/NA)
delta_loss <- loss_with - loss_without
if (is.na(delta_loss) || !is.finite(delta_loss)) {
  LR_i <- 1
} else {
  log_LR <- -lam_i * delta_loss
  if (log_LR > 700) LR_i <- 1e15
  else if (log_LR < -700) LR_i <- .Machine$double.eps
  else LR_i <- exp(log_LR)
  LR_i <- max(LR_i, .Machine$double.eps)
}
if (is.infinite(LR_i) || is.nan(LR_i)) LR_i <- 1e10

## Update  $\gamma_i \sim \text{Bernoulli}$  [Pers. 2.85]
prob_incl <- (p_i[i] * LR_i) / (p_i[i] * LR_i + (1 - p_i[i]))
if (is.nan(prob_incl) || is.infinite(prob_incl))
  prob_incl <- ifelse(LR_i > 1, 1, 0)
prob_incl <- min(max(prob_incl, 0), 1)
gamma_current[i] <- rbinom(1, 1, prob_incl)
}

gamma_chain[m, ] <- gamma_current

if (verbose && (m %% check_interval == 0 || m == 1)) {

```

```

cat(sprintf(" Iter %4d | Aktif: %d | %s\n",
           m, sum(gamma_current),
           paste(var_names[gamma_current == 1], collapse = ", ")))
}

### --- Cek Konvergensi (setelah mcmc_min iterasi) -----
if (m >= mcmc_min && m %% check_interval == 0) {
  current_burnin <- max(min_burnin, floor(m * burnin_pct))
  if (m > current_burnin) {
    gamma_post_tmp <- gamma_chain[(current_burnin + 1):m, , drop = FALSE]
    PIP_new <- colMeans(gamma_post_tmp)
    max_change <- max(abs(PIP_new - PIP_old), na.rm = TRUE)
    if (verbose)
      cat(sprintf(" [CONV] Iter %d | Burn-in: %d | Max PIP change = %.5f (threshold =
%.4f)\n",
                  m, current_burnin, max_change, conv_threshold))
    if (max_change < conv_threshold) {
      converged <- TRUE; final_iter <- m; conv_iter <- m
      if (verbose) cat(" ✓ KONVERGEN pada iterasi", m, "\n")
      break
    }
    PIP_old <- PIP_new
  }
}
}

if (verbose && !converged)
  cat(" ⚠ Mencapai batas maksimum", mcmc_max, "iterasi tanpa konvergensi\n")

## --- Post-processing -----
burnin_final <- max(min_burnin, floor(final_iter * burnin_pct))
post_burnin <- gamma_chain[(burnin_final + 1):final_iter, , drop = FALSE]
pip <- colMeans(post_burnin)
names(pip) <- var_names

selected_moderat <- var_names[pip >= 0.5]
selected_konservatif <- var_names[pip >= 0.7]
selected_sangat_ketat <- var_names[pip >= 0.9]

results_df <- data.frame(
  Variable = var_names,
  Prior = round(p_i, 4),
  PIP = round(pip, 4),
  Terpilih = ifelse(pip >= 0.5, "Ya (PIP≥0.5)", "Tidak"),
  stringsAsFactors = FALSE
)
results_df <- results_df[order(-results_df$PIP), ]

if (verbose) {

```

```

cat("\n", strrep("-", 60), "\n")
cat("POSTERIOR INCLUSION PROBABILITY (PIP) | tau =", tau, "\n")
cat(strrep("-", 60), "\n")
print(results_df)
cat("\nSeleksi Variabel:\n")
cat(" Moderat (PIP  $\geq$  0.5):", paste(selected_moderat, collapse = ", "), "\n")
cat(" Konservatif (PIP  $\geq$  0.7):", paste(selected_konservatif, collapse = ", "), "\n")
cat(" Sangat ketat (PIP  $\geq$  0.9):", paste(selected_sangat_ketat, collapse = ", "), "\n")
cat(" Iterasi final:", final_iter, "| Burn-in final:", burnin_final,
    "\n", round(burnin_final/final_iter*100), "%) | Post-burnin:", final_iter - burnin_final,
    "\n")
cat(" Status:", ifelse(converged, "KONVERGEN", "MAX ITER TERCAPAI"), "\n")
cat(strrep("-", 60), "\n\n")
}

return(list(
  pip = pip,
  Prior_pi = p_i,
  gamma_chain = gamma_chain[1:final_iter, , drop = FALSE],
  post_burnin = post_burnin,
  selected_moderat = selected_moderat,
  selected_konservatif = selected_konservatif,
  selected_sangat_ketat = selected_sangat_ketat,
  results_df = results_df,
  var_names = var_names,
  tau = tau,
  mcmc_final = final_iter,
  mcmc_max = mcmc_max,
  n_burnin = burnin_final,
  burnin_pct = burnin_pct,
  converged = converged,
  convergence_iter = conv_iter,
  lambda = lambda
))
}

```

Lampiran 39 Syntax Eksekusi SSVS untuk Masing-Masing Emiten

```

VaR01_100 <- VaR01[, saham_names] * 100
VaR05_100 <- VaR05[, saham_names] * 100
CoVaR_01_100 <- CoVaR_01 * 100
CoVaR_05_100 <- CoVaR_05 * 100

ssvs_results_01 <- list()
ssvs_results_05 <- list()
CoVaR_SSVS_01 <- list()
CoVaR_SSVS_05 <- list()

conv_summary_01 <- data.frame()
conv_summary_05 <- data.frame()

```

```

simpan_konv <- function(df, ssvs_res, saham_i) {
  rbind(df, data.frame(
    Saham      = saham_i,
    Iterasi_Final = ssvs_res$mcmc_final,
    Burn_in     = ssvs_res$n_burnin,
    Burn_in_Pct  = round(ssvs_res$n_burnin / ssvs_res$mcmc_final * 100, 1),
    Post_Burnin  = ssvs_res$mcmc_final - ssvs_res$n_burnin,
    Konvergen    = ssvs_res$converged,
    Konvergen_Pada = ifelse(ssvs_res$converged, ssvs_res$convergence_iter, NA),
    stringsAsFactors = FALSE
  ))
}

run_analisis_per_tau <- function(saham_i, ssvs_result, X_100, y_ssvs, tau,
                                VaR_asli, return_df, seed = 1000) {
  tau_label <- ifelse(tau == 0.01, "1%", "5%")

  sel <- if (length(ssvs_result$selected_moderat) > 0)
    ssvs_result$selected_moderat else names(which.max(ssvs_result$pi))

  cat(sprintf("\nVariabel terpilih (PIP>=0.5): %s\n", paste(sel, collapse = ", ")))

  X_sel_asli <- as.matrix(VaR_asli[, sel, drop = FALSE])
  y_ret_asli <- as.numeric(tail(return_df[, saham_i], nrow(X_sel_asli)))
  n_min <- min(nrow(X_sel_asli), length(y_ret_asli))
  X_sel_asli <- X_sel_asli[1:n_min, , drop = FALSE]
  y_ret_asli <- y_ret_asli[1:n_min]

  cat(sprintf("\nMelatih QRF final (MBB, n=%d, p=%d)... \n", n_min, length(sel)))
  set.seed(seed)
  qrf_final <- qrf_dengan_bootstrap(
    X      = X_sel_asli,
    Y      = y_ret_asli,
    quantiles = tau,
    num.trees = 1000,
    block_size = 63
  )
  pred_raw <- predict(qrf_final, X_sel_asli, quantiles = tau)
  if (is.matrix(pred_raw)) covar_ssvs <- pred_raw[, 1]
  else if (is.list(pred_raw) && "predictions" %in% names(pred_raw))
    covar_ssvs <- pred_raw$predictions[, 1]
  else
    covar_ssvs <- as.numeric(pred_raw)

  return(covar_ssvs)
}

### EMITEN 1: ASII -----
saham_i <- "ASII"

```

```

saham_minus_i <- setdiff(saham_names, saham_i)

X_ASII_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_ASII_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_ASII_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_ASII_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_ASII_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_ASII_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_ASII_01 <- ssvs_qrf_adaptive(y_ASII_01, X_ASII_01, 0.01, Prior_ASII_01, seed =
124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_ASII_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_ASII_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_ASII_01, X_ASII_01,
y_ASII_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_ASII_05 <- ssvs_qrf_adaptive(y_ASII_05, X_ASII_05, 0.05, Prior_ASII_05, seed =
124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_ASII_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_ASII_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_ASII_05, X_ASII_05,
y_ASII_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 2: IMPC -----
saham_i <- "IMPC"
saham_minus_i <- setdiff(saham_names, saham_i)

X_IMPC_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_IMPC_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_IMPC_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_IMPC_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_IMPC_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_IMPC_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_IMPC_01 <- ssvs_qrf_adaptive(y_IMPC_01, X_IMPC_01, 0.01, Prior_IMPC_01,
seed = 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_IMPC_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_IMPC_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_IMPC_01,
X_IMPC_01, y_IMPC_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_IMPC_05 <- ssvs_qrf_adaptive(y_IMPC_05, X_IMPC_05, 0.05, Prior_IMPC_05,
seed = 124, verbose = TRUE)

```

```

ssvs_results_05[[saham_i]] <- ssvs_IMPC_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_IMPC_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_IMPC_05,
X_IMPC_05, y_IMPC_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
  seed = 1000)

### EMITEN 3: UNTR -----
saham_i <- "UNTR"
saham_minus_i <- setdiff(saham_names, saham_i)

X_UNTR_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_UNTR_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_UNTR_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_UNTR_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_UNTR_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_UNTR_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_UNTR_01 <- ssvs_qrf_adaptive(y_UNTR_01, X_UNTR_01, 0.01, Prior_UNTR_01,
seed = 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_UNTR_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_UNTR_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_UNTR_01,
X_UNTR_01, y_UNTR_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
  seed = 1000)

ssvs_UNTR_05 <- ssvs_qrf_adaptive(y_UNTR_05, X_UNTR_05, 0.05, Prior_UNTR_05,
seed = 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_UNTR_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_UNTR_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_UNTR_05,
X_UNTR_05, y_UNTR_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
  seed = 1000)

### EMITEN 4: SKRN -----
saham_i <- "SKRN"
saham_minus_i <- setdiff(saham_names, saham_i)

X_SKRN_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_SKRN_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_SKRN_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_SKRN_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_SKRN_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_SKRN_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_SKRN_01 <- ssvs_qrf_adaptive(y_SKRN_01, X_SKRN_01, 0.01, Prior_SKRN_01,
seed = 124, verbose = TRUE)

```

```

ssvs_results_01[[saham_i]] <- ssvs_SKRN_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_SKRN_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SKRN_01,
X_SKRN_01, y_SKRN_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_SKRN_05 <- ssvs_qrf_adaptive(y_SKRN_05, X_SKRN_05, 0.05, Prior_SKRN_05,
seed = 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_SKRN_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_SKRN_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SKRN_05,
X_SKRN_05, y_SKRN_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 5: SINI -----
saham_i <- "SINI"
saham_minus_i <- setdiff(saham_names, saham_i)

X_SINI_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_SINI_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_SINI_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)])])
y_SINI_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)])])
Prior_SINI_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_SINI_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_SINI_01 <- ssvs_qrf_adaptive(y_SINI_01, X_SINI_01, 0.01, Prior_SINI_01, seed =
124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_SINI_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_SINI_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SINI_01, X_SINI_01,
y_SINI_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_SINI_05 <- ssvs_qrf_adaptive(y_SINI_05, X_SINI_05, 0.05, Prior_SINI_05, seed =
124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_SINI_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_SINI_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SINI_05, X_SINI_05,
y_SINI_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 6: SMIL -----
saham_i <- "SMIL"
saham_minus_i <- setdiff(saham_names, saham_i)

```

```

X_SMIL_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_SMIL_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_SMIL_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_SMIL_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_SMIL_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_SMIL_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_SMIL_01 <- ssvs_qrf_adaptive(y_SMIL_01, X_SMIL_01, 0.01, Prior_SMIL_01, seed
= 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_SMIL_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_SMIL_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SMIL_01,
X_SMIL_01, y_SMIL_01,
tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_SMIL_05 <- ssvs_qrf_adaptive(y_SMIL_05, X_SMIL_05, 0.05, Prior_SMIL_05, seed
= 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_SMIL_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_SMIL_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_SMIL_05,
X_SMIL_05, y_SMIL_05,
tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 7: ARNA -----
saham_i <- "ARNA"
saham_minus_i <- setdiff(saham_names, saham_i)

X_ARNA_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_ARNA_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_ARNA_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_ARNA_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_ARNA_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_ARNA_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_ARNA_01 <- ssvs_qrf_adaptive(y_ARNA_01, X_ARNA_01, 0.01, Prior_ARNA_01,
seed = 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_ARNA_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_ARNA_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_ARNA_01,
X_ARNA_01, y_ARNA_01,
tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_ARNA_05 <- ssvs_qrf_adaptive(y_ARNA_05, X_ARNA_05, 0.05, Prior_ARNA_05,
seed = 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_ARNA_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_ARNA_05, saham_i)

```

```

CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_ARNA_05,
X_ARNA_05, y_ARNA_05,
tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 8: TOTO -----
saham_i <- "TOTO"
saham_minus_i <- setdiff(saham_names, saham_i)

X_TOTO_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_TOTO_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_TOTO_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_TOTO_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_TOTO_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_TOTO_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_TOTO_01 <- ssvs_qrf_adaptive(y_TOTO_01, X_TOTO_01, 0.01, Prior_TOTO_01,
seed = 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_TOTO_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_TOTO_01, saham_i)
CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_TOTO_01,
X_TOTO_01, y_TOTO_01,
tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

ssvs_TOTO_05 <- ssvs_qrf_adaptive(y_TOTO_05, X_TOTO_05, 0.05, Prior_TOTO_05,
seed = 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_TOTO_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_TOTO_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_TOTO_05,
X_TOTO_05, y_TOTO_05,
tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

### EMITEN 9: MARK -----
saham_i <- "MARK"
saham_minus_i <- setdiff(saham_names, saham_i)

X_MARK_01 <- as.matrix(VaR01_100[, saham_minus_i])
X_MARK_05 <- as.matrix(VaR05_100[, saham_minus_i])
y_MARK_01 <- as.numeric(CoVaR_01_100[[paste0("CoVaR_", saham_i)]])
y_MARK_05 <- as.numeric(CoVaR_05_100[[paste0("CoVaR_", saham_i)]])
Prior_MARK_01 <- get_Prior_per_saham(vi_df_01, saham_i, saham_minus_i)
Prior_MARK_05 <- get_Prior_per_saham(vi_df_05, saham_i, saham_minus_i)

ssvs_MARK_01 <- ssvs_qrf_adaptive(y_MARK_01, X_MARK_01, 0.01,
Prior_MARK_01, seed = 124, verbose = TRUE)
ssvs_results_01[[saham_i]] <- ssvs_MARK_01
conv_summary_01 <- simpan_konv(conv_summary_01, ssvs_MARK_01, saham_i)

```

```

CoVaR_SSVS_01[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_MARK_01,
X_MARK_01, y_MARK_01,
  tau = 0.01, VaR_asli = VaR01[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)
ssvs_MARK_05 <- ssvs_qrf_adaptive(y_MARK_05, X_MARK_05, 0.05,
Prior_MARK_05, seed = 124, verbose = TRUE)
ssvs_results_05[[saham_i]] <- ssvs_MARK_05
conv_summary_05 <- simpan_konv(conv_summary_05, ssvs_MARK_05, saham_i)
CoVaR_SSVS_05[[saham_i]] <- run_analisis_per_tau(saham_i, ssvs_MARK_05,
X_MARK_05, y_MARK_05,
  tau = 0.05, VaR_asli = VaR05[, saham_minus_i, drop = FALSE], return_df = return_df,
seed = 1000)

# Ringkasan konvergensi
cat("\n==== RINGKASAN KONVERGENSI MCMC SSVS tau=1% ===\n");
print(conv_summary_01)
cat("\n==== RINGKASAN KONVERGENSI MCMC SSVS tau=5% ===\n");
print(conv_summary_05)

# Bentuk data frame hasil CoVaR SSVS
CoVaR_SSVS_df_01 <- as.data.frame(CoVaR_SSVS_01)
colnames(CoVaR_SSVS_df_01) <- paste0("CoVaR_SSVS_", names(CoVaR_SSVS_01))

CoVaR_SSVS_df_05 <- as.data.frame(CoVaR_SSVS_05)
colnames(CoVaR_SSVS_df_05) <- paste0("CoVaR_SSVS_", names(CoVaR_SSVS_05))

cat("\nPreview CoVaR SSVS 1%:\n"); print(head(CoVaR_SSVS_df_01))
cat("\nPreview CoVaR SSVS 5%:\n"); print(head(CoVaR_SSVS_df_05))

##Tabel Ringkasan PIP per Emiten -----
create_ssvs_summary <- function(ssvs_result_list, tau_label) {
  cat("\n", rep("=", 70), "\n")
  cat("RINGKASAN PIP SSVS | tau =", tau_label, "\n")
  cat(rep("=", 70), "\n")

  do.call(rbind, lapply(names(ssvs_result_list), function(s) {
    res <- ssvs_result_list[[s]]
    df <- data.frame(
      Emiten_Response = s,
      Prediktor = res$var_names,
      Prior_pi = round(res$Prior_pi, 4),
      PIP = round(res$pip, 4),
      Moderat_05 = ifelse(res$pip >= 0.5, "Terpilih", "Tidak"),
      Konservatif_07 = ifelse(res$pip >= 0.7, "Terpilih", "Tidak"),
      Ketat_09 = ifelse(res$pip >= 0.9, "Terpilih", "Tidak")
    )
    df[order(-df$PIP), ]
  })))
}

```

```
ssvs_summary_01 <- create_ssvs_summary(ssvs_results_01, "0.01")
ssvs_summary_05 <- create_ssvs_summary(ssvs_results_05, "0.05")

print(ssvs_summary_01)
print(ssvs_summary_05)
```

Lampiran 40 Hasil Nilai PIP Kuantil 1% dan 5%

Emiten Response	$\tau = 1\%$		$\tau = 5\%$	
	Prediktor	Prior pi	Prediktor	Prior pi
ASII	UNTR	0,9000	IMPC	0,9000
ASII	IMPC	0,8530	SMIL	0,8358
ASII	SMIL	0,7959	UNTR	0,7168
ASII	MARK	0,7690	SKRN	0,6029
ASII	SKRN	0,7676	MARK	0,5207
ASII	SINI	0,5931	SINI	0,4052
ASII	ARNA	0,4370	ARNA	0,3213
ASII	TOTO	0,1000	TOTO	0,1000
IMPC	ARNA	0,9000	ARNA	0,9000
IMPC	MARK	0,8851	SINI	0,7184
IMPC	UNTR	0,7839	MARK	0,6884
IMPC	SMIL	0,5429	SKRN	0,6842
IMPC	SINI	0,3879	UNTR	0,6508
IMPC	SKRN	0,3118	ASII	0,2527
IMPC	ASII	0,2495	TOTO	0,1656
IMPC	TOTO	0,1000	SMIL	0,1000
UNTR	ASII	0,9000	ASII	0,9000
UNTR	SKRN	0,8147	SKRN	0,8956
UNTR	SMIL	0,6426	SMIL	0,6562
UNTR	SINI	0,5985	SINI	0,6383
UNTR	IMPC	0,6325	IMPC	0,5467
UNTR	ARNA	0,5760	ARNA	0,5181
UNTR	MARK	0,4129	MARK	0,4484
UNTR	TOTO	0,1000	TOTO	0,1000
SKRN	SMIL	0,9000	SMIL	0,9000
SKRN	ARNA	0,7459	ARNA	0,7529
SKRN	IMPC	0,6634	ASII	0,6194
SKRN	UNTR	0,5728	IMPC	0,5657
SKRN	ASII	0,5682	SINI	0,4910
SKRN	SINI	0,5479	UNTR	0,5306
SKRN	MARK	0,3080	MARK	0,3776
SKRN	TOTO	0,1000	TOTO	0,1000
SINI	MARK	0,9000	SMIL	0,9000
SINI	SMIL	0,7825	MARK	0,8066
SINI	ARNA	0,6776	ARNA	0,6206
SINI	IMPC	0,5352	IMPC	0,4895
SINI	SKRN	0,4981	SKRN	0,4541
SINI	ASII	0,4445	ASII	0,3806
SINI	UNTR	0,3844	UNTR	0,3141
SINI	TOTO	0,1000	TOTO	0,1000
SMIL	IMPC	0,9000	IMPC	0,9000
SMIL	UNTR	0,4577	UNTR	0,4103
SMIL	MARK	0,3520	MARK	0,3146

SMIL	ASII	0,3074	0,2725	ASII	0,2891	0,3075
SMIL	SINI	0,2401	0,2375	SINI	0,2432	0,2825
SMIL	SKRN	0,2335	0,2325	SKRN	0,2029	0,2025
SMIL	ARNA	0,1410	0,1425	ARNA	0,1371	0,1375
SMIL	TOTO	0,1000	0,1400	TOTO	0,1000	0,0825
ARNA	SINI	0,9000	0,8975	SINI	0,9000	0,8800
ARNA	IMPC	0,5783	0,5850	IMPC	0,7645	0,7625
ARNA	UNTR	0,4497	0,4175	UNTR	0,5663	0,5650
ARNA	ASII	0,3778	0,3200	MARK	0,4817	0,4900
ARNA	MARK	0,3082	0,3125	ASII	0,4561	0,4725
ARNA	SKRN	0,2495	0,2900	SMIL	0,1510	0,1400
ARNA	SMIL	0,1713	0,1650	TOTO	0,1032	0,1150
ARNA	TOTO	0,1000	0,1100	SKRN	0,1000	0,1125
TOTO	ARNA	0,9000	0,9225	MARK	0,9000	0,8925
TOTO	IMPC	0,7036	0,6700	ARNA	0,8758	0,8375
TOTO	MARK	0,6435	0,6600	SKRN	0,8153	0,7850
TOTO	SKRN	0,4160	0,4000	IMPC	0,3237	0,3025
TOTO	SINI	0,3390	0,3625	ASII	0,2469	0,2650
TOTO	SMIL	0,2851	0,2850	SMIL	0,1726	0,1550
TOTO	UNTR	0,1325	0,1475	SINI	0,1564	0,1450
TOTO	ASII	0,1000	0,0850	UNTR	0,1000	0,0800
MARK	TOTO	0,9000	0,9300	ARNA	0,9000	0,9125
MARK	ARNA	0,8790	0,8825	TOTO	0,8990	0,9075
MARK	SINI	0,6735	0,6600	SINI	0,8651	0,8825
MARK	IMPC	0,5232	0,5025	IMPC	0,4658	0,4875
MARK	UNTR	0,3398	0,3175	SMIL	0,3002	0,3225
MARK	ASII	0,2106	0,2300	ASII	0,1050	0,1175
MARK	SKRN	0,1615	0,1250	UNTR	0,1311	0,1150
MARK	SMIL	0,1000	0,1075	SKRN	0,1000	0,0975

Lampiran 41 Hasil Estimasi CoVaR SSVS Kuantil 1%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
-0,0286	-0,0498	-0,0422	-0,1308	-0,1000	-0,1040	-0,0403	-0,0374	-0,0524
-0,0894	-0,0498	-0,0422	-0,1106	-0,0989	-0,1339	-0,0290	-0,0508	-0,0736
-0,0286	-0,0395	-0,0423	-0,1139	-0,1000	-0,2981	-0,0403	-0,0214	-0,0736
-0,0310	-0,0642	-0,0363	-0,1011	-0,0995	-0,2981	-0,0588	-0,0214	-0,0524
-0,0286	-0,0514	-0,0478	-0,1285	-0,0991	-0,0826	-0,0280	-0,0345	-0,0659
-0,0287	-0,0405	-0,0334	-0,1011	-0,0991	-0,0817	-0,0362	-0,0214	-0,0659
-0,0332	-0,0406	-0,0422	-0,1011	-0,0989	-0,1339	-0,0290	-0,0263	-0,0811
-0,0286	-0,1500	-0,0269	-0,1011	-0,0986	-0,2981	-0,0815	-0,0263	-0,0622
-0,0286	-0,1500	-0,0269	-0,1106	-0,0995	-0,0826	-0,0821	-0,0263	-0,0659
-0,0286	-0,0514	-0,0422	-0,1280	-0,0986	-0,1339	-0,0815	-0,0263	-0,0811
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0286	-0,0473	-0,0441	-0,0732	-0,1000	-0,2981	-0,0821	-0,0427	-0,0736
-0,0333	-0,0498	-0,0441	-0,1280	-0,0989	-0,1339	-0,0403	-0,0374	-0,0524
-0,0286	-0,0473	-0,0441	-0,1011	-0,1000	-0,2080	-0,0403	-0,0263	-0,0538
-0,0287	-0,0498	-0,0334	-0,1139	-0,1000	-0,1467	-0,0821	-0,0345	-0,0622
-0,0310	-0,0514	-0,0343	-0,1308	-0,0997	-0,0909	-0,0629	-0,0183	-0,0524
-0,0287	-0,1500	-0,0334	-0,1011	-0,1000	-0,1339	-0,0403	-0,0263	-0,0538
-0,0287	-0,0514	-0,0334	-0,1011	-0,0995	-0,0909	-0,0629	-0,0345	-0,0659
-0,0894	-0,1500	-0,0422	-0,0960	-0,1000	-0,0909	-0,0370	-0,0159	-0,0736
-0,0333	-0,0498	-0,0478	-0,1106	-0,1000	-0,1491	-0,0362	-0,0381	-0,0622
-0,0355	-0,0498	-0,0422	-0,1139	-0,0991	-0,1339	-0,0233	-0,0263	-0,0659

Lampiran 42 Hasil Estimasi CoVaR SSVS Kuantil 5%

ASII	IMPC	UNTR	SKRN	SINI	SMIL	ARNA	TOTO	MARK
-0,0249	-0,0256	-0,0257	-0,0588	-0,0990	-0,0826	-0,0157	-0,0097	-0,0372
-0,0282	-0,0278	-0,0257	-0,0287	-0,0970	-0,1339	-0,0185	-0,0091	-0,0526
-0,0286	-0,0248	-0,0288	-0,0417	-0,0533	-0,1016	-0,0163	-0,0183	-0,0329
-0,0332	-0,0278	-0,0351	-0,0647	-0,0755	-0,0513	-0,0171	-0,0096	-0,0484
-0,0243	-0,0278	-0,0249	-0,0313	-0,0982	-0,0343	-0,0185	-0,0092	-0,0450
-0,0282	-0,0258	-0,0263	-0,0426	-0,0743	-0,0576	-0,0179	-0,0172	-0,0526
-0,0277	-0,0278	-0,0249	-0,0315	-0,0952	-0,2080	-0,0189	-0,0091	-0,0272
-0,0237	-0,0278	-0,0249	-0,0685	-0,0755	-0,0561	-0,0207	-0,0093	-0,0299
-0,0243	-0,0270	-0,0249	-0,0685	-0,0755	-0,0826	-0,0189	-0,0146	-0,0529
-0,0243	-0,0242	-0,0257	-0,0315	-0,0743	-0,0561	-0,0163	-0,0172	-0,0272
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
-0,0284	-0,0278	-0,0240	-0,0245	-0,0533	-0,0459	-0,0179	-0,0138	-0,0363
-0,0249	-0,0256	-0,0249	-0,0455	-0,0990	-0,0310	-0,0208	-0,0092	-0,0363
-0,0277	-0,0313	-0,0257	-0,0588	-0,0982	-0,1000	-0,0183	-0,0172	-0,0299
-0,0284	-0,0349	-0,0257	-0,0647	-0,0982	-0,0315	-0,0180	-0,0172	-0,0444
-0,0287	-0,0256	-0,0241	-0,0963	-0,0841	-0,1491	-0,0226	-0,0091	-0,0363
-0,0234	-0,0260	-0,0288	-0,0455	-0,0755	-0,1339	-0,0167	-0,0159	-0,0444
-0,0234	-0,0256	-0,0241	-0,0287	-0,0988	-0,1040	-0,0145	-0,0138	-0,0372
-0,0222	-0,0270	-0,0271	-0,0429	-0,0841	-0,0909	-0,0270	-0,0159	-0,0392
-0,0314	-0,0354	-0,0211	-0,0433	-0,0970	-0,0333	-0,0270	-0,0146	-0,0444
-0,0325	-0,0313	-0,0202	-0,0278	-0,0841	-0,0310	-0,0180	-0,0183	-0,0412

Lampiran 43 Syntax Trace Plot dan Visualisasi Running PIP

```
## Trace Plot & Diagnostik Konvergensi -----
plot_trace_gamma <- function(ssvs_result, saham_label, tau_label) {
  chain_df <- as.data.frame(ssvs_result$gamma_chain)
  chain_df$iterasi <- 1:nrow(chain_df)
  burnin_line <- ssvs_result$n_burnin
  chain_long <- melt(chain_df, id.vars = "iterasi",
    variable.name = "Prediktor", value.name = "gamma")

  ggplot(chain_long, aes(x = iterasi, y = gamma, color = Prediktor)) +
    geom_line(alpha = 0.6, linewidth = 0.4) +
    geom_vline(xintercept = burnin_line, linetype = "dashed",
      color = "black", linewidth = 0.8) +
    annotate("text", x = burnin_line + 10, y = 1.05,
      label = paste("Burn-in =", burnin_line), hjust = 0, size = 3) +
    facet_wrap(~ Prediktor, ncol = 3) +
    scale_y_continuous(breaks = c(0, 1)) +
    labs(
      title = paste("Trace Plot  $\gamma_i$  | Emiten:", saham_label, "| tau =", tau_label),
      subtitle = paste("Garis putus-putus = burn-in |",
        "Iterasi final:", ssvs_result$mcmc_final,
        "| Status:", ifelse(ssvs_result$converged, "Konvergen", "Max Iter")),
      x = "Iterasi MCMC", y = expression(gamma[i])
    ) +
    theme_minimal(base_size = 11) +
    theme(plot.title = element_text(hjust = 0.5, face = "bold"),
      plot.subtitle = element_text(hjust = 0.5, color = "grey40"),
```

```

        legend.position = "none",
        strip.text = element_text(face = "bold"))
    }

# Plot konvergensi Running PIP (post-burnin)
plot_convergence_pip <- function(ssvs_result, saham_label, tau_label) {
  gamma_post <- ssvs_result$post_burnin
  n_iter <- nrow(gamma_post)
  Running_pip <- apply(gamma_post, 2,
    function(x) cumsum(x) / seq_along(x))
  df_conv <- data.frame(
    Iterasi = rep(1:n_iter, ncol(gamma_post)),
    Prediktor = rep(colnames(gamma_post), each = n_iter),
    PIP = as.vector(Running_pip)
  )
  ggplot(df_conv, aes(x = Iterasi, y = PIP, color = Prediktor)) +
    geom_line(linewidth = 0.8) +
    geom_hline(yintercept = 0.5, linetype = "dashed", color = "red", alpha = 0.7) +
    scale_color_brewer(palette = "Set1") +
    scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.2)) +
    labs(
      title = paste("Running PIP (post-burnin) | Emiten:", saham_label, "| tau =", tau_label),
      subtitle = paste("Iterasi final:", ssvs_result$mcmc_final,
        "| Burn-in:", ssvs_result$n_burnin,
        "|", round(ssvs_result$n_burnin/ssvs_result$mcmc_final*100, "%)"),
      x = "Iterasi post-burnin", y = "Running PIP"
    ) +
    theme_minimal(base_size = 11) +
    theme(plot.title = element_text(hjust = 0.5, face = "bold"),
      plot.subtitle = element_text(hjust = 0.5, color = "darkred"),
      legend.position = "bottom")
  }

cat("\n=== Trace Plot & Konvergensi MCMC ===\n")
for (saham_i in saham_names) {
  print(plot_trace_gamma(ssvs_results_01[[saham_i]], saham_i, "0.01"))
  print(plot_convergence_pip(ssvs_results_01[[saham_i]], saham_i, "0.01"))
  print(plot_trace_gamma(ssvs_results_05[[saham_i]], saham_i, "0.05"))
  print(plot_convergence_pip(ssvs_results_05[[saham_i]], saham_i, "0.05"))
}

## Visualisasi PIP per Emiten -----
plot_pip_per_emiten <- function(ssvs_result, saham_label, tau_label) {
  df_pip <- data.frame(
    Prediktor = names(ssvs_result$pip),
    PIP = ssvs_result$pip
  )
  df_pip <- df_pip[order(-df_pip$PIP), ]
  df_pip$Prediktor <- factor(df_pip$Prediktor, levels = df_pip$Prediktor)
}

```

```

df_pip$Kategori <- cut(df_pip$PIP,
  breaks = c(-Inf, 0.5, 0.7, 0.9, Inf),
  labels = c("Tidak Terpilih", "Moderat (>0.5)",
    "Konservatif (>0.7)", "Sangat Konservatif (>0.9)"),
  right = FALSE)

ggplot(df_pip, aes(x = Prediktor, y = PIP, fill = Kategori)) +
  geom_col(color = "white", width = 0.7) +
  geom_hline(yintercept = c(0.5, 0.7, 0.9),
    linetype = "dashed",
    color = c("red3", "darkorange", "darkgreen"),
    linewidth = 0.8) +
  geom_text(aes(label = round(PIP, 3)), vjust = -0.4, size = 3.5) +
  scale_fill_manual(values = c(
    "Tidak Terpilih" = "grey70",
    "Moderat (>0.5)" = "#4E9AF1",
    "Konservatif (>0.7)" = "#F4A261",
    "Sangat Konservatif (>0.9)" = "#2A9D8F"
  )) +
  scale_y_continuous(limits = c(0, 1.1), breaks = seq(0, 1, 0.2)) +
  labs(
    title = paste("PIP SSVS | Emiten:", saham_label, "| tau =", tau_label),
    subtitle = "Prediktor = VaR emiten lain",
    x = "Emiten Prediktor", y = "PIP",
    fill = "Kategori Seleksi"
  ) +
  theme_minimal(base_size = 12) +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
    plot.subtitle = element_text(hjust = 0.5, color = "grey40"),
    legend.position = "bottom",
    axis.text.x = element_text(face = "bold"))
}

cat("\n=== Plot PIP per Emiten ===\n")
for (saham_i in saham_names) {
  print(plot_pip_per_emiten(ssvs_results_01[[saham_i]], saham_i, "0.01"))
  print(plot_pip_per_emiten(ssvs_results_05[[saham_i]], saham_i, "0.05"))
}

```

Lampiran 44 *Syntax* Statistika Deskriptif CoVaR SSVS Kuantil 1% dan 5%

```

statdes_covar_ssvs <- function(covar_ssvs_list, saham_names, tau_label) {
  library(e1071)
  cat("\n", rep("=", 70), "\n")
  cat("STATISTIKA DESKRIPTIF CoVaR SSVS |", tau_label, "\n")
  cat(rep("=", 70), "\n")

  tabel <- do.call(rbind, lapply(saham_names, function(s) {
    x <- na.omit(as.numeric(covar_ssvs_list[[s]]))
    data.frame(

```

```

    Saham    = s,
    N        = length(x),
    Mean     = round(mean(x), 6),
    Min      = round(min(x), 6),
    Max      = round(max(x), 6),
    Variance = round(var(x), 6),
    row.names = NULL
  )
}))
print(tabel, row.names = FALSE)
return(invisible(tabel))
}

statdes_covar_ssvs(CoVaR_SSVS_01, saham_names, "Kuantil 1%")
statdes_covar_ssvs(CoVaR_SSVS_05, saham_names, "Kuantil 5%")

```

Lampiran 45 *Syntax Plot CoVaR SSVS 1% dan 5% vs Actual Return*

```

plot_covar_ssvs_vs_return <- function(saham, return_df, dates,
                                     covar_ssvs_vals, tau, ylim = NULL) {
  tau_label <- ifelse(tau == 0.01, "1%", "5%")
  n_obs    <- length(covar_ssvs_vals)
  dates_obs <- tail(dates, n_obs)
  ret_obs  <- tail(as.numeric(return_df[[saham]]), n_obs)

  df <- data.frame(
    Tanggal = dates_obs,
    Return  = ret_obs,
    CoVaR   = as.numeric(covar_ssvs_vals)
  )
  df$Violation <- df$Return < df$CoVaR
  vd <- df[df$Violation, ]

  ggplot(df, aes(x = Tanggal)) +
    geom_line(aes(y = Return, color = "Actual Return"), linewidth = 0.8, alpha = 0.8) +
    geom_line(aes(y = CoVaR, color = paste0("CoVaR SSVS ", tau_label)),
              linewidth = 0.8, alpha = 0.9) +
    {if (nrow(vd) > 0)
      geom_point(data = vd, aes(y = Return, shape = "Violation"),
                 color = "black", size = 3, stroke = 1.5, fill = NA)} +
    scale_color_manual(
      values = setNames(c("blue", "#8B3A62"),
                        c("Actual Return", paste0("CoVaR SSVS ", tau_label))),
      name = "" ) +
    {if (nrow(vd) > 0)
      scale_shape_manual(values = c("Violation" = 1), name = "")} +
    scale_y_continuous(
      labels = scales::percent_format(accuracy = 0.1),
      breaks = if (!is.null(ylim)) nice_breaks(ylim) else scales::pretty_breaks(n = 8)) +
    coord_cartesian(ylim = ylim) +

```

```

scale_x_date(date_breaks = "3 months", date_labels = "%b %Y",
             expand = c(0.02, 0)) +
labs(
  title   = paste0("CoVaR SSVS ", tau_label, " vs Actual Return — ", saham),
  subtitle = paste0("Violations: ", nrow(vd),
                    " (", round(nrow(vd) / nrow(df) * 100, 2), "%)",
  x = "Tanggal", y = "Return / CoVaR SSVS"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title   = element_text(hjust = 0.5, face = "bold", size = 14),
  plot.subtitle = element_text(hjust = 0.5, size = 11, color = "#8B3A62"),
  axis.text.x   = element_text(angle = 45, hjust = 1),
  axis.title    = element_text(face = "bold"),
  legend.position = "bottom",
  panel.grid.major = element_line(color = "grey90", linewidth = 0.2),
  panel.grid.minor = element_blank()
)
}

#### Plot CoVaR SSVS tau=1% per saham -----
dates <- return_df$Tanggal
ylim_covar_ssvs01 <- c(
  min(unlist(return_df[, -1]), unlist(CoVaR_SSVS_01), na.rm = TRUE),
  max(unlist(return_df[, -1]), unlist(CoVaR_SSVS_01), na.rm = TRUE)
)
for (saham in saham_names) {
  print(plot_covar_ssvs_vs_return(saham, return_df, dates,
                                  CoVaR_SSVS_01[[saham]], tau = 0.01,
                                  ylim = ylim_covar_ssvs01))
}

#### Plot CoVaR SSVS tau=5% per saham -----
ylim_covar_ssvs05 <- c(
  min(unlist(return_df[, -1]), unlist(CoVaR_SSVS_05), na.rm = TRUE),
  max(unlist(return_df[, -1]), unlist(CoVaR_SSVS_05), na.rm = TRUE)
)
for (saham in saham_names) {
  print(plot_covar_ssvs_vs_return(saham, return_df, dates,
                                  CoVaR_SSVS_05[[saham]], tau = 0.05,
                                  ylim = ylim_covar_ssvs05))
}

```

Lampiran 46 *Syntax Proportion Shortfall CoVaR SSVS Kuantil 1% dan 5%*

```

####A. Proportion of Shortfall CoVaR SSVS -----
ps_covar_ssvs_01 <- list()
ps_covar_ssvs_05 <- list()

for (saham_i in saham_names) {

```

```

y_i <- tail(return_df[[saham_i]], n_obs)

ps_covar_ssvs_01[[saham_i]] <- proportion_shortfall_covar(
  y_i, CoVaR_SSVS_01[[saham_i]], 0.01)
ps_covar_ssvs_05[[saham_i]] <- proportion_shortfall_covar(
  y_i, CoVaR_SSVS_05[[saham_i]], 0.05)
}

df_ps_ssvs_01 <- do.call(rbind, lapply(names(ps_covar_ssvs_01), function(s)
  data.frame(Saham = s, as.data.frame(ps_covar_ssvs_01[[s]]))))
df_ps_ssvs_05 <- do.call(rbind, lapply(names(ps_covar_ssvs_05), function(s)
  data.frame(Saham = s, as.data.frame(ps_covar_ssvs_05[[s]]))))

cat("\n=== Proportion of Shortfall CoVaR SSVS 1% ===\n"); print(df_ps_ssvs_01)
cat("\n=== Proportion of Shortfall CoVaR SSVS 5% ===\n"); print(df_ps_ssvs_05)

```

Lampiran 47 *Syntax Kupiec Test CoVaR SSVS Kuantil 1% dan 5%*

```

####B. Kupiec Test CoVaR SSVS -----
kupiec_ssvs_01 <- list()
kupiec_ssvs_05 <- list()

for (saham_i in saham_names) {
  y_i <- tail(return_df[[saham_i]], n_obs)
  kupiec_ssvs_01[[saham_i]] <- data.frame(
    Saham = saham_i,
    Kupiec_CoVaR(y_i, CoVaR_SSVS_01[[saham_i]], tau = 0.01))
  kupiec_ssvs_05[[saham_i]] <- data.frame(
    Saham = saham_i,
    Kupiec_CoVaR(y_i, CoVaR_SSVS_05[[saham_i]], tau = 0.05))
}

df_kupiec_ssvs_01 <- do.call(rbind, kupiec_ssvs_01); rownames(df_kupiec_ssvs_01) <-
NULL
df_kupiec_ssvs_05 <- do.call(rbind, kupiec_ssvs_05); rownames(df_kupiec_ssvs_05) <-
NULL

cat("\n=== Kupiec Test CoVaR SSVS 1% ===\n"); print(df_kupiec_ssvs_01)
cat("\n=== Kupiec Test CoVaR SSVS 5% ===\n"); print(df_kupiec_ssvs_05)

```

Lampiran 48 *Syntax Pinball Loss Estimasi VaR, CoVaR, dan CoVaR SSVS*

```

compare_pinball <- function(saham_list, tau, var_df, covar_df, covar_ssvs_df,
  return_df, n_obs) {
  do.call(rbind, lapply(saham_list, function(s) {
    y_i <- tail(return_df[[s]], n_obs)
    # VaR
    if (tau == 0.01) var_i <- tail(as.numeric(VaR01[[s]]), n_obs)
    else var_i <- tail(as.numeric(VaR05[[s]]), n_obs)
    # CoVaR
    covar_col <- paste0("CoVaR ", s)

```

```

if (tau == 0.01) covar_i <- as.numeric(covar_df[[covar_col]])
else          covar_i <- as.numeric(covar_df[[covar_col]])
# CoVaR SSVS
ssvs_col <- paste0("CoVaR_SSVS_", s)
if (tau == 0.01) ssvs_i <- as.numeric(covar_ssvs_df[[ssvs_col]])
else          ssvs_i <- as.numeric(covar_ssvs_df[[ssvs_col]])

data.frame(
  Saham      = s,
  PB_VaR     = round(pinball_loss(y_i, tail(var_i, length(y_i)), tau), 5),
  PB_CoVaR   = round(pinball_loss(y_i, tail(covar_i, length(y_i)), tau), 5),
  PB_CoVaR_SSVS = round(pinball_loss(y_i, tail(ssvs_i, length(y_i)), tau), 5)
)
}))
}

df_compare_01 <- compare_pinball(saham_names, 0.01,
                                VaR01, CoVaR_01, CoVaR_SSVS_df_01,
                                return_df, n_obs)
df_compare_05 <- compare_pinball(saham_names, 0.05,
                                VaR05, CoVaR_05, CoVaR_SSVS_df_05,
                                return_df, n_obs)

cat("\n--- Perbandingan Pinball Loss tau=0.01 ---\n"); print(df_compare_01)
cat("\n--- Perbandingan Pinball Loss tau=0.05 ---\n"); print(df_compare_05)

```

SURAT PERNYATAAN

Saya yang bertanda tangan di bawah ini, mahasiswa Departemen Statistika FSAD ITS:

Nama : Ayunda Fatikha

NRP : 5003221023

menyatakan bahwa data yang digunakan dalam Tugas Akhir/ ~~Thesis~~ ini merupakan data sekunder yang diambil dari ~~penelitian / buku / Tugas Akhir/ Thesis /~~ publikasi lainnya yaitu:


Sumber : Yahoo Finance

Keterangan : Data Historis Harga Penutupan Saham Harian PT Astra Internasional Tbk (ASII), PT Impack Pratama Industri Tbk (IMPC), PT United Tractors Tbk (UNTR), PT Superkrane Mitra Utama Tbk (SKRN), PT Singaraja Putra Tbk (SINI), PT Sarana Mitra Luas Tbk (SMIL), PT Arwana Citramulia Tbk (ARNA), PT Hexindo Adiperkasa Tbk (HEXA), PT Surya Toto Indonesia Tbk (TOTO), dan PT Mark Dynamics Indonesia Tbk (MARK) dengan periode data dari tanggal 3 Juli 2023 hingga 31 Desember 2025.

Surat Pernyataan ini dibuat dengan sebenarnya. Apabila terdapat pemalsuan data maka saya siap menerima sanksi sesuai aturan yang berlaku.

Mengetahui,
Pembimbing Tugas Akhir

Surabaya, 8 Juni 2026



(Prof. Dr. rer. pol. Dedy Dwi Prastyo, S.Si., M.Si.)
NIP 19831204 200812 1 002



(Ayunda Fatikha)
NRP 5003221023

(Halaman ini sengaja dikosongkan)

BIODATA PENULIS



Ayunda Fatikha lahir di Kota Salatiga, pada tanggal 28 Januari 2004 dan merupakan anak pertama dari dua bersaudara. Penulis menyelesaikan pendidikan formal di SDN 1 Suruh, SMPN 2 Salatiga, dan SMAN 1 Salatiga. Pada tahun 2022 tepat setelah lulus dari bangku SMA, penulis melanjutkan studi S1 di Departemen Statistika, Fakultas Sains dan Analitika Data (FSAD) Institut Teknologi Sepuluh Nopember (ITS) dengan Nomor Registrasi Pokok (NRP) 5003221023. Selama menjalani pendidikan di bangku perkuliahan, penulis aktif di berbagai kepanitiaan dan organisasi, antara lain *volunteer* PR Station 2023, staff PR HopeHelps ITS 2023, staff ahli LO Station 2024, serta menjabat sebagai bendahara IMAGARA 2024.

Pada tahun 2024 penulis lolos pendanaan dan memperoleh insentif PKM-GFT. Tahun ketiga dan keempat, penulis berkesempatan menyelesaikan Kerja Praktik di PT Terminal Petikemas Surabaya (TPS) dan mengikuti program MAGENTA BUMN di PT Pelindo Terminal Petikemas (SPTP), tepatnya di Departemen Transformasi Penunjang Operasi. Penulis juga pernah menjadi Asisten Dosen pada mata kuliah Teknik Simulasi Departemen Statistika FSAD ITS. Kepada pembaca yang ingin mengirimkan kritik, saran, serta berdiskusi terkait Tugas Akhir ini dapat langsung disampaikan melalui email penulis: ayundafatikha135@gmail.com.

